Inferência Estatística Moderna: Algoritmos, Evidência e Dados

Manual de Teoria e Problemas

MI421 · Instituto de Matemática, Estatística e Computação Científica da Universidade Estadual de Campinas

4 de setembro de 2026

Conteúdo

Prefácio **xiii**

1 Método de Bayes Empírico **1**
1.1 Motivação . . . 1
1.2 A fórmula de Robbins . . . 2
1.2.1 O modelo Poisson hierárquico . . . 2
1.2.2 Demonstração . . . 3
1.2.3 Estimador empírico . . . 3
1.2.4 Generalização: fórmula de Tweedie . . . 3
1.3 Bayes empírico paramétrico: o modelo Normal–Normal . . . 4
1.3.1 A regra de Bayes nesse modelo . . . 4
1.3.2 Estimação dos hiperparâmetros . . . 5
1.4 O estimador de James–Stein . . . 5
1.4.1 Definição e propriedade de dominância . . . 5
1.4.2 Interpretação como Bayes empírico . . . 6
1.5 Efeitos aleatórios e modelos hierárquicos . . . 7
1.5.1 O modelo de efeitos aleatórios de uma via . . . 7
1.5.2 O melhor preditor linear não viesado e o encolhimento diferencial . . . 8
1.5.3 Estimação dos componentes de variância . . . 9
1.6 Notas sobre testes em larga escala . . . 9
1.7 Exemplos resolvidos . . . 10
1.8 Laboratório computacional em `R` . . . 12
1.9 Exercícios propostos . . . 14
1.10 Glossário bilíngue e de siglas . . . 16

2 Regressão Ridge **17**
2.1 Motivação . . . 17
2.2 O estimador ridge . . . 18
2.3 Propriedades estatísticas . . . 18
2.3.1 Viés . . . 19
2.3.2 Variância . . . 19
2.3.3 Erro quadrático médio e dominância . . . 19
2.3.4 Caso ortogonal . . . 20
2.4 Decomposição espectral em valores singulares . . . 20
2.5 Equivalência bayesiana . . . 21
2.6 Escolha do parâmetro de regularização . . . 21
2.7 Comparação com a regressão lasso . . . 22
2.7.1 O caso ortogonal: três regras de limiar . . . 22
2.7.2 A geometria da esparsidade . . . 23
2.7.3 Preditores correlacionados e a *elastic net* . . . 24
2.7.4 Qual usar? . . . 25
2.8 Exemplos resolvidos . . . 25

2.9 Laboratório computacional em R . . . 26
2.10 Exercícios propostos . . . 29
2.11 Glossário bilíngue e de siglas . . . 31

3 Modelos Lineares Generalizados **33**
3.1 Motivação . . . 33
3.2 A família exponencial . . . 33
3.2.1 Casos clássicos . . . 34
3.2.2 Média e variância . . . 34
3.3 A estrutura do modelo linear generalizado . . . 35
3.4 Regressão logística . . . 35
3.4.1 Verossimilhança . . . 35
3.4.2 Interpretação dos coeficientes . . . 36
3.5 Regressão de Poisson . . . 36
3.6 Regressão binomial negativa . . . 36
3.6.1 Como mistura Poisson–Gama . . . 36
3.6.2 O modelo de regressão . . . 37
3.6.3 Testar sobre-dispersão . . . 37
3.7 Inferência por máxima verossimilhança . . . 38
3.7.1 Equação de escore e *Fisher scoring* . . . 38
3.7.2 Mínimos quadrados ponderados iterativos . . . 39
3.7.3 Deviância . . . 39
3.8 Ajuste e diagnóstico . . . 40
3.8.1 Resíduos . . . 40
3.8.2 Sobre-dispersão . . . 40
3.8.3 Alavancagem e influência . . . 41
3.8.4 Diagnósticos específicos da regressão logística . . . 42
3.8.5 Um roteiro mínimo . . . 42
3.9 Exemplos resolvidos . . . 42
3.10 Laboratório computacional em R . . . 44
3.11 Exercícios propostos . . . 47
3.12 Glossário bilíngue e de siglas . . . 50

4 Árvores de Regressão **51**
4.1 Motivação . . . 51
4.2 Particionamento recursivo . . . 52
4.3 O algoritmo de árvores de classificação e regressão . . . 52
4.3.1 Crescimento da árvore . . . 52
4.3.2 Critérios de parada . . . 53
4.4 Poda por complexidade-custo . . . 53
4.4.1 O critério C_α . . . 53
4.4.2 Sequência de árvores podadas . . . 53
4.4.3 Escolha de α via validação cruzada . . . 54
4.5 Árvores em comparação com regressão linear . . . 54
4.6 Introdução aos métodos de ensemble . . . 54
4.6.1 Bagging . . . 55
4.6.2 Random forests . . . 56
4.6.3 Boosting . . . 56
4.6.4 Comparação . . . 57
4.7 Exemplos resolvidos . . . 58
4.8 Laboratório computacional em R . . . 59
4.9 Exercícios propostos . . . 63

4.10 Glossário bilíngue e de siglas . . . 66

5 Análise de Sobrevivência **67**
5.1 Motivação . . . 67
5.2 Funções fundamentais . . . 67
5.3 Censura à direita e verossimilhança . . . 68
5.4 O estimador de Kaplan–Meier . . . 68
5.4.1 Definição . . . 68
5.4.2 Variância: fórmula de Greenwood . . . 69
5.5 Teste *log-rank* . . . 69
5.6 O modelo de Cox . . . 70
5.6.1 Modelo de riscos proporcionais . . . 70
5.6.2 Verossimilhança parcial . . . 70
5.6.3 Interpretação dos coeficientes . . . 70
5.6.4 Empates e verificação da proporcionalidade . . . 71
5.7 Modelos paramétricos . . . 71
5.7.1 Famílias usuais . . . 71
5.7.2 Estimação por máxima verossimilhança . . . 72
5.7.3 Duas maneiras de acomodar covariáveis . . . 72
5.7.4 Verificação gráfica da forma . . . 73
5.7.5 Paramétrico ou Cox? . . . 73
5.8 Censura à esquerda, intervalar e truncamento . . . 74
5.8.1 Quatro esquemas de observação . . . 74
5.8.2 Truncamento à esquerda e entrada tardia . . . 74
5.8.3 Truncamento à direita e viés de comprimento . . . 75
5.9 Exemplos resolvidos . . . 76
5.10 Laboratório computacional em `R` . . . 77
5.11 Exercícios propostos . . . 81
5.12 Glossário bilíngue e de siglas . . . 83

6 Algoritmo de esperança e maximização **85**
6.1 Motivação . . . 85
6.2 Formulação geral . . . 86
6.3 A identidade fundamental e monotonicidade . . . 86
6.3.1 Decomposição da log-verossimilhança . . . 86
6.3.2 Lema de Gibbs . . . 87
6.3.3 Monotonicidade . . . 87
6.4 Mistura de gaussianas . . . 87
6.4.1 Modelo . . . 87
6.4.2 Passos de esperança e de maximização . . . 88
6.5 Dados normais com observações faltantes . . . 88
6.5.1 Mecanismos de dados faltantes . . . 89
6.6 Convergência e limitações . . . 90
6.6.1 Taxa de convergência . . . 91
6.6.2 Erros-padrão . . . 92
6.6.3 Limitações . . . 93
6.7 Exemplos resolvidos . . . 93
6.8 Laboratório computacional em `R` . . . 94
6.9 Exercícios propostos . . . 98
6.10 Glossário bilíngue e de siglas . . . 100

7 Jackknife **101**
7.1 Motivação . . . 101
7.2 Definição . . . 101
7.2.1 Justificativa intuitiva . . . 102
7.3 Pseudo-valores . . . 102
7.4 Conexão com funções de influência . . . 103
7.5 Limitações . . . 104
7.5.1 Estatísticas insuficientemente suaves . . . 104
7.5.2 Remoção de d observações . . . 105
7.6 Exemplos resolvidos . . . 105
7.7 Laboratório computacional em `R` . . . 106
7.8 Exercícios propostos . . . 108
7.9 Glossário bilíngue e de siglas . . . 109

8 Bootstrap **111**
8.1 Motivação e princípio do *plug-in* . . . 111
8.2 Bootstrap não paramétrico . . . 112
8.2.1 Algoritmo . . . 112
8.2.2 Como escolher B . . . 112
8.3 Bootstrap paramétrico . . . 112
8.4 Intervalos de confiança *bootstrap* . . . 113
8.4.1 Intervalo pela aproximação normal . . . 113
8.4.2 Percentil . . . 113
8.4.3 Intervalo básico . . . 113
8.4.4 Intervalo com correção de viés . . . 114
8.4.5 Intervalo com correção de viés e aceleração . . . 114
8.4.6 Intervalo estudentizado . . . 114
8.5 Bootstrap em regressão . . . 115
8.5.1 Bootstrap de pares . . . 115
8.5.2 Bootstrap de resíduos . . . 115
8.6 Exemplos resolvidos . . . 116
8.7 Laboratório computacional em `R` . . . 117
8.8 Exercícios propostos . . . 118
8.9 Glossário bilíngue e de siglas . . . 120

9 Validação cruzada **121**
9.1 Motivação . . . 121
9.2 Erro de predição . . . 121
9.3 Validação *holdout* simples . . . 122
9.4 Validação cruzada em k blocos . . . 122
9.4.1 Estratificação . . . 123
9.5 Remoção de uma observação por vez: caso $k = n$ . . . 123
9.5.1 Validação cruzada generalizada . . . 123
9.6 Viés e variância da estimativa de validação . . . 124
9.6.1 Viés . . . 124
9.6.2 Variância . . . 124
9.6.3 Recomendação prática . . . 124
9.7 Seleção de hiperparâmetros por validação cruzada . . . 124
9.7.1 Heurística de um erro-padrão . . . 125
9.8 Funções de perda e métricas de erro . . . 125
9.8.1 Regressão: perdas quadrática e absoluta . . . 125
9.8.2 Classificação: além da acurácia . . . 126

9.8.3 Curva de sensibilidade e área de ordenação . . . 127
9.8.4 Avaliar probabilidades: regras de pontuação próprias . . . 128
9.9 Sobreajuste e subajuste na prática . . . 129
9.9.1 As duas curvas . . . 129
9.9.2 Diagnóstico e remédios . . . 130
9.9.3 Curvas de aprendizado . . . 130
9.9.4 Protocolo . . . 131
9.10 Ressalvas e armadilhas . . . 131
9.11 Exemplos resolvidos . . . 132
9.12 Laboratório computacional em R . . . 133
9.13 Exercícios propostos . . . 137
9.14 Glossário bilíngue e de siglas . . . 139

10 Erro de predição e seleção de modelos **141**
10.1 Otimismo do erro de treinamento . . . 141
10.2 C_p de Mallows . . . 142
10.3 Critério de Akaike . . . 143
10.3.1 Motivação via divergência de Kullback–Leibler . . . 143
10.3.2 Caso gaussiano . . . 144
10.4 Critério de Schwarz . . . 144
10.4.1 Motivação via probabilidade posterior . . . 144
10.5 Comparação dos critérios . . . 144
10.5.1 Eficiência preditiva do critério de Akaike . . . 145
10.5.2 Consistência de seleção do critério de Schwarz . . . 145
10.5.3 Recomendação prática . . . 145
10.6 Seleção de subconjuntos . . . 145
10.7 Exemplos resolvidos . . . 146
10.8 Laboratório computacional em R . . . 147
10.9 Exercícios propostos . . . 149
10.10 Glossário bilíngue e de siglas . . . 150

11 Inferência bayesiana objetiva **151**
11.1 Bayes objetivo: motivação . . . 151
11.2 Princípios da inferência bayesiana . . . 152
11.2.1 Os três ingredientes e a posterior . . . 152
11.2.2 Estimação pontual como decisão . . . 152
11.2.3 Intervalos de credibilidade . . . 153
11.2.4 Predição . . . 153
11.2.5 Conjugação . . . 153
11.3 Prioris não informativas . . . 154
11.3.1 Prior uniforme e suas patologias . . . 154
11.4 A priori de Jeffreys . . . 154
11.4.1 Invariância sob reparametrização . . . 155
11.4.2 Casos clássicos . . . 155
11.5 Prioris de referência . . . 156
11.5.1 A ideia: maximizar o que os dados têm a dizer . . . 156
11.5.2 Vários parâmetros: a ordenação importa . . . 156
11.6 Métodos de Monte Carlo via cadeias de Markov . . . 157
11.6.1 Algoritmo Metropolis–Hastings . . . 158
11.6.2 Algoritmo Gibbs . . . 158
11.7 Diagnósticos de convergência . . . 159
11.7.1 Fator de redução de escala . . . 159

11.7.2 Tamanho efetivo de amostra . . . 159
11.7.3 Gráficos de trajetória . . . 159
11.8 Bayes objetivo e inferência frequentista . . . 160
11.8.1 A diferença de interpretação . . . 160
11.8.2 Concordância assintótica . . . 160
11.8.3 *Prioris* de casamento de probabilidade . . . 160
11.8.4 Onde os dois paradigmas divergem . . . 161
11.8.5 Síntese . . . 161
11.9 Exemplos resolvidos . . . 162
11.10 Laboratório computacional em `R` . . . 162
11.11 Exercícios propostos . . . 165
11.12 Glossário bilíngue e de siglas . . . 168

A Resumo de `R` para a disciplina **169**
A.1 Pacotes utilizados . . . 169
A.2 Instalação rápida . . . 169
A.3 Convenções de código . . . 169
A.4 Reproduzindo gráficos do livro . . . 170

B Gabarito dos exercícios propostos **171**

Referências **201**

Lista de Tabelas

Lista de Figuras

1.1 Encolhimento em dados reais: mortalidade municipal 8

2.1 Trajetórias de coeficientes regularizados 23

3.1 Resíduos de deviância e resíduos quantílicos 41

4.1 Comportamento em B: floresta e combinação sequencial 58

5.1 O viés de ignorar o truncamento à esquerda 76

6.1 Convergência e informação ausente 92

7.1 Inconsistência do *jackknife* para a mediana 104

8.1 Comparação empírica de cobertura 115

9.1 Ordenação e precisão no conjunto `Default` 128

9.2 Curvas de aprendizado empíricas 131

11.1 Posteriores sob três *prioris* de referência 154

Prefácio

Este *Manual de Teoria e Problemas* foi concebido como apoio à disciplina **ME904/MI421: Inferência Estatística na Era Computacional**, oferecida pelo Instituto de Matemática, Estatística e Computação Científica da Universidade Estadual de Campinas. Cada unidade desenvolve os conceitos desde as definições, explicita as hipóteses dos resultados, apresenta demonstrações e exemplos resolvidos e encerra com laboratórios em `R` e exercícios propostos com respostas ao final.

A referência principal é *Computer Age Statistical Inference: Algorithms, Evidence, and Data Science*, de Bradley Efron e Trevor Hastie (2016). As demais referências indicadas ao fim de cada capítulo complementam demonstrações, aplicações e perspectivas históricas.

Ao final de cada capítulo, um glossário bilíngue relaciona a terminologia em português com o termo em inglês do livro-texto e registra as siglas correspondentes.

Capítulo 1

Método de Bayes Empírico

Objetivos da unidade

- Apresentar a ideia central do método de Bayes empírico como ponte entre a estatística clássica e a bayesiana.
- Derivar a fórmula de Robbins para o caso Poisson e discutir suas hipóteses.
- Estudar a versão paramétrica do método e sua conexão com o estimador de James–Stein.
- Implementar estimativas de Bayes empírico em `R` e avaliar seu desempenho frente ao estimador direto.

Leitura primária: Efron e Hastie 2016, capítulo 6.
Leitura complementar: Robbins 1956; Efron 2010, capítulos 1–3.

1.1 Motivação

A inferência estatística clássica trata, em geral, da estimação de um *único* parâmetro θ a partir de uma amostra $X_1, \dots, X_n$. Em muitos contextos modernos, porém, o problema é estruturalmente diferente: observamos N **unidades de análise**, indexadas por $i = 1, \dots, N$. Uma unidade de análise é a entidade sobre a qual se deseja fazer uma inferência, como um segurado, um jogador, um gene ou um município. Para a unidade i, θ_i é o parâmetro não observado de interesse e X_i é a observação que traz informação principalmente sobre esse parâmetro. Assim, dispomos de N pares (X_i, θ_i) e desejamos estimar simultaneamente $\theta_1, \dots, \theta_N$. Exemplos típicos:

- **Atuária**: X_i é o número de sinistros do segurado i no ano corrente; θ_i é a sua taxa anual média de sinistros.
- **Esportes**: X_i é o número de rebatidas válidas de um jogador de beisebol em n vezes ao bastão; θ_i é sua probabilidade subjacente de rebater.
- **Genômica**: X_i é a expressão observada do gene i entre $N \sim 10^4$ genes; θ_i é o efeito médio do gene i.
- **Saúde pública**: X_i é a contagem de óbitos por causa específica no município i; θ_i é a taxa subjacente.

A intuição central, formalizada por Robbins 1956, é a seguinte: embora cada X_i seja informativo apenas sobre θ_i, a coleção $\{X_1, \dots, X_N\}$ é também informativa sobre a *distribuição* G dos θ_i. Se aceitarmos um modelo hierárquico

$$\theta_1, \dots, \theta_N \overset{\text{independentes}}{\sim} G, \qquad X_i \mid \theta_i \sim f(\cdot \mid \theta_i), \tag{1.1}$$

então conhecer G permite calcular, via teorema de Bayes, a distribuição *a posteriori* de cada θ_i dado X_i, e em particular obter o estimador de Bayes

$$\hat{\theta}_i^{\text{Bayes}}(x) = \mathbb{E}_G[\theta_i \mid X_i = x] = \frac{\int \theta\, f(x \mid \theta)\, dG(\theta)}{\int f(x \mid \theta)\, dG(\theta)}. \tag{1.2}$$

Quatro objetos aparecem nessa construção e não devem ser confundidos. A distribuição G descreve como os parâmetros θ_i variam na população de unidades. A distribuição $f(\,\cdot \mid \theta)$ descreve como uma observação varia quando o parâmetro é fixado em θ. A distribuição marginal

$$f_G(x) = \int f(x \mid \theta)\, dG(\theta)$$

descreve os valores observáveis de X depois que a heterogeneidade de θ foi integrada. Por fim, $dG(\theta \mid x)$ denota a distribuição a posteriori do parâmetro depois de observar $X = x$. A marginal $f_G(x)$ aparece no denominador da regra de Bayes porque é a constante que faz a posterior integrar a um:

$$dG(\theta \mid x) = \frac{f(x \mid \theta)\, dG(\theta)}{f_G(x)}, \qquad f_G(x) > 0.$$

Observação (Como ler a notação $dG(\theta)$)*.* A expressão $dG(\theta)$ indica que a integração é feita segundo a distribuição de probabilidade G, sem exigir que essa distribuição possua uma densidade. Para qualquer função integrável h, se G possui densidade g, então

$$\int h(\theta)\, dG(\theta) = \int h(\theta) g(\theta)\, d\theta.$$

Se G é discreta e atribui probabilidade p_j ao valor θ_j, então

$$\int h(\theta)\, dG(\theta) = \sum_j h(\theta_j) p_j.$$

Assim, a mesma fórmula do estimador de Bayes abrange distribuições contínuas, discretas e combinações das duas.

A ideia do *método de Bayes empírico* é usar a amostra coletiva para *estimar* G (ou a marginal f_G) e, em seguida, substituir esse estimador na regra de Bayes (1.2), obtendo

$$\hat{\theta}_i^{\text{emp}}(x) = \mathbb{E}_{\hat{G}_N}[\theta \mid X = x].$$

Observação. Diferentemente do bayesiano subjetivo, o estatístico de Bayes empírico não fixa G *a priori*: G é vista como uma característica empírica da população de parâmetros, a ser inferida dos dados. Por essa razão, o método é, em essência, *frequentista*: a inferência sobre G usa apenas a função de verossimilhança marginal.

Nota. Há duas grandes vertentes do método:

- **Bayes empírico não paramétrico**: G é deixada totalmente livre; estima-se diretamente f_G pela frequência empírica.
- **Bayes empírico paramétrico**: postula-se uma família G_η, por exemplo normal, e estimam-se os hiperparâmetros η pela verossimilhança marginal.

Apresentamos as duas a seguir.

1.2 A fórmula de Robbins

1.2.1 O modelo Poisson hierárquico

Considere o modelo (1.1) com $f(x \mid \theta) = e^{-\theta}\theta^x/x!$ para $x \in \mathbb{N}_0$. A distribuição marginal de X é

$$f_G(x) = \int_0^\infty \frac{e^{-\theta}\theta^x}{x!}\, dG(\theta), \qquad x \in \mathbb{N}_0. \tag{1.3}$$

A regra de Bayes (1.2) torna-se

$$\mathbb{E}_G[\theta \mid X = x] = \frac{1}{f_G(x)} \int_0^\infty \theta \cdot \frac{e^{-\theta}\theta^x}{x!}\, dG(\theta).$$

A observação genial de Robbins é que essa última integral pode ser reescrita em termos de $f_G(x+1)$, dispensando completamente o conhecimento de G.

1.2.2 Demonstração

Teorema 1.1 (Fórmula de Robbins)**.** *Sob o modelo Poisson hierárquico* (1.1) *com* $f(x \mid \theta) = e^{-\theta}\theta^x/x!$*, para qualquer* $x \in \mathbb{N}_0$ *tal que* $f_G(x) > 0$*,*

$$\mathbb{E}_G[\theta \mid X = x] = (x+1)\,\frac{f_G(x+1)}{f_G(x)}. \tag{1.4}$$

Demonstração. Pela definição da marginal,

$$(x+1)\, f_G(x+1) = (x+1) \int_0^\infty \frac{e^{-\theta}\theta^{x+1}}{(x+1)!}\, dG(\theta) = \int_0^\infty \theta \cdot \frac{e^{-\theta}\theta^x}{x!}\, dG(\theta).$$

Dividindo ambos os membros por $f_G(x) > 0$, obtemos

$$(x+1)\frac{f_G(x+1)}{f_G(x)} = \frac{1}{f_G(x)} \int_0^\infty \theta \cdot \frac{e^{-\theta}\theta^x}{x!}\, dG(\theta) = \mathbb{E}_G[\theta \mid X = x],$$

como queríamos. □

1.2.3 Estimador empírico

A fórmula (1.4) expressa $\mathbb{E}_G[\theta \mid X = x]$ inteiramente em termos de f_G, e não de G. Como f_G é a distribuição marginal observável de X, podemos estimá-la pela frequência empírica

$$\hat{f}_N(x) = \frac{\#\{i : X_i = x\}}{N}, \qquad x \in \mathbb{N}_0, \tag{1.5}$$

e definir o **estimador de Robbins**

$$\hat{\theta}^{\,\mathrm{R}}(x) = (x+1)\,\frac{\hat{f}_N(x+1)}{\hat{f}_N(x)}, \qquad x \in \mathbb{N}_0. \tag{1.6}$$

Observação (Notável independência de G). O lado direito de (1.6) pode ser computado sem qualquer suposição sobre G. Por isso, Robbins 1956 batizou-o de *estimador de Bayes empírico não paramétrico*: a única hipótese paramétrica é a Poisson.

Observação (Limitações). O estimador (1.6) é *ruidoso* para valores raros de x (frequências pequenas). Em aplicações, costuma-se suavizar $\hat{f}_N$ por *splines* monotônicos, métodos de máxima verossimilhança não paramétrica ou aproximações log-côncavas. Veja Efron e Hastie 2016, §6.1.

1.2.4 Generalização: fórmula de Tweedie

A fórmula de Robbins é caso particular de uma identidade geral em famílias exponenciais.

Teorema 1.2 (Fórmula de Tweedie)**.** *Suponha que, condicionalmente a* $\theta \in \Theta \subset \mathbb{R}$*, a variável contínua* X *tenha densidade*

$$f(x \mid \theta) = e^{\theta x - \psi(\theta)} h(x)$$

em um intervalo aberto que não depende de θ*. Suponha ainda que* $h(x) > 0$*, que* h *seja duas vezes diferenciável e que as integrais a seguir possam ser diferenciadas duas vezes em relação a* x*. Defina a densidade marginal* $f_G(x) = \int f(x \mid \theta)\, dG(\theta)$ *e seu logaritmo* $\lambda(x) = \log f_G(x)$*. Então*

$$\mathbb{E}_G[\theta \mid X = x] = \lambda'(x) - \frac{h'(x)}{h(x)}, \qquad \mathrm{Var}_G(\theta \mid X = x) = \lambda''(x) - \big(\log h(x)\big)''.$$

Demonstração. Separe primeiro a parte de f_G que depende de h:

$$q(x) = \frac{f_G(x)}{h(x)} = \int_\Theta \exp\{\theta x - \psi(\theta)\}\, dG(\theta).$$

As hipóteses do teorema permitem diferenciar sob o sinal de integral. Isso vale, por exemplo, quando as integrais de $|\theta|$ e de θ^2 vezes o integrando são finitas em uma vizinhança de x. A primeira e a segunda derivadas são

$$q'(x) = \int \theta e^{\theta x - \psi(\theta)} dG(\theta), \qquad q''(x) = \int \theta^2 e^{\theta x - \psi(\theta)} dG(\theta).$$

A distribuição a posteriori de θ, antes da divisão pela constante de normalização $q(x)$, é $e^{\theta x - \psi(\theta)} dG(\theta)$. Portanto, dividir $q'(x)$ por $q(x)$ produz o primeiro momento posterior, e dividir $q''(x)$ por $q(x)$ produz o segundo:

$$\frac{q'(x)}{q(x)} = \mathbb{E}_G(\theta \mid X = x), \qquad \frac{q''(x)}{q(x)} = \mathbb{E}_G(\theta^2 \mid X = x).$$

Logo,

$$\frac{q''(x)}{q(x)} - \left\{\frac{q'(x)}{q(x)}\right\}^2 = \mathrm{Var}_G(\theta \mid X = x).$$

Como $\log q(x) = \lambda(x) - \log h(x)$, a primeira derivada de $\log q$ é a média posterior e a segunda é a variância posterior. Substituir essa identidade nas duas expressões anteriores fornece exatamente as fórmulas enunciadas. □

Nota. Para a Normal $X \mid \mu \sim N(\mu, 1)$, tem-se $\theta = \mu$ e a fórmula de Tweedie produz

$$\mathbb{E}[\mu \mid X = x] = x + \frac{d}{dx} \log f_G(x),$$

o que viabiliza estimação por suavização de uma única log-densidade marginal.

1.3 Bayes empírico paramétrico: o modelo Normal–Normal

Considere agora o modelo hierárquico *conjugado*

$$\mu_1, \ldots, \mu_N \overset{\text{independentes}}{\sim} N(M, A), \qquad X_i \mid \mu_i \sim N(\mu_i, \sigma^2), \tag{1.7}$$

com $\sigma^2 > 0$ *conhecido* (caso típico em *microarray*, onde σ^2 é estimado de réplicas técnicas).

1.3.1 A regra de Bayes nesse modelo

Proposição 1.3 (Posterior Normal–Normal)**.** *Sob* (1.7)*, a distribuição de* μ_i *dado* $X_i = x$ *é*

$$\mu_i \mid X_i = x \;\sim\; N\Big((1 - B)\, x + BM,\; (1 - B)\, \sigma^2\Big), \qquad B = \frac{\sigma^2}{\sigma^2 + A}.$$

Em particular, o estimador de Bayes é

$$\hat{\mu}_i^{\,Bayes} = (1 - B)\, X_i + B\, M. \tag{1.8}$$

Demonstração. A posterior é proporcional ao produto $f(x \mid \mu)\, g(\mu)$, ou seja,

$$\pi(\mu \mid x) \propto \exp\Big\{-\tfrac{1}{2\sigma^2}(x - \mu)^2 - \tfrac{1}{2A}(\mu - M)^2\Big\}.$$

Expandindo e completando o quadrado em μ, encontra-se uma normal com precisão $1/\sigma^2 + 1/A$ e média $(x/\sigma^2 + M/A)/(1/\sigma^2 + 1/A)$. Após simplificação algébrica, essa média iguala $(1-B)x + BM$ e a variância iguala $(1 - B)\sigma^2$. □

Observação (Encolhimento). A média a posteriori (1.8) é uma combinação convexa entre o dado X_i e a média populacional M, com peso $B \in (0,1)$ controlando o quanto X_i é *encolhido* (*shrunk*) em direção a M. Quando A é pequeno (parâmetros muito concentrados em torno de M), B é próximo de 1 e o encolhimento é forte; quando A é grande, B é próximo de 0 e X_i é mantido praticamente intacto.

1.3.2 Estimação dos hiperparâmetros

Em geral, os hiperparâmetros (M, A) são desconhecidos. Eles podem, contudo, ser estimados a partir da *distribuição marginal* de X_i.

Proposição 1.4 (Marginal). *Sob o modelo* (1.7)*, $X_1, \dots, X_N$ são independentes e têm a mesma distribuição $N(M,\, \sigma^2 + A)$.*

Demonstração. $X_i = \mu_i + \varepsilon_i$, com μ_i e ε_i independentes, $\mu_i \sim N(M, A)$ e $\varepsilon_i \sim N(0, \sigma^2)$. A soma de normais independentes é normal, com média M e variância $A + \sigma^2$. □

A Proposição 1.4 sugere os estimadores de momentos

$$\hat{M} = \bar{X} = \frac{1}{N}\sum_{i=1}^{N} X_i, \qquad \hat{A} = \max\left(0,\ \tfrac{1}{N-1}\sum_{i=1}^{N}(X_i - \bar{X})^2 - \sigma^2\right). \tag{1.9}$$

Substituindo em $B = \sigma^2/(\sigma^2 + A)$, obtemos

$$\hat{B} = \frac{\sigma^2}{\sigma^2 + \hat{A}} = \min\left(1,\ \frac{\sigma^2}{\hat{A} + \sigma^2}\right),$$

e o **estimador de Bayes empírico paramétrico Normal–Normal**

$$\hat{\mu}_i^{\,\mathrm{emp}} = (1 - \hat{B})\, X_i + \hat{B}\, \bar{X}. \tag{1.10}$$

Observação. A versão de (1.9) mais usada na literatura é $\hat{A} = \max(0,\, S/(N-3) - \sigma^2)$ com $S = \sum (X_i - \bar{X})^2$: a escolha do denominador $N - 3$ torna $\hat{B}$ não viesado (Efron–Morris). A escolha do denominador e da forma de $\hat{B}$ leva a variantes do estimador de Bayes empírico; algumas coincidem exatamente com o estimador de James–Stein, como veremos.

1.4 O estimador de James–Stein

1.4.1 Definição e propriedade de dominância

Considere o caso $M = 0$ em (1.7), escrito como problema de estimação multivariada. Sejam $X_1, \dots, X_k$ observações independentes com $X_i \sim N(\mu_i, 1)$ (o caso $\sigma^2 \neq 1$ se reduz a este por reescala). O estimador de máxima verossimilhança é o próprio vetor $\hat{\mu}^{\,\mathrm{direto}} = (X_1, \dots, X_k)$, com risco quadrático total $\mathbb{E}\,\sum_i (\hat{\mu}_i - \mu_i)^2 = k$.

Definição 1.5 (Estimador de James–Stein). Para $k \geq 3$, o estimador de James–Stein é

$$\hat{\mu}_i^{\,\mathrm{Stein}} = \left(1 - \frac{k-2}{\|X\|^2}\right) X_i, \qquad i = 1, \dots, k, \tag{1.11}$$

onde $\|X\|^2 = \sum_{j=1}^{k} X_j^2$.

Teorema 1.6 (Dominância de James–Stein). *Para todo $\mu \in \mathbb{R}^k$, com $k \geq 3$,*

$$\mathbb{E}\sum_{i=1}^{k}(\hat{\mu}_i^{\,Stein} - \mu_i)^2 < \mathbb{E}\sum_{i=1}^{k}(X_i - \mu_i)^2 = k.$$

Lema 1.7 (Identidade de Stein)**.** *Se $X \sim N_k(\mu, I_k)$ e $g : \mathbb{R}^k \to \mathbb{R}^k$ é diferenciável, com as esperanças abaixo finitas e termos de fronteira nulos, então*

$$\mathbb{E}_\mu\{(X_i - \mu_i)g_i(X)\} = \mathbb{E}_\mu\left\{\frac{\partial g_i(X)}{\partial x_i}\right\}, \qquad i = 1, \ldots, k.$$

Demonstração. Fixadas as demais coordenadas, integre por partes em x_i. Como a derivada da densidade normal em relação a x_i é $-(x_i - \mu_i)$ vezes a própria densidade, o termo de fronteira é zero e a igualdade segue. Integrar também nas demais coordenadas conclui a prova. □

Demonstração do Teorema 1.6. Considere um estimador da forma $\delta(X) = X + g(X)$. Expandindo sua perda e aplicando o Lema 1.7,

$$R(\mu, \delta) = k + \mathbb{E}_\mu\left[\|g(X)\|^2 + 2\sum_{i=1}^{k}\frac{\partial g_i(X)}{\partial x_i}\right].$$

Tome $g(x) = -ax/\|x\|^2$. Fora do ponto $x = 0$, que tem probabilidade zero,

$$\|g(x)\|^2 = \frac{a^2}{\|x\|^2}, \qquad \sum_{i=1}^{k}\frac{\partial g_i(x)}{\partial x_i} = -\frac{a(k-2)}{\|x\|^2}.$$

Logo

$$R(\mu, \delta) - k = \{a^2 - 2a(k-2)\}\mathbb{E}_\mu\left(\frac{1}{\|X\|^2}\right).$$

Para $k \geq 3$ essa esperança é finita. Escolhendo $a = k - 2$, obtém-se

$$R(\mu, \hat{\mu}^{\text{Stein}}) - k = -(k-2)^2\mathbb{E}_\mu\left(\frac{1}{\|X\|^2}\right) < 0,$$

para todo $\mu \in \mathbb{R}^k$, como se queria demonstrar. □

O resultado é espantoso: independentemente dos valores reais de $\mu_1, \ldots, \mu_k$, o estimador direto $\hat{\mu}_i = X_i$ é inadmissível sob risco quadrático total quando $k \geq 3$. A comparação é de risco total; não afirma que cada coordenada melhore em toda realização.

1.4.2 Interpretação como Bayes empírico

A versão paramétrica do método de Bayes empírico no modelo Normal–Normal com $M = 0$ produz, segundo (1.10) e (1.9),

$$\hat{\mu}_i^{\text{emp}} = (1 - \hat{B})\, X_i, \qquad \hat{B} = \frac{\sigma^2}{\sigma^2 + \hat{A}}.$$

Sob $\sigma^2 = 1$ e usando como estimador de momentos *específico*

$$\hat{B}^{\,\text{Stein}} = \frac{k-2}{\|X\|^2},$$

recuperamos exatamente o estimador de James–Stein (1.11). Ou seja, o estimador de James–Stein é a regra de Bayes empírico paramétrica Normal–Normal com uma escolha específica do estimador do fator de encolhimento. Esse estimador particular, $(k-2)/\|X\|^2$, é *não-viesado* para $1/(1+A)$ no sentido de que $\mathbb{E}\big[(k-2)/\|X\|^2\big] = 1/(1+A)$ quando $X_i \sim N(0, 1+A)$ (ver Exercício 1.3).

Observação (Quando James–Stein não vale a pena). A redução de risco do estimador de James–Stein é maior quando os μ_i estão concentrados em torno de zero e tende a zero quando sua dispersão cresce sem limite. Ele nunca é pior que o estimador direto em risco quadrático total, embora o ganho possa ser pequeno quando os parâmetros estão muito dispersos.

Nota (Versão com média não nula). A versão centrada na média amostral, válida para $k \geq 4$, é

$$\hat{\mu}_i^{\text{Stein, centro}} = \bar{X} + \left(1 - \frac{k-3}{\sum_{j=1}^{k}(X_j - \bar{X})^2}\right)(X_i - \bar{X}),$$

correspondendo ao método de Bayes empírico com M desconhecido. Ela domina o estimador direto para $k \geq 4$. Outra modificação, chamada de *parte positiva*, substitui o fator por $\max\{0, 1 - (k-2)/\|X\|^2\}$ e melhora ainda mais o risco do estimador original.

1.5 Efeitos aleatórios e modelos hierárquicos

A estrutura Normal–Normal da Seção 1.3 coincide com o **modelo de efeitos aleatórios de uma via** apresentado a seguir, escrito em outra linguagem. Essa correspondência torna o Bayes empírico uma ferramenta de trabalho: quando os hiperparâmetros são estimados a partir dos dados, parte dos procedimentos de ajuste de modelos mistos, amplamente disponíveis em `R`, admite uma interpretação de Bayes empírico.

1.5.1 O modelo de efeitos aleatórios de uma via

Considere N *grupos* (escolas, municípios, hospitais, laboratórios), com n_i observações no grupo i:

$$Y_{ij} = \mu + a_i + \varepsilon_{ij}, \qquad a_i \overset{\text{independentes}}{\sim} N(0, \tau^2), \qquad \varepsilon_{ij} \overset{\text{independentes}}{\sim} N(0, \sigma^2), \tag{1.12}$$

para $i = 1, \ldots, N$ e $j = 1, \ldots, n_i$, sendo a coleção dos efeitos a_i independente da coleção dos erros ε_{ij}. O termo a_i é o **efeito aleatório** do grupo i; μ é o *efeito fixo* (a média geral); τ^2 e σ^2 são os **componentes de variância**, entre grupos e dentro de grupos, respectivamente.

A quantidade de interesse costuma ser $\theta_i = \mu + a_i$, a média verdadeira do grupo i. Duas estratégias ingênuas estão nos extremos:

- **Sem agrupamento** (*no pooling*): $\hat{\theta}_i = \bar{Y}_{i\cdot}$, a média do grupo. Não viesada, mas de variância σ^2/n_i, desastrosa para grupos pequenos.
- **Agrupamento total** (*complete pooling*): $\hat{\theta}_i = \bar{Y}_{\cdot\cdot}$ para todo i. Produz estimativas com menor variabilidade entre grupos, mas ignora completamente a heterogeneidade real entre eles.

No modelo Normal–Normal, com hiperparâmetros dados e sob perda quadrática, a média posterior determina um meio-termo entre essas alternativas: o *agrupamento parcial* (*partial pooling*). Quando os hiperparâmetros são estimados, esse mesmo mecanismo é usado com os valores estimados; sua qualidade passa então a depender também da adequação do modelo e dessa estimação.

Proposição 1.8 (Redução ao modelo Normal–Normal)**.** *Sob* (1.12)*, e dados os hiperparâmetros, toda a informação sobre θ_i contida no grupo i passa pela média $X_i := \bar{Y}_{i\cdot}$, que satisfaz*

$$X_i \mid \theta_i \sim N\left(\theta_i,\ \frac{\sigma^2}{n_i}\right), \qquad \theta_i \overset{\text{independentes}}{\sim} N(\mu, \tau^2),$$

que é o modelo (1.7) *com $M = \mu$, $A = \tau^2$ e variância amostral* específica ao grupo *$\sigma_i^2 = \sigma^2/n_i$.*

Demonstração. Condicionalmente a a_i, os Y_{ij} são independentes e têm distribuição $N(\mu + a_i, \sigma^2)$; logo $\bar{Y}_{i\cdot} \mid a_i \sim N(\mu + a_i, \sigma^2/n_i)$. Pela decomposição

$$\sum_j (Y_{ij} - \theta_i)^2 = \sum_j (Y_{ij} - \bar{Y}_{i\cdot})^2 + n_i(\bar{Y}_{i\cdot} - \theta_i)^2,$$

o primeiro termo não depende de θ_i. Assim, para inferir θ_i com os hiperparâmetros fixos, basta a média do grupo. A distribuição marginal de $\theta_i = \mu + a_i$ é $N(\mu, \tau^2)$ por construção. □

1.5.2 O melhor preditor linear não viesado e o encolhimento diferencial

Aplicando (1.8) grupo a grupo obtemos o resultado central desta seção.

Teorema 1.9 (Preditor de Bayes para efeitos aleatórios)**.** *Sob* (1.12) *com* (μ, τ^2, σ^2) *conhecidos,*

$$\mathbb{E}[\theta_i \mid Y] \;=\; (1 - B_i)\,\bar{Y}_{i\cdot} + B_i\,\mu, \qquad B_i \;=\; \frac{\sigma^2/n_i}{\sigma^2/n_i + \tau^2} \;=\; \frac{\sigma^2}{\sigma^2 + n_i\tau^2}. \tag{1.13}$$

Equivalentemente, $\mathbb{E}[a_i \mid Y] = (1 - B_i)(\bar{Y}_{i\cdot} - \mu)$.

Demonstração. Imediato da Proposição 1.8 e do Teorema de Bayes no modelo Normal–Normal (Seção 1.3), substituindo σ^2 por σ^2/n_i. □

O ponto decisivo é que agora o fator de encolhimento B_i **depende de** i, através de n_i:

$$\begin{aligned} n_i \to \infty \;&\Longrightarrow\; B_i \to 0 && \text{(nenhum encolhimento)},\\ n_i = 1 \;&\Longrightarrow\; B_i = \frac{\sigma^2}{\sigma^2 + \tau^2} && \text{(encolhimento máximo)}. \end{aligned}$$

Observação (Encolhimento diferencial)*.* Grupos com muitos dados são deixados quase intactos; grupos com poucos dados são puxados fortemente para a média geral. Este é precisamente o comportamento que se deseja de um estimador de ranqueamento: sem ele, os extremos de qualquer *ranking* de municípios, escolas ou hospitais são sistematicamente ocupados pelos grupos *menores*, cujas médias amostrais são as mais ruidosas, um artefato estatístico frequentemente confundido com achado substantivo.

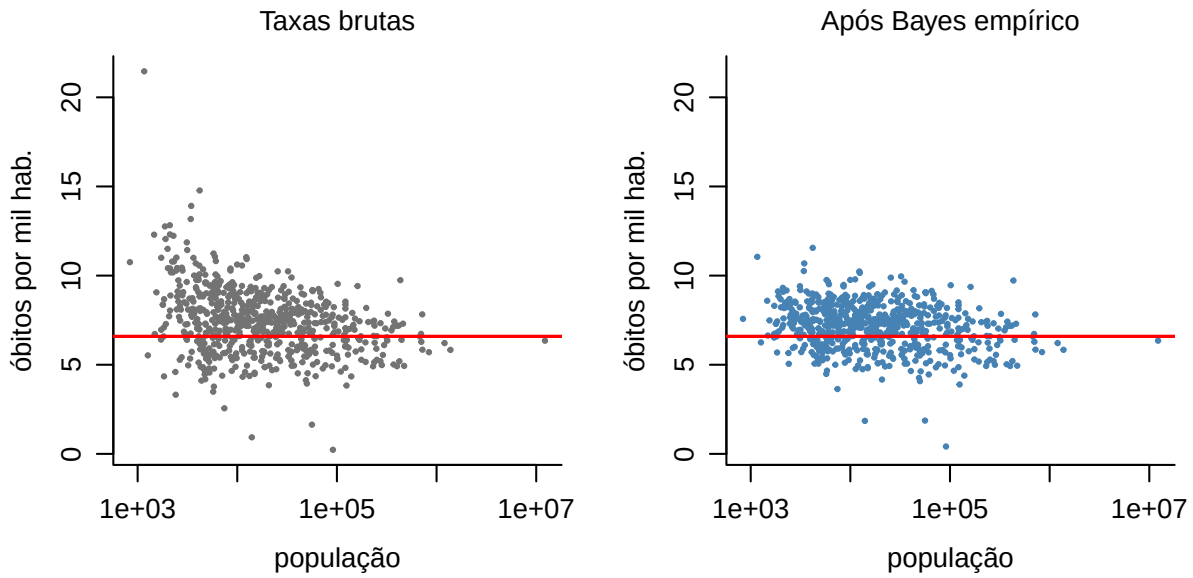


Figura 1.1: Taxa de mortalidade nos 645 municípios de São Paulo em 2019, com dados do Instituto Brasileiro de Geografia e Estatística. À esquerda, as taxas brutas contra a população em escala logarítmica exibem a forma de funil: a dispersão cresce nos municípios pequenos. À direita, aparecem as estimativas após o encolhimento de Bayes empírico Poisson–Gama. A linha vermelha é a taxa global. Uru, com 1.165 habitantes e 25 óbitos, passa de 21,5 para 11,1 óbitos por mil, recebendo peso 0,30 na própria taxa. Dos vinte municípios no topo da ordenação bruta, onze saem do topo após o encolhimento.

Definição 1.10 (Melhor preditor linear não viesado)**.** Na literatura de modelos mistos, (1.13) é o **melhor preditor linear não viesado**: entre todos os preditores lineares em Y com $\mathbb{E}(\hat{a}_i - a_i) = 0$, é o que minimiza $\mathbb{E}[(\hat{a}_i - a_i)^2]$. Quando os componentes de variância são substituídos por estimativas, obtém-se o **melhor preditor linear não viesado empírico**, que é precisamente o estimador de Bayes empírico deste capítulo.

1.5.3 Estimação dos componentes de variância

Resta estimar (μ, σ^2, τ^2). Com $n_i \equiv n$ balanceado, a tabela de análise de variância fornece estimadores de momentos em forma fechada. Denote por Q_{entre} e Q_{dentro} os quadrados médios entre grupos e dentro dos grupos, respectivamente:

$$Q_{\text{entre}} = \frac{n}{N-1}\sum_{i=1}^{N}(\bar{Y}_{i\cdot} - \bar{Y}_{\cdot\cdot})^2, \qquad Q_{\text{dentro}} = \frac{1}{N(n-1)}\sum_{i=1}^{N}\sum_{j=1}^{n}(Y_{ij} - \bar{Y}_{i\cdot})^2.$$

Proposição 1.11 (Estimadores pela análise de variância)**.** *No caso balanceado,* $\mathbb{E}[Q_{dentro}] = \sigma^2$ *e* $\mathbb{E}[Q_{entre}] = \sigma^2 + n\tau^2$*. Logo*

$$\hat{\sigma}^2 = Q_{dentro}, \qquad \hat{\tau}^2 = \max\!\left(0,\ \frac{Q_{entre} - Q_{dentro}}{n}\right), \qquad \hat{\mu} = \bar{Y}_{\cdot\cdot},$$

são não viesados (antes do truncamento em zero) para os respectivos parâmetros.

O truncamento em $\max(0, \cdot)$ é o mesmo expediente de (1.9): a diferença dos quadrados médios pode ser negativa em amostras finitas, embora $\tau^2 \geq 0$. Em desenhos desbalanceados, os estimadores fechados deixam de ser não viesados e a prática padrão é a **máxima verossimilhança restrita**, que maximiza a verossimilhança dos contrastes ortogonais a μ e reduz o viés para baixo que a máxima verossimilhança plena costuma introduzir em $\hat{\tau}^2$.

Exemplo 1.12 (Taxas hospitalares)**.** Suponha $N = 40$ hospitais, $\sigma^2 = 4$, e um hospital A com $n_A = 100$ pacientes e média $\bar{Y}_A = 7{,}0$, e um hospital B com $n_B = 4$ pacientes e média $\bar{Y}_B = 9{,}0$; a média geral é $\hat{\mu} = 6{,}0$ e $\hat{\tau}^2 = 1{,}0$. Então

$$B_A = \frac{4}{4 + 100 \cdot 1} = 0{,}038, \qquad B_B = \frac{4}{4 + 4 \cdot 1} = 0{,}5,$$

e os melhores preditores lineares não viesados empíricos são $\hat{\theta}_A = 0{,}962 \cdot 7{,}0 + 0{,}038 \cdot 6{,}0 = 6{,}96$ e $\hat{\theta}_B = 0{,}5 \cdot 9{,}0 + 0{,}5 \cdot 6{,}0 = 7{,}5$. O hospital B, que liderava o *ranking* bruto com folga de 2 pontos, cai para uma vantagem de 0,54, e a diferença remanescente é a parte da evidência que sobrevive ao ajuste pelo tamanho da amostra.

Nota (Além do caso gaussiano)*.* Substituindo a normal por um modelo linear generalizado (Capítulo 3) e mantendo o efeito aleatório gaussiano no preditor linear, obtém-se um **modelo linear generalizado misto**: por exemplo, $Y_{ij} \sim \text{Poisson}(e^{\mu + a_i})$ com $a_i \sim N(0, \tau^2)$ é o modelo natural para contagens de eventos por município. A verossimilhança marginal já não tem forma fechada, e o ajuste requer quadratura de Gauss–Hermite ou aproximação de Laplace (`lme4::glmer`). A lógica do encolhimento, contudo, é idêntica à do Teorema 1.9. O modelo Poisson–Gama da Seção 1.2 é a versão conjugada desse mesmo programa.

1.6 Notas sobre testes em larga escala

A mesma estrutura hierárquica que motiva o método de Bayes empírico para *estimação* também é natural em testes simultâneos. Seja R o número de hipóteses rejeitadas e V o número, não observado, de hipóteses nulas verdadeiras entre elas. A **taxa de falsas descobertas** é

$$\mathbb{E}\left\{\frac{V}{\max(R, 1)}\right\}.$$

Num modelo de mistura para uma estatística Z, a **taxa local de falsas descobertas** no valor z é a probabilidade posterior $\mathbb{P}(\text{hipótese nula verdadeira} \mid Z = z)$. As duas quantidades não são iguais: a primeira avalia um procedimento de rejeição inteiro; a segunda avalia uma observação específica. A modelagem de Bayes empírico permite estimar ambas a partir do conjunto de estatísticas. O desenvolvimento completo não faz parte desta disciplina; veja Efron 2010.

1.7 Exemplos resolvidos

Exercício resolvido 1.1 : Robbins para sinistros de seguros

Enunciado. Uma seguradora observa o número de sinistros X_i de cada um de $N = 9461$ segurados em um ano. Os dados, agregados por contagem, são (Efron e Hastie 2016, Tabela 6.1):

x	0	1	2	3	4	5	6	7
$\#\{X_i = x\}$	7840	1317	239	42	14	4	4	1

Suponha $X_i \mid \theta_i \sim \text{Poisson}(\theta_i)$ com $\theta_i \overset{\text{independentes}}{\sim} G$. Estime, por meio da fórmula de Robbins, a taxa anual média $\mathbb{E}_G[\theta_i \mid X_i = x]$ para $x = 0, 1, 2, 3$.

Solução. Pela fórmula (1.6),

$$\hat{\theta}^{\mathrm{R}}(x) = (x+1)\,\frac{\hat{f}_N(x+1)}{\hat{f}_N(x)} = (x+1)\,\frac{\#\{X_i = x+1\}}{\#\{X_i = x\}}.$$

Daí:

$$\begin{aligned}
\hat{\theta}^{\mathrm{R}}(0) &= 1 \cdot 1317/7840 \approx 0{,}168,\\
\hat{\theta}^{\mathrm{R}}(1) &= 2 \cdot 239/1317 \approx 0{,}363,\\
\hat{\theta}^{\mathrm{R}}(2) &= 3 \cdot 42/239 \approx 0{,}527,\\
\hat{\theta}^{\mathrm{R}}(3) &= 4 \cdot 14/42 \approx 1{,}333.
\end{aligned}$$

Em particular, um segurado que teve 1 sinistro neste ano deve ser projetado para ter, em média, 0,363 sinistros no próximo, bem abaixo da observação $X_i = 1$. Isto é *encolhimento* (*shrinkage*): a estimativa Bayes empírico se ajusta em direção à média populacional, $\bar{X} \approx 0{,}214$.

O encolhimento não significa simplesmente substituir toda observação pela média. A intensidade do ajuste resulta da distribuição coletiva: para $x = 0, 1, 2, 3$, as estimativas aumentam com x, mas permanecem menos extremas do que as contagens observadas. Essa regularização é especialmente útil porque uma única contagem anual é uma medida ruidosa da taxa própria do segurado.

Na cauda da tabela, contudo, a fórmula empírica sem regularização fica instável. Aplicada separadamente a $x = 4, 5, 6, 7$, ela fornece, respectivamente,

$$1{,}43, \qquad 6{,}00, \qquad 1{,}75, \qquad 0{,}00.$$

A sequência deixa de ser crescente e a estimativa para $x = 7$ cai a zero apenas porque não houve segurado com oito sinistros. Isso é um problema de frequências esparsas, não evidência de que uma contagem maior indique uma taxa menor.

Três formas de estabilização ilustram compromissos diferentes. Primeiro, pode-se reunir a cauda $A = \{4, 5, 6, 7\}$. Condicionalmente apenas ao evento $X \in A$, a identidade de Robbins dá

$$\widehat{\mathbb{E}}(\theta \mid X \in A) = \frac{5N_5 + 6N_6 + 7N_7 + 8N_8}{N_4 + N_5 + N_6 + N_7} = \frac{51}{23} \approx 2{,}22,$$

onde $N_x = \#\{i : X_i = x\}$. A estimativa fica estável, mas deixa de distinguir as quatro contagens da cauda. Segundo, um modelo Poisson–Gama ajustado por máxima verossimilhança, com forma $a \approx 0{,}701$ e taxa $b \approx 3{,}273$, produz a média posterior $(a + x)/(b + 1)$ e, para $x = 4, 5, 6, 7$, os valores 1,10, 1,33, 1,57 e 1,80. Terceiro, uma máxima verossimilhança não paramétrica para G, calculada em uma grade fina de taxas entre zero e oito, produz aproximadamente 2,20, 2,54, 2,60 e 2,60. As duas últimas soluções preservam a informação de cada x e evitam as oscilações da razão de frequências; em troca, dependem, respectivamente, de uma família paramétrica ou de uma escolha numérica de grade. Em uma análise real, essas escolhas e uma avaliação de sensibilidade devem ser relatadas.

Exercício resolvido 1.2 : Bayes empírico Normal–Normal numérico

Enunciado. Em um experimento, $N = 10$ médias amostrais $X_1, \dots, X_{10}$ são observadas independentemente, com $X_i \mid \mu_i \sim N(\mu_i, 1)$. Os valores observados são

$$2{,}3,\ 0{,}1,\ -1{,}2,\ 0{,}8,\ 1{,}5,\ -0{,}4,\ 2{,}1,\ -0{,}9,\ 0{,}3,\ 1{,}0.$$

Calcule $\hat{\mu}_i^{\text{emp}}$ pelo modelo (1.7), usando os estimadores de momentos (1.9).
Solução. Computamos:

$$\bar{X} = \frac{1}{10}\sum X_i = 0{,}560, \qquad \frac{1}{N-1}\sum (X_i - \bar{X})^2 = 1{,}440.$$

Como $\sigma^2 = 1$, os estimadores são

$$\hat{M} = 0{,}560, \qquad \hat{A} = 1{,}440 - 1 = 0{,}440, \qquad \hat{B} = \frac{1}{1 + 0{,}440} \approx 0{,}694.$$

O estimador de Bayes empírico é então $\hat{\mu}_i^{\text{emp}} = 0{,}306\, X_i + 0{,}694 \cdot 0{,}560 = 0{,}306\, X_i + 0{,}389$. Aplicando aos X_i:

i	1	2	3	4	5	6	7	8	9	10
X_i	2,3	0,1	-1,2	0,8	1,5	-0,4	2,1	-0,9	0,3	1,0
$\hat{\mu}_i^{\text{emp}}$	1,09	0,42	0,02	0,63	0,85	0,27	1,03	0,11	0,48	0,69

Observe o encolhimento: o maior valor $X_1 = 2{,}3$ é puxado para 1,09, e o menor $X_3 = -1{,}2$ é puxado para 0,02. O encolhimento é proporcional a $\hat{B} \approx 0{,}69$.

Exercício resolvido 1.3 : James–Stein e estimação direta em simulação controlada

Enunciado. Considere $k = 5$ parâmetros $\mu = (1, 2, 3, 4, 5)$ e gere $X_i \sim N(\mu_i, 1)$ independentes. Uma realização produziu $X = (1{,}2,\ 1{,}9,\ 4{,}1,\ 3{,}5,\ 4{,}8)$. Calcule (i) o erro quadrático total do estimador direto; (ii) o estimador de James–Stein (1.11); (iii) seu erro quadrático total. Comente o resultado.
Solução. (i) $\sum (X_i - \mu_i)^2 = 0{,}04 + 0{,}01 + 1{,}21 + 0{,}25 + 0{,}04 = 1{,}55$.
(ii) $\|X\|^2 = 1{,}44 + 3{,}61 + 16{,}81 + 12{,}25 + 23{,}04 = 57{,}15$, e o fator $1 - 3/57{,}15 \approx 0{,}9475$. Logo

$$\hat{\mu}^{\,\text{Stein}} \approx (1{,}137,\ 1{,}800,\ 3{,}885,\ 3{,}316,\ 4{,}548).$$

(iii) $\sum (\hat{\mu}_i^{\text{Stein}} - \mu_i)^2 \approx 0{,}019 + 0{,}040 + 0{,}783 + 0{,}467 + 0{,}204 = 1{,}513$. O estimador de James–Stein reduziu o erro nesta realização. Repetindo a simulação muitas vezes, obtém-se uma redução média maior quando os μ_i estão concentrados em torno de zero.

1.8 Laboratório computacional em R

Laboratório em R : Robbins não paramétrico

O bloco a seguir implementa diretamente o estimador (1.6) para os dados de seguros do Exercício resolvido 1.1.

```
# Contagens observadas (Tabela 6.1 do livro principal)
contagens <- c(0, 1, 2, 3, 4, 5, 6, 7)
n_x       <- c(7840, 1317, 239, 42, 14, 4, 4, 1)
N         <- sum(n_x)

# Frequencia empirica f_N(x)
f_emp <- n_x / N

# Estimador de Robbins: theta_hat(x) = (x+1) * f(x+1) / f(x)
robbins <- (contagens + 1) * c(f_emp[-1], NA) / f_emp

resultado <- data.frame(
  x       = contagens,
  freq    = round(f_emp, 5),
  robbins = round(robbins, 4)
)
print(resultado)
```

A coluna `robbins` reproduz os números do Exercício resolvido 1.1. Note como, para $x = 6$ e $x = 7$, o estimador é instável: as frequências empíricas envolvidas são minúsculas e a razão tem variância grande. Em uma aplicação séria, suavizaríamos $\hat{f}_N$ por máxima verossimilhança não-paramétrica (pacote `REBayes`) ou por uma família paramétrica.

Laboratório em R : James–Stein em simulação

A vantagem do estimador de James–Stein sobre o estimador direto é uma afirmação sobre a média em repetições de $X \mid \mu$. Para verificá-la, geramos R réplicas e comparamos os erros quadráticos totais.

```
js <- function(x) {
  # Estimador de James-Stein (M = 0, variancia = 1)
  k <- length(x)
  if (k < 3) stop("James-Stein requer k >= 3")
  fator <- 1 - (k - 2) / sum(x^2)
  fator * x
}

set.seed(2026)
mu  <- c(1, 2, 3, 4, 5)            # parametros verdadeiros
k   <- length(mu)
R   <- 5000

erro_direto <- erro_stein <- numeric(R)
for (r in seq_len(R)) {
  x           <- rnorm(k, mean = mu, sd = 1)
  erro_direto[r] <- sum((x - mu)^2)
  erro_stein[r]  <- sum((js(x) - mu)^2)
}
```

```
c(direto = mean(erro_direto), stein = mean(erro_stein))
```

Com a semente acima, as médias são aproximadamente 5,043 e 4,863, uma redução de 3,6%. Ela é modesta porque os μ_i não estão concentrados em torno de zero. Repetindo o experimento com $\mu = (0{,}1, 0{,}2, 0{,}3, 0{,}4, 0{,}5)$, a redução média é aproximadamente 54,8%. Esses números reproduzem o estimador do Teorema 1.6; para estudar a variante de parte positiva, troque a linha que define `fator` por `max(0, fator)`.

Laboratório em R : Bayes empírico Normal–Normal aplicado

```
# Estimador de Bayes empirico normal-normal com sigma^2 conhecido
eb_normal <- function(x, sigma2 = 1) {
  N      <- length(x)
  M_hat  <- mean(x)
  A_hat  <- max(0, var(x) - sigma2)
  B_hat  <- sigma2 / (sigma2 + A_hat)
  list(
    mu_eb = (1 - B_hat) * x + B_hat * M_hat,
    M_hat = M_hat, A_hat = A_hat, B_hat = B_hat
  )
}

x  <- c(2.3, 0.1, -1.2, 0.8, 1.5, -0.4, 2.1, -0.9, 0.3, 1.0)
ajuste <- eb_normal(x)
ajuste$B_hat
round(ajuste$mu_eb, 2)
```

A saída reproduz o Exercício resolvido 1.2. Em taxas de eventos para populações pequenas, $\hat{B}$ pode ser alto, e o estimador de Bayes empírico produz encolhimento substancial. O tamanho deve ser avaliado nos dados, não presumido.

Laboratório em R : Efeitos aleatórios: cálculo manual e via lme4

Simulamos $N = 30$ grupos de tamanhos muito desiguais e comparamos as três estratégias da Seção 1.5.

```
library(lme4)
set.seed(1)

N     <- 30
n_i   <- sample(c(2, 5, 10, 50, 200), N, replace = TRUE)  # grupos
    desiguais
mu    <- 10; tau2 <- 1; sigma2 <- 4

a     <- rnorm(N, sd = sqrt(tau2))                  # efeitos
    aleatorios
grupo <- rep(seq_len(N), times = n_i)
y     <- rnorm(sum(n_i), mean = (mu + a)[grupo], sd = sqrt(sigma2))
dados <- data.frame(grupo = factor(grupo), y = y)

# --- (1) sem agrupamento: media por grupo
media_grupo <- tapply(y, grupo, mean)

# --- (2) agrupamento total
```

```
media_geral <- mean(y)

# --- (3) agrupamento parcial calculado diretamente
# REML e o argumento literal para maxima verossimilhanca restrita
ajuste  <- lmer(y ~ 1 + (1 | grupo), data = dados, REML = TRUE)
vc      <- as.data.frame(VarCorr(ajuste))
tau2_h  <- vc$vcov[vc$grp == "grupo"]
sigma2_h<- vc$vcov[vc$grp == "Residual"]
mu_h    <- fixef(ajuste)[1]

B_i     <- sigma2_h / (sigma2_h + n_i * tau2_h)   # fator de
   encolhimento
preditor_empirico <- (1 - B_i) * media_grupo + B_i * mu_h
```

Confirme que o cálculo manual coincide com o do pacote e compare os erros:

```
# Coincide com os efeitos aleatorios extraidos pelo lme4?
max(abs(preditor_empirico - (mu_h + ranef(ajuste)$grupo[, 1]))) # ~
   1e-8

theta <- mu + a                                          # verdade
c(sem_agrup   = mean((media_grupo - theta)^2),
  agrup_total = mean((media_geral - theta)^2),
  parcial     = mean((preditor_empirico - theta)^2))

# Encolhimento em funcao do tamanho do grupo
plot(n_i, B_i, log = "x", pch = 19,
     xlab = "tamanho do grupo", ylab = "fator de encolhimento B_i")
```

A saída típica mostra o erro quadrático médio do agrupamento parcial abaixo das duas alternativas extremas, e o gráfico exibe B_i decaindo de aproximadamente 0,7, em grupos com $n_i = 2$, a 0,01, em grupos com $n_i = 200$. Os valores exatos variam com a simulação.

1.9 Exercícios propostos

Ex. 1.1. Derive a fórmula de Robbins quando $X \mid \theta \sim \text{Geom}(\theta)$, isto é, $\mathbb{P}(X = x \mid \theta) = \theta(1-\theta)^x$ para $x \in \mathbb{N}_0$ e $\theta \in (0,1)$. Mostre que

$$\mathbb{E}_G[\theta \mid X = x] = \frac{f_G(x) - f_G(x+1)}{f_G(x)}.$$

Ex. 1.2. Mostre que, no modelo (1.7), o estimador de Bayes (1.8) pode ser escrito como

$$\hat{\mu}_i^{\text{Bayes}} = M + \frac{A}{A + \sigma^2}(X_i - M).$$

Interprete o fator $A/(A+\sigma^2)$ como uma razão sinal-ruído.

Ex. 1.3. Seja $X \sim N_k(0, \tau^2 I_k)$ com $\tau^2 > 0$. Mostre que, para $k \geq 3$,

$$\mathbb{E}\left[\frac{k-2}{\|X\|^2}\right] = \frac{1}{\tau^2}.$$

Sugestão: $\|X\|^2/\tau^2 \sim \chi^2_k$ e use $\mathbb{E}[1/Y] = 1/(k-2)$ para $Y \sim \chi^2_k$, $k \geq 3$.

Ex. 1.4. No modelo (1.7) com $\sigma^2 = 1$, mostre que o erro quadrático esperado do estimador de Bayes (1.8) satisfaz

$$\mathbb{E}\left[\sum_{i=1}^{N} (\hat{\mu}_i^{\text{Bayes}} - \mu_i)^2\right] = N(1 - B) = \frac{NA}{A+1},$$

e portanto é estritamente menor que o erro do estimador de máxima verossimilhança, N, para todo $A < \infty$.

Ex. 1.5. O arquivo `datasets/obitos-municipios-sp.csv` traz óbitos e população dos 645 municípios paulistas, com fonte nas Estatísticas do Registro Civil e nas estimativas populacionais do Instituto Brasileiro de Geografia e Estatística. Tomando $E_i = \texttt{populacao}_i/1000$ e $X_i \mid \theta_i \sim \text{Poisson}(E_i\theta_i)$: estime os hiperparâmetros gama, calcule a taxa de Bayes empírico e seu peso na taxa bruta, verifique o funil e compare o tamanho populacional dos vinte primeiros municípios antes e depois do encolhimento.

Ex. 1.6. *Bayes empírico beta-binomial.* Suponha $X_i \mid \theta_i \sim \text{Bin}(n_i, \theta_i)$ e $\theta_i \overset{\text{independentes}}{\sim} \text{Beta}(\alpha, \beta)$. Mostre que o estimador de Bayes é $\mathbb{E}[\theta_i \mid X_i = x] = (\alpha + x)/(\alpha + \beta + n_i)$ e proponha estimadores de momentos para (α, β) a partir de $\bar{X}/\bar{n}$ e da variância empírica das proporções X_i/n_i.

Ex. 1.7. No modelo de efeitos aleatórios balanceado (1.12) com $n_i \equiv n$, demonstre a Proposição 1.11: mostre que $\mathbb{E}[Q_{\text{dentro}}] = \sigma^2$ e $\mathbb{E}[Q_{\text{entre}}] = \sigma^2 + n\tau^2$. *Sugestão*: escreva $\bar{Y}_{i\cdot} = \mu + a_i + \bar{\varepsilon}_{i\cdot}$ com $\bar{\varepsilon}_{i\cdot}$ normal de média zero e variância σ^2/n, independente de a_i, e use a distribuição qui-quadrado da soma de quadrados centrada.

Ex. 1.8. Mostre que o fator de encolhimento $B_i = \sigma^2/(\sigma^2 + n_i\tau^2)$ do Teorema 1.9 é decrescente em n_i e τ^2 e crescente em σ^2. Em seguida, sob hiperparâmetros conhecidos, mostre que o erro quadrático do melhor preditor linear não viesado no grupo i vale $(1 - B_i)\sigma^2/n_i$.

Ex. 1.9. *Ranqueamento de escolas.* Simule $N = 200$ escolas com tamanhos n_i sorteados de $\{5, 10, \ldots, 400\}$ e desempenho verdadeiro θ_i normal de média 500 e desvio-padrão 30, gerando observações normais de média θ_i e desvio-padrão 80. Construa (a) o *ranking* pelas médias brutas $\bar{Y}_{i\cdot}$ e (b) o *ranking* pelos melhores preditores lineares não viesados empíricos. Para cada um, registre o tamanho médio n_i das 10 escolas do topo e das 10 do fundo. Comente o que o resultado implica para divulgações públicas de *rankings* escolares baseadas em médias brutas.

Ex. 1.10. *Robbins não paramétrico em dados reais.*

No arquivo `datasets/obitos-municipios-sp.csv` do Exercício 1.5, restrinja-se aos municípios com menos de 20 mil habitantes e aplique o estimador de Robbins (1.6) diretamente às contagens de óbitos, sem qualquer modelo paramétrico para G. (a) Construa $\hat{f}_N$ pela frequência empírica e reporte $\hat{\theta}^{\text{R}}(x)$ para os valores de x mais frequentes. (b) Explique por que a estimativa fica instável para x grande e proponha uma suavização. (c) Compare com o estimador paramétrico Poisson–Gama do Exercício 1.5 e discuta em que faixa de x os dois mais divergem.

Notas e leituras complementares

- Robbins 1956: artigo seminal de uma página, com a derivação original.
- W. James e Stein 1961: prova da dominância do estimador de James–Stein pela identidade de Stein.
- Efron 2010: tratamento moderno de inferência em larga escala, com aplicações a microarrays e *local fdr*.
- Efron e Hastie 2016, §6.5: notas históricas sobre Robbins, Stein e a recepção do paradoxo da estimação simultânea.

1.10 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Unidade de análise	*unit of analysis*	—
Método de Bayes empírico	*empirical Bayes*	EB
Bayes empírico não paramétrico	*nonparametric empirical Bayes*	EB
Bayes empírico paramétrico	*parametric empirical Bayes*	EB
Modelo hierárquico	*hierarchical model*	—
Distribuição a priori	*prior distribution*	—
Distribuição posterior	*posterior distribution*	—
Distribuição marginal	*marginal distribution*	—
Hiperparâmetro	*hyperparameter*	—
Fórmula de Robbins	*Robbins' formula*	—
Fórmula de Tweedie	*Tweedie's formula*	—
Mistura Poisson–gama	*Poisson–gamma mixture*	—
Estimador de James–Stein	*James–Stein estimator*	JS
Encolhimento	*shrinkage*	—
Risco quadrático	*squared-error risk*	—
Estimador de máxima verossimilhança	*maximum likelihood estimator*	MLE
Máxima verossimilhança não paramétrica	*nonparametric maximum likelihood*	NPMLE
Modelo de efeitos aleatórios	*random-effects model*	—
Modelo linear misto	*linear mixed model*	LMM
Modelo linear generalizado misto	*generalized linear mixed model*	GLMM
Melhor preditor linear não viesado	*best linear unbiased predictor*	BLUP
Melhor preditor linear não viesado empírico	*empirical best linear unbiased predictor*	EBLUP
Máxima verossimilhança restrita	*restricted maximum likelihood*	REML
Taxa de falsas descobertas	*false discovery rate*	FDR
Taxa local de falsas descobertas	*local false discovery rate*	local FDR

Capítulo 2

Regressão Ridge

Objetivos da unidade

- Apresentar a regressão *ridge* como solução para a multicolinearidade e o sobreajuste em regressão linear.
- Derivar o estimador *ridge* e estudar suas propriedades (viés, variância, erro quadrático médio).
- Mostrar a equivalência bayesiana (*priori* normal) e a interpretação espectral via decomposição em valores singulares.
- Discutir métodos de escolha do parâmetro de regularização λ, incluindo validação cruzada comum e generalizada.
- Implementar a regressão *ridge* em `R` via `glmnet` e analisar trajetórias de coeficientes.

Leitura primária: Efron e Hastie 2016, capítulo 7.
Leitura complementar: Hoerl e Kennard 1970; G. James et al. 2013, capítulo 6; Hastie, R. Tibshirani e Wainwright 2015.

2.1 Motivação

Considere n observações e p variáveis preditoras. Seja $y \in \mathbb{R}^n$ o vetor de respostas, seja $X \in \mathbb{R}^{n\times p}$ a matriz de planejamento, cuja linha i contém os preditores da observação i, e seja $\beta \in \mathbb{R}^p$ o vetor de coeficientes desconhecidos. Denote por I_n a matriz identidade de ordem n e por $N_n(m, \Sigma)$ a distribuição normal de dimensão n, com vetor de médias m e matriz de covariância Σ. O modelo de regressão linear gaussiana é

$$y = X\beta + \varepsilon, \qquad \varepsilon \sim N_n(0, \sigma^2 I_n), \tag{2.1}$$

em que $\varepsilon \in \mathbb{R}^n$ é o vetor de erros aleatórios e $\sigma^2 > 0$ é a variância comum desses erros. Quando as p colunas de X são linearmente independentes, isto é, quando X tem posto de colunas completo, o estimador de mínimos quadrados é

$$\hat{\beta}_{\text{direto}} = (X^\top X)^{-1} X^\top y,$$

onde o sobrescrito apenas recorda que se usaram mínimos quadrados. Pelo teorema de Gauss–Markov, sua matriz de covariância é menor, na ordem de matrizes semidefinidas positivas, que a de qualquer outro estimador linear não viesado. Em duas situações de grande importância prática, contudo, esse estimador é insatisfatório:

1. **Multicolinearidade severa.** Quando colunas de X são fortemente correlacionadas, $X^\top X$ é *quase* singular, $\mathrm{Var}(\hat{\beta}_{\text{direto}}) = \sigma^2 (X^\top X)^{-1}$ pode ter entradas muito grandes, e os coeficientes estimados oscilam entre amostras, mesmo quando o modelo prediz y com erro pequeno.

2. **Alta dimensionalidade.** Quando $p > n$, a matriz $X^\top X$ é singular e as soluções de mínimos quadrados, quando existem, não são únicas. Se X tem posto de linhas completo, há soluções que interpolam a resposta de treinamento; isso, por si só, não garante nem impede boa predição fora da amostra.

A regressão *ridge*, introduzida por Hoerl e Kennard 1970, contorna esses problemas adicionando uma penalidade quadrática à função objetivo, induzindo viés em troca de uma redução drástica de variância, e, frequentemente, de erro quadrático médio.

Observação (Padronização das colunas)*.* Em todo o capítulo, suporemos que as colunas de X foram *centradas* ($\sum_i X_{ij} = 0$) e que y também foi centrado. Quando os preditores estiverem em escalas distintas, é prática essencial *padronizá-los* adicionalmente para variância 1, pois a penalidade quadrática $\|\beta\|^2$ não é invariante por reescala. O *intercepto* é tratado fora da penalidade.

2.2 O estimador ridge

Definição 2.1 (Estimador *ridge*)**.** Sejam $X \in \mathbb{R}^{n \times p}$ com colunas centradas e $y \in \mathbb{R}^n$ centrado. Denote por I_p a matriz identidade de ordem p. Para $\lambda \geq 0$,

$$\hat{\beta}_\lambda \;=\; \arg\min_{\beta \in \mathbb{R}^p} \left\{ \|y - X\beta\|^2 + \lambda \|\beta\|^2 \right\}. \tag{2.2}$$

Proposição 2.2 (Forma fechada)**.** *Para todo $\lambda > 0$, a solução de (2.2) é única e dada por*

$$\hat{\beta}_\lambda = (X^\top X + \lambda I_p)^{-1} X^\top y. \tag{2.3}$$

Demonstração. A função objetivo $L(\beta) = \|y - X\beta\|^2 + \lambda \|\beta\|^2$ é estritamente convexa em β pois sua Hessiana é $2(X^\top X + \lambda I_p)$, que é definida positiva quando $\lambda > 0$ (pois $X^\top X$ é semidefinida positiva e λI_p é definida positiva). Logo o mínimo é único e satisfaz $\nabla L(\hat{\beta}_\lambda) = 0$, isto é,

$$-2X^\top (y - X\hat{\beta}_\lambda) + 2\lambda \hat{\beta}_\lambda = 0 \iff (X^\top X + \lambda I_p)\, \hat{\beta}_\lambda = X^\top y. \qquad \square$$

Observação (Caso $\lambda = 0$)*.* Para $\lambda = 0$, recuperamos a equação normal de mínimos quadrados. Quando $X^\top X$ é não singular, $\hat{\beta}_0 = \hat{\beta}_{\text{direto}}$. Para $\lambda > 0$, a solução existe e é única *mesmo quando* $p > n$, pois λI_p regulariza a matriz singular.

Observação (Restrição equivalente)*.* O problema (2.2) é equivalente, por dualidade lagrangiana, ao problema com restrição

$$\min_{\beta} \|y - X\beta\|^2 \quad \text{sujeito a} \quad \|\beta\|^2 \leq t,$$

para um valor $t = t(\lambda) \geq 0$ associado à solução. Ou seja, a regressão *ridge* equivale a mínimos quadrados restritos a uma bola de raio $\sqrt{t}$ em $\mathbb{R}^p$. A correspondência pode deixar de ser um a um quando a restrição não é ativa.

2.3 Propriedades estatísticas

Adotamos o modelo (2.1) com β fixo (visão frequentista) e X não aleatório. Defina $A_\lambda := (X^\top X + \lambda I_p)^{-1} X^\top X$.

2.3.1 Viés

Proposição 2.3 (Viés)**.** *Para todo* $\lambda \geq 0$*,*

$$\mathbb{E}[\hat{\beta}_\lambda] = A_\lambda \beta, \qquad \textit{vies}(\hat{\beta}_\lambda) = (A_\lambda - I_p)\beta = -\lambda(X^\top X + \lambda I_p)^{-1}\beta.$$

Em particular, $\hat{\beta}_\lambda$ *é* viesado *para* $\lambda > 0$*.*

Demonstração. Da forma fechada e $\mathbb{E}[y] = X\beta$,

$$\mathbb{E}[\hat{\beta}_\lambda] = (X^\top X + \lambda I_p)^{-1} X^\top X \beta = A_\lambda \beta.$$

Subtraindo β e usando a identidade $(X^\top X + \lambda I_p)^{-1}(X^\top X) - I_p = -\lambda(X^\top X + \lambda I_p)^{-1}$, obtemos a expressão do viés. □

2.3.2 Variância

Proposição 2.4 (Variância)**.**

$$\mathrm{Var}(\hat{\beta}_\lambda) = \sigma^2 \, (X^\top X + \lambda I_p)^{-1} \, X^\top X \, (X^\top X + \lambda I_p)^{-1}.$$

Demonstração. Aplicar $\mathrm{Var}(My) = M\mathrm{Var}(y)M^\top$ com $M = (X^\top X + \lambda I_p)^{-1} X^\top$ e $\mathrm{Var}(y) = \sigma^2 I_n$. □

Observação. Comparando com $\mathrm{Var}(\hat{\beta}_{\text{direto}}) = \sigma^2 (X^\top X)^{-1}$, vê-se que $\mathrm{Var}(\hat{\beta}_\lambda) \preceq \mathrm{Var}(\hat{\beta}_{\text{direto}})$ na ordem de matrizes semidefinidas positivas: a variância da regressão em crista é menor em toda direção linear.

2.3.3 Erro quadrático médio e dominância

O erro quadrático médio total, $R(\lambda) = \mathbb{E}\left\|\hat{\beta}_\lambda - \beta\right\|^2$, decompõe-se em viés ao quadrado mais traço da variância:

$$R(\lambda) = \left\|\mathrm{vies}(\hat{\beta}_\lambda)\right\|^2 + \mathrm{tr}\big(\mathrm{Var}(\hat{\beta}_\lambda)\big).$$

Teorema 2.5 (Dominância de Hoerl e Kennard 1970)**.** *Para o modelo* (2.1) *com* $X^\top X$ *não singular, existe* $\lambda^* > 0$ *tal que*

$$R(\lambda^*) < R(0).$$

Demonstração. Diagonalize $X^\top X = V \,\mathrm{diag}(s_1, \ldots, s_p) V^\top$, com $s_j > 0$, e escreva $b = V^\top \beta$. Nas coordenadas dessa base ortonormal, o viés na direção j é $-\lambda b_j/(s_j+\lambda)$ e a variância é $\sigma^2 s_j/(s_j+\lambda)^2$. Portanto

$$R(\lambda) = \sum_{j=1}^{p} \frac{\lambda^2 b_j^2 + \sigma^2 s_j}{(s_j + \lambda)^2}.$$

Essa função é contínua à direita de zero e

$$R'(0) = -2\sigma^2 \sum_{j=1}^{p} \frac{1}{s_j^2} < 0.$$

O termo de viés não contribui para essa derivada porque cresce apenas na ordem λ^2. Pela definição de derivada, existe então $\lambda^* > 0$ suficientemente pequeno para o qual $R(\lambda^*) < R(0)$. □

Nota. O Teorema 2.5 mostra a *existência* de $\lambda^* > 0$ vantajoso, mas não fornece seu valor: λ^* depende de β e σ^2, ambos desconhecidos. Daí a necessidade de critérios baseados em dados (validação cruzada) para escolher λ na prática.

2.3.4 Caso ortogonal

Quando os preditores são *ortogonais*, $X^\top X = I_p$, o estimador *ridge* assume forma especialmente transparente.

Proposição 2.6 (Encolhimento uniforme no caso ortogonal)**.** *Se $X^\top X = I_p$, então*

$$\hat{\beta}_\lambda = \frac{1}{1+\lambda}\,\hat{\beta}_{\text{direto}}.$$

Demonstração. Da forma fechada (2.3), $\hat{\beta}_\lambda = (I_p + \lambda I_p)^{-1} X^\top y = \frac{1}{1+\lambda} X^\top y = \frac{1}{1+\lambda}\hat{\beta}_{\text{direto}}$. □

Note a analogia perfeita com o estimador de Bayes empírico Normal–Normal do Capítulo 1: ambos são *encolhimentos* (*shrinkages*) lineares do estimador clássico em direção à origem.

2.4 Decomposição espectral em valores singulares

Seja $r = \operatorname{rank}(X)$ e escreva a decomposição compacta em valores singulares como $X = UDV^\top$. Aqui $U \in \mathbb{R}^{n\times r}$ e $V \in \mathbb{R}^{p\times r}$ têm colunas ortonormais, e $D = \operatorname{diag}(d_1, \ldots, d_r)$, com $d_1 \geq \cdots \geq d_r > 0$. Essa forma inclui somente as direções em que X contém informação; as direções do núcleo de X têm valor singular zero.

Proposição 2.7 (Forma espectral)**.** *Os valores ajustados pela regressão* ridge *são*

$$\hat{y}_\lambda = X\hat{\beta}_\lambda = \sum_{j=1}^{r} \frac{d_j^2}{d_j^2 + \lambda}\, u_j u_j^\top y, \tag{2.4}$$

onde u_j é a j-ésima coluna de U. O estimador dos coeficientes é

$$\hat{\beta}_\lambda = \sum_{j=1}^{r} \frac{d_j}{d_j^2 + \lambda}\, (u_j^\top y)\, v_j.$$

Demonstração. Complete as colunas de V para formar uma matriz ortogonal $\widetilde{V} = (V, V_0)$. Nessa base,

$$X^\top X + \lambda I_p = \widetilde{V}\,\operatorname{diag}(d_1^2 + \lambda, \ldots, d_r^2 + \lambda, \lambda, \ldots, \lambda)\widetilde{V}^\top.$$

Além disso, $X^\top y = VDU^\top y$ não tem componente nas direções de V_0. Aplicar a inversa da matriz anterior produz $\hat{\beta}_\lambda = V(D^2 + \lambda I_r)^{-1} DU^\top y$, que é a segunda expressão. Multiplicar por $X = UDV^\top$ fornece a primeira. □

A interpretação é instrutiva: a *ridge encolhe* os componentes principais de y na base $\{u_j\}$ pelo fator $d_j^2/(d_j^2 + \lambda)$. Componentes associados a valores singulares pequenos (direções de baixa variabilidade dos preditores) são fortemente encolhidos, enquanto componentes de alta variabilidade são pouco afetados.

Definição 2.8 (Graus de liberdade efetivos)**.**

$$\operatorname{gl}(\lambda) := \operatorname{tr}[X(X^\top X + \lambda I_p)^{-1} X^\top] = \sum_{j=1}^{r} \frac{d_j^2}{d_j^2 + \lambda}.$$

Proposição 2.9. $\operatorname{gl}(\lambda)$ *é decrescente em λ, com o valor em zero definido por continuidade como* $\operatorname{gl}(0) = r$*, e* $\operatorname{gl}(\lambda) \to 0$ *quando* $\lambda \to \infty$.

Demonstração. Cada termo $d_j^2/(d_j^2 + \lambda)$ é decrescente em $\lambda \geq 0$, igual a 1 quando $d_j > 0, \lambda = 0$, e tendendo a 0 quando $\lambda \to \infty$. □

2.5 Equivalência bayesiana

Proposição 2.10 (Ridge como média a posteriori)**.** *Considere o modelo bayesiano*

$$y \mid \beta \sim N_n(X\beta, \sigma^2 I_n), \qquad \beta \sim N_p(0, \tau^2 I_p),$$

com σ^2 *e* τ^2 *conhecidos. Então a distribuição* a posteriori *é*

$$\beta \mid y \;\sim\; N_p(\hat{\beta}_\lambda,\; \sigma^2 (X^\top X + \lambda I_p)^{-1}), \qquad \lambda = \frac{\sigma^2}{\tau^2},$$

onde $\hat{\beta}_\lambda$ *é o estimador* ridge (2.3)*.*

Demonstração. A posterior é proporcional ao produto da verossimilhança com a *priori*, isto é,

$$\pi(\beta \mid y) \propto \exp\Big\{ -\tfrac{1}{2\sigma^2}\,\|y - X\beta\|^2 - \tfrac{1}{2\tau^2}\,\|\beta\|^2 \Big\}.$$

Expandindo o expoente e completando o quadrado em β, encontra-se uma normal multivariada com precisão $\sigma^{-2}X^\top X + \tau^{-2} I_p = \sigma^{-2}(X^\top X + \lambda I_p)$ e média $[\sigma^{-2}(X^\top X + \lambda I_p)]^{-1}\sigma^{-2}X^\top y = (X^\top X + \lambda I_p)^{-1} X^\top y = \hat{\beta}_\lambda$. □

Observação. A equivalência mostra que a regressão *ridge* é simultaneamente a média e a moda da distribuição a posteriori sob uma distribuição normal independente para os coeficientes. Além disso, λ é a razão ruído–sinal σ^2/τ^2. Quando os coeficientes são fortemente concentrados em torno de zero antes de observar os dados, τ^2 é pequeno, λ é grande e o estimador encolhe fortemente.

2.6 Escolha do parâmetro de regularização

A escolha de λ em aplicações se baseia em *erro de predição estimado* a partir dos próprios dados, sem recurso a β ou σ^2. Os métodos mais usados são:

Validação cruzada em k blocos. Particiona-se $\{1, \dots, n\}$ em k blocos disjuntos $B_1, \dots, B_k$, cuja união contém todos os índices. Para uma grade de valores $\{\lambda_1, \dots, \lambda_M\}$, ajusta-se o modelo sem o bloco B_j e calcula-se o erro de predição médio

$$\widehat{\mathrm{erro}}_k(\lambda) = \frac{1}{n} \sum_{j=1}^{k} \sum_{i \in B_j} (y_i - \hat{y}_i^{(-B_j)}(\lambda))^2,$$

e seleciona-se $\hat{\lambda} = \arg\min_\lambda \widehat{\mathrm{erro}}_k(\lambda)$. Veja Capítulo 9 para detalhes.

O centro e a escala de cada coluna também devem ser estimados novamente usando apenas os dados de treinamento de cada bloco. Usar a média ou o desvio-padrão calculado com todas as observações deixa o bloco de validação influenciar o ajuste e produz uma estimativa de erro otimista.

Validação cruzada generalizada. Craven e Wahba 1979; Golub, Heath e Wahba 1979 mostraram que

$$\widehat{\mathrm{erro}}_{\mathrm{gen}}(\lambda) = \frac{1}{n} \sum_{i=1}^{n} \left(\frac{y_i - \hat{y}_i(\lambda)}{1 - \mathrm{gl}(\lambda)/n} \right)^2$$

aproxima a validação que retira uma observação por vez ao substituir as alavancagens individuais por sua média. Pode ser computada em uma única passada depois da decomposição em valores singulares de X.

Regra de um erro padrão. Em vez de tomar o minimizador, é comum escolher o maior λ cujo erro estimado não exceda o mínimo mais um erro padrão estimado. A regra é uma heurística de parcimônia: os erros dos blocos não são independentes porque os conjuntos de treinamento se sobrepõem, de modo que a quantidade calculada não é um erro padrão exato.

2.7 Comparação com a regressão lasso

A penalidade quadrática não é a única possível. Substituindo $\|\beta\|_2^2$ por $\|\beta\|_1$ obtém-se um estimador com propriedades qualitativamente distintas, e a comparação entre os dois é o meio mais rápido de entender o que a penalidade, e não apenas o encolhimento, está fazendo.

Definição 2.11 (Estimador lasso)**.** O estimador **lasso** (*least absolute shrinkage and selection operator*), introduzido por R. Tibshirani 1996, é

$$\hat{\beta}^{\mathrm{L}}_{\lambda} = \operatorname*{arg\,min}_{\beta \in \mathbb{R}^p} \left\{ \|y - X\beta\|^2 + \lambda \sum_{j=1}^{p} |\beta_j| \right\}, \qquad \lambda \geq 0, \tag{2.5}$$

com as colunas de X padronizadas e o intercepto excluído da penalidade, como na Observação da Seção 2.1.

Assim como a regressão *ridge*, (2.5) admite uma forma restrita: minimizar $\|y - X\beta\|^2$ sob $\sum_j |\beta_j| \leq s$. Para cada λ existe um valor apropriado de s, e s não cresce quando λ aumenta; a correspondência não precisa ser biunívoca em trechos nos quais a solução permanece inalterada. Para X geral, a função objetivo é convexa, mas não diferenciável na origem de cada coordenada, e não há uma forma fechada análoga a (2.3). O pacote `glmnet` usa descida por coordenadas para resolvê-la.

2.7.1 O caso ortogonal: três regras de limiar

Sob ortogonalidade a comparação torna-se completamente explícita, porque o problema se separa em p problemas escalares independentes.

Teorema 2.12 (Limiar suave)**.** *Se $X^\top X = I_p$, a solução de (2.5) é, coordenada a coordenada,*

$$\hat{\beta}^{L}_{\lambda,j} = \mathcal{S}_{\lambda/2}(\hat{\beta}_j^{\text{direto}}) := \operatorname{sinal}(\hat{\beta}_j^{\text{direto}}) \cdot \left(|\hat{\beta}_j^{\text{direto}}| - \tfrac{\lambda}{2} \right)_+, \tag{2.6}$$

onde $(u)_+ = \max(u, 0)$.

Demonstração. Com $X^\top X = I_p$ vale $\|y - X\beta\|^2 = \|y\|^2 - 2\beta^\top \hat{\beta}^{\,\text{direto}} + \|\beta\|^2$, pois $X^\top y = \hat{\beta}^{\,\text{direto}}$. A função objetivo separa-se em

$$\sum_{j=1}^{p} \left[\beta_j^2 - 2\beta_j \hat{\beta}_j^{\text{direto}} + \lambda\,|\beta_j| \right] + \|y\|^2 .$$

Fixe j e suponha $\hat{\beta}_j^{\text{direto}} > 0$. Se o mínimo ocorre em $\beta_j > 0$, a derivada $2\beta_j - 2\hat{\beta}_j^{\text{direto}} + \lambda$ anula-se em $\beta_j = \hat{\beta}_j^{\text{direto}} - \lambda/2$, o que é admissível apenas se $\hat{\beta}_j^{\text{direto}} > \lambda/2$. Caso contrário, a derivada à direita em 0 é $-2\hat{\beta}_j^{\text{direto}} + \lambda \geq 0$ e a derivada à esquerda é $-2\hat{\beta}_j^{\text{direto}} - \lambda < 0$: o subdiferencial contém zero e o mínimo é $\beta_j = 0$. O caso $\hat{\beta}_j^{\text{direto}} < 0$ é simétrico. □

Confrontando com a Proposição 2.6 e com a seleção de subconjuntos (que penaliza $\lambda \cdot \#\{j : \beta_j \neq 0\}$ e produz *hard-thresholding* em $\sqrt{\lambda}$), obtemos o quadro completo:

Método	Penalidade	Solução ortogonal
Seleção de subconjuntos	$\lambda \#\{\beta_j \neq 0\}$	$\hat{\beta}_j \, \mathbb{1}\{\lvert\hat{\beta}_j\rvert > \sqrt{\lambda}\}$ (*hard*)
Lasso	$\lambda \sum_j \lvert\beta_j\rvert$	$\text{sinal}(\hat{\beta}_j)(\lvert\hat{\beta}_j\rvert - \lambda/2)_+$ (*soft*)
Ridge	$\lambda \sum_j \beta_j^2$	$\hat{\beta}_j/(1+\lambda)$ (proporcional)

Observação (A diferença essencial). A *ridge* multiplica todos os coeficientes por um mesmo fator $1/(1+\lambda) > 0$: nenhum coeficiente é jamais *exatamente* zero, por maior que seja λ (embora todos tendam a zero conjuntamente). O lasso subtrai uma constante $\lambda/2$ do valor absoluto e trunca em zero: coeficientes pequenos são **anulados exatamente**. Portanto o lasso realiza, simultaneamente, encolhimento *e* seleção de variáveis; a *ridge* realiza apenas encolhimento.

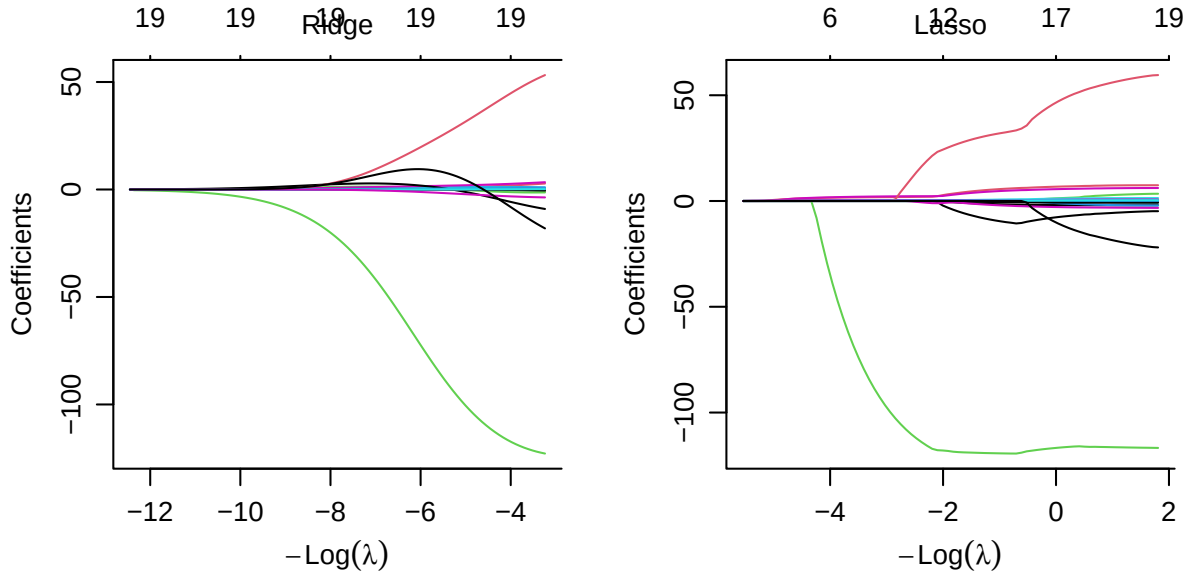
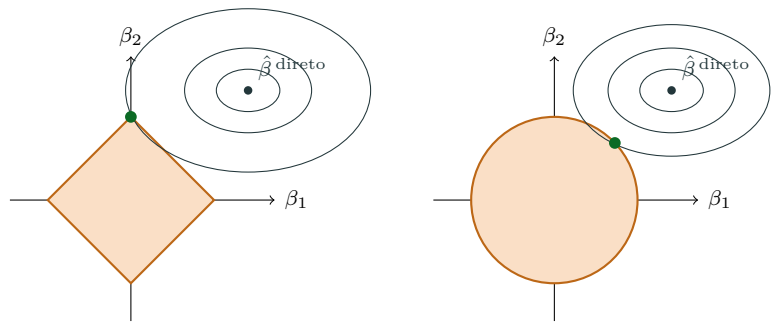


Figura 2.1: Trajetórias dos 19 coeficientes no conjunto `Hitters`, em função de $\log \lambda$. Sob penalidade quadrática, à esquerda, as curvas aproximam-se de zero assintoticamente. Sob penalidade absoluta, à direita, elas atingem zero em valores finitos. Com o valor escolhido pela heurística de um erro-padrão, o segundo ajuste retém quatro preditores e o primeiro mantém os dezenove.

2.7.2 A geometria da esparsidade

A explicação geométrica é a mais memorável. Na forma restrita, procura-se o ponto da região de restrição mais próximo de $\hat{\beta}^{\text{direto}}$ na métrica dos contornos elípticos da soma de quadrados residual.



Lasso (ℓ_1)
solução no *vértice*: $\hat{\beta}_1 = 0$

Ridge (ℓ_2)
solução no *interior de um arco*: ambos $\neq 0$

A bola ℓ_1 é um losango, com *vértices sobre os eixos*; a bola ℓ_2 é um círculo, *liso em toda parte*. Contornos elípticos que se expandem a partir de $\hat{\beta}^{\text{direto}}$ tocam o losango, com probabilidade positiva, exatamente em um vértice, e um vértice é um ponto em que alguma coordenada se anula. O círculo, por não ter quinas, é tocado quase sempre em um ponto com todas as coordenadas não nulas. A esparsidade do lasso é, nesse sentido preciso, uma consequência da *não diferenciabilidade* da penalidade na origem.

Nota (Interpretação bayesiana comparada). A Proposição 2.10 identificou a regressão quadrática regularizada com a média e a moda posteriores sob coeficientes independentes $\beta_j \sim N(0, \tau^2)$. O análogo para a penalidade absoluta é que (2.5) representa a moda posterior sob uma distribuição de Laplace,

$$\pi(\beta_j) = \frac{\lambda}{4\sigma^2} \exp\!\left(-\frac{\lambda\,|\beta_j|}{2\sigma^2}\right),$$

pois $-\log \pi(\beta) \propto \lambda \left\|\beta\right\|_1 / (2\sigma^2)$. A densidade de Laplace tem uma ponta em zero e caudas mais pesadas que a normal, favorecendo coeficientes próximos de zero e permitindo alguns valores grandes. Como essa distribuição é contínua, ela atribui probabilidade zero ao evento de um coeficiente ser *exatamente* nulo; os zeros do lasso surgem da ponta da função objetivo e caracterizam a moda. No caso da regressão *ridge*, média e moda a posteriori coincidem; sob a distribuição de Laplace, a média a posteriori não é esparsa.

2.7.3 Preditores correlacionados e a *elastic net*

O comportamento dos dois métodos diverge de forma prática quando há grupos de preditores fortemente correlacionados.

- A ***ridge*** distribui o coeficiente aproximadamente por igual entre os membros do grupo. No limite de dois preditores idênticos, a solução *ridge* atribui exatamente metade do coeficiente a cada um, consequência da estrita convexidade da penalidade quadrática, que penaliza mais um coeficiente grande do que dois pela metade.
- O **lasso** pode selecionar um membro do grupo e zerar os demais. Com preditores idênticos, a solução pode não ser única: alocações diferentes do mesmo coeficiente total podem ser ótimas. Isso ajuda a explicar a instabilidade do conjunto selecionado entre reamostragens.
- Sob condições usuais de posição geral e quando a solução é única, o lasso seleciona no máximo $\min(n, p)$ variáveis. Empates e degenerações do desenho exigem qualificar essa afirmação.

A ***elastic net*** de Zou e Hastie 2005 combina as duas penalidades:

$$\hat{\beta}^{\text{mista}}_{\lambda,\alpha} = \arg\min_{\beta} \left\{ \left\|y - X\beta\right\|^2 + \lambda\Big[\alpha \left\|\beta\right\|_1 + \frac{1-\alpha}{2} \left\|\beta\right\|_2^2\Big] \right\}, \qquad \alpha \in [0,1], \tag{2.7}$$

recuperando o lasso em $\alpha = 1$ e a família da regressão *ridge* em $\alpha = 0$ (neste extremo, o valor numérico de λ difere por um fator 2 da convenção de (2.2)). Quando $\lambda > 0$ e $\alpha < 1$, o termo quadrático torna a função objetivo estritamente convexa e garante unicidade. Ele também favorece, sem garantir em toda amostra, que preditores correlacionados recebam coeficientes semelhantes. Em `glmnet`, α é o argumento `alpha` e a mistura das penalidades é exatamente a de (2.7). Para a família gaussiana, o pacote divide a soma de quadrados residual por $2n$; portanto seu valor de `lambda` corresponde a $\lambda/(2n)$ na convenção de (2.7).

Observação (Graus de liberdade do lasso). Para a regressão *ridge*, $\mathrm{gl}(\lambda)$ é a quantidade contínua da Definição 2.8. Para erros gaussianos e sob condições de posição geral do desenho, Zou, Hastie e R. Tibshirani 2007 mostraram que a contagem observada de coeficientes não nulos, $\#\{j : \hat{\beta}^{\mathrm{L}}_{\lambda,j} \neq 0\}$, é um estimador não viesado dos graus de liberdade efetivos: $\mathrm{gl}(\lambda) = \mathbb{E}\big[\#\{j : \hat{\beta}^{\mathrm{L}}_{\lambda,j} \neq 0\}\big]$. Fora dessas condições, a fórmula precisa de ajustes.

2.7.4 Qual usar?

	Ridge	**Lasso**
Esparsidade	Não (nenhum zero exato)	Sim (seleção automática)
Solução	Fechada, linear em y	Numérica, não linear em y
Preditores correlacionados	Distribui o peso; estável	Escolha arbitrária; instável
Caso $p > n$	Sem limite de variáveis	No máximo n selecionadas
Cenário favorável	Muitos efeitos pequenos (sinal *denso*)	Poucos efeitos grandes (sinal *esparso*)
Interpretação	Modelo completo encolhido	Modelo reduzido e legível

A regra prática decorre da última linha: quando se acredita que *muitos* preditores contribuem pouco cada um, o cenário típico em genômica quantitativa ou em previsão macroeconômica, a *ridge* costuma prever melhor. Quando se acredita que *poucos* preditores concentram o sinal e se deseja um modelo comunicável, o lasso é preferível. Na dúvida, a *elastic net* com α escolhido por validação cruzada interpola entre os dois regimes, e o custo de decidir empiricamente é apenas computacional.

Nota (Inferência pós-seleção). Um alerta importante: os erros-padrão usuais reportados após um ajuste lasso são inválidos, porque ignoram que o conjunto de variáveis foi *escolhido a partir dos mesmos dados*. Intervalos de confiança e valores-p ingênuos são anticonservadores. O tratamento correto exige inferência seletiva condicional ou o lasso *desviesado*; veja Hastie, R. Tibshirani e Wainwright 2015, capítulo 6. A validação cruzada do Capítulo 9 e o *bootstrap* do Capítulo 8 sofrem do mesmo problema se a seleção não for repetida *dentro* de cada reamostra.

2.8 Exemplos resolvidos

Exercício resolvido 2.1 : Caso ortogonal: risco quadrático explícito

Enunciado. Seja $X^\top X = I_p$. Mostre que o risco quadrático $\mathbb{E}\|\hat\beta_\lambda - \beta\|^2$ é $\{p\sigma^2 + \lambda^2\|\beta\|^2\}/(1+\lambda)^2$ e encontre seu minimizador.

Solução. Pela Proposição 2.6, $\hat\beta_\lambda = \frac{1}{1+\lambda}\hat\beta_{\text{direto}}$. O viés é $-\frac{\lambda}{1+\lambda}\beta$ e a variância $\frac{\sigma^2}{(1+\lambda)^2} I_p$. Portanto

$$\text{Risco}(\hat\beta_\lambda) = \frac{\lambda^2\|\beta\|^2 + p\sigma^2}{(1+\lambda)^2}.$$

Diferenciando em λ, obtém-se $d\,\text{Risco}\,/d\lambda = \{2\lambda\|\beta\|^2 - 2p\sigma^2\}/(1+\lambda)^3$, que se anula em

$$\lambda^* = \frac{p\sigma^2}{\|\beta\|^2}.$$

Esse é o λ ótimo *na população*; comparando com a Proposição 2.10, vê-se que $\lambda^* = \sigma^2/\tau^2$ se interpretarmos $\tau^2 = \|\beta\|^2/p$, isto é, a variância média dos coeficientes. Esta é a versão para regressão do estimador de James–Stein.

Exercício resolvido 2.2 : Ridge em pequena dimensão

Enunciado. Considere $n = 5$ observações com matriz de design e resposta

$$X = \begin{pmatrix} -1 & -1 \\ -0{,}5 & -0{,}4 \\ 0 & 0{,}1 \\ 0{,}5 & 0{,}4 \\ 1 & 0{,}9 \end{pmatrix}, \qquad y = (-1{,}2,\ -0{,}7,\ 0{,}1,\ 0{,}9,\ 1{,}1)^\top.$$

Calcule $\hat{\beta}_\lambda$ para $\lambda \in \{0,\ 0{,}1,\ 1,\ 10\}$ e comente.
Solução. Calculamos

$$X^\top X = \begin{pmatrix} 2{,}5 & 2{,}3 \\ 2{,}3 & 2{,}14 \end{pmatrix}, \qquad X^\top y = \begin{pmatrix} 3{,}10 \\ 2{,}84 \end{pmatrix}.$$

A matriz $X^\top X$ tem determinante 0,06: as colunas são quase colineares. Para cada λ, $\hat{\beta}_\lambda = (X^\top X + \lambda I_2)^{-1} X^\top y$:

λ	$\hat{\beta}_{\lambda,1}$	$\hat{\beta}_{\lambda,2}$
0	1,700	−0,500
0,1	0,772	0,476
1	0,562	0,493
10	0,212	0,194

Para $\lambda = 0$, o ajuste direto produz coeficientes de sinais opostos, 1,70 e −0,50: a quase-colinearidade permite compensações grandes sem alterar muito os valores ajustados. Para $\lambda = 0{,}1$, os coeficientes tornam-se menores e comparáveis. Isso mostra estabilidade numérica, mas não prova uma interpretação causal para seus sinais. Com $\lambda = 10$, o encolhimento é forte.

Exercício resolvido 2.3 : Equivalência bayesiana numérica

Enunciado. No exemplo anterior, suponha $\sigma^2 = 0{,}05$ (estimativa razoável) e adote a *priori* $\beta \sim N_2(0, \tau^2 I_2)$. Que valor de τ^2 corresponde a $\lambda = 0{,}1$? Dê um intervalo de credibilidade 95% *a posteriori* para β_1.
Solução. $\lambda = \sigma^2/\tau^2 \Rightarrow \tau^2 = \sigma^2/\lambda = 0{,}05/0{,}1 = 0{,}5$. A posterior é normal com média $\hat{\beta}_{0,1} = (0{,}772,\ 0{,}476)$ e variância $\sigma^2(X^\top X + \lambda I_2)^{-1}$. Numericamente,

$$(X^\top X + 0{,}1 I_2)^{-1} \approx \begin{pmatrix} 4{,}19 & -4{,}31 \\ -4{,}31 & 4{,}87 \end{pmatrix},$$

e a variância *a posteriori* de β_1 é $0{,}05 \cdot 4{,}19 \approx 0{,}21$, com desvio padrão $\approx 0{,}46$. Portanto o intervalo de credibilidade de 95% para β_1, sob aproximação normal, é aproximadamente $0{,}772 \pm 1{,}96 \cdot 0{,}46 = (-0{,}13,\ 1{,}67)$. Note como o intervalo é largo, refletindo a quase-colinearidade do planejamento.

2.9 Laboratório computacional em `R`

Laboratório em R : Implementação manual de *ridge*

A forma fechada (2.3) pode ser implementada em poucas linhas; o bloco a seguir reproduz o Exercício resolvido 2.2:

```
ridge_manual <- function(X, y, lambda) {
  # X centrado por colunas; y centrado.
  p <- ncol(X)
  solve(crossprod(X) + lambda * diag(p), crossprod(X, y))
}

# Dados do exercicio resolvido de ridge em pequena dimensao
X <- matrix(c(-1, -0.5, 0, 0.5, 1,
              -1, -0.4, 0.1, 0.4, 0.9), ncol = 2)
y <- c(-1.2, -0.7, 0.1, 0.9, 1.1)

sapply(c(0, 0.1, 1, 10),
       function(lam) round(ridge_manual(X, y, lam), 3))
```

Laboratório em R : glmnet no conjunto Hitters

O pacote `glmnet` implementa *ridge* ($\alpha = 0$), *lasso* ($\alpha = 1$) e *elastic net* ($0 < \alpha < 1$) com algoritmo de descida coordenada eficiente em alta dimensão.

```
library(ISLR2)
library(glmnet)

dados <- na.omit(Hitters)
X <- model.matrix(Salary ~ ., dados)[, -1]
y <- dados$Salary

# Trajetorias de coeficientes
ajuste_ridge <- glmnet(X, y, alpha = 0,
                       lambda = 10^seq(4, -2, length.out = 100))
plot(ajuste_ridge, xvar = "lambda", label = TRUE)

# Validacao cruzada 10-fold para selecionar lambda
set.seed(1)
cv_ridge <- cv.glmnet(X, y, alpha = 0)
plot(cv_ridge)
lambda_min <- cv_ridge$lambda.min   # menor erro de validacao
lambda_1se <- cv_ridge$lambda.1se   # regra de um erro-padrao
c(lambda_min = lambda_min, lambda_1se = lambda_1se)

# Coeficientes no lambda otimo
coef(cv_ridge, s = "lambda.min")
```

A trajetória de $\hat{\beta}_\lambda$ contra $\log \lambda$ mostra o encolhimento: para λ grande, os coeficientes se aproximam de zero; para λ pequeno, retornam ao ajuste direto. O valor de validação deve ser lido na curva produzida pelos dados.

Laboratório em R : Comparação de risco quadrático em simulação

Para comparar a penalidade quadrática com o ajuste direto quando p é próximo de n:

```
set.seed(2026)
n <- 50; p <- 40
beta_real <- rnorm(p, 0, 0.5)

simular <- function() {
  X <- matrix(rnorm(n * p), n, p)
  y <- X %*% beta_real + rnorm(n, sd = 1)
  ajustar <- function(lambda)
    solve(crossprod(X) + lambda * diag(p), crossprod(X, y))
  c(direto = sum((ajustar(1e-6) - beta_real)^2),
    ridge  = sum((ajustar(5)    - beta_real)^2))
}

R <- 200
erros <- replicate(R, simular())
rowMeans(erros)
```

O desenho e a resposta agora são os mesmos para os dois métodos em cada repetição; essa comparação emparelhada separa o efeito da regularização da variação entre amostras. A saída típica mostra erro quadrático médio menor para a regressão *ridge*: a redução de variância compensa o viés introduzido.

Laboratório em R : Regressão em crista e lasso: trajetórias e esparsidade

O mesmo `glmnet` produz os dois estimadores; muda-se apenas `alpha`.

```
library(ISLR2); library(glmnet)
dados <- na.omit(Hitters)
X <- model.matrix(Salary ~ ., dados)[, -1]
y <- dados$Salary

set.seed(1)
cv_ridge <- cv.glmnet(X, y, alpha = 0)   # ridge
cv_lasso <- cv.glmnet(X, y, alpha = 1)   # lasso

# Quantos coeficientes exatamente nulos em cada caso?
b_ridge <- coef(cv_ridge, s = "lambda.1se")
b_lasso <- coef(cv_lasso, s = "lambda.1se")
c(zeros_ridge = sum(b_ridge == 0), zeros_lasso = sum(b_lasso == 0))

# Trajetorias lado a lado
par(mfrow = c(1, 2))
plot(glmnet(X, y, alpha = 0), xvar = "lambda", main = "Ridge")
plot(glmnet(X, y, alpha = 1), xvar = "lambda", main = "Lasso")
```

A penalidade quadrática mantém os 19 coeficientes não nulos, apenas encolhidos. A penalidade absoluta, no valor escolhido pela heurística de um erro-padrão nesta execução, zera 15 e retém quatro. A seleção exata pode mudar com a partição; o contraste estrutural entre encolher continuamente e atingir zero permanece.

Para verificar o *soft-thresholding* do Teorema 2.12 diretamente, construa um desenho ortogonal:

```
set.seed(7)
```

```
n <- 200; p <- 5
X_ort <- qr.Q(qr(matrix(rnorm(n * p), n, p)))   # colunas
    ortonormais
beta  <- c(3, 1.5, 0, 0, -2)
y_ort <- as.vector(X_ort %*% beta + rnorm(n, sd = 0.3))

b_ols <- as.vector(crossprod(X_ort, y_ort))     # ajuste direto
    quando X'X = I
lam   <- 0.8

# Regra teorica de limiar suave (convencao do capitulo: corte em
    lambda/2)
soft <- function(b, corte) sign(b) * pmax(abs(b) - corte, 0)
rbind(direto = round(b_ols, 3), limiar = round(soft(b_ols, lam / 2),
    3))
```

Os coeficientes cujo valor absoluto for menor que $\lambda/2 = 0{,}4$ são levados exatamente a zero; os demais são deslocados de 0,4 em direção à origem, e não multiplicados por um fator comum, a diferença entre limiar suave e encolhimento proporcional.

2.10 Exercícios propostos

Ex. 2.1. Mostre que, sob $X^\top X = I_p$, $\hat\beta_\lambda = (1+\lambda)^{-1}\hat\beta_{\text{direto}}$ realiza encolhimento uniforme. Calcule o risco quadrático por componente e determine os valores de $\lambda > 0$ que o reduzem em relação ao ajuste direto. Para $\beta_j \neq 0$, determine também o valor de λ que minimiza esse risco; trate separadamente o caso $\beta_j = 0$.

Ex. 2.2. Demonstre a Proposição 2.10 (média *a posteriori* sob *priori* normal $\beta \sim N_p(0, \tau^2 I_p)$) detalhando o cálculo do completar quadrados.

Ex. 2.3. Mostre que o número efetivo de graus de liberdade $\mathrm{gl}(\lambda) = \sum_{j=1}^{r} d_j^2/(d_j^2+\lambda)$, em que $d_1, \ldots, d_r$ são os valores singulares positivos e $r = \mathrm{posto}(X)$, é estritamente decrescente em $\lambda \geq 0$ desde que $r \geq 1$. Calcule $\mathrm{gl}(\lambda)$ explicitamente para $X^\top X = I_p$.

Ex. 2.4. Na decomposição compacta em valores singulares $X = UDV^\top$, seja $r = \mathrm{posto}(X)$ e sejam $u_1, \ldots, u_r$ as colunas de U. Mostre que o ajuste direto é $\hat y_{\text{direto}} = \sum_{j=1}^{r} u_j u_j^\top y$ e compare-o com (2.4).

Ex. 2.5. Use `set.seed(2026)` e gere, uma única vez, um vetor β com os dez primeiros coeficientes independentes $N(0,1)$ e os demais nulos. Em cada uma de 200 repetições, gere $n = 100$, $p = 80$, entradas de X independentes $N(0,1)$ e ruído independente de desvio-padrão 1. Em `cv.glmnet`, use `intercept=FALSE` e `standardize=FALSE`. Compare a média de $\left\|\hat\beta - \beta\right\|^2$ do ajuste direto e da penalidade quadrática, com λ escolhido por validação cruzada em dez blocos tanto pelo mínimo quanto pela heurística de um erro-padrão. Reporte também o erro-padrão de Monte Carlo de cada média.

Ex. 2.6. No conjunto de dados `Hitters`, remova as linhas incompletas, use `Salary` como resposta e todas as demais variáveis como preditores. Com `set.seed(1)`, ajuste a regressão em crista por `cv.glmnet` e registre o valor escolhido pela heurística de um erro-padrão. Compare os coeficientes regularizados com os de mínimos quadrados e discuta o encolhimento sem atribuir interpretação causal automática.

Ex. 2.7. Considere o problema de seleção de subconjuntos no caso ortogonal $X^\top X = I_p$, isto é, a minimização de $\|y - X\beta\|^2 + \lambda \#\{j : \beta_j \neq 0\}$. Mostre que uma solução é o limiar duro $\hat\beta_j \, \mathbb{1}\{|\hat\beta_j| > \sqrt{\lambda}\}$, com $\hat\beta = \hat\beta^{\text{direto}}$, e descreva o que ocorre na igualdade $|\hat\beta_j| = \sqrt{\lambda}$. Em seguida, fixe um limiar comum $c > 0$: use penalidade c^2 para seleção de subconjuntos e penalidade $2c$ para o lasso. Esboce, nos mesmos eixos, as regras de limiar duro, limiar suave e encolhimento proporcional como funções de $\hat\beta_j$; para a última, use qualquer penalidade quadrática $\rho > 0$, pois ela não possui limiar de entrada. Compare continuidade, viés para sinais grandes e estabilidade sob pequenas perturbações nos dados.

Ex. 2.8. Mostre que $\hat\beta^{\mathrm{L}}_\lambda$ de (2.5) é a moda *a posteriori* do modelo $y \mid \beta \sim N_n(X\beta, \sigma^2 I_n)$ com *priori* de Laplace independente $\pi(\beta_j) \propto \exp(-\lambda\,|\beta_j|\,/(2\sigma^2))$. Em seguida, para $p = 1$, $X^\top X = 1$ e $\sigma^2 = 1$, argumente (analiticamente ou por simulação) que a *média a posteriori* é diferente de zero com probabilidade 1, e explique por que apenas a moda é esparsa.

Ex. 2.9. *Efeito de agrupamento.* Suponha $p = 2$ com $x_2 = x_1 \neq 0$ exatamente (preditores idênticos) e $X^\top X$ singular. (a) Mostre que, para um coeficiente total ótimo c, o conjunto de soluções do lasso é $\{(t, c - t) : t \in [\min(0, c), \max(0, c)]\}$, isto é, a solução não é única quando $c \neq 0$. (b) Para $\lambda > 0$, mostre que a solução da regressão em crista é única e satisfaz $\hat\beta_1 = \hat\beta_2$. (c) Verifique que a combinação das penalidades de valor absoluto e quadrática, com $\alpha < 1$ e $\lambda > 0$, também tem solução única com $\hat\beta_1 = \hat\beta_2$. Conclua por que essa combinação é útil quando há grupos de preditores correlacionados.

Ex. 2.10. *Sinal denso e esparso.* Use `set.seed(1)`, cem repetições, $n = 100$, $p = 60$, ruído independente $N(0, 1)$ e uma amostra de teste independente de tamanho 1000. Gere as entradas das matrizes de desenho como independentes $N(0, 1)$. Compare as penalidades quadrática, absoluta e combinada por meio de `cv.glmnet`, com $\alpha = 0{,}5$ para a terceira, em dois cenários: os cinco primeiros coeficientes iguais a 2 e os demais nulos; ou, a cada repetição, sessenta coeficientes independentes $N(0, 0{,}2^2)$. Para os três métodos, use os mesmos dez blocos de validação, `intercept=FALSE`, `standardize=FALSE` e selecione `lambda.min`. Reporte o erro quadrático médio de teste, seu erro-padrão de Monte Carlo e o número médio de coeficientes não nulos.

Notas e leituras complementares

- Hoerl e Kennard 1970: artigo seminal, com a primeira prova do Teorema 2.5.
- Hastie, R. Tibshirani e Wainwright 2015: visão moderna englobando *ridge*, *lasso* e suas generalizações.
- Hastie, R. Tibshirani e J. Friedman 2009, §3.4: tratamento detalhado, incluindo conexões com regressão por componentes principais e mínimos quadrados parciais.
- G. James et al. 2013, §6.2: exposição introdutória com aplicações em `R`.

2.11 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Mínimos quadrados ordinários	*ordinary least squares*	OLS
Multicolinearidade	*multicollinearity*	—
Alta dimensionalidade	*high dimensionality*	—
Regressão ridge	*ridge regression*	—
Regularização	*regularization*	—
Parâmetro de regularização	*regularization parameter*	—
Penalidade quadrática	*squared ℓ_2 penalty*	—
Compromisso entre viés e variância	*bias–variance trade-off*	—
Erro quadrático médio	*mean squared error*	MSE
Decomposição em valores singulares	*singular value decomposition*	SVD
Valor singular	*singular value*	—
Direção de componente principal	*principal component direction*	PC
Graus de liberdade efetivos	*effective degrees of freedom*	df
Validação cruzada	*cross-validation*	CV
Validação cruzada generalizada	*generalized cross-validation*	GCV
Regra de um erro padrão	*one-standard-error rule*	1-SE rule
Regressão lasso	*lasso regression*	LASSO
Penalidade absoluta	*absolute ℓ_1 penalty*	—
Limiar suave	*soft thresholding*	—
Limiar rígido	*hard thresholding*	—
Esparsidade	*sparsity*	—
Rede elástica	*elastic net*	EN
Descida coordenada	*coordinate descent*	—
Inferência pós-seleção	*post-selection inference*	—

Capítulo 3

Modelos Lineares Generalizados

Objetivos da unidade

- Definir a família exponencial e identificar suas componentes (parâmetro natural, função base, função cumulante).
- Apresentar a estrutura de um modelo linear generalizado: componente aleatória, componente sistemática e função de ligação.
- Estudar a regressão logística e a regressão de Poisson como casos centrais.
- Discutir inferência por máxima verossimilhança pela pontuação de Fisher, implementada como mínimos quadrados reponderados iterativamente, e pela deviância.

Leitura primária: Efron e Hastie 2016, capítulo 8.
Leitura complementar: Nelder e Wedderburn 1972; G. James et al. 2013, capítulo 4; para a regressão de Poisson e o exemplo `Bikeshare`, a 2ª edição G. James et al. 2021, §4.6.

3.1 Motivação

Seja Y a variável resposta e seja $x = (x_1, \ldots, x_p)^\top$ o vetor de p preditores. A regressão linear gaussiana é restrita: ela supõe resposta contínua, ruído normal com variância constante e dependência linear de $\mathbb{E}[Y \mid x]$ nos preditores. Em muitos contextos, essas hipóteses falham:

- **Resposta binária** (sucesso ou falha): se $p = \mathbb{P}(Y = 1 \mid x)$, a regressão linear pode produzir probabilidades estimadas fora de $[0, 1]$ e não representa a variância $\mathrm{Var}(Y \mid x) = p(1 - p)$.
- **Contagens** (número de eventos): $Y \in \mathbb{N}_0$, com variância tipicamente proporcional à média ($\mathrm{Var}(Y) \approx \mathbb{E}[Y]$ na Poisson).
- **Tempos positivos ou taxas**: $Y > 0$, frequentemente com $\mathrm{Var}(Y) \propto \mathbb{E}[Y]^2$ (Gama, log-Normal).

A teoria dos **modelos lineares generalizados**, proposta por Nelder e Wedderburn 1972, unifica esses casos: a resposta segue uma distribuição da família exponencial e uma transformação da média, $g(\mu)$, é modelada como combinação linear dos preditores.

3.2 A família exponencial

Definição 3.1 (Família exponencial unidimensional)**.** A distribuição de uma variável aleatória Y pertence à **família exponencial** (forma canônica) se sua densidade ou função de probabilidade

pode ser escrita como

$$f(y;\theta,\phi) = \exp\left\{ \frac{y\theta - b(\theta)}{a(\phi)} + c(y,\phi) \right\}, \qquad y \in \mathcal{Y}, \tag{3.1}$$

onde:

- $\theta \in \Theta \subset \mathbb{R}$ é o *parâmetro natural* (ou canônico);
- $\phi > 0$ é o *parâmetro de dispersão*, eventualmente conhecido;
- a, b, c são funções conhecidas, com b duas vezes diferenciável e $a(\phi) > 0$.

3.2.1 Casos clássicos

Exemplo 3.2 (Normal)**.** Para $Y \sim N(\mu, \sigma^2)$, $f(y) = (2\pi\sigma^2)^{-1/2} \exp(-(y-\mu)^2/(2\sigma^2))$. Reescrevendo,

$$f(y) = \exp\left\{ \frac{y\mu - \mu^2/2}{\sigma^2} - \tfrac{1}{2}\left(\tfrac{y^2}{\sigma^2} + \log(2\pi\sigma^2) \right) \right\}.$$

Logo $\theta = \mu$, $b(\theta) = \theta^2/2$, $a(\phi) = \phi = \sigma^2$, $c(y,\phi) = -\frac{1}{2}(y^2/\phi + \log(2\pi\phi))$.

Exemplo 3.3 (Bernoulli)**.** Para $Y \sim \text{Bernoulli}(p)$, $f(y) = p^y(1-p)^{1-y}$ pode ser escrito

$$f(y) = \exp\left\{ y \log \tfrac{p}{1-p} + \log(1-p) \right\}.$$

Logo $\theta = \log(p/(1-p))$ (*logito*), $b(\theta) = \log(1+e^\theta)$, $a(\phi) = 1$, $c(y,\phi) = 0$.

Exemplo 3.4 (Poisson)**.** Para $Y \sim \text{Poisson}(\mu)$, $f(y) = e^{-\mu}\mu^y/y!$ reescreve-se como

$$f(y) = \exp\{ y \log \mu - \mu - \log y! \}.$$

Logo $\theta = \log\mu$, $b(\theta) = e^\theta$, $a(\phi) = 1$, $c(y,\phi) = -\log y!$.

Exemplo 3.5 (Gama)**.** Para $Y \sim \text{Gama}(\alpha, \alpha/\mu)$ com média $\mu > 0$, forma $\alpha > 0$ e taxa α/μ, a densidade é

$$f(y) = \frac{(\alpha/\mu)^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\alpha y/\mu}, \qquad y > 0.$$

Defina $\theta = -1/\mu$, $\phi = 1/\alpha$, $a(\phi) = \phi$ e $b(\theta) = -\log(-\theta)$. Então

$$\frac{y\theta - b(\theta)}{a(\phi)} = -\frac{\alpha y}{\mu} - \alpha \log \mu,$$

e os termos restantes são reunidos em

$$c(y,\phi) = \frac{1}{\phi}\log\frac{1}{\phi} - \log\Gamma\left(\frac{1}{\phi}\right) + \left(\frac{1}{\phi} - 1\right)\log y.$$

Isso verifica a forma (3.1). Além disso, $b'(\theta) = -1/\theta = \mu$ e $a(\phi)b''(\theta) = \phi/\theta^2 = \mu^2/\alpha$, que são a média e a variância da distribuição Gama nessa parametrização.

3.2.2 Média e variância

Teorema 3.6 (Identidades de média e variância)**.** *Para Y com densidade* (3.1)*,*

$$\mathbb{E}[Y] = b'(\theta), \qquad \text{Var}(Y) = a(\phi)\, b''(\theta).$$

Demonstração. A identidade $\int f(y;\theta,\phi)\, dy = 1$ derivada em θ produz

$$\int \frac{\partial \log f}{\partial \theta} f \, dy = 0 \implies \mathbb{E}\left[\frac{Y - b'(\theta)}{a(\phi)} \right] = 0,$$

ou seja, $\mathbb{E}[Y] = b'(\theta)$. Derivando duas vezes em θ e usando $\mathbb{E}[(\partial \log f/\partial\theta)^2] = -\mathbb{E}[\partial^2 \log f/\partial\theta^2]$,

$$\frac{\text{Var}(Y)}{a(\phi)^2} = \frac{b''(\theta)}{a(\phi)} \implies \text{Var}(Y) = a(\phi)\, b''(\theta). \qquad \square$$

Observação (Função de variância). A relação $\mu = b'(\theta)$ define implicitamente θ como função de μ, e $V(\mu) := b''(\theta(\mu))$ é a *função de variância*: ela caracteriza, junto com $a(\phi)$, a distribuição na família. Assim, $\mathrm{Var}(Y) = a(\phi)\, V(\mu)$:

- Normal: $V(\mu) = 1$ (homoscedástica).
- Bernoulli: $V(\mu) = \mu(1-\mu)$.
- Poisson: $V(\mu) = \mu$.
- Gama: $V(\mu) = \mu^2$.

3.3 A estrutura do modelo linear generalizado

Definição 3.7 (Modelo linear generalizado)**.** Um modelo linear generalizado consiste em:

(i) **Componente aleatória**: $Y_1, \ldots, Y_n$ independentes, cada Y_i na família exponencial com parâmetros θ_i e ϕ (mesmo ϕ para todas as observações).

(ii) **Componente sistemática**: o preditor linear $\eta_i = x_i^\top \beta$ para $\beta \in \mathbb{R}^p$ e $x_i \in \mathbb{R}^p$.

(iii) **Função de ligação**: uma função monotônica e diferenciável g tal que

$$g(\mu_i) = \eta_i = x_i^\top \beta, \qquad \mu_i = \mathbb{E}[Y_i].$$

Definição 3.8 (Ligação canônica)**.** A ligação g é dita *canônica* se $\theta_i = \eta_i$ para todo i, equivalentemente $g = (b')^{-1}$.

Observação (Ligações canônicas dos casos clássicos). Da relação $\mu = b'(\theta)$ derivam-se diretamente:

- Normal: $g(\mu) = \mu$ (identidade).
- Bernoulli: $g(\mu) = \log(\mu/(1-\mu))$ (logito).
- Poisson: $g(\mu) = \log \mu$.
- Gama: $g(\mu) = -1/\mu$ (em geral usa-se também log ou inversa).

A ligação canônica simplifica a estrutura de inferência (a equação de escore tem forma especialmente simples), mas qualquer ligação suave é admissível.

3.4 Regressão logística

Especialização para $Y_i \mid x_i \sim \mathrm{Bernoulli}(p_i)$ com ligação canônica logito:

$$\log \frac{p_i}{1-p_i} = x_i^\top \beta, \quad \text{equivalentemente,} \quad p_i = \frac{e^{x_i^\top \beta}}{1 + e^{x_i^\top \beta}}. \tag{3.2}$$

3.4.1 Verossimilhança

A log-verossimilhança é

$$\ell(\beta) = \sum_{i=1}^{n} \left[y_i\, x_i^\top \beta - \log(1 + e^{x_i^\top \beta}) \right]. \tag{3.3}$$

Tomando o gradiente em β e usando $p_i = e^{x_i^\top \beta}/(1 + e^{x_i^\top \beta})$:

$$U(\beta) := \nabla \ell(\beta) = \sum_{i=1}^{n} (y_i - p_i)\, x_i = X^\top (y - p), \tag{3.4}$$

onde $p = (p_1, \ldots, p_n)^\top$. A Hessiana é

$$H(\beta) = \nabla^2 \ell(\beta) = -\sum_i p_i(1-p_i)\, x_i x_i^\top = -X^\top W X, \quad W = \mathrm{diag}(p_i(1-p_i)). \tag{3.5}$$

Como $0 < p_i < 1$, a matriz diagonal W é definida positiva. Se X tem posto de colunas completo, $X^\top W X$ também é definida positiva e a log-verossimilhança é estritamente côncava. Nesse caso, se o máximo finito existe, ele é único. A existência ainda pode falhar quando as classes são separáveis, como discutido na Seção 3.8.

3.4.2 Interpretação dos coeficientes

O coeficiente β_j na regressão logística mede o efeito do preditor j sobre o *logito* de p. Equivalentemente, e^{β_j} é a *razão de chances* (*odds ratio*) associada a um aumento unitário de x_j mantendo as demais covariáveis fixas:

$$\frac{p(x_j+1)/(1-p(x_j+1))}{p(x_j)/(1-p(x_j))} = e^{\beta_j}.$$

3.5 Regressão de Poisson

Para $Y_i \mid x_i \sim \text{Poisson}(\mu_i)$ com ligação canônica log:

$$\log \mu_i = x_i^\top \beta + \log t_i, \tag{3.6}$$

onde $t_i > 0$ é uma exposição conhecida, como tempo sob observação ou número de tentativas. O termo $\log t_i$ entra com coeficiente fixado em um e é chamado *deslocamento*. A log-verossimilhança é

$$\ell(\beta) = \sum_i [y_i(x_i^\top \beta + \log t_i) - t_i e^{x_i^\top \beta} - \log y_i!],$$

com escore $U(\beta) = X^\top(y-\mu)$ e Hessiana $-X^\top W X$, $W = \text{diag}(\mu_i)$.

Observação (Sobre-dispersão). O modelo de Poisson assume $\text{Var}(Y) = \mathbb{E}(Y)$. Quando a variância excede a média, há sobre-dispersão, que pode refletir heterogeneidade não modelada. Alternativas incluem o modelo binomial negativo, a quase-verossimilhança de Poisson e modelos hierárquicos.

3.6 Regressão binomial negativa

A Observação anterior identificou o ponto fraco do modelo Poisson: a rigidez $\text{Var}(Y) = \mathbb{E}[Y]$. Dados de contagem reais frequentemente apresentam variância maior do que a média. Quando essa sobre-dispersão é ignorada, os erros-padrão de $\hat\beta$ podem ficar subestimados, os valores-p podem ficar artificialmente pequenos e variáveis irrelevantes podem parecer significativas. O modelo binomial negativo é uma alternativa importante para representar essa heterogeneidade.

3.6.1 Como mistura Poisson–Gama

A construção a seguir postula uma heterogeneidade não observada por meio de uma mistura Poisson–Gama; ao integrar a taxa latente, deriva-se a distribuição binomial negativa marginal. Denote por

$$\Gamma(c) = \int_0^\infty u^{c-1}e^{-u}\,du, \qquad c>0,$$

a função Gama.

Proposição 3.9 (Mistura Poisson–Gama)**.** *Considere uma unidade de análise, isto é, uma entidade que gera uma contagem Y, como um município ou um segurado. Suponha que sua taxa não observada Λ seja aleatória e que*

$$Y \mid \Lambda \sim \text{Poisson}(\Lambda), \qquad \Lambda \sim \text{Gama}(\textit{forma } \theta,\ \textit{taxa } \theta/\mu),$$

de modo que $\mathbb{E}[\Lambda] = \mu$ e $\text{Var}(\Lambda) = \mu^2/\theta$. Então a distribuição marginal de Y é

$$\mathbb{P}(Y=y) = \frac{\Gamma(y+\theta)}{\Gamma(\theta)\,y!}\left(\frac{\theta}{\theta+\mu}\right)^{\theta}\left(\frac{\mu}{\theta+\mu}\right)^{y}, \qquad y\in\mathbb{N}_0, \tag{3.7}$$

denotada $\text{BinNeg}(\mu,\theta)$*, com*

$$\mathbb{E}[Y]=\mu, \qquad \text{Var}(Y) = \mu + \frac{\mu^2}{\theta}. \tag{3.8}$$

Demonstração. Integrando a mistura,

$$\mathbb{P}(Y=y)=\int_0^\infty \frac{e^{-\lambda}\lambda^y}{y!}\cdot\frac{(\theta/\mu)^\theta}{\Gamma(\theta)}\lambda^{\theta-1}e^{-\theta\lambda/\mu}\,d\lambda=\frac{(\theta/\mu)^\theta}{y!\,\Gamma(\theta)}\int_0^\infty \lambda^{y+\theta-1}e^{-\lambda(1+\theta/\mu)}\,d\lambda.$$

A integral é $\Gamma(y+\theta)\,(1+\theta/\mu)^{-(y+\theta)}$. Substituindo e reorganizando as potências de μ e $\mu+\theta$ obtém-se (3.7). Para os momentos, use a decomposição da variância:

$$\mathbb{E}[Y]=\mathbb{E}\big[\mathbb{E}[Y\mid\Lambda]\big]=\mathbb{E}[\Lambda]=\mu,$$

$$\operatorname{Var}(Y)=\mathbb{E}\big[\operatorname{Var}(Y\mid\Lambda)\big]+\operatorname{Var}\big(\mathbb{E}[Y\mid\Lambda]\big)=\mathbb{E}[\Lambda]+\operatorname{Var}(\Lambda)=\mu+\frac{\mu^2}{\theta}.$$ □

O parâmetro $\theta>0$ é chamado **parâmetro de dispersão** (ou de forma). A leitura de (3.8) é direta: a variância excede a média exatamente pelo termo μ^2/θ, que é a variância da heterogeneidade latente. Quando $\theta\to\infty$, a Gama degenera em um ponto, $\operatorname{Var}(\Lambda)\to 0$ e recupera-se a Poisson: **o modelo Poisson é o caso-limite da binomial negativa**, e não um modelo separado.

Observação (Interpretação substantiva)*.* A mistura não é um truque algébrico: ela afirma que unidades de análise com o *mesmo* vetor de covariáveis x_i ainda diferem em risco, por fatores não medidos. Em contagens de internações por município, Λ absorve diferenças de cobertura assistencial não registradas; em contagens de sinistros, diferenças de comportamento do segurado. A sobre-dispersão é, nessa leitura, o rastro estatístico de covariáveis omitidas.

3.6.2 O modelo de regressão

Fixado θ, a família (3.7) é uma família exponencial de um parâmetro em μ, com parâmetro canônico $\vartheta=\log(\mu/(\mu+\theta))$ e função de variância

$$V(\mu)=\mu+\frac{\mu^2}{\theta}.$$

Na prática, é mais comum não usar a ligação canônica nesse caso: adota-se a **ligação log**,

$$Y_i\mid x_i\sim\operatorname{BinNeg}(\mu_i,\theta),\qquad \log\mu_i=x_i^\top\beta+\log t_i,\tag{3.9}$$

exatamente como em (3.6). Com ligação logarítmica, e^{β_j} continua sendo a razão de taxas associada a um acréscimo unitário em x_j. A equação de escore perde a forma simples (3.10), mas o algoritmo de mínimos quadrados reponderados iterativamente continua válido com a função de variância modificada.

O parâmetro θ não pertence ao preditor linear. O procedimento implementado na função literal `MASS::glm.nb` alterna entre ajustar β por mínimos quadrados reponderados, com θ fixo, e maximizar a log-verossimilhança em θ, com β fixo.

Observação (Efeito sobre os erros-padrão)*.* Se a média condicional estiver corretamente especificada e valerem as condições usuais de estimação, o estimador de Poisson pode continuar consistente mesmo quando a variância não é Poisson. Seus erros padrão usuais, porém, estarão incorretos. O ajuste binomial negativo também muda os pesos das observações e, por isso, pode alterar as estimativas pontuais, sobretudo quando as médias ajustadas são muito diferentes. Não se deve pressupor que apenas a incerteza mudará: é preciso comparar os dois ajustes.

3.6.3 Testar sobre-dispersão

Como Poisson é o caso-limite $\theta\to\infty$, comparar os dois modelos é um teste de hipótese na *fronteira* do espaço paramétrico, e a teoria assintótica usual não se aplica diretamente.

Nota (A correção do valor-p). Reparametrizando por $\alpha = 1/\theta \geq 0$, o teste de $H_0 : \alpha = 0$ contra $H_1 : \alpha > 0$ tem H_0 no bordo. Sob condições de regularidade apropriadas, a estatística da razão de verossimilhanças $2(\ell_{\text{BinNeg}} - \ell_{\text{Poisson}})$ converge para a mistura $\frac{1}{2}\chi^2_0 + \frac{1}{2}\chi^2_1$, em que χ^2_0 é uma massa pontual em zero. Para uma estatística estritamente positiva, o valor-p é metade daquele calculado com χ^2_1; se a estatística for zero, o valor-p é um. A regra da metade não deve ser aplicada mecanicamente quando outras condições de fronteira ou identificabilidade falham.

Uma alternativa de estimação, e não de modelagem, é o modelo **quasi-Poisson**, que abandona a verossimilhança e postula apenas

$$\mathbb{E}[Y_i] = \mu_i, \qquad \operatorname{Var}(Y_i) = \phi\, \mu_i,$$

estimando ϕ pela estatística de Pearson, $\hat{\phi} = \frac{1}{n-p}\sum_i (y_i - \hat{\mu}_i)^2/\hat{\mu}_i$, e multiplicando todos os erros-padrão por $\sqrt{\hat{\phi}}$. O contraste entre as duas correções é instrutivo:

	Quasi-Poisson	**Binomial negativa**
Variância	$\phi\mu$ (linear em μ)	$\mu + \mu^2/\theta$ (quadrática)
Natureza	Quase-verossimilhança	Verossimilhança plena
Permite critérios de informação e teste da razão de verossimilhanças	Não	Sim
Peso relativo	Preserva os pesos do Poisson	Reduz o peso das contagens grandes
Quando preferir	Variância aproximadamente proporcional à média; inferência sobre a média	Variância com componente quadrática; necessidade de distribuição preditiva

Como a binomial negativa é um modelo probabilístico completo, ela admite os critérios de informação de Akaike e de Schwarz (Capítulo 10), predição de quantis e simulação, recursos que não decorrem apenas da especificação de quase-verossimilhança. A escolha entre as duas abordagens deve refletir o objetivo e a forma plausível da variância.

3.7 Inferência por máxima verossimilhança

3.7.1 Equação de escore e *Fisher scoring*

Para qualquer modelo linear generalizado com ligação canônica, a equação de escore tem a forma compacta

$$U(\beta) = X^\top (y - \mu(\beta)) = 0, \tag{3.10}$$

e a matriz de informação de Fisher é

$$I(\beta) = X^\top W(\beta) X, \qquad W(\beta) = \operatorname{diag}\!\left(\frac{1}{V(\mu_i)\, g'(\mu_i)^2}\right). \tag{3.11}$$

(Aqui tomamos $a(\phi) = 1$. Com dispersão geral e ligação canônica, tanto $U(\beta) = X^\top(y-\mu)/a(\phi)$ quanto $I(\beta) = X^\top W X/a(\phi)$ contêm o mesmo fator, que se cancela na atualização abaixo.) Sob ligação canônica, $g'(\mu) = 1/V(\mu)$ e $W = \operatorname{diag}(V(\mu_i))$. Para uma ligação não canônica, o escore geral é $U(\beta) = X^\top W \operatorname{diag}(g'(\mu_i))(y-\mu)/a(\phi)$; a expressão da informação permanece válida.

A iteração de *Fisher scoring* é

$$\beta^{(t+1)} = \beta^{(t)} + I(\beta^{(t)})^{-1}\, U(\beta^{(t)}). \tag{3.12}$$

3.7.2 Mínimos quadrados ponderados iterativos

A iteração (3.12) pode ser reescrita como uma sequência de regressões ponderadas. Definindo a *resposta de trabalho*

$$z_i^{(t)} = \eta_i^{(t)} + (y_i - \mu_i^{(t)})\, g'(\mu_i^{(t)}),$$

e os *pesos* $w_i^{(t)}$ como acima, mostra-se que

$$\beta^{(t+1)} = (X^\top W^{(t)} X)^{-1} X^\top W^{(t)} z^{(t)}.$$

Ou seja: cada passo é um problema de mínimos quadrados ponderados com resposta sintética $z^{(t)}$ e pesos $w_i^{(t)}$ atualizados a partir do ajuste corrente.

Essa expressão supõe $\eta = X\beta$. Se houver um vetor conhecido de *offsets* o, com $\eta = X\beta + o$, mantém-se a definição de z, mas a resposta da regressão ponderada passa a ser $z - o$: $\beta^{(t+1)} = (X^\top W^{(t)} X)^{-1} X^\top W^{(t)} (z^{(t)} - o)$.

O símbolo $\xrightarrow{d}$ usado a seguir denota convergência em distribuição: a distribuição da expressão à esquerda se aproxima da distribuição indicada à direita quando n cresce.

Teorema 3.10 (Distribuição assintótica do estimador de máxima verossimilhança)**.** *Sob condições padrão de regularidade,*

$$\sqrt{n}\,(\hat\beta_{\,max} - \beta) \;\xrightarrow{d}\; N_p\Big(0,\, \mathcal{I}(\beta)^{-1}\Big),$$

onde $\hat\beta_{\,max}$ *é o estimador de máxima verossimilhança e* $\mathcal{I}(\beta) = \lim_{n\to\infty} I(\beta)/n$ *é a informação de Fisher por observação. Em amostras finitas, costuma-se aproximar* $\operatorname{Var}(\hat\beta_{\,max}) \approx I(\hat\beta_{\,max})^{-1}$.

3.7.3 Deviância

Definição 3.11 (Deviância)**.** A deviância não escalada de um modelo linear generalizado é

$$D(y, \hat\mu) = 2a(\phi)\big[\ell(y, \phi; y) - \ell(\hat\mu, \phi; y)\big],$$

onde o primeiro termo é a log-verossimilhança no modelo *saturado* (uma média por observação) e o segundo corresponde ao modelo ajustado, mantendo-se a mesma dispersão fixa em ambos. Valores de fronteira são entendidos por limites. A quantidade $D/a(\phi)$ é a *deviância escalada*. Esta distinção coincide, nos casos clássicos abaixo, com a convenção da função literal `deviance` do `R`, que devolve a versão não escalada.

A deviância é análoga à soma de quadrados residual. Para dados agrupados com contagens grandes por célula e sob condições adequadas de aproximação, $D/a(\phi)$ tem distribuição aproximadamente χ^2_{n-p} sob o modelo correto. Isso não se transfere automaticamente a dados de Bernoulli individuais ou contagens pequenas. Para comparar modelos aninhados $M_0 \subset M_1$ com p_0 e p_1 parâmetros, sob M_0, dispersão conhecida e condições usuais de regularidade,

$$\frac{D(y, \hat\mu_0) - D(y, \hat\mu_1)}{a(\phi)} \;\xrightarrow{d}\; \chi^2_{p_1 - p_0},$$

fornecendo o *teste da razão de verossimilhanças*. Com parâmetros de dispersão desconhecidos, deve-se trabalhar com as verossimilhanças maximizadas também nesses parâmetros; uma diferença de deviâncias não escaladas não é, em geral, a estatística desse teste. Hipóteses na fronteira exigem tratamento próprio, como na comparação entre Poisson e binomial negativa.

Exemplo 3.12 (Deviâncias específicas)**.**

- Bernoulli: $D = -2\sum_i \{y_i \log \hat p_i + (1 - y_i)\log(1 - \hat p_i)\}$, pois a log-verossimilhança do modelo saturado é zero.
- Binomial agrupada: se y_i é o número de sucessos em m_i tentativas, então

$$D = 2\sum_i \left\{ y_i \log \frac{y_i}{m_i \hat p_i} + (m_i - y_i)\log \frac{m_i - y_i}{m_i(1 - \hat p_i)} \right\},$$

  com a convenção de que cada termo $0 \log 0$ vale zero.

- Poisson: $D = 2\sum_i [y_i \log(y_i/\hat{\mu}_i) - (y_i - \hat{\mu}_i)]$, com a convenção $0 \log 0 = 0$.
- Gaussiana: $D = \sum_i (y_i - \hat{\mu}_i)^2$; a versão escalada é D/σ^2. Na definição, não se maximiza a variância do modelo saturado: com resíduos nulos, deixar $\sigma^2 \to 0$ tornaria a verossimilhança ilimitada.

3.8 Ajuste e diagnóstico

Ajustar um modelo linear generalizado é rotina; verificar o ajuste exige ferramentas próprias porque a variância depende da média. Esta seção organiza o diagnóstico em quatro perguntas.

3.8.1 Resíduos

Definição 3.13 (Resíduos de Pearson e de deviância)**.** Para uma observação i com valor ajustado $\hat{\mu}_i$,

$$r_i^{\mathrm{P}} = \frac{y_i - \hat{\mu}_i}{\sqrt{V(\hat{\mu}_i)}}, \qquad r_i^{\mathrm{D}} = \mathrm{sinal}(y_i - \hat{\mu}_i)\,\sqrt{d_i},$$

onde $d_i \geq 0$ é a contribuição da observação i à deviância, $D(y, \hat{\mu}) = \sum_i d_i$.

Ambos levam em conta a escala local da resposta, mas ainda não incorporam a dispersão global. Somando quadrados, defina $Q_{\mathrm{P}} = \sum_i (r_i^{\mathrm{P}})^2$, a **estatística de Pearson generalizada**; analogamente, $\sum_i (r_i^{\mathrm{D}})^2 = D$. As versões *padronizadas* dividem por $\sqrt{a(\hat{\phi})(1 - h_{ii})}$, usando a dispersão conhecida quando for o caso, com h_{ii} definido a seguir. Para Poisson e Bernoulli, $a(\phi) = 1$. Resíduos de deviância podem ser menos assimétricos que os de Pearson, mas isso não garante normalidade.

Observação (A armadilha dos resíduos discretos)*.* Para respostas de Bernoulli ou contagens pequenas, a aproximação normal desses resíduos pode ser ruim mesmo quando o modelo está correto. O gráfico de r_i contra $\hat{\eta}_i$ exibe faixas curvas (uma por valor possível de y), e é comum interpretá-las erroneamente como falha de ajuste. Em regressão logística binária, duas curvas decorrem da própria definição dos resíduos; sua presença, isoladamente, não evidencia falha, embora a distribuição das observações sobre elas ainda possa ser informativa.

A saída elegante são os **resíduos quantílicos aleatorizados** de Dunn e Smyth 1996. Seja F_i a função de distribuição condicional de Y_i e seja Φ a função de distribuição da normal padrão. Usando a versão ajustada $\hat{F}_i$, define-se

$$r_i^{\mathrm{quant}} = \Phi^{-1}(u_i), \qquad u_i \sim \mathrm{Uniforme}\big(\hat{F}_i(y_i^-),\ \hat{F}_i(y_i)\big),$$

em que $\hat{F}_i(y_i^-)$ é o limite à esquerda da distribuição acumulada. Com os parâmetros verdadeiros, a transformação produz exatamente uma distribuição normal padrão. Quando $\hat{F}_i$ usa parâmetros estimados nos mesmos dados, a normalidade é aproximada e os resíduos são dependentes. Ainda assim, o gráfico é muito mais legível que o dos resíduos discretos. Convém gerar algumas realizações para verificar que a conclusão não depende do sorteio auxiliar.

3.8.2 Sobre-dispersão

Se $\mathrm{Var}(Y_i) = \phi V(\mu_i)$ e a média está corretamente especificada, a aproximação usual de Pearson fornece $\mathbb{E}[Q_{\mathrm{P}}] \approx \phi(n - p)$, sob condições regulares de ajuste. Isso motiva o estimador

$$\hat{\phi}_{\mathrm{P}} = \frac{Q_{\mathrm{P}}}{n - p}.$$

Para avaliar um modelo Poisson, cuja dispersão de referência é 1, valores de $\hat{\phi}_{\mathrm{P}}$ muito acima de 1 sugerem sobre-dispersão relativa ao ajuste; valores muito abaixo sugerem subdispersão. Essas

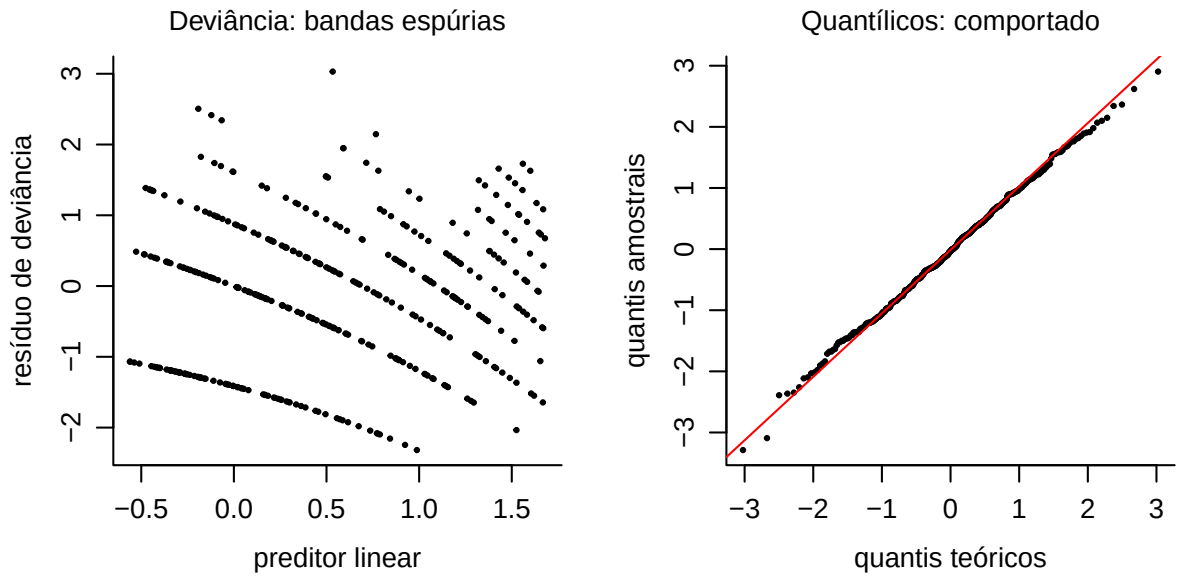


Figura 3.1: Diagnóstico de um modelo Poisson corretamente especificado, com $n = 400$ e $\log \mu_i = 0{,}5 + 1{,}2\, x_i$. À esquerda, as faixas dos resíduos de deviância decorrem da resposta discreta e não constituem, sozinhas, evidência de falha. À direita, os resíduos quantílicos aleatorizados ficam aproximadamente alinhados com os quantis normais. A exatidão normal vale quando se usa a distribuição condicional verdadeira; parâmetros estimados introduzem aproximação e dependência.

razões são diagnósticos, não testes com um limiar universal: é preciso considerar incerteza amostral, especificação da média e independência.

Não se pode substituir automaticamente Q_{P} por D: a aproximação $\mathbb{E}[D] \approx \phi(n-p)$ exige condições adicionais, que falham para contagens pequenas e Bernoulli individuais. Por exemplo, numa regressão de Bernoulli apenas com intercepto e probabilidade verdadeira 0,1, D/n converge para $-2[0{,}1\log(0{,}1) + 0{,}9\log(0{,}9)] \approx 0{,}650$, não para 1. Além disso, uma Bernoulli individual tem variância determinada pela média; não se identifica uma dispersão extra arbitrária mantendo essa distribuição.

Nota. Antes de atribuir a discrepância apenas à distribuição, verifique covariáveis omitidas, forma funcional errada, dependência e observações atípicas. Excesso de zeros relativamente à Poisson pode ser explicado pela binomial negativa: com $\mu = 2$ e $\theta = 1$, ela atribui probabilidade $1/3$ ao zero, contra $e^{-2} \approx 0{,}135$ na Poisson. Modelos inflacionados de zeros ou de barreira são candidatos quando houver justificativa para um mecanismo próprio de geração de zeros ou inadequação persistente da distribuição ajustada; muitos zeros, por si sós, não determinam a escolha.

3.8.3 Alavancagem e influência

O algoritmo de mínimos quadrados reponderados da Seção 3.7 produz localmente uma regressão ponderada, da qual se obtém a matriz chapéu

$$H = \hat{W}^{1/2} X (X^\top \hat{W} X)^{-1} X^\top \hat{W}^{1/2}, \qquad \hat{W} = \mathrm{diag}(\hat{w}_i),$$

avaliada em $\hat{\beta}$. Os elementos diagonais $h_{ii} \in [0,1]$ medem **alavancagem**, com $\sum_i h_{ii} = \mathrm{rank}(X)$, valor igual a p quando X tem posto de colunas completo; a regra de bolso usual sinaliza $h_{ii} > 2p/n$. A **distância de Cook** aproximada,

$$C_i = \frac{(r_i^{\mathrm{P}})^2\, h_{ii}}{p\, a(\hat{\phi})\, (1-h_{ii})^2},$$

combina resíduo e alavancagem e mede o quanto $\hat{\beta}$ se desloca ao remover a observação i. Note que alavancagem alta não é problema por si: o problema é a conjunção de alavancagem alta com resíduo grande.

3.8.4 Diagnósticos específicos da regressão logística

As três verificações seguintes são especialmente importantes na regressão logística. Calibração e problemas de existência das estimativas também têm análogos em outros modelos.

Separação. Se existe um hiperplano que separa perfeitamente $y = 0$ de $y = 1$, o supremo da verossimilhança é atingido apenas no limite: algumas componentes de β divergem, e o `R` pode devolver coeficientes muito grandes com erros padrão enormes. É um problema de existência da estimativa de máxima verossimilhança, não uma ausência de associação. Primeiro confira codificação, desenho e possíveis erros de dados. Quando a separação é genuína, use uma verossimilhança penalizada, como a correção de Firth implementada em `logistf`, ou uma distribuição a priori própria; remover uma covariável substantivamente necessária apenas para forçar convergência muda a pergunta científica.

Calibração. Pergunta: entre as observações com $\hat{p}_i \approx 0{,}3$, aproximadamente 30% de fato tiveram $y = 1$? O diagnóstico visual é o *gráfico de calibração*: agrupar as observações por decis de $\hat{p}$ e plotar a frequência observada contra a média predita, esperando a diagonal. O teste de Hosmer–Lemeshow formaliza o mesmo procedimento com uma estatística χ^2 sobre os grupos, mas depende do número arbitrário de grupos e tem baixo poder; use-o, se usar, como complemento do gráfico e nunca como único critério.

Discriminação. Pergunta distinta: o modelo ordena corretamente indivíduos de classes diferentes? A curva de sensibilidade contra taxa de falsos positivos e sua área são definidas na Seção 9.8. A área depende da ordenação, enquanto calibração depende dos valores das probabilidades; uma pode ser boa e a outra ruim. Ambas devem ser avaliadas fora dos dados de ajuste.

3.8.5 Um roteiro mínimo

1. $\hat{\phi}_{\mathrm{P}} = Q_{\mathrm{P}}/(n-p)$: está perto de 1?
2. Resíduos (quantílicos, se a resposta for discreta) contra $\hat{\eta}$: há curvatura? há heterocedasticidade residual?
3. Resíduos contra cada covariável contínua: falta um termo não linear?
4. h_{ii} e C_i: alguma observação domina o ajuste?
5. Se logística: os coeficientes são finitos? Há separação? Como está a calibração e a ordenação em validação?
6. Para modelos aninhados: teste da razão de verossimilhanças; para predição logarítmica: critério de Akaike.

3.9 Exemplos resolvidos

Exercício resolvido 3.1 : Bernoulli como família exponencial

Enunciado. Verifique que a Bernoulli pertence à família exponencial e identifique $\theta, b(\theta), a(\phi), c(y,\phi)$ e $V(\mu)$. Compute também a ligação canônica.
Solução. De $f(y) = p^y(1-p)^{1-y} = (1-p)(p/(1-p))^y$,

$$\log f(y) = y \log \tfrac{p}{1-p} + \log(1-p).$$

Comparando com (3.1): $\theta = \log(p/(1-p))$, donde $p = e^\theta/(1+e^\theta)$ e $1-p = 1/(1+e^\theta)$. Logo $\log(1-p) = -\log(1+e^\theta) = -b(\theta)$, ou seja, $b(\theta) = \log(1+e^\theta)$. Tem-se $a(\phi) = 1$ e $c \equiv 0$. Verificação dos momentos: $b'(\theta) = e^\theta/(1+e^\theta) = p = \mu$ e $b''(\theta) = e^\theta/(1+e^\theta)^2 = p(1-p) = V(\mu)$, confirmando o Teorema 3.6. A ligação canônica é $g = (b')^{-1}$, ou seja, $g(\mu) = \log(\mu/(1-\mu))$, o *logito*.

Exercício resolvido 3.2 : Logística numérica em pequena amostra

Enunciado. Considere $n = 6$ observações:

i	1	2	3	4	5	6
x_i	0	1	2	3	4	5
y_i	0	0	1	0	1	1

Modele $\mathbb{P}(Y_i = 1) = e^{\beta_0+\beta_1 x_i}/(1+e^{\beta_0+\beta_1 x_i})$. Inicialize $\beta^{(0)} = (0,0)$ e dê um passo de mínimos quadrados reponderados iterativamente.

Solução. Com $\beta^{(0)} = 0$, todos os $p_i^{(0)} = 0{,}5$ e $W^{(0)} = 0{,}25 \cdot I_6$. A matriz de design é $X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 & 4 & 5 \end{pmatrix}^\top$. Calculamos:

$$X^\top W X = 0{,}25 \begin{pmatrix} 6 & 15 \\ 15 & 55 \end{pmatrix}, \quad X^\top (y - p) = \begin{pmatrix} 0 \\ 3{,}5 \end{pmatrix},$$

pois $\sum (y_i - p_i) = 3 - 3 = 0$ e $\sum x_i (y_i - p_i) = 2 + 4 + 5 - 0{,}5(0+1+\cdots+5) = 11 - 7{,}5 = 3{,}5$. Logo

$$\beta^{(1)} = \beta^{(0)} + (X^\top W X)^{-1} X^\top (y - p) = 0{,}25^{-1} \begin{pmatrix} 6 & 15 \\ 15 & 55 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 3{,}5 \end{pmatrix}.$$

A inversa de $\begin{pmatrix} 6 & 15 \\ 15 & 55 \end{pmatrix}$ é $\frac{1}{105}\begin{pmatrix} 55 & -15 \\ -15 & 6 \end{pmatrix}$. Portanto

$$\beta^{(1)} = 4 \cdot \frac{1}{105} \begin{pmatrix} 55 & -15 \\ -15 & 6 \end{pmatrix} \begin{pmatrix} 0 \\ 3{,}5 \end{pmatrix} = \frac{4}{105} \begin{pmatrix} -52{,}5 \\ 21 \end{pmatrix} = \begin{pmatrix} -2 \\ 0{,}8 \end{pmatrix}.$$

A iteração já caminha na direção certa; continuando até a convergência (ou via `glm(y ~ x, family = binomial)`), obtém-se o estimador de máxima verossimilhança $\hat\beta \approx (-3{,}04,\ 1{,}21)$.

Exercício resolvido 3.3 : Equação de escore para Poisson

Enunciado. Mostre que, no modelo Poisson com ligação log, a equação de escore tem a forma $X^\top(y - \mu) = 0$.

Solução. A log-verossimilhança é $\ell(\beta) = \sum_i [y_i x_i^\top \beta - e^{x_i^\top \beta}]$ (descartando termos não dependentes de β). Diferenciando em β_j,

$$\frac{\partial \ell}{\partial \beta_j} = \sum_i (y_i - e^{x_i^\top \beta})\, x_{ij} = \sum_i (y_i - \mu_i)\, x_{ij},$$

ou seja, $U(\beta) = X^\top(y - \mu)$. Igualando a zero, recupera-se a forma canônica. Em particular, se X contém uma coluna constante, a equação implica $\sum_i y_i = \sum_i \hat\mu_i$: a soma observada das contagens iguala a soma ajustada.

3.10 Laboratório computacional em R

Laboratório em R : Regressão logística no conjunto `Default`

O conjunto simulado `Default` (`ISLR2`) contém $n = 10\,000$ observações com indicador de inadimplência (`default`), saldo devedor remanescente no cartão após o pagamento mensal (`balance`, em dólares), renda (`income`, em dólares) e indicador de estudante.

```
library(ISLR2)
ajuste <- glm(default ~ balance + income + student,
              data = Default, family = binomial)
summary(ajuste)

# Razoes de chances e intervalos de confianca de 95 por cento
exp(cbind(razao_de_chances = coef(ajuste), confint(ajuste)))

# Probabilidades preditas e classificacao com corte 0.5
prob   <- predict(ajuste, type = "response")
classe <- ifelse(prob > 0.5, "Yes", "No")
table(predito = classe, real = Default$default)
```

A inadimplência está fortemente associada ao saldo devedor: mantendo renda e condição de estudante fixas, cada mil dólares a mais *multiplica* as chances ajustadas por $e^{1000\,\hat{\beta}_{\text{balance}}} \approx 310$, usando a estimativa não arredondada ($\hat{\beta}_{\text{balance}} \approx 0{,}0057$). Isso não significa multiplicar a probabilidade por 310 nem demonstra efeito causal. Para a renda, um coeficiente pequeno por dólar não basta para concluir ausência de associação: examine $e^{10000\,\hat{\beta}_{\text{income}}}$ e seu intervalo para uma diferença de dez mil dólares. Neste ajuste, não há evidência estatística clara de associação adicional da renda; isso não prova efeito exatamente nulo.

Laboratório em R : Regressão de Poisson com *offset*

Modelos de contagem com tempo de exposição variável requerem o uso de *offset*.

```
# Exemplo simulado: numero de eventos por municipio (offset =
    populacao em milhoes)
set.seed(2026)
n         <- 100
populacao <- runif(n, 0.1, 5)
x         <- rnorm(n)
mu        <- populacao * exp(0.3 + 0.5 * x)
y         <- rpois(n, mu)

ajuste <- glm(y ~ x + offset(log(populacao)), family = poisson)
summary(ajuste)

# Diagnostico de dispersao relativo ao modelo Poisson
sum(residuals(ajuste, type = "pearson")^2) / df.residual(ajuste)
```

Na última linha, divide-se a estatística de Pearson pelos graus de liberdade residuais. Uma razão próxima de 1 é compatível com a dispersão Poisson, mas não comprova o ajuste. Valores muito acima de 1 motivam verificar a média, a independência e a distribuição; a binomial negativa é uma alternativa possível. Não usamos aqui a razão entre deviância e graus de liberdade: algumas médias simuladas são pequenas, regime em que essa razão não precisa estar próxima de 1 mesmo sob Poisson.

Laboratório em R : Mínimos quadrados reponderados implementados manualmente

O bloco a seguir reproduz o algoritmo usado para regressão logística pela função literal `glm`.

```
irls_logistico <- function(X, y, tol = 1e-8, maxit = 50) {
  beta <- rep(0, ncol(X))
  for (it in seq_len(maxit)) {
    eta  <- as.numeric(X %*% beta)
    p    <- 1 / (1 + exp(-eta))
    W    <- p * (1 - p)
    z    <- eta + (y - p) / W            # resposta de trabalho
    XtWX <- crossprod(X * sqrt(W))
    XtWz <- crossprod(X, W * z)
    beta_novo <- solve(XtWX, XtWz)
    if (max(abs(beta_novo - beta)) < tol) break
    beta <- beta_novo
  }
  list(beta = as.numeric(beta_novo), iter = it)
}

# Verificacao com Default
X <- model.matrix(default ~ balance + student, data = ISLR2::Default
   )
y <- as.numeric(ISLR2::Default$default == "Yes")
ajuste_manual <- irls_logistico(X, y)
ajuste_glm    <- glm(default ~ balance + student, data = ISLR2::
   Default,
                     family = binomial)
cbind(manual = ajuste_manual$beta, glm = coef(ajuste_glm))
```

A coincidência numérica dos coeficientes confirma, neste exemplo, a equivalência com a pontuação de Fisher: o ajuste é uma sequência de regressões ponderadas.

Laboratório em R : Poisson e binomial negativa em Bikeshare

Ajustamos o mesmo preditor linear sob as duas distribuições e comparamos o que muda. O conjunto `Bikeshare`, analisado com regressão de Poisson em G. James et al. 2021, §4.6, registra aluguéis por hora. A resposta `bikers` é o número de bicicletas alugadas; `mnth` identifica o mês; `hr`, a hora; `workingday`, se o dia é útil; `temp`, a temperatura normalizada; e `weathersit`, a condição meteorológica.

```
library(ISLR2); library(MASS)

ajuste_poisson <- glm(bikers ~ mnth + hr + workingday + temp +
   weathersit,
                      data = Bikeshare, family = poisson)

# 1) Ha sobre-dispersao?
residuos_pearson <- residuals(ajuste_poisson, type = "pearson")
estatistica_pearson <- sum(residuos_pearson^2)
graus_liberdade_residuais <- df.residual(ajuste_poisson)
dispersao_pearson <- estatistica_pearson / graus_liberdade_residuais
razao_deviancia <- deviance(ajuste_poisson) /
   graus_liberdade_residuais
c(dispersao_pearson = dispersao_pearson,
  razao_deviancia = razao_deviancia)
```

```
# 2) Ajuste binomial negativa (mesma ligacao log)
ajuste_binomial_negativo <- glm.nb(
  bikers ~ mnth + hr + workingday + temp + weathersit,
  data = Bikeshare)
ajuste_binomial_negativo$theta  # parametro de dispersao estimado
```

O valor de `dispersao_pearson` sai muito acima de 1, indicando forte discrepância em relação ao ajuste Poisson. Compare agora estimativas e incertezas:

```
comparacao <- cbind(
  coeficiente_poisson = coef(ajuste_poisson),
  erro_padrao_poisson = summary(ajuste_poisson)$coef[, 2],
  coeficiente_binomial_negativo = coef(ajuste_binomial_negativo),
  erro_padrao_binomial_negativo = summary(ajuste_binomial_negativo)
     $coef[, 2]
)
round(head(comparacao, 8), 4)
round(summary(ajuste_binomial_negativo)$coef[, 2] /
      summary(ajuste_poisson)$coef[, 2], 2)  # razao dos erros-
         padrao
```

Os erros-padrão do modelo binomial negativo são **várias vezes maiores**, mas as estimativas pontuais também mudam. Por exemplo, o coeficiente de `workingday` passa de aproximadamente 0,0147 para −0,1725; o de `temp`, de 0,7853 para 0,9501. Há até mudança de sinal no primeiro caso. Como discutido na Seção 3.6, a nova função de variância altera os pesos do ajuste: não se trata apenas de ampliar intervalos mantendo os coeficientes. A estatística de Pearson por grau de liberdade é cerca de 25,60 no ajuste Poisson; isso evidencia forte discrepância relativa a esse ajuste, sem identificar sozinho sua causa. Finalmente, o teste na fronteira, com a correção do valor-p:

```
estatistica_razao_verossimilhancas <- 2 * (
  logLik(ajuste_binomial_negativo) - logLik(ajuste_poisson))
valor_p_incorreto <- pchisq(
  as.numeric(estatistica_razao_verossimilhancas),
  df = 1, lower.tail = FALSE)
estatistica_numerica <- as.numeric(
   estatistica_razao_verossimilhancas)
c(razao_verossimilhancas = estatistica_numerica,
  valor_p_corrigido = if (estatistica_numerica <= 0) 1 else
                      valor_p_incorreto / 2) # mistura: zero e qui-
                         quadrado
```

Laboratório em R : Diagnóstico: resíduos quantílicos e influência

Primeiro, a armadilha dos resíduos discretos e sua correção.

```
set.seed(1)
# Modelo CORRETO, de proposito: os residuos deveriam parecer bem
    comportados
n  <- 400
x  <- runif(n, -1, 1)
y  <- rpois(n, lambda = exp(0.5 + 1.2 * x))
m  <- glm(y ~ x, family = poisson)
```

```
par(mfrow = c(1, 2))
plot(predict(m), residuals(m, type = "deviance"),
     xlab = "preditor linear", ylab = "residuo de deviancia",
     main = "Bandas espurias")             # faixas curvas: artefato
         da discretizacao

# Residuos quantilicos aleatorizados (Dunn & Smyth)
res_quant <- function(modelo, y) {
  mu <- fitted(modelo)
  a  <- ppois(y - 1, mu); b <- ppois(y, mu)
  qnorm(runif(length(y), a, b))
}
rq <- res_quant(m, y)
qqnorm(rq, main = "quantis normais contra residuos"); qqline(rq, col
    = "red")
```

O primeiro gráfico exibe faixas nítidas *apesar de o modelo estar correto*; o segundo cai sobre a reta, como deve. Repita o sorteio algumas vezes para confirmar que a leitura não depende dele.

Alavancagem, influência e, para a logística, calibração e discriminação:

```
m_log <- glm(default ~ balance + student + income,
             data = ISLR2::Default, family = binomial)

h <- hatvalues(m_log); p <- length(coef(m_log)); n <- nrow(ISLR2::
   Default)
which(h > 2 * p / n)                          # alavancagem alta
plot(cooks.distance(m_log), type = "h", ylab = "distancia de Cook")

# Calibracao em observacoes que nao participaram do ajuste
set.seed(2026)
dados <- ISLR2::Default
idx_treino <- sample(nrow(dados), floor(0.7 * nrow(dados)))
m_cal <- glm(default ~ balance + student + income,
             data = dados[idx_treino, ], family = binomial)
dados_teste <- dados[-idx_treino, ]
p_hat <- predict(m_cal, newdata = dados_teste, type = "response")
obs   <- as.numeric(dados_teste$default == "Yes")
grupo <- cut(p_hat, breaks = quantile(p_hat, 0:10/10), include.
   lowest = TRUE)
tab   <- aggregate(cbind(p_hat, obs) ~ grupo, FUN = mean)
plot(tab$p_hat, tab$obs, pch = 19, xlab = "media predita",
     ylab = "frequencia observada"); abline(0, 1, col = "red")
```

Pontos próximos da diagonal são compatíveis com boa calibração nos dados de teste, mas há incerteza amostral, sobretudo com poucos inadimplentes por grupo. O agrupamento em decis é apenas um resumo; pode ocultar desvios locais. Não use esse conjunto para escolher e avaliar repetidamente o modelo. A ordenação entre classes é tratada no Capítulo 9 e também deve ser avaliada fora dos dados de ajuste.

3.11 Exercícios propostos

Ex. 3.1. Mostre que a binomial $Y \sim \mathrm{Bin}(m, p)$ com m conhecido pertence à família exponencial. Identifique θ, $b(\theta)$, $a(\phi)$ e $V(\mu)$, e verifique a relação $\mathbb{E}[Y] = b'(\theta)$.

Ex. 3.2. Repita o exercício 3.1 para a Gama com média μ e parâmetro de forma α. Identifique a função de variância $V(\mu) = \mu^2$.

Ex. 3.3. Supondo que exista um estimador de máxima verossimilhança finito, mostre que, em um modelo linear generalizado de Poisson com intercepto e ligação log, $\sum_i y_i = \sum_i \hat{\mu}_i$. Compare com a propriedade da regressão linear gaussiana.

Ex. 3.4. Em um modelo logístico, suponha que $\hat{\beta}_j = 0{,}5$. Mantendo os demais preditores fixos, interprete o efeito do preditor j em termos de razão de chances. Se x_j aumenta em duas unidades, qual a razão de chances correspondente?

Ex. 3.5. Derive a expressão da deviância para a regressão logística:

$$D(y, \hat{p}) = -2 \sum_i \big[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \big],$$

ou seja, identifique como a deviância se relaciona à log-verossimilhança maximizada (atenção: o modelo saturado é $\hat{p}_i = y_i$, com $\ell(y; y) = 0$).

Ex. 3.6. Aplicação. Use o conjunto `Bikeshare` do pacote `ISLR2` para modelar o número de bicicletas alugadas por hora (`bikers`) como função da temperatura normalizada (`temp`), da hora do dia (`hr`) e do indicador de dia útil (`workingday`). Compare:

(a) Regressão linear gaussiana sobre $\log(\texttt{bikers} + 1)$.

(b) Regressão de Poisson com ligação log.

(c) Para o modelo Poisson, a dispersão de Pearson $Q_{\mathrm{P}}/(n-p)$ e a razão entre a deviância e os graus de liberdade residuais, $D/(n-p)$.

(d) Regressão binomial negativa com o mesmo preditor linear e ligação log.

Reporte os coeficientes, a variância residual do modelo gaussiano, os dois indicadores de dispersão dos modelos de contagem e o parâmetro de dispersão da binomial negativa. Não compare diretamente a variância residual gaussiana com as razões de dispersão: as respostas estão em escalas diferentes. Discuta qual modelo lhe parece mais adequado e quais limitações permanecem.

Ex. 3.7. Demonstre a Proposição 3.9 completando os passos indicados: (a) obtenha (3.7) resolvendo a integral da mistura; (b) verifique que (3.7) soma 1 sobre $y \in \mathbb{N}_0$ (*sugestão*: série binomial negativa); (c) obtenha $\mathbb{E}[Y]$ e $\mathrm{Var}(Y)$ pela decomposição da variância; (d) mostre que a distribuição binomial negativa de média μ e parâmetro de dispersão θ converge para a distribuição de Poisson de média μ quando $\theta \to \infty$, tomando o limite da função geradora de probabilidades ou da própria (3.7).

Ex. 3.8. Fixe θ e mostre que (3.7), vista como família em μ, é uma família exponencial de um parâmetro com parâmetro canônico $\vartheta = \log(\mu/(\mu+\theta))$. Identifique $b(\vartheta)$ e verifique que $b'(\vartheta) = \mu$ e $b''(\vartheta) = \mu + \mu^2/\theta = V(\mu)$. Em seguida, explique em duas ou três frases por que, apesar disso, a prática padrão usa a ligação log e não a canônica.

Ex. 3.9. Sob quasi-Poisson, $\mathrm{Var}(Y_i) = \phi\mu_i$; sob binomial negativa, $\mathrm{Var}(Y_i) = \mu_i + \mu_i^2/\theta$. (a) Mostre que os pesos de mínimos quadrados ponderados implícitos, $w_i \propto 1/V(\mu_i) \cdot (d\mu_i/d\eta_i)^2$, sob ligação log valem μ_i/ϕ no primeiro caso e $\mu_i\theta/(\theta+\mu_i)$ no segundo. (b) Conclua que a binomial negativa atribui peso *relativamente menor* às observações com μ_i grande, enquanto o quasi-Poisson preserva a hierarquia de pesos do modelo Poisson. (c) Descreva um cenário de dados em que essa diferença mudaria materialmente as conclusões.

Ex. 3.10. *Resíduos quantílicos.* Execute `set.seed(1)` e simule $n = 300$ observações de um modelo Poisson *correto* com $\log \mu_i = 0{,}5 + 1{,}2x_i$ e $x_i \sim \text{Unif}(-1, 1)$. (a) Faça o gráfico dos resíduos de deviância contra o preditor linear e descreva o padrão espúrio observado. (b) Execute `set.seed(2026)`, implemente os resíduos quantílicos aleatorizados e produza o gráfico quantil-quantil normal. (c) Repita a aleatorização 5 vezes e verifique se a conclusão global, e não a posição de cada ponto, é estável. (d) Execute novamente `set.seed(1)` e simule sob $\log \mu_i = 0{,}5 + 1{,}2x_i + 1{,}5x_i^2$, mas ajuste apenas o termo linear em x. Compare o gráfico quantil-quantil com os gráficos dos resíduos quantílicos e de deviância contra x, acrescentando uma curva suavizada. Explique por que o gráfico quantil-quantil, isoladamente, pode não revelar uma especificação errada da média condicional.

Ex. 3.11. *Separação em regressão logística.* Tome $x_i = -1 + 2(i-1)/39$, para $i = 1, \ldots, 40$, e $y_i = \mathbb{1}\{x_i > 0\}$, obtendo separação perfeita por construção. (a) Ajuste `glm(y ~ x, family = binomial)` e reporte intercepto e inclinação, seus erros-padrão, valores-p, avisos de convergência e deviância residual. (b) Explique por que o valor-p de Wald é grande apesar de a associação ser determinística, e por que interpretá-lo como "não significativo" seria um erro grave. (c) Mostre diretamente que a log-verossimilhança se aproxima de seu supremo ao longo de $(\beta_0, \beta_1) = (0, t)$, com $t \to \infty$, mas não o atinge em nenhum ponto finito. (d) Reajuste com a correção de Firth (`logistf::logistf` ou `brglm2`) e compare.

Ex. 3.12. *Calibração e discriminação.* Ajuste `default ~ balance + student + income` no conjunto `Default`, obtenha as probabilidades $\hat{p}_i$ e defina $\tilde{p}_i = \hat{p}_i/3$. (a) Mostre que a transformação preserva exatamente a área de ordenação. (b) Use a equação de escore do intercepto para mostrar que $\hat{p}$ tem calibração média na amostra de ajuste, enquanto $\tilde{p}$ não tem. (c) Sob a hipótese adicional de que $\hat{p}$ seja perfeitamente calibrada, obtenha $\mathbb{E}[Y \mid \tilde{p} = t]$. (d) Compare as duas versões em um gráfico de calibração por decis e explique por que ordenação e calibração devem ser avaliadas fora da amostra quando as probabilidades alimentam decisões.

Notas e leituras complementares

- Nelder e Wedderburn 1972: artigo seminal que unificou a teoria.
- McCullagh e Nelder 1989: tratamento clássico aprofundado.
- G. James et al. 2013, §4: exposição introdutória com aplicações em `R`; a regressão de Poisson e o exemplo `Bikeshare` aparecem apenas na 2ª edição, G. James et al. 2021, §4.6.
- Efron e Hastie 2016, §8: discussão histórica e conexão com regressão regularizada.

3.12 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Unidade de análise	*unit of analysis*	—
Modelo linear generalizado	*generalized linear model*	GLM
Família exponencial	*exponential family*	—
Parâmetro natural	*natural parameter*	—
Função cumulante	*cumulant function*	—
Função Gama	*gamma function*	—
Função de variância	*variance function*	—
Preditor linear	*linear predictor*	—
Função de ligação	*link function*	—
Ligação canônica	*canonical link*	—
Regressão logística	*logistic regression*	—
Logito	*logit*	—
Razão de chances	*odds ratio*	OR
Regressão de Poisson	*Poisson regression*	—
Termo de exposição	*offset*	—
Sobre-dispersão	*overdispersion*	—
Regressão binomial negativa	*negative binomial regression*	NB
Quase-Poisson	*quasi-Poisson*	—
Estimador de máxima verossimilhança	*maximum likelihood estimator*	MLE
Equação de escore	*score equation*	—
Informação de Fisher	*Fisher information*	—
Pontuação de Fisher	*Fisher scoring*	—
Mínimos quadrados reponderados iterativamente	*iteratively reweighted least squares*	IRLS
Deviância	*deviance*	—
Modelo saturado	*saturated model*	—
Teste da razão de verossimilhanças	*likelihood ratio test*	LRT
Resíduo de Pearson	*Pearson residual*	—
Resíduo de deviância	*deviance residual*	—
Resíduo quantílico aleatorizado	*randomized quantile residual*	RQR
Alavancagem	*leverage*	—
Distância de Cook	*Cook's distance*	—
Separação completa	*complete separation*	—
Calibração	*calibration*	—
Discriminação	*discrimination*	—

Capítulo 4

Árvores de Regressão

Objetivos da unidade

- Apresentar a ideia de *particionamento recursivo* do espaço de preditores como base dos modelos de árvore.
- Descrever o algoritmo de árvores de classificação e regressão para problemas de regressão.
- Discutir critérios de divisão (redução da soma de quadrados) e poda por complexidade-custo.
- Comparar árvores com modelos lineares clássicos em termos de viés, variância e interpretabilidade.

Leitura primária: Efron e Hastie 2016, capítulo 8 (parte 2).
Leitura complementar: Breiman et al. 1984; G. James et al. 2013, capítulo 8.

4.1 Motivação

Seja Y a variável resposta e seja $x = (x_1, \ldots, x_p)^\top \in \mathbb{R}^p$ o vetor de p preditores. Modelos lineares como o do Capítulo 2 supõem que $\mathbb{E}[Y \mid x] = x^\top \beta$ é *linear* nos preditores. Tal hipótese é restritiva quando:

- a relação entre Y e x apresenta **descontinuidades** ou **patamares** (por exemplo, efeito limiar de uma dose);
- há **interações de alta ordem** (por exemplo, o efeito da idade depende do sexo, e ambos dependem do nível socioeconômico);
- alguns preditores são **categóricos** com muitas classes, dificultando a parametrização linear.

As **árvores de regressão** contornam essas dificuldades modelando $\mathbb{E}[Y \mid x]$ como uma função *constante por partes*: o espaço dos preditores $\mathbb{R}^p$ é particionado em regiões disjuntas $R_1, \ldots, R_M$, e a predição é a média de y na região correspondente. Embora individualmente as árvores sejam estimadores instáveis e de viés relativamente alto, sua simplicidade conceitual e capacidade de capturar interações tornaram-nas o elemento básico de três métodos estudados adiante. A agregação por reamostragem calcula a média de árvores ajustadas a reamostras; a floresta aleatória acrescenta um sorteio de preditores em cada divisão; a combinação sequencial ajusta cada nova árvore ao erro deixado pelas anteriores.

Observação (Vantagens e limitações). **Vantagens.** Interpretação visual direta; admite preditores numéricos, ordinais e categóricos sem pré-processamento; não requer padronização de escala; pode tratar valores faltantes por divisões substitutas, nas quais outro preditor procura reproduzir a divisão principal quando seu valor está ausente; captura interações automaticamente.

Transformações estritamente monótonas preservam as partições candidatas das observações de treinamento e seus valores de impureza, salvo questões de desempate e precisão numérica. A

ressalva é a previsão de pontos novos: implementações que colocam o corte no ponto médio entre valores consecutivos podem mudar a fronteira sob transformação não linear. Por exemplo, entre 0 e 2 o ponto médio é 1; após a exponencial, o ponto médio corresponde, na escala original, a $\log[(1+e^2)/2] \approx 1{,}434$.

Limitações. Alta variância (pequenas perturbações nos dados levam a árvores muito diferentes); viés relativamente alto, particularmente quando a verdadeira superfície de regressão é suave; desempenho preditivo inferior aos modelos lineares quando o sinal é genuinamente linear.

4.2 Particionamento recursivo

Definição 4.1 (Árvore de regressão)**.** Uma árvore de regressão é uma partição de $\mathbb{R}^p$ em regiões (*folhas*) disjuntas $R_1, \ldots, R_M$ e a função estimadora associada

$$\hat{f}(x) = \sum_{m=1}^{M} \hat{c}_m \, \mathbb{1}\{x \in R_m\}, \qquad \hat{c}_m = \bar{y}_m = \frac{1}{n_m} \sum_{i : x_i \in R_m} y_i,$$

onde $n_m = \#\{i : x_i \in R_m\}$ é o número de observações na folha R_m. A função $\hat{f}$ é constante por partes, com no máximo M valores distintos.

A escolha de $\hat{c}_m = \bar{y}_m$ minimiza a soma de quadrados residual em cada região, $\sum_{i:x_i \in R_m} (y_i - c)^2$. O problema central é, portanto, escolher *como particionar* $\mathbb{R}^p$.

Nota (Restrição a partições retilíneas)*.* O algoritmo de árvores de classificação e regressão restringe-se a partições *retilíneas*: cada divisão é da forma $\{x_j \le s\}$ versus $\{x_j > s\}$ para algum preditor j e ponto de corte $s \in \mathbb{R}$. A partição final é uma combinação aninhada de tais divisões e tem a forma de uma *árvore binária*.

4.3 O algoritmo de árvores de classificação e regressão

4.3.1 Crescimento da árvore

A construção de uma árvore procede por *busca gulosa, recursiva e binária.* Partindo da raiz (que contém todas as observações), a cada nó:

(1) para cada par (j, s) candidato (preditor j, ponto de corte s), avalia-se o critério de divisão;

(2) escolhe-se o par (j^*, s^*) que minimiza o critério;

(3) dividem-se as observações em dois nós filhos conforme $\{x_j \le s\}$ ou $\{x_j > s\}$;

(4) repete-se nos nós filhos até que algum critério de parada seja satisfeito.

Definição 4.2 (Critério de divisão para regressão)**.** Para o nó atual R com observações $\{(x_i, y_i) : x_i \in R\}$, sejam

$$R_1(j, s) = R \cap \{x : x_j \le s\}, \qquad R_2(j, s) = R \cap \{x : x_j > s\}.$$

Um corte é *admissível* se houver pelo menos uma observação em cada região filha. Para cada corte admissível, defina $Q(j, s)$ como a *soma de quadrados após a divisão* produzida pelo preditor j e pelo ponto de corte s:

$$Q(j, s) = \sum_{i : x_i \in R_1} (y_i - \bar{y}_{R_1})^2 + \sum_{i : x_i \in R_2} (y_i - \bar{y}_{R_2})^2,$$

onde $n_{R_k} = \#\{i : x_i \in R_k\}$ e $\bar{y}_{R_k} = n_{R_k}^{-1} \sum_{i : x_i \in R_k} y_i$. A divisão ótima é

$$(j^*, s^*) = \operatorname*{arg\,min}_{(j,s) \text{ admissível}} Q(j, s).$$

Observação (Variáveis qualitativas). Para um preditor categórico com K níveis, há $2^{K-1}-1$ partições binárias possíveis. O algoritmo tipicamente reordena os níveis pela média de y em cada um e considera apenas as $K-1$ divisões correspondentes a essa ordenação, procedimento ótimo no caso gaussiano segundo Breiman et al. 1984.

4.3.2 Critérios de parada

Critérios usuais incluem tamanho mínimo do nó, por exemplo cinco observações, profundidade máxima da árvore ou redução mínima da soma de quadrados residual para autorizar a divisão. Uma estratégia comum é crescer uma árvore profunda e escolher sua poda com dados de validação, porque uma divisão inicialmente modesta pode permitir divisões úteis em níveis inferiores.

4.4 Poda por complexidade-custo

4.4.1 O critério C_α

Seja T_0 a árvore inicial, profundamente crescida, e $T \preceq T_0$ qualquer subárvore obtida colapsando subárvores internas em folhas (*pruning*).

Definição 4.3 (Funcional de complexidade-custo)**.** Seja $|T|$ o número de folhas de T. Para $\alpha \geq 0$,

$$C_\alpha(T) = \sum_{m=1}^{|T|} \sum_{i:x_i \in R_m} (y_i - \bar{y}_m)^2 + \alpha\,|T|.$$

O parâmetro α regula o *trade-off* entre ajuste e parcimônia: $\alpha = 0$ minimiza apenas o erro de treinamento (podendo haver empates com podas sem perda de ajuste); $\alpha \to \infty$ colapsa a árvore à raiz.

4.4.2 Sequência de árvores podadas

Teorema 4.4 (Sequência aninhada de árvores podadas, Breiman et al. 1984)**.** *Seja $T_{\max}$ a árvore inicial. Entre minimizadores do critério, escolha sempre a menor subárvore (por inclusão). Em $\alpha = 0$, isso remove ramos cuja poda não aumenta o erro; denote o resultado por T_0. Existe então uma sequência finita*

$$T_0 \supsetneq T_1 \supsetneq T_2 \supsetneq \cdots \supsetneq T_K = \{\textit{raiz}\}$$

e valores $0 = \alpha_0 < \alpha_1 < \alpha_2 < \cdots < \alpha_K$, com a convenção $\alpha_{K+1} = \infty$, tais que, para todo $\alpha \in [\alpha_k, \alpha_{k+1})$,

$$T_k \in \operatorname*{arg\,min}_{T \preceq T_{\max}} C_\alpha(T),$$

com T_k sendo o menor minimizador. Nos valores críticos, essa convenção escolhe a árvore já podada, justificando os intervalos fechados à esquerda.

Demonstração. Denote por $R(T)$ a soma de quadrados residual de uma árvore T. Para um nó interno t, seja T_t a subárvore que começa em t, seja $|T_t|$ seu número de folhas e seja $R(t)$ o erro obtido ao substituir toda T_t por uma única folha. Defina o aumento médio de erro por folha removida,

$$g(t) = \frac{R(t) - R(T_t)}{|T_t| - 1}.$$

Comparando manter T_t com colapsá-la em t, a diferença entre os critérios é

$$\{R(t) + \alpha\} - \{R(T_t) + \alpha|T_t|\} = (|T_t| - 1)\{g(t) - \alpha\}.$$

Assim, quando α alcança o menor valor de $g(t)$ entre os nós internos, colapsar os nós que atingem esse mínimo não aumenta o critério. Esse é o *elo mais fraco*. Repetindo a operação na árvore

resultante obtém-se uma sequência estritamente aninhada e valores críticos crescentes. Entre dois valores críticos, nenhuma comparação muda de sinal e a mesma subárvore minimiza C_α. Ramos empatados são colapsados conjuntamente (uma poda ancestral já inclui suas descendentes), e empates que persistam no mesmo valor de α são resolvidos antes de passar ao próximo valor crítico. A remoção inicial dos ramos de custo zero e a escolha do menor minimizador dão a convenção do enunciado. □

4.4.3 Escolha de α via validação cruzada

A sequência $\{T_k\}$ é finita e independe de α a posteriori. Para escolher uma árvore da sequência, particione os índices em V blocos disjuntos $B_1, \ldots, B_V$, com $2 \leq V \leq n$, e selecione $\hat{\alpha}$ pelo erro de validação cruzada:

$$\widehat{\mathrm{Val}}_V(\alpha) = \frac{1}{n} \sum_{j=1}^{V} \sum_{i \in B_j} \left(y_i - \hat{f}_\alpha^{(-B_j)}(x_i)\right)^2,$$

onde $\hat{f}_\alpha^{(-B_j)}$ é a árvore podada com complexidade α ajustada nos dados sem o bloco B_j. Veja Capítulo 9. A regra de um erro padrão também pode ser usada como heurística para produzir árvores mais parcimoniosas.

4.5 Árvores em comparação com regressão linear

A escolha entre árvores e regressão linear depende fortemente da natureza do problema:

- Se $\mathbb{E}[Y \mid x] = x^\top \beta$ é genuinamente linear, a regressão linear costuma ser mais eficiente: árvores aproximam $x^\top \beta$ por uma função em escada e podem introduzir erro de aproximação.

- Se $\mathbb{E}[Y \mid x]$ contém descontinuidades, interações ou patamares, árvores se ajustam naturalmente; regressão linear requer engenharia manual de variáveis (interações, *splines*, transformações).

Nota (Métodos baseados em árvores). A alta variância das árvores individuais pode ser reduzida por combinações de muitos ajustes:
- **Bagging**: agrega árvores ajustadas em *bootstrap samples*, reduzindo variância.
- **Random forests**: *bagging* com aleatorização adicional dos preditores em cada divisão.
- **Boosting**: ajusta árvores rasas sequencialmente aos resíduos.

Todos dependem inteiramente da definição de árvore individual aqui apresentada, e são desenvolvidos na Seção 4.6 a seguir.

4.6 Introdução aos métodos de ensemble

A Observação da Seção 4.1 identificou a fraqueza decisiva das árvores: *alta variância*. Uma perturbação pequena nos dados pode alterar a primeira divisão e reorganizar toda a árvore abaixo dela. A ideia dos *ensembles* é reduzir essa instabilidade pela agregação: erros parcialmente distintos podem se compensar. Para perda quadrática, o erro da média das predições não excede a média dos erros individuais, por convexidade; isso não garante superar a melhor árvore individual em cada amostra.

Há duas filosofias distintas, e confundi-las é a origem de boa parte dos enganos práticos. *Bagging* e *random forests* ajustam árvores **em paralelo** e agregam pela média, atacando a *variância*. *Boosting* ajusta árvores **em sequência**, cada uma corrigindo o que a anterior deixou passar, atacando o *viés*.

4.6.1 Bagging

Definição 4.5 (Bagging)**.** O *bagging* (*bootstrap aggregating*) de Breiman 1996 consiste em:

1. Para $b = 1, \dots, B$: sortear uma amostra *bootstrap* $\mathcal{D}^{*b}$ de tamanho n com reposição de $\mathcal{D}$, e ajustar nela uma árvore $\hat{f}^{*b}$ **profunda e sem poda**.
2. Agregar:

$$\hat{f}_{\text{bag}}(x) = \frac{1}{B} \sum_{b=1}^{B} \hat{f}^{*b}(x)$$

em regressão; por voto majoritário em classificação.

A ausência de poda merece ênfase: árvores profundas têm viés baixo e variância alta, e é exatamente essa variância que a agregação reduz. Podar antes de agregar introduziria viés para combater um problema que a média já atenua.

Quanto se ganha? A resposta é o resultado que organiza toda esta seção.

Proposição 4.6 (Variância de uma média correlacionada)**.** *Fixe um vetor de preditores x. Seja $T_b = T_b(x)$ a predição da árvore b nesse mesmo ponto, para $b = 1, \dots, B$. Suponha que essas predições sejam identicamente distribuídas, cada uma com variância σ^2, e tenham correlação par a par $\rho \geq 0$. Então*

$$\operatorname{Var}\left(\frac{1}{B} \sum_{b=1}^{B} T_b \right) = \rho\, \sigma^2 + \frac{1-\rho}{B}\, \sigma^2. \tag{4.1}$$

Demonstração.

$$\operatorname{Var}\left(\frac{1}{B} \sum_{b} T_b \right) = \frac{1}{B^2} \left[\sum_{b} \operatorname{Var}(T_b) + \sum_{b \neq b'} \operatorname{Cov}(T_b, T_{b'}) \right] = \frac{1}{B^2} \left[B\sigma^2 + B(B-1)\rho\sigma^2 \right],$$

que simplifica para $\sigma^2/B + (B-1)\rho\sigma^2/B = \rho\sigma^2 + (1-\rho)\sigma^2/B$. □

Observação (O piso da correlação)*.* Fazendo $B \to \infty$ em (4.1), a variância tende a $\rho\sigma^2$, positiva quando $\rho > 0$ e $\sigma^2 > 0$. O segundo termo, o único que B controla nessa expressão, desaparece. Esse é um limite de *variância da predição*, não do erro quadrático de previsão: este também inclui viés ao quadrado e variância do ruído.

Aqui a variância e a correlação consideram tanto a amostra de treinamento aleatória quanto a aleatorização das árvores. Condicionalmente a uma amostra fixa, reamostragens independentes geram árvores independentes; marginalmente, compartilhar a mesma amostra pode induzir forte correlação. Um preditor dominante tende a ser escolhido com frequência nas primeiras divisões. Reduzir essa dependência, preservando capacidade preditiva, motiva a floresta aleatória.

Uma consequência colateral do *bootstrap* é uma estimativa de erro obtida de graça.

Proposição 4.7 (Observações *out-of-bag*)**.** *A probabilidade de uma observação fixa não ser sorteada para uma dada amostra* bootstrap *de tamanho n é*

$$\left(1 - \frac{1}{n}\right)^n \longrightarrow e^{-1} \approx 0{,}368.$$

Logo cada árvore deixa de fora cerca de 36,8% das observações. Predizendo cada y_i apenas com as árvores que não usaram essa observação e agregando os erros, obtém-se uma estimativa interna do erro de predição. Ela compartilha a lógica de avaliação fora do ajuste, mas não equivale à validação que retira uma observação por vez: cada árvore foi treinada com cerca de 63,2% de observações distintas, enquanto a validação por retirada usa $n - 1$ observações. Além disso, qualquer escolha de hiperparâmetro feita com o mesmo erro precisa ser incluída na avaliação final.

4.6.2 Random forests

A leitura de (4.1) sugere de imediato o que fazer: se $\rho\sigma^2$ é o piso, ataque ρ.

Definição 4.8 (Random forest)**.** A *random forest* de Breiman 2001 é um *bagging* com uma modificação em cada divisão: antes de procurar a melhor divisão, sorteia-se um subconjunto de $m \leq p$ preditores, e a busca fica restrita a eles. O sorteio é refeito em *cada nó* de *cada* árvore.

Os valores convencionais são $m = \lfloor p/3 \rfloor$ em regressão e $m = \lfloor \sqrt{p} \rfloor$ em classificação; $m = p$ recupera a agregação sem sorteio de preditores. O valor de m costuma ser importante, mas tamanho mínimo das folhas, profundidade, fração amostrada e pesos de classe também podem merecer ajuste, conforme o problema.

Observação (Diversidade e qualidade das árvores)*.* Restringir os candidatos pode excluir o melhor preditor de um nó e reduzir a qualidade de uma árvore individual, mas também pode diminuir a dependência entre as árvores. Pior qualidade preditiva não significa necessariamente maior variância: o viés também pode mudar. Na expressão (4.1), uma redução de $\rho\sigma^2$ reduz a variância limite; para reduzir o erro de previsão, é preciso considerar também o viés. O número de candidatos por divisão controla esse compromisso e deve ser escolhido por validação ou erro fora da reamostra. Não há garantia de que restringir mais os candidatos sempre melhore o conjunto.

Importância de variáveis. Perdida a árvore única legível, resta medir a contribuição de cada preditor. Há duas medidas, e elas não são intercambiáveis:

- **Por impureza**: soma, sobre todos os nós de todas as árvores, da redução da soma de quadrados residual (ou do índice de Gini, em classificação) atribuída a divisões naquele preditor. É gratuita, mas *enviesada*: favorece preditores contínuos ou com muitas categorias, simplesmente porque oferecem mais pontos de corte candidatos.

- **Por permutação**: para cada preditor j, permute aleatoriamente seus valores nas observações que ficaram fora da reamostra e meça o aumento do erro interno. Mede o que se perde ao destruir a informação de x_j, é bem menos enviesada, e custa uma passada adicional. Sob preditores correlacionados, porém, tende a *diluir* a importância entre os membros do grupo: permutar um deles pouco muda, porque os outros carregam informação semelhante.

4.6.3 Boosting

O *boosting* inverte a lógica. Em vez de muitas árvores profundas independentes, usa muitas árvores *rasas*, ajustadas em sequência, cada uma ao que sobrou da anterior.

Definição 4.9 (Boosting de árvores para perda quadrática)**.** Defina $\bar{y} = n^{-1}\sum_{i=1}^{n} y_i$, inicialize $\hat{f}_0(x) = \bar{y}$ e tome $r_i = y_i - \bar{y}$ para todo i. Para $b = 1, \ldots, B$, repita:
1. Ajuste uma árvore $\hat{g}^b$ de profundidade máxima d aos *resíduos correntes* (x_i, r_i);
2. Atualize $\hat{f}_b(x) = \hat{f}_{b-1}(x) + \nu\,\hat{g}^b(x)$;
3. Atualize $r_i \leftarrow r_i - \nu\,\hat{g}^b(x_i)$.
A saída é $\hat{f}_B(x) = \bar{y} + \nu\sum_{b=1}^{B}\hat{g}^b(x)$. A constante inicial $\bar{y}$ é a que minimiza a soma de quadrados antes da inclusão de qualquer árvore.

São *três* os parâmetros de ajuste, e sua interação é o ponto sensível:

- B, o **número de árvores**. Em combinação sequencial, aumentar B aumenta a flexibilidade e pode produzir sobreajuste; por isso B deve ser escolhido por validação cruzada ou parada antecipada. Numa floresta com os demais parâmetros fixos, aumentar B apenas estabiliza a média em seu limite, embora esse limite ainda possa sobreajustar por outras escolhas de ajuste.

- ν, a **taxa de aprendizado** (ou encolhimento), tipicamente 0,01 a 0,1. Valores pequenos exigem B maior, ν e B trocam-se aproximadamente na razão inversa, mas costumam prever melhor.

- d, a **profundidade de interação**. Com $d = 1$ (*stumps*), o modelo resultante é aditivo, $\hat{f}(x) = \sum_j h_j(x_j)$, sem interações. Cada incremento unitário em d admite interações de mais uma ordem; valores de d entre 2 e 6 constituem uma faixa inicial comum, mas a escolha deve ser validada para o problema em estudo.

Nota (Gradient boosting). A Definição 4.9 é o caso de perda quadrática, em que o resíduo $y_i - \hat{f}_{b-1}(x_i)$ é exatamente o negativo do gradiente da perda em relação à predição. J. H. Friedman 2001 observou que essa coincidência é a chave da generalização: para uma perda diferenciável qualquer $L(y, f)$, basta ajustar a árvore ao *gradiente negativo*

$$r_i^{(b)} = - \left. \frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right|_{f=\hat{f}_{b-1}},$$

obtendo a combinação sequencial por gradiente, isto é, uma descida de gradiente no espaço de funções, com a árvore no papel de passo. É o que permite aplicar o procedimento a perdas logística, de Poisson, de Cox ou robustas, e é o motor de `gbm`, `xgboost` e `lightgbm`. Historicamente, o algoritmo veio antes da explicação: a combinação adaptativa de Freund e Schapire 1997 para classificação foi reinterpretada *a posteriori* como descida de gradiente com perda exponencial.

4.6.4 Comparação

	Árvore única	**Floresta aleatória**	**Combinação sequencial**
Ajuste	–	Paralelo	Sequencial
Árvores	Podada	Profundas	Rasas (d pequeno)
Ataca	–	Variância	Viés
Efeito de aumentar B	–	Estabiliza a média	Aumenta a flexibilidade e pode sobreajustar
Ajuste necessário	α (poda)	m (pouco sensível)	B, ν, d (sensível)
Erro sem validação externa	Não	Sim (fora da reamostra)	Não
Paralelizável	–	Trivialmente	Não (por construção)
Interpretável	**Sim**	Só importâncias	Só importâncias

Uma floresta aleatória costuma fornecer uma base competitiva com poucos parâmetros de ajuste e uma estimativa interna de erro. A combinação sequencial pode melhorar a predição em alguns problemas, mas não há dominância universal: profundidade, taxa de aprendizado, número de árvores, métrica e estrutura dos dados determinam o resultado. A comparação deve ser feita no mesmo esquema de validação.

Observação (O que se perde). Ambos abandonam a única vantagem que motivou as árvores: a leitura direta do modelo. Uma árvore podada com 8 folhas cabe em um slide e pode ser discutida com um clínico ou um gestor; uma floresta de 500 árvores, não. Recursos parciais existem (importância de variáveis, gráficos de dependência parcial, valores de Shapley) mas são *resumos* de um objeto que já não se pode inspecionar diretamente. Quando a finalidade da análise é explicar, e não apenas predizer, a árvore única pode continuar sendo a escolha correta, mesmo custando erro de predição.

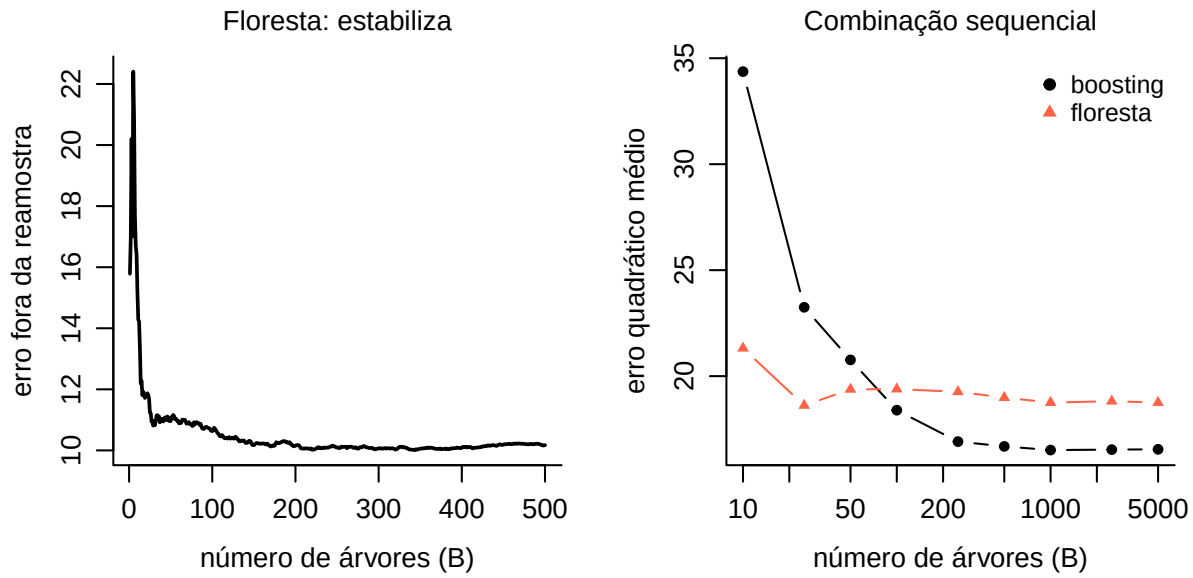


Figura 4.1: Erro em função do número de árvores no conjunto `Boston`. À esquerda, a estimativa interna da floresta cai e se estabiliza, como sugere o termo $(1-\rho)\sigma^2/B$ de (4.1). À direita, para esta divisão dos dados e estes parâmetros, o erro de teste da combinação sequencial tem mínimo interior, enquanto o da floresta se estabiliza. O gráfico ilustra uma possibilidade, não uma lei universal: outras amostras e ajustes podem produzir curvas diferentes.

4.7 Exemplos resolvidos

Exercício resolvido 4.1 : Divisão ótima em $\mathbb{R}^1$

Enunciado. Considere as 6 observações (x_i, y_i):

$$(1,2),\ (2,3),\ (3,5),\ (4,8),\ (5,9),\ (6,11).$$

Determine o ponto de corte s^* que minimiza a soma de quadrados residual após uma única divisão.

Solução. Para qualquer nó A, denote por $Q(A) = \sum_{i\in A}(y_i - \bar{y}_A)^2$ sua soma de quadrados residual. Como x tem 6 valores distintos, há 5 candidatos a corte (entre cada par de valores consecutivos): $s \in \{1{,}5,\ 2{,}5,\ 3{,}5,\ 4{,}5,\ 5{,}5\}$. Para cada s, o critério é $Q_s = Q(R_1(s)) + Q(R_2(s))$. Por exemplo, para $s = 3{,}5$:

- $R_1 = \{(1,2),(2,3),(3,5)\}$, $\bar{y}_{R_1} = 10/3 \approx 3{,}33$, $Q(R_1) = (2-3{,}33)^2 + (3-3{,}33)^2 + (5-3{,}33)^2 \approx 4{,}67$;
- $R_2 = \{(4,8),(5,9),(6,11)\}$, $\bar{y}_{R_2} = 28/3 \approx 9{,}33$, $Q(R_2) \approx 4{,}67$.

Total: $Q_{3{,}5} \approx 9{,}33$. Repetindo para todos os candidatos:

s	$\bar{y}_{R_1}$	$\bar{y}_{R_2}$	Q_s
1,5	2,00	7,20	40,80
2,5	2,50	8,25	19,25
3,5	3,33	9,33	9,33
4,5	4,50	10,00	23,00
5,5	5,40	11,00	37,20

O mínimo está em $s^* = 3{,}5$, com $Q_{3{,}5} \approx 9{,}33$. Compare com a soma de quadrados residual original (sem divisão), $\sum_i (y_i - 6{,}33)^2 \approx 63{,}33$: a divisão a reduz para cerca de 15% do valor inicial.

Exercício resolvido 4.2 : Árvore manual em $\mathbb{R}^2$

Enunciado. Considere 8 observações em $\mathbb{R}^2$:

$$(x_1, x_2, y) \in \{(1,1,5), (1,2,4), (2,1,6), (2,2,5), (3,3,12), (3,4,11), (4,3,13), (4,4,14)\}.$$

Construa, manualmente, uma árvore com até duas divisões e descreva a partição.
Solução. Divisão 1. Os cortes $x_1 \leq 2{,}5$ e $x_2 \leq 2{,}5$ empatam: ambos separam as quatro primeiras observações ($\bar{y} = 5$) das quatro últimas ($\bar{y} = 12{,}5$). Fixando a convenção de resolver o empate em favor de x_1, escolhemos $x_1 \leq 2{,}5$. A soma de quadrados cai de 119,5 para 7. A árvore com uma divisão produz duas folhas: $R_1 = \{x_1 \leq 2{,}5\}$, $\hat{c}_1 = 5$, com soma de quadrados 2; $R_2 = \{x_1 > 2{,}5\}$, $\hat{c}_2 = 12{,}5$, com soma de quadrados 5.
Divisão 2. As somas de quadrados residuais restantes parecem pequenas, mas convém avaliar os cortes antes de concluir. Em R_2, o corte $x_1 \leq 3{,}5$ separa $\{12, 11\}$ ($\bar{y} = 11{,}5$) de $\{13, 14\}$ ($\bar{y} = 13{,}5$) e reduz a soma de quadrados residual de 5 para 1: ganho de 4. Em R_1, o melhor corte a reduz de 2 para 1: ganho de 1. O algoritmo guloso divide, portanto, R_2 em $x_1 \leq 3{,}5$, e a árvore com 2 divisões tem folhas $R_1 = \{x_1 \leq 2{,}5\}$ ($\hat{c} = 5$), $R_{21} = \{2{,}5 < x_1 \leq 3{,}5\}$ ($\hat{c} = 11{,}5$) e $R_{22} = \{x_1 > 3{,}5\}$ ($\hat{c} = 13{,}5$), com soma de quadrados residual total $2 + 1 = 3$. A lição: um nó com erro aparentemente modesto ainda pode admitir divisão com ganho relevante; quem decide se ela deve ser mantida é a poda por complexidade-custo, não a inspeção visual das médias.

Exercício resolvido 4.3 : Sequência de podas em árvore de 3 folhas

Enunciado. Suponha uma árvore T_0 com 3 folhas e somas de quadrados residuais $\{4, 5, 3\}$ nas folhas. A árvore com 2 folhas (colapsando duas das três) tem soma de quadrados residual 20. A árvore raiz (1 folha) tem soma de quadrados residual 40. Determine α_1 e α_2 tais que T_2 = raiz seja ótima para $\alpha \geq \alpha_2$ e T_1 (2 folhas) seja ótima para $\alpha \in [\alpha_1, \alpha_2)$.
Solução. Escreva $Q(T)$ para a soma de quadrados residual da árvore T. Então $Q(T_0) = 12$, $|T_0| = 3$; $Q(T_1) = 20$, $|T_1| = 2$; e $Q(T_{\text{raiz}}) = 40$, $|T_{\text{raiz}}| = 1$.
T_1 supera T_0 quando $C_\alpha(T_1) < C_\alpha(T_0)$, isto é, $20 + 2\alpha < 12 + 3\alpha$, ou $\alpha > 8$. Logo $\alpha_1 = 8$.
A raiz supera T_1 quando $40 + \alpha < 20 + 2\alpha$, ou $\alpha > 20$. Logo $\alpha_2 = 20$.
Sequência: T_0 ótima para $\alpha \in [0, 8)$; T_1 para $\alpha \in [8, 20)$; raiz para $\alpha \geq 20$.

4.8 Laboratório computacional em R

Laboratório em R : rpart no conjunto Boston

O conjunto `Boston`, fornecido pelo pacote `ISLR2`, contém preços medianos de imóveis por bairro de Boston (`medv`) e 12 preditores. Ajustamos uma árvore profunda e a podamos por complexidade-custo mediante validação interna.

```
library(ISLR2)
Boston <- ISLR2::Boston # fixa a versao: 12 preditores, mesmo com
    MASS carregado
library(rpart)
library(rpart.plot)

set.seed(1)
arvore_grande <- rpart(medv ~ ., data = Boston,
```

```
                        control = rpart.control(cp = 0.001, minsplit
                            = 5))

# Tabela de complexidade
printcp(arvore_grande)
plotcp(arvore_grande)

# Escolha de cp pela regra de um erro-padrao
cp_idx_min  <- which.min(arvore_grande$cptable[, "xerror"])
xerr_min    <- arvore_grande$cptable[cp_idx_min, "xerror"]
xstd_min    <- arvore_grande$cptable[cp_idx_min, "xstd"]
cp_idx_1se  <- min(which(arvore_grande$cptable[, "xerror"] <=
    xerr_min + xstd_min))
cp_otimo    <- arvore_grande$cptable[cp_idx_1se, "CP"]

# Arvore podada
arvore_podada <- prune(arvore_grande, cp = cp_otimo)
rpart.plot(arvore_podada, type = 4, extra = 101, fallen.leaves =
    TRUE)
```

A árvore podada tem tipicamente 7 a 10 folhas e revela que os preditores mais importantes são `rm` (número médio de cômodos) e `lstat` (porcentagem de população de baixo nível socioeconômico).

Laboratório em R : Árvore em comparação com regressão linear: simulação

Para evidenciar quando árvores ganham ou perdem em relação à regressão linear:

```
set.seed(2026)
gerar <- function(n, cenario) {
  x1 <- runif(n)
  x2 <- runif(n)
  media <- if (cenario == "A") 2 + 3*x1 - 1.5*x2 else
                               ifelse(x1 + x2 > 1, 5, 1)
  data.frame(x1, x2, y = media + rnorm(n, sd = 0.5))
}

for (cenario in c("A", "B")) {
  treino <- gerar(500, cenario)
  teste  <- gerar(500, cenario)

  m_lm  <- lm(y ~ x1 + x2, data = treino)
  m_arv <- rpart(y ~ x1 + x2, data = treino,
                 control = rpart.control(cp = 0.001))

  cat("Cenario", cenario, ":\n",
      "  erro linear:", round(mean((teste$y - predict(m_lm, teste))
          ^2), 3), "\n",
      "  erro arvore:", round(mean((teste$y - predict(m_arv, teste))
          ^2), 3), "\n\n")
}
```

Com a semente acima, os erros de teste no cenário linear ficam próximos de 0,213 para a regressão e 0,264 para a árvore. No cenário descontínuo, ficam próximos de 1,620 e 0,987, respectivamente. A comparação usa dados novos; erros de treinamento seriam inadequados porque favorecem o método mais flexível.

Laboratório em R : Visualizando uma única divisão

Para entender concretamente o que o algoritmo faz, plote a partição induzida pela primeira divisão:

```
arvore_1 <- rpart(medv ~ rm + lstat, data = Boston,
                  control = rpart.control(maxdepth = 1))
arvore_1
# A primeira (e unica) divisao ocorre em rm; observe o threshold
    reportado.
```

A primeira divisão tipicamente ocorre em `rm` próximo de 6,9 cômodos; bairros com casas maiores formam uma folha de preço médio elevado, e os demais formam a outra folha.

Laboratório em R : Agregação e floresta aleatória com erro fora da reamostra

Partindo da árvore podada já ajustada, subimos a escada dos *ensembles*.

```
library(randomForest)
set.seed(1)

treino <- sample(nrow(Boston), nrow(Boston) / 2)
p      <- ncol(Boston) - 1

# Bagging = random forest com m = p
bag <- randomForest(medv ~ ., data = Boston, subset = treino,
                    mtry = p, ntree = 500, importance = TRUE)

# Random forest: m = p/3 (padrao em regressao)
rf  <- randomForest(medv ~ ., data = Boston, subset = treino,
                    mtry = floor(p / 3), ntree = 500, importance =
                       TRUE)

erro_teste <- function(m) mean((predict(m, Boston[-treino, ]) -
                                Boston$medv[-treino])^2)
c(bagging = erro_teste(bag), floresta = erro_teste(rf))
```

Compare os dois valores. Nesta divisão a floresta pode ou não superar a agregação sem sorteio de preditores; a Proposição 4.6 explica o compromisso entre variância individual e correlação, mas não garante a ordem em toda amostra. Examine também o retorno decrescente em B e a estimativa interna de erro:

```
plot(rf$mse, type = "l", xlab = "numero de arvores (B)",
     ylab = "erro fora da reamostra") # inclui vies, variancia e
        ruido

c(fora_reamostra = rf$mse[500], teste = erro_teste(rf))

# Fracao esperada de observacoes out-of-bag
n <- length(treino); c(limite = exp(-1), exato_n = (1 - 1/n)^n)
```

A curva de erro fora da reamostra tende a estabilizar conforme a média das árvores se torna menos sensível à aleatorização, embora a curva realizada possa oscilar. O termo $(1-\rho)\sigma^2/B$ descreve a parcela de variância que decresce com B; o patamar do erro não é simplesmente $\rho\sigma^2$, pois inclui também viés e ruído. Com os demais parâmetros fixos, aumentar B aproxima a mesma média limite, com retorno decrescente.

Finalmente, as duas medidas de importância, que *não* devem ser lidas como equivalentes:

```
importance(rf)       # coluna 1: permutacao (%IncMSE); coluna 2:
    impureza
varImpPlot(rf)
```

Compare as duas ordenações. A medida por impureza tende a inflar preditores contínuos ou de muitas categorias; a de permutação é mais fiel, mas dilui a importância entre preditores correlacionados (aqui, `rm` e `lstat`).

Laboratório em R : Boosting: os três parâmetros e o sobreajuste em B

```
library(gbm)
set.seed(1)

boost <- gbm(medv ~ ., data = Boston[treino, ], distribution = "
    gaussian",
             n.trees = 5000, interaction.depth = 4,
             shrinkage = 0.01, cv.folds = 5, n.cores = 1)

# B otimo por validacao cruzada -- B grande pode causar sobreajuste
B_otimo <- gbm.perf(boost, method = "cv")
B_otimo

pred <- predict(boost, Boston[-treino, ], n.trees = B_otimo)
mean((pred - Boston$medv[-treino])^2)
```

Contraste com o comportamento da floresta: lá o erro fora da reamostra decresce e estabiliza; para esta divisão dos dados e estes ajustes, a curva de erro de validação da combinação sequencial tem **mínimo interior** e volta a subir. Esse comportamento pode ocorrer porque B controla a flexibilidade do modelo sequencial; não é uma garantia de que toda curva realizada terá uma subida visível.
Verifique a troca entre ν e B, e o significado de d:

```
for (nu in c(0.001, 0.01, 0.1)) {
  m <- gbm(medv ~ ., data = Boston[treino, ], distribution = "
      gaussian",
           n.trees = 5000, interaction.depth = 4, shrinkage = nu,
           cv.folds = 5, n.cores = 1)
  cat("nu =", nu, " B_otimo =", gbm.perf(m, method = "cv", plot.it =
      FALSE),
      " erro quadratico medio =", mean((predict(m, Boston[-treino,
          ],
                                n.trees = gbm.perf(m, method = "cv",
                                                   plot.it = FALSE))
                     - Boston$medv[-treino])^2), "\n")
}

# d = 1 produz um modelo ADITIVO (sem interacoes)
aditivo <- gbm(medv ~ ., data = Boston[treino, ], distribution = "
    gaussian",
               n.trees = 5000, interaction.depth = 1, shrinkage =
                   0.01)
plot(aditivo, i = "lstat")      # dependencia parcial: uma curva h_j(
    x_j)
```

Em geral, menor ν desloca $B_{\text{ótimo}}$ para valores maiores, com relação aproximadamente inversa nas trajetórias comparáveis. Com $d = 1$, o gráfico de dependência parcial recupera

a forma de h_j exatamente, a menos de uma constante: se $\hat{f}(x) = \beta_0 + \sum_k h_k(x_k)$, a média empírica sobre os demais preditores é $h_j(x_j) + \beta_0 + \sum_{k \neq j} n^{-1} \sum_i h_k(x_{ik})$. Portanto, diferenças ao longo da curva coincidem com diferenças de h_j; a igualdade dos níveis depende da convenção de centralização. Isso torna os efeitos aditivos legíveis, sem lhes dar interpretação causal.

4.9 Exercícios propostos

Ex. 4.1. Para um nó A, defina $Q(A) = \sum_{i \in A} (y_i - \bar{y}_A)^2$. Mostre que, em uma divisão $R = R_1 \cup R_2$, a redução da soma de quadrados residual pode ser escrita como

$$Q(R) - Q(R_1) - Q(R_2) = \frac{|R_1|\,|R_2|}{|R|} \, (\bar{y}_{R_1} - \bar{y}_{R_2})^2.$$

Mostre ainda que, *mantida fixa* a diferença entre as médias, o fator $|R_1||R_2|/|R|$ é máximo quando os dois tamanhos são tão equilibrados quanto possível. Explique por que isso não permite concluir que a melhor divisão entre todas as candidatas será necessariamente equilibrada.

Ex. 4.2. Mostre, com um contraexemplo simples (digamos, $n = 4$ observações em $\mathbb{R}^2$), que o algoritmo guloso *não* produz necessariamente a árvore globalmente ótima de tamanho $|T| = 3$. Construa o caso e descreva a árvore ótima global.

Ex. 4.3. Considere um preditor categórico X com 3 níveis $\{A, B, C\}$ e respostas médias $\bar{y}_A = 1$, $\bar{y}_B = 5$, $\bar{y}_C = 3$ com tamanhos iguais. Liste todas as partições binárias possíveis e identifique a partição ótima sob o critério da soma de quadrados residual.

Ex. 4.4. Em uma árvore com somas de quadrados residuais $\{2, 3, 4, 5\}$ nas folhas ($|T_0| = 4$) e soma de quadrados residual 34 na raiz ($|T| = 1$), suponha que as podas intermediárias produzam T_1 com 3 folhas e soma 18, e T_2 com 2 folhas e soma 24. Determine os valores $\alpha_1 < \alpha_2 < \alpha_3$ que delimitam os intervalos onde cada subárvore é ótima e indique os empates nos pontos de transição.

Ex. 4.5. *Aplicação prática.* No conjunto `Hitters`, do pacote `ISLR2`, remova as observações com valores faltantes. Com `set.seed(1)`, sorteie 70% delas para treino e reserve as demais para teste. (a) No treino, modele `Salary`, em sua escala original, com `rpart`, usando `cp = 0.001`, `minsplit = 5` e validação cruzada com 10 blocos. (b) Escolha a poda tanto pelo menor erro de validação quanto pela regra de um erro-padrão. O `CP` informado por `rpart` é normalizado pela soma de quadrados residual da raiz; converta-o para o parâmetro do texto por $\alpha = \texttt{CP}\, Q(R)$. (c) Descreva em palavras a árvore escolhida pela regra de um erro-padrão. (d) Repita, na mesma amostra de treino, a regressão em crista do Capítulo 2 e compare os erros quadráticos médios de teste para as escolhas de mínimo e de um erro-padrão. Use `set.seed(2)` imediatamente antes de cada validação interna.

Ex. 4.6. *Limitação ao suave.* Use `set.seed(2026)` e, nessa ordem, gere uma amostra de treino com $n = 200$ e outra de teste com $n = 1\,000$, com x uniforme em $(0, 1)$ e $y = \sin(2\pi x) + \varepsilon$, em que ε tem distribuição normal de média zero e desvio-padrão 0,1. Ajuste (i) uma regressão polinomial de grau 5, usando `poly(..., raw = TRUE)`, e (ii) uma árvore suficientemente grande, podada depois para ter exatamente 10 folhas. Compare os erros quadráticos médios no teste e explique a diferença.

Ex. 4.7. Demonstre a Proposição 4.6. Em seguida: (a) calcule o limite de (4.1) quando $B \to \infty$ e interprete-o; (b) para $\sigma^2 = 1$, faça uma tabela do valor de (4.1) para $B \in \{10, 50, 100, 500, \infty\}$

e $\rho \in \{0;\ 0{,}2;\ 0{,}5;\ 0{,}8\}$; (c) use a tabela para argumentar quantitativamente por que passar de $B = 100$ para $B = 500$ árvores traz ganho desprezível, ao passo que reduzir ρ de 0,8 para 0,5 é substancial.

Ex. 4.8. (a) Demonstre a Proposição 4.7 e calcule $(1 - 1/n)^n$ para $n = 10, 50, 100, 1000$, comparando com e^{-1}. (b) Descreva com precisão o algoritmo do erro fora da reamostra: para cada i, quais árvores entram na predição e como os erros são agregados. (c) Compare-o com a validação que retira uma observação por vez: quantas observações distintas treinam cada árvore e quantas treinam cada ajuste de validação? Explique por que os procedimentos não são equivalentes, mesmo quando B é grande. (d) Explique como reutilizar esse erro para escolher hiperparâmetros pode tornar otimista uma avaliação final feita nos mesmos dados.

Ex. 4.9. *Sobreajuste em B.* No conjunto `Boston`, use `set.seed(1)` para sortear metade das observações para treino. Considere $B \in \{10, 25, 50, 100, 250, 500, 1000, 2500, 5000\}$. Ajuste (i) uma floresta aleatória com $m = \lfloor p/3 \rfloor$ e (ii) uma combinação sequencial com $\nu = 0{,}1$ e profundidade de interação $d = 4$. Para obter trajetórias comparáveis, reinicie a mesma semente antes de cada floresta e ajuste uma única combinação sequencial até $B = 5000$, extraindo suas predições nos valores intermediários. Trace os erros de teste contra B no mesmo gráfico. (a) Localize os mínimos empíricos e explique por que pequenas oscilações da curva da floresta não constituem sobreajuste sistemático em B. (b) Relacione essa diferença às naturezas paralela e sequencial dos algoritmos. (c) Repita a combinação sequencial com $\nu = 0{,}01$; use validação cruzada com 5 blocos para escolher B em cada taxa e verifique a relação aproximadamente inversa entre ν e $B_{\text{ótimo}}$.

Ex. 4.10. *As duas importâncias discordam.* Com $n = 500$ e `set.seed(1)`, gere x_1, x_3, ε independentes com distribuição normal padrão; x_2 uniforme em $\{-1, +1\}$; e x_4 uniforme em 20 níveis, como fator. Tome $y = x_1 + x_2 + \varepsilon$: os dois preditores relevantes têm o mesmo coeficiente e a mesma variância de sinal. Com `set.seed(3)`, ajuste uma floresta aleatória com 1 000 árvores, $m = 2$ e cálculo de importância. Compare a importância por permutação, sem padronização, com a importância por redução de impureza. (a) Qual delas atribui importância espúria a x_4, e por quê? (b) Com `set.seed(2)`, gere $x_5 = x_1 + \eta$, com η normal de desvio-padrão 0,1; reajuste a floresta com `set.seed(3)` e verifique a diluição da importância por permutação. (c) Que recomendação prática você daria a alguém que pretende usar importâncias de variáveis para *selecionar* preditores?

Ex. 4.11. *Boosting é descida de gradiente.* Para a perda quadrática $L(y, f) = \frac{1}{2}(y - f)^2$, verifique que $-\partial L/\partial f = y - f$, isto é, o resíduo corrente é exatamente o gradiente negativo, o que justifica o passo 1 da Definição 4.9. Em seguida, deduza o alvo de ajuste $r_i^{(b)}$ do *gradient boosting* para: (a) a perda absoluta $L(y, f) = |y - f|$; (b) a perda logística binária $L(y, f) = \log(1 + e^{-yf})$, com $y \in \{-1, +1\}$; (c) a log-verossimilhança negativa de Poisson com $f = \log \mu$. No caso não diferenciável da perda absoluta, use um subgradiente e adote o valor zero quando $y = f$. Comente por que o alvo do item (a) reduz a influência de valores atípicos na resposta e qual tipo de valor atípico essa conclusão não abrange.

Notas e leituras complementares

- Breiman et al. 1984: monografia clássica sobre árvores de classificação e regressão.
- Hastie, R. Tibshirani e J. Friedman 2009, §9: tratamento detalhado, incluindo classificação com mais de duas classes e regressão por funções de base adaptativas multivariadas.
- G. James et al. 2013, §8: introdução com `R` e conexão com *bagging* e *random forests*.

- Breiman 1996 e Breiman 2001: os dois artigos que criaram, respectivamente, o *bagging* e as *random forests*.
- J. H. Friedman 2001: formulação da combinação sequencial por gradiente como descida de gradiente em espaço de funções; Freund e Schapire 1997 para o algoritmo original de combinação adaptativa.
- Hastie, R. Tibshirani e J. Friedman 2009, §15–16: análise teórica de *random forests* e *boosting*, incluindo a decomposição $\rho\sigma^2 + (1-\rho)\sigma^2/B$ e o papel da profundidade de interação.

4.10 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Árvore de regressão	*regression tree*	—
Árvore de classificação	*classification tree*	—
Árvores de classificação e regressão	*classification and regression trees*	CART
Particionamento recursivo	*recursive partitioning*	—
Divisão binária recursiva	*recursive binary splitting*	—
Corte admissível	*admissible split*	—
Divisão substituta	*surrogate split*	—
Nó terminal	*terminal node*	—
Região terminal	*terminal region*	—
Crescimento guloso	*greedy growing*	—
Soma de quadrados residual	*residual sum of squares*	RSS
Poda por complexidade-custo	*cost-complexity pruning*	—
Validação cruzada	*cross-validation*	CV
Método de combinação	*ensemble method*	—
Agregação bootstrap	*bootstrap aggregating (bagging)*	—
Observação fora da reamostra	*out-of-bag observation*	OOB
Erro fora da reamostra	*out-of-bag error*	OOB error
Floresta aleatória	*random forest*	RF
Importância por impureza	*impurity-based importance*	—
Importância por permutação	*permutation importance*	—
Reforço sequencial	*boosting*	—
Combinação por gradiente	*gradient boosting*	—
Taxa de aprendizado	*learning rate*	—
Parada antecipada	*early stopping*	—
Gráfico de dependência parcial	*partial dependence plot*	PDP

Capítulo 5

Análise de Sobrevivência

Objetivos da unidade

- Introduzir as funções de sobrevivência $S(t)$, risco $h(t)$ e risco acumulado $H(t)$ e suas relações.
- Discutir o papel da censura à direita e do truncamento na construção da verossimilhança.
- Apresentar o estimador de Kaplan–Meier, sua variância (fórmula de Greenwood) e o teste *log-rank*.
- Apresentar o modelo de riscos proporcionais de Cox e a verossimilhança parcial.

Leitura primária: Efron e Hastie 2016, capítulo 9.
Leitura complementar: Kaplan e Meier 1958; Cox 1972.

5.1 Motivação

A **análise de sobrevivência** estuda o tempo até a ocorrência de um evento, morte de um paciente, falha de um equipamento, recidiva de uma doença, abandono de um cliente, formatura de um aluno. A peculiaridade desses dados é que, frequentemente, observamos apenas que o tempo até o evento *excede* certo valor: ou o estudo terminou antes do evento, ou o sujeito foi perdido para acompanhamento, ou ainda não morreu. Essa é a **censura à direita**, um mecanismo de observação parcial que invalida a aplicação direta de regressão linear ou de modelos lineares generalizados ao tempo T.

Os métodos da análise de sobrevivência foram desenvolvidos para lidar com essa especificidade. O estimador não paramétrico de Kaplan–Meier, o teste *log-rank* e o modelo semiparamétrico de Cox (introduzidos em três artigos seminais entre 1958 e 1972) constituem o tripé da disciplina e estão entre os métodos mais utilizados em medicina, engenharia de confiabilidade e demografia.

5.2 Funções fundamentais

Seja $T \geq 0$ o tempo até o evento, com distribuição absolutamente contínua e densidade f.

Definição 5.1 (Funções de sobrevivência, risco e risco acumulado)**.**

$$
\begin{aligned}
S(t) &= \mathbb{P}(T > t) = \int_t^\infty f(u)\,du, \\
h(t) &= \lim_{\Delta t \downarrow 0} \frac{\mathbb{P}(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} = \frac{f(t)}{S(t)}, \\
H(t) &= \int_0^t h(u)\,du.
\end{aligned}
$$

S é não crescente com $S(0) = 1$ e $\lim_{t\to\infty} S(t) = 0$; $h(t)$ é a taxa instantânea de risco; H é o risco acumulado.

Proposição 5.2 (Identidade fundamental)**.** *Sob T contínua, $S(t) = \exp(-H(t))$, equivalentemente $H(t) = -\log S(t)$.*

Demonstração. Como $h(t) = -\frac{d}{dt}\log S(t)$ (pois $h = f/S$ e $f = -S'$), integrando de 0 a t obtém-se $H(t) = -\log S(t) + \log S(0) = -\log S(t)$, donde $S(t) = e^{-H(t)}$. □

Exemplo 5.3 (Distribuição exponencial)**.** Se T tem distribuição exponencial com taxa λ, então $f(t) = \lambda e^{-\lambda t}$, $S(t) = e^{-\lambda t}$, $h(t) = \lambda$ (constante, ausência de memória) e $H(t) = \lambda t$.

Exemplo 5.4 (Distribuição Weibull)**.** Se $T \sim \text{Weibull}(\lambda, \kappa)$, $S(t) = \exp(-(\lambda t)^\kappa)$, $h(t) = \kappa\lambda^\kappa t^{\kappa-1}$. O parâmetro κ controla o comportamento do risco: $\kappa < 1$ é decrescente (risco de mortalidade infantil), $\kappa = 1$ exponencial, $\kappa > 1$ crescente (envelhecimento).

5.3 Censura à direita e verossimilhança

Considere n indivíduos com tempos verdadeiros $T_1, \dots, T_n$ independentes e de densidade f, e tempos de censura $C_1, \dots, C_n$. Quando há covariáveis x_i, supomos que T_i e C_i são independentes *condicionalmente* a x_i; independência marginal não basta. Observamos

$$\tilde{T}_i = \min(T_i, C_i), \qquad \delta_i = \mathbb{1}\{T_i \le C_i\}.$$

$\tilde{T}_i$ é o tempo observado e δ_i o indicador de evento (1 se observamos a falha, 0 se censurada).

Proposição 5.5 (Verossimilhança com censura à direita não informativa)**.** *Sob censura independente do tempo de evento e com a distribuição da censura sem parâmetros em comum com o modelo de interesse, denote por $L(\theta)$ a parte da verossimilhança que depende de θ. Ela é proporcional a*

$$L(\theta) \propto \prod_{i=1}^{n} f(\tilde{T}_i;\theta)^{\delta_i}\, S(\tilde{T}_i;\theta)^{1-\delta_i}.$$

Esboço. Para $\delta_i = 1$ (evento observado), a contribuição é $f(t_i)\,P(C_i > t_i)$; para $\delta_i = 0$ (censurado em c_i), é $S(c_i)\,g_C(c_i)$. Como os fatores da distribuição de C não dependem de θ, eles formam uma constante multiplicativa na verossimilhança de θ, restando o produto enunciado. □

Observação. A hipótese de *censura não informativa* é crucial: se a probabilidade de censura depende do tempo de evento (por exemplo, pacientes mais doentes abandonam o estudo mais cedo), a Proposição 5.5 falha e métodos especializados são necessários.

5.4 O estimador de Kaplan–Meier

5.4.1 Definição

Sejam $t_{(1)} < t_{(2)} < \cdots < t_{(K)}$ os tempos distintos em que ocorrem eventos. Para cada j, defina

- d_j: número de eventos em $t_{(j)}$;
- n_j: número de indivíduos *em risco* imediatamente antes de $t_{(j)}$ (isto é, ainda não morreram nem foram censurados antes de $t_{(j)}$).

Definição 5.6 (Estimador de Kaplan–Meier)**.**

$$\hat{S}(t) = \prod_{j:\, t_{(j)} \le t} \left(1 - \frac{d_j}{n_j}\right). \tag{5.1}$$

A motivação informal: a probabilidade de sobreviver até $t_{(j)}$ é a probabilidade de sobreviver até $t_{(j-1)}$ *vezes* a probabilidade condicional de sobreviver mais, dado que estava vivo. Esta última é estimada empiricamente por $1 - d_j/n_j$. O produto desses fatores condicionais é a **decomposição de produto-limite**.

Observação (Comportamento). $\hat{S}$ é uma função em escada não crescente, com saltos para baixo nos $t_{(j)}$. Censuras *não* produzem saltos: elas apenas reduzem n_j nos tempos seguintes. $\hat{S}(0) = 1$. Se a maior observação for censurada, $\hat{S}$ não atinge zero.

5.4.2 Variância: fórmula de Greenwood

Teorema 5.7 (Fórmula de Greenwood)**.** *Para um tempo t tal que $d_j < n_j$ em todos os tempos de evento $t_{(j)} \le t$,*

$$\widehat{\mathrm{Var}}(\hat{S}(t)) = \hat{S}(t)^2 \sum_{j:t_{(j)} \le t} \frac{d_j}{n_j(n_j - d_j)}.$$

Esboço. Aplique o método delta a $\log \hat{S}(t) = \sum_j \log(1 - d_j/n_j)$. Condicionalmente ao conjunto em risco, trate d_j como uma variável binomial com tamanho n_j e probabilidade de evento q_j. A variância aproximada de $\log(1 - d_j/n_j)$, depois de substituir q_j por d_j/n_j, é $d_j/\{n_j(n_j - d_j)\}$. Somar essas contribuições fornece a variância aproximada de $\log \hat{S}(t)$. Uma segunda aplicação do método delta à transformação exponencial multiplica essa soma por $\hat{S}(t)^2$. □

A fórmula de Greenwood permite construir intervalos de confiança pontuais para $S(t)$. É comum aplicar a transformação $\log(-\log)$ para obter intervalos que respeitam $S(t) \in [0, 1]$. Se ocorrer um salto terminal com $d_j = n_j$, a curva estimada chega a zero, o somando da fórmula fica indefinido e o intervalo transformado não pode ser usado nesse ponto nem depois dele; isso é uma limitação da aproximação na extremidade da curva, não uma falha numérica do programa.

5.5 Teste *log-rank*

Para comparar as curvas de sobrevivência de dois grupos (por exemplo, tratado e controle), o teste de postos logarítmicos, conhecido pelo nome original *log-rank*, é o procedimento padrão. Sejam d_{1j} e d_{2j} os números de eventos no tempo $t_{(j)}$ nos grupos 1 e 2, e n_{1j}, n_{2j} os números em risco; $d_j = d_{1j} + d_{2j}$ e $n_j = n_{1j} + n_{2j}$.

Definição 5.8 (Estatística *log-rank*)**.** Sob a hipótese $H_0 : S_1 = S_2$, em cada $t_{(j)}$ a distribuição condicional de d_{1j} é hipergeométrica com média e variância

$$e_{1j} = \frac{n_{1j}\, d_j}{n_j}, \qquad v_j = \frac{n_{1j}\, n_{2j}\, d_j\, (n_j - d_j)}{n_j^2 (n_j - 1)}.$$

A estatística *log-rank* é

$$Z = \frac{\sum_j (d_{1j} - e_{1j})}{\sqrt{\sum_j v_j}} \xrightarrow{d} N(0, 1) \text{ sob } H_0.$$

O símbolo $\xrightarrow{d}$ denota convergência em distribuição quando o tamanho da amostra cresce.

Equivalentemente, $Z^2 \sim \chi^2_1$ sob H_0. Generalizações multidimensionais comparam K grupos via χ^2_{K-1}.

5.6 O modelo de Cox

5.6.1 Modelo de riscos proporcionais

Definição 5.9 (Modelo de Cox)**.** Para covariáveis $x \in \mathbb{R}^p$, o modelo de riscos proporcionais é

$$h(t \mid x) = h_0(t)\, \exp(x^\top \beta),$$

onde h_0 é o *risco basal* (não especificado) e $\beta \in \mathbb{R}^p$.

O risco basal $h_0(t)$ é o risco do indivíduo de referência com $x = 0$. Se as covariáveis forem centradas, esse vetor representa um indivíduo com valores médios; sem centramento, sua interpretação depende da codificação escolhida.

A hipótese central é que o efeito de x é *multiplicativo* no risco e *constante no tempo*. Para dois indivíduos com covariáveis x_a e x_b,

$$\frac{h(t \mid x_a)}{h(t \mid x_b)} = \exp\big((x_a - x_b)^\top \beta\big) \quad \text{para todo } t.$$

5.6.2 Verossimilhança parcial

Teorema 5.10 (Verossimilhança parcial de Cox)**.** *Sob censura não informativa, independência condicional entre indivíduos e tempos de evento distintos, a verossimilhança parcial é*

$$L_{parcial}(\beta) = \prod_{i:\delta_i=1} \frac{\exp(x_i^\top \beta)}{\sum_{j \in \mathcal{R}(\tilde{T}_i)} \exp(x_j^\top \beta)},$$

onde $\mathcal{R}(\tilde{T}_i) = \{j : \tilde{T}_j \geq \tilde{T}_i\}$ *é o conjunto em risco no tempo observado do evento.*

Demonstração. Fixe um tempo de evento t e seu conjunto em risco $\mathcal{R}(t)$. Para um intervalo curto $[t, t + \Delta t)$, o modelo de risco implica

$$\mathbb{P}\{i \text{ falha no intervalo} \mid i \in \mathcal{R}(t)\} = h_0(t) e^{x_i^\top \beta} \Delta t + o(\Delta t),$$

onde $o(\Delta t)$ denota um resto que, dividido por Δt, tende a zero quando $\Delta t \downarrow 0$. Condicione agora ao evento de que exatamente um integrante de $\mathcal{R}(t)$ falha nesse intervalo. Pela independência condicional, a probabilidade de esse integrante ser i é, no limite,

$$\frac{h_0(t) e^{x_i^\top \beta}}{\sum_{j \in \mathcal{R}(t)} h_0(t) e^{x_j^\top \beta}} = \frac{e^{x_i^\top \beta}}{\sum_{j \in \mathcal{R}(t)} e^{x_j^\top \beta}}.$$

O comprimento Δt e o risco basal $h_0(t)$ se cancelam. Como os tempos de evento são distintos, há um fator desse tipo para cada falha observada. Multiplicá-los produz L_{parcial}. □

Observação (Por que "parcial"?)*.* L_{parcial} não usa os espaçamentos entre os tempos de evento para estimar β; retém a ordenação dos eventos e os conjuntos em risco formados ao longo do acompanhamento. Apesar disso, $\hat{\beta}_{\text{parcial}} = \arg\max_\beta L_{\text{parcial}}(\beta)$ é consistente e assintoticamente normal sob condições regulares. A informação observada é a negativa da matriz Hessiana de $\log L_{\text{parcial}}$, o que torna a inferência sobre β idêntica em forma à da máxima verossimilhança usual.

5.6.3 Interpretação dos coeficientes

$e^{\hat{\beta}_j}$ é a **razão de riscos** (*hazard ratio*) associada a um aumento unitário em x_j, controlando pelas demais covariáveis. Por exemplo, $\hat{\beta}_{\text{idade}} = 0{,}03$ implica $e^{0{,}03} \approx 1{,}03$: cada ano adicional de idade aumenta o risco instantâneo em 3%, supondo proporcionalidade.

5.6.4 Empates e verificação da proporcionalidade

A fórmula do Teorema 5.10 supõe tempos de evento distintos. Se D_ℓ é o conjunto dos d_ℓ indivíduos que falham no mesmo tempo t_ℓ e $\mathcal{R}(t_\ell)$ é o conjunto em risco, a aproximação de Breslow substitui o denominador correspondente por

$$\left\{ \sum_{j \in \mathcal{R}(t_\ell)} e^{x_j^\top \beta} \right\}^{d_\ell}.$$

A aproximação de Efron reconhece que parte do grupo empatado sai gradualmente do conjunto de risco e usa

$$\prod_{q=0}^{d_\ell - 1} \left\{ \sum_{j \in \mathcal{R}(t_\ell)} e^{x_j^\top \beta} - \frac{q}{d_\ell} \sum_{i \in D_\ell} e^{x_i^\top \beta} \right\}.$$

Ela costuma ser mais precisa quando há muitos empates; a opção exata condiciona ao conjunto de falhas e é mais custosa.

Para verificar a hipótese de efeito constante no tempo, defina a média ponderada das covariáveis no conjunto de risco,

$$\bar{x}(\beta, t) = \frac{\sum_{j \in \mathcal{R}(t)} x_j e^{x_j^\top \beta}}{\sum_{j \in \mathcal{R}(t)} e^{x_j^\top \beta}},$$

e, para quem falha em t_i, o **resíduo de Schoenfeld** $r_i = x_i - \bar{x}(\hat{\beta}, t_i)$. Sob riscos proporcionais, versões escaladas desses resíduos não devem exibir tendência sistemática com o tempo. Gráficos e testes de tendência são diagnósticos; um valor-p grande não demonstra que a proporcionalidade seja verdadeira.

5.7 Modelos paramétricos

Kaplan–Meier e Cox devem sua popularidade a uma virtude comum: nada supõem sobre a *forma* de S ou de h. Essa mesma virtude é uma limitação quando se quer mais do que comparar grupos.

- A estimativa de Kaplan–Meier permanece constante depois do último evento observado durante o seguimento, mas a cauda da distribuição além do período observado não é identificada pelos dados; qualquer extrapolação exige hipóteses adicionais.
- Quantis como a mediana de sobrevivência são estimados com precisão ruim, e às vezes nem são alcançados.
- Sob censura pesada, um modelo com dois parâmetros pode ser bem mais eficiente que um com n saltos livres.
- Censura intervalar e truncamento, Seção 5.8, acomodam-se com naturalidade em um modelo paramétrico, e com dificuldade fora dele.

O preço, evidentemente, é a má especificação: se a forma escolhida estiver errada, tudo o que dela se deduz está errado.

5.7.1 Famílias usuais

Na tabela, Φ denota a função de distribuição da normal padrão e todos os parâmetros de escala ou forma, λ, κ e σ, são positivos.

Família	$S(t)$	$h(t)$	Formato do risco
Exponencial	$e^{-\lambda t}$	λ	Constante
Weibull	$e^{-(\lambda t)^\kappa}$	$\kappa \lambda^\kappa t^{\kappa-1}$	Monótono ($\uparrow$ se $\kappa > 1$)
Log-normal	$1 - \Phi\big(\frac{\log t - \mu}{\sigma}\big)$	–	Unimodal (sobe, depois cai)
Log-logística	$\big[1 + (\lambda t)^\kappa\big]^{-1}$	$\frac{\kappa \lambda^\kappa t^{\kappa-1}}{1+(\lambda t)^\kappa}$	Unimodal se $\kappa > 1$
Gama generalizada	–	–	Engloba as três primeiras

A escolha não é estética: ela codifica uma hipótese substantiva sobre o mecanismo. Risco monótono crescente descreve desgaste ou envelhecimento; risco unimodal descreve mortalidade cirúrgica (alto nos primeiros dias, depois decrescente); risco constante descreve falha puramente acidental. A gama generalizada, por conter as demais como casos particulares, permite testá-las por razão de verossimilhanças.

5.7.2 Estimação por máxima verossimilhança

A verossimilhança é a da Proposição 5.5, agora com f e S paramétricas:

$$L(\theta) \propto \prod_{i=1}^{n} f(\tilde{T}_i;\theta)^{\delta_i}\, S(\tilde{T}_i;\theta)^{1-\delta_i}. \tag{5.2}$$

Proposição 5.11 (Estimador de máxima verossimilhança exponencial: eventos por tempo de exposição)**.** *Sob tempos T_i independentes, todos com distribuição exponencial de taxa λ, e censura à direita não informativa,*

$$\hat{\lambda} = \frac{d}{\sum_{i=1}^{n} \tilde{T}_i}, \qquad d = \sum_{i=1}^{n} \delta_i,$$

isto é, o número de eventos observados dividido pelo tempo total sob risco*.*

Demonstração. De (5.2) com $f(t) = \lambda e^{-\lambda t}$ e $S(t) = e^{-\lambda t}$,

$$\ell(\lambda) = \sum_i \big[\delta_i(\log\lambda - \lambda\tilde{T}_i) + (1-\delta_i)(-\lambda\tilde{T}_i)\big] = d\log\lambda - \lambda\sum_i \tilde{T}_i.$$

Se $d > 0$, derivar fornece $d/\lambda - \sum_i \tilde{T}_i = 0$ e a segunda derivada $-d/\lambda^2 < 0$ confirma o máximo. Se $d = 0$, a log-verossimilhança decresce em $\lambda > 0$: o supremo ocorre no limite $\lambda \downarrow 0$ e não há máximo positivo interior. □

Observação. A fórmula é exatamente a taxa de incidência da epidemiologia, casos por pessoa-ano, e mostra que uma observação censurada *contribui* para a estimativa: ela não fornece um evento, mas fornece tempo de exposição. Ignorar as censuras e usar $d/\sum_{i:\,\delta_i=1} t_i$ (dividindo apenas pelo tempo acumulado de quem teve o evento, e descartando o tempo de exposição dos censurados) superestima λ grosseiramente. Note também que a informação observada, a negativa da segunda derivada de $\ell(\lambda)$, é d/λ^2: quem determina a precisão é o número de **eventos**, não o número de indivíduos, princípio que vale em toda a análise de sobrevivência e que governa o cálculo de tamanho amostral nessa área.

5.7.3 Duas maneiras de acomodar covariáveis

Modelo paramétrico de riscos proporcionais. Mantém-se a estrutura do modelo de Cox, mas com h_0 especificada:

$$h(t \mid x) = h_0(t;\theta)\, e^{x^\top \beta},$$

e e^{β_j} continua sendo a razão de riscos. A diferença em relação a Cox é que agora h_0 é estimada conjuntamente, e não deixada livre.

Modelo de tempo de falha acelerado. A alternativa age sobre a *escala de tempo*:

$$\log T_i = x_i^\top \beta + \sigma W_i, \tag{5.3}$$

com W_i de distribuição fixa (valor extremo, normal ou logística, gerando respectivamente Weibull, log-normal e log-logística). Equivalentemente,

$$S(t \mid x) = S_0\Big(t\, e^{-x^\top \beta}\Big),$$

isto é, a covariável *comprime ou dilata* o relógio do indivíduo. Aqui e^{β_j} é uma **razão de tempos**: $e^{\beta_j} = 1{,}5$ significa que o indivíduo vive, em qualquer quantil, 50% mais tempo.

Observação (Não confunda as duas leituras). Razão de riscos e razão de tempos respondem a perguntas diferentes e apontam em sentidos opostos: um fator protetor tem razão de riscos < 1 e razão de tempos > 1. Relatar um coeficiente de `survreg` como se fosse uma razão de riscos é um erro comum e grave. Além disso, a interpretação em termos de tempo de falha acelerado é frequentemente mais direta para não estatísticos: "o tratamento prolonga a sobrevida em 50%" comunica melhor que "reduz o risco instantâneo em 30%".

Teorema 5.12 (Unicidade da família Weibull)**.** *Considere uma família de escala com sobrevivência basal contínua, não degenerada, e risco acumulado positivo para $t > 0$. Se a família admite, para uma faixa aberta de valores da covariável, representações de riscos proporcionais e de tempo de falha acelerado, então a sobrevivência basal é Weibull. Incluindo a exponencial como caso $\kappa = 1$, as parametrizações relacionam-se por*

$$\beta^{riscos} = -\kappa\, \beta^{tempo}.$$

Demonstração. Escreva $H_0(t) = -\log S_0(t)$. A representação por riscos proporcionais dá $S(t \mid x) = \exp\{-H_0(t) e^{x^\top \beta^{\text{riscos}}}\}$, enquanto a de tempo acelerado dá $S(t \mid x) = S_0(t e^{-x^\top \beta^{\text{tempo}}})$. Consequentemente, para fatores de escala a numa faixa aberta,

$$H_0(at) = c(a) H_0(t),$$

com $c(a) > 0$. Aplicar a igualdade sucessivamente com a e b mostra que $c(ab) = c(a)c(b)$. Continuidade implica $c(a) = a^\kappa$ para algum $\kappa > 0$. Tomando $t = 1$, segue que $H_0(t) = H_0(1) t^\kappa = (\lambda t)^\kappa$, com $\lambda = H_0(1)^{1/\kappa}$; portanto $S_0(t) = \exp\{-(\lambda t)^\kappa\}$, a sobrevivência Weibull. Finalmente,

$$S_0(t e^{-x^\top \beta^{\text{tempo}}}) = \exp\{-(\lambda t)^\kappa e^{-\kappa x^\top \beta^{\text{tempo}}}\},$$

que coincide com riscos proporcionais quando $\beta^{\text{riscos}} = -\kappa \beta^{\text{tempo}}$. □

Daí a posição especial da Weibull na prática: é o único modelo paramétrico cujos resultados podem ser confrontados diretamente com os de uma regressão de Cox.

5.7.4 Verificação gráfica da forma

Um diagnóstico simples decorre da Proposição 5.2. Sob Weibull, $S(t) = \exp(-(\lambda t)^\kappa)$, logo

$$\log(-\log S(t)) = \kappa \log t + \kappa \log \lambda.$$

Portanto, o gráfico de $\log(-\log \hat{S}(t))$ contra $\log t$, com $\hat{S}$ igual ao estimador de Kaplan–Meier, deve ser aproximadamente uma **reta**, com inclinação κ. Curvatura sistemática indica que a Weibull não serve. Se, além disso, o gráfico for feito separadamente por grupo, retas *paralelas* corroboram a hipótese de riscos proporcionais, o mesmo diagnóstico já usado para validar o modelo de Cox.

5.7.5 Paramétrico ou Cox?

	Cox	**Paramétrico**
Hipótese sobre h_0	Nenhuma	Forma fixada
Extrapolação	Requer hipótese adicional	Direta, mas dependente da família
Quantis e mediana	Ruins sob censura pesada	Suaves e estáveis
Eficiência se correto	Perde pouco	Máxima
Se mal especificado	Pode errar a forma do efeito	Pode enviesar curvas e efeitos
Censura intervalar	Difícil	Natural
Interpretação	Razão de riscos	Razão de riscos ou de tempos

Uma prática comum em medicina é usar Cox quando a inferência sobre efeitos relativos é central e a hipótese de proporcionalidade é defensável. Isso evita especificar a forma basal, mas não elimina riscos de má especificação. Modelos paramétricos são especialmente úteis quando o objetivo exige a curva completa, como projeções de custo, extrapolação além do seguimento ou simulação; nesses casos, análise de sensibilidade a famílias diferentes é indispensável.

5.8 Censura à esquerda, intervalar e truncamento

A Seção 5.3 tratou do esquema mais comum, mas não do único. Convém, antes de tudo, fixar uma distinção que é fonte permanente de confusão.

Definição 5.13 (Censura e truncamento)**.** Sob **censura**, o indivíduo *está* na amostra e sabemos algo sobre seu tempo, apenas não o valor exato. Sob **truncamento**, o indivíduo *sequer entra* na amostra quando seu tempo cai fora de uma janela: é um efeito de *seleção*, não de observação incompleta.

Censura é informação parcial; truncamento é ausência total. A consequência prática é que a censura corrige-se pela verossimilhança, e o truncamento, por *condicionamento*.

5.8.1 Quatro esquemas de observação

- **À direita**: sabe-se $T > c$. Contribuição $S(c)$. (Já tratada.)
- **À esquerda**: sabe-se $T \leq c$; o evento já havia ocorrido na primeira observação. Contribuição $F(c) = 1 - S(c)$. Exemplo: idade da primeira infecção, em uma criança que já chega soropositiva ao estudo.
- **Intervalar**: sabe-se $T \in (l, r]$, tipicamente porque o desfecho só é verificado em consultas periódicas. Contribuição $S(l) - S(r)$. Exemplo: data de recidiva detectável apenas por exame semestral.
- **Exata**: contribuição $f(t)$.

Note que os três primeiros são casos particulares do intervalar: à direita é (c, ∞), à esquerda é $(0, c]$. A verossimilhança geral é, portanto,

$$L(\theta) = \prod_{i \in \mathcal{E}} f(t_i; \theta) \prod_{i \in \mathcal{I}} [S(l_i; \theta) - S(r_i; \theta)], \tag{5.4}$$

com $\mathcal{E}$ os tempos exatos e $\mathcal{I}$ os intervalares, com a convenção $S(\infty) = 0$.

Nota (O análogo não paramétrico). Sob censura intervalar não existe forma fechada como a de Kaplan–Meier: os intervalos podem sobrepor-se de maneira arbitrária e a maximização não paramétrica precisa ser feita numericamente. A solução é o **estimador de Turnbull**, obtido pelo algoritmo de esperança e maximização do Capítulo 6 sobre os chamados *intervalos de Turnbull*; ele reduz-se exatamente a Kaplan–Meier quando toda a censura é à direita. Em `R`, pode-se usar `icenReg` ou `interval`.

5.8.2 Truncamento à esquerda e entrada tardia

O caso de longe mais frequente, e o mais ignorado, é o truncamento à esquerda.

Definição 5.14 (Truncamento à esquerda)**.** O indivíduo i só é observável se $T_i > u_i$, onde u_i é seu tempo de *entrada* no estudo. Toda a informação a seu respeito é condicional a esse evento.

Proposição 5.15 (Verossimilhança sob truncamento à esquerda)**.** *Com truncamento à esquerda em u_i e censura à direita,*

$$L(\theta) = \prod_{i=1}^{n} \left[\frac{f(t_i;\theta)}{S(u_i;\theta)}\right]^{\delta_i} \left[\frac{S(t_i;\theta)}{S(u_i;\theta)}\right]^{1-\delta_i}. \tag{5.5}$$

Demonstração. A densidade condicional de T dado $T > u$ é $f(t)/S(u)$ para $t > u$, e a sobrevivência condicional é $\mathbb{P}(T > t \mid T > u) = S(t)/S(u)$. Substituindo cada fator de (5.2) por sua versão condicional obtém-se (5.5). □

Observação (A tradução operacional: o conjunto de risco)*.* Há uma leitura muito mais útil de (5.5) do que a fórmula. Em Kaplan–Meier e em Cox, o único lugar em que os indivíduos aparecem é o **conjunto de risco** $R(t) = \{i : \text{sob observação e sem evento em } t^-\}$. Corrigir o truncamento à esquerda significa apenas:

$$i \in R(t) \iff u_i < t \leq t_i,$$

isto é, o indivíduo *entra* no conjunto de risco em u_i, e não em zero. Feita essa troca, todas as fórmulas dos estimadores permanecem literalmente idênticas. Em `R`, basta escrever `Surv(entrada, saida, evento)` em vez de `Surv(tempo, evento)`.

Exemplo 5.16 (Idade como escala de tempo)**.** Um estudo de coorte recruta em 2020 pessoas com idades entre 50 e 70 anos e as acompanha até 2030, com a *idade* como escala de tempo. Uma pessoa recrutada aos 63 anos contribui com informação apenas a partir dos 63: ela precisou sobreviver até essa idade para ser recrutada, e nada nos diz sobre a mortalidade entre 0 e 63.

Tratar essa pessoa como se estivesse sob observação desde a idade 0 implica atribuir-lhe 63 anos de sobrevivência que jamais foram observados. Neste exemplo simples, isso superestima a sobrevivência nas idades iniciais. A direção e a magnitude do viés em modelos mais complexos dependem da relação entre entrada, covariáveis e evento; não há uma regra universal sem essas hipóteses.

5.8.3 Truncamento à direita e viés de comprimento

Truncamento à direita. O indivíduo só é observado se $T_i \leq v_i$. O caso clássico é o estudo do período de incubação da síndrome da imunodeficiência adquirida: só entram na amostra os indivíduos cuja doença já se manifestou até a data de fechamento do registro, de modo que incubações longas estão sistematicamente ausentes. A verossimilhança condiciona-se por $F(v_i)$ no lugar de $S(u_i)$, e o análogo não paramétrico de Kaplan–Meier é o estimador de Lynden-Bell 1971, originalmente concebido para corrigir seleção observacional em amostras de quasares: um dos empréstimos mais improváveis entre a astronomia e a bioestatística.

Viés de comprimento. Um caso particular importante de truncamento à esquerda ocorre ao amostrar *casos prevalentes* em vez de *incidentes*: entrevistar pacientes que estão internados hoje, em vez de acompanhar todos os que internam. Sob incidência estacionária, a probabilidade de um episódio ser captado é proporcional à sua duração, e a densidade observada é

$$f^{\text{obs}}(t) = \frac{t\, f(t)}{\mathbb{E}[T]},$$

enviesada para durações longas. Para quantificar a distorção, defina o coeficiente de variação da duração por

$$c_T = \frac{\sqrt{\operatorname{Var}(T)}}{\mathbb{E}[T]}.$$

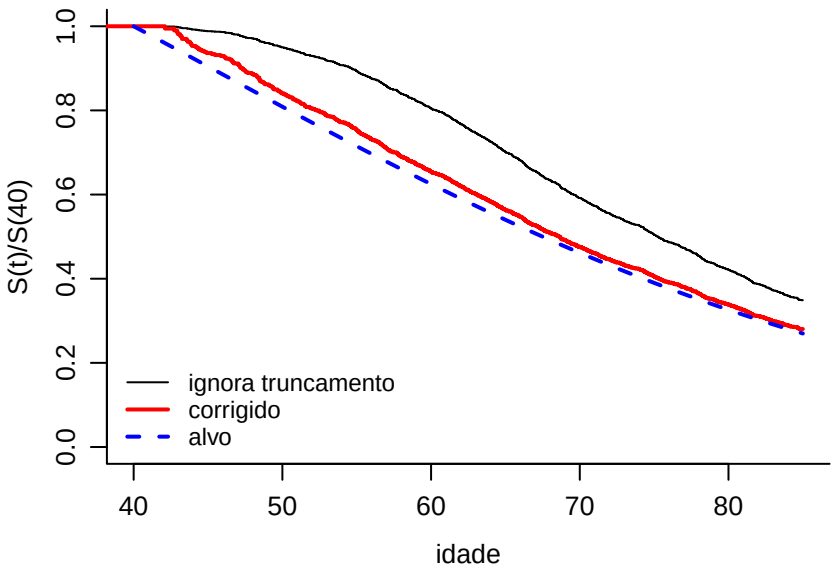


Figura 5.1: Coorte simulada com $n = 3000$, tempos Weibull($\kappa = 2$) na escala de idade e recrutamento uniforme entre 40 e 65 anos. A curva preta ignora a entrada tardia e fica muito acima do alvo; a vermelha usa `Surv(entrada, saída, evento)` e o acompanha. Note o *estimando*: sob truncamento à esquerda nada se observa antes da primeira entrada, de modo que o que se identifica é a sobrevivência *condicional* $S(t)/S(40)$, e não $S(t)$. A discrepância residual da curva corrigida vem do conjunto de risco muito pequeno perto dos 40 anos.

A média observada é

$$\mathbb{E}[T^{\text{obs}}] = \int_0^\infty t\, f^{\text{obs}}(t)\, dt = \frac{\mathbb{E}[T^2]}{\mathbb{E}[T]} = \mathbb{E}[T](1 + c_T^2).$$

Assim, quanto mais heterogêneas forem as durações, maior será a inflação. Para uma duração exponencial, $c_T = 1$ e a amostragem de casos prevalentes dobra a duração média aparente. A correção mais direta no planejamento é acompanhar uma coorte de casos incidentes. Quando apenas casos prevalentes estão disponíveis, deve-se incorporar o mecanismo de seleção ou de truncamento à verossimilhança; sob incidência estacionária e amostragem uniforme no tempo, ponderar por $1/t$ desfaz o viés para certos funcionais. Em aplicações gerais, a contribuição precisa ser derivada do desenho de amostragem, pois a ponderação simples não é universal.

Nota (Resumo operacional).

Esquema	Contribuição à verossimilhança	Em `R`
Exata	$f(t_i)$	`Surv(t, 1)`
Censura à direita	$S(t_i)$	`Surv(t, 0)`
Censura à esquerda	$1 - S(t_i)$	`Surv(t, 0, type="left")`
Censura intervalar	$S(l_i) - S(r_i)$	`Surv(l, r, type="interval2")`
Truncamento à esquerda	dividir por $S(u_i)$	`Surv(u, t, evento)`
Truncamento à direita	dividir por $F(v_i)$	Lynden-Bell

5.9 Exemplos resolvidos

Exercício resolvido 5.1 : Kaplan–Meier passo a passo

Enunciado. Tempos observados (em meses) e indicadores de evento (+ = censurado):

$$\{4,\ 7^+,\ 9,\ 12,\ 13^+,\ 17\}.$$

Compute $\hat{S}(t)$ pelo estimador de Kaplan–Meier para todos os tempos relevantes.
Solução. Identifique os tempos distintos de evento (não censurados): $4, 9, 12, 17$. Para cada um, conte n_j (em risco imediatamente antes) e d_j (eventos):

$t_{(j)}$	n_j	d_j	$1 - d_j/n_j$	$\hat{S}(t_{(j)})$
4	6	1	5/6	$5/6 \approx 0{,}833$
9	4	1	3/4	$(5/6)(3/4) = 5/8 = 0{,}625$
12	3	1	2/3	$(5/8)(2/3) = 5/12 \approx 0{,}417$
17	1	1	0	0

Note que, ao chegar em $t_{(j)} = 9$, o conjunto em risco é {os que tinham $\tilde{T} \geq 9$} = $\{9, 12, 13^+, 17\}$, ou seja, $n_j = 4$ (o indivíduo censurado em 7^+ saiu antes de 9). $\hat{S}$ salta de 0,833 para 0,625, depois para 0,417, e finalmente para 0 em $t = 17$.

Exercício resolvido 5.2 : Greenwood numérico

Enunciado. Para o exemplo anterior, calcule $\widehat{\mathrm{Var}}(\hat{S}(12))$ e construa um intervalo de confiança pontual com nível de 95% para $S(12)$.
Solução. Pela fórmula de Greenwood,

$$\widehat{\mathrm{Var}}(\hat{S}(12)) = \hat{S}(12)^2 \left[\tfrac{1}{6\cdot 5} + \tfrac{1}{4\cdot 3} + \tfrac{1}{3\cdot 2}\right] = (0{,}417)^2 \cdot 0{,}284 = 0{,}0494.$$

$\widehat{\mathrm{ep}}(\hat{S}(12)) = 0{,}222$. O intervalo de confiança normal com nível de 95% é $0{,}417 \pm 1{,}96 \cdot 0{,}222 = (-0{,}018,\ 0{,}852)$. Note que este intervalo viola a restrição $S(t) \in [0, 1]$, por isso é prática comum aplicar a transformação $\log(-\log \hat{S})$ antes de construir o intervalo.

Exercício resolvido 5.3 : Razão de riscos numérica

Enunciado. Em um modelo Cox para tempo de sobrevida pós-cirurgia, $\hat{\beta}_{\text{tabagismo}} = 0{,}45$ (indicador 0/1) e $\widehat{\mathrm{ep}}(\hat{\beta}) = 0{,}12$. Construa um intervalo de confiança com nível de 95% para a razão de riscos.
Solução. A razão de riscos é $e^{0{,}45} \approx 1{,}568$. O intervalo para β é $0{,}45 \pm 1{,}96 \cdot 0{,}12 = (0{,}215,\ 0{,}685)$. Exponenciando os dois extremos, o intervalo para a razão de riscos é $(e^{0{,}215},\ e^{0{,}685}) = (1{,}24,\ 1{,}98)$. Tabagistas têm risco instantâneo de morte cerca de 57% maior, com intervalo de 95% correspondente a um aumento entre 24% e 98% em relação a não tabagistas.

5.10 Laboratório computacional em R

Laboratório em R : Kaplan–Meier e *log-rank* em `lung`

O conjunto `lung` (`survival`) traz tempos de sobrevida de 228 pacientes com câncer de pulmão.

```
library(survival)

# Surv() codifica tempo + indicador de evento
ajuste_km <- survfit(Surv(time, status) ~ sex, data = lung)
print(ajuste_km, print.rmean = TRUE)

# Curvas estratificadas por sexo
plot(ajuste_km, col = c("steelblue", "tomato"), lwd = 2,
     xlab = "Dias", ylab = "S(t)",
     main = "Kaplan-Meier estratificado por sexo")
legend("topright", legend = c("Homens", "Mulheres"),
       col = c("steelblue", "tomato"), lty = 1, lwd = 2)

# Teste log-rank
survdiff(Surv(time, status) ~ sex, data = lung)
```

A saída de `survdiff` reporta a estatística χ^2 com p-valor; tipicamente $p < 0{,}01$, sugerindo curvas diferentes (mulheres têm sobrevida superior).

Laboratório em R : Modelo de Cox em `lung`

```
ajuste_cox <- coxph(Surv(time, status) ~ age + sex + ph.ecog,
                    data = lung)
summary(ajuste_cox)

# Razoes de riscos e intervalos de confianca
exp(cbind(razao_de_riscos = coef(ajuste_cox), confint(ajuste_cox)))

# Residuos de Schoenfeld e verificacao da proporcionalidade
cox.zph(ajuste_cox)
```

A saída traz estimativas, erros padrão, estatísticas de teste, valores-p e razões de riscos. Use `plot(cox.zph(ajuste_cox))` para procurar tendências nos resíduos escalados. Valores-p pequenos constituem evidência contra a proporcionalidade; valores grandes não a comprovam, especialmente com poucos eventos. Se houver padrão substantivo, considere estratificação ou efeitos que variam no tempo.

Laboratório em R : Curva ajustada com Cox

Para visualizar curvas $S(t \mid x)$ implicadas pelo Cox, use `survfit` aplicado ao ajuste:

```
# Curvas para perfis especificos
novos <- data.frame(age = c(50, 70), sex = c(1, 1), ph.ecog = c(0,
   0))
curvas <- survfit(ajuste_cox, newdata = novos)
plot(curvas, col = c("steelblue", "tomato"), lwd = 2,
     xlab = "Dias", ylab = "S(t | x)")
legend("topright", legend = c("50 anos", "70 anos"),
       col = c("steelblue", "tomato"), lty = 1, lwd = 2)
```

Laboratório em R : Modelos paramétricos com survreg

Comece pelo diagnóstico gráfico da forma, antes de escolher a família.

```
library(survival)
km <- survfit(Surv(time, status) ~ 1, data = lung)

# Sob Weibull, log(-log S(t)) em funcao de log(t) deve ser uma RETA
# de inclinacao kappa
ok <- km$surv > 0 & km$surv < 1
plot(log(km$time[ok]), log(-log(km$surv[ok])), pch = 19, cex = 0.5,
     xlab = "log t", ylab = "log(-log S(t))")
abline(lm(log(-log(km$surv[ok])) ~ log(km$time[ok])), col = "red")
```

Curvatura sistemática rejeita a Weibull. Se a reta servir, ajuste os modelos, lembrando que **survreg** usa a parametrização de **tempo de falha acelerado**:

```
m_exp   <- survreg(Surv(time, status) ~ age + sex, data = lung, dist
    = "exponential")
m_wei   <- survreg(Surv(time, status) ~ age + sex, data = lung, dist
    = "weibull")
m_logn  <- survreg(Surv(time, status) ~ age + sex, data = lung, dist
    = "lognormal")

# AIC e o nome literal da funcao que calcula o criterio de Akaike
sapply(list(exp = m_exp, weibull = m_wei, lognormal = m_logn), AIC)

summary(m_wei)
kappa <- 1 / m_wei$scale        # forma da Weibull
c(kappa = kappa, razao_de_tempos_sexo = exp(coef(m_wei)["sex"]))
```

Confirme agora o Teorema 5.12 numericamente, comparando com o Cox:

```
m_cox <- coxph(Surv(time, status) ~ age + sex, data = lung)

cbind(cox_beta_riscos = coef(m_cox),
      wei_beta_riscos = -coef(m_wei)[-1] * kappa)
```

Se a forma Weibull for adequada, os dois conjuntos de coeficientes podem ficar próximos dentro da incerteza de estimação; a proximidade não é garantida em uma amostra e sua ausência também serve como diagnóstico. Note ainda os sinais opostos: `sex` tem razão de riscos menor que um e razão de tempos maior que um. São leituras diferentes da mesma direção de associação.

Por fim, a vantagem que motivou o modelo paramétrico, extrapolar:

```
tempos <- seq(1, 2000, by = 10)          # alem do seguimento
    observado
perfil <- data.frame(age = 60, sex = 1)
S_wei  <- 1 - psurvreg(tempos, mean = predict(m_wei, perfil, type =
    "lp"),
                       scale = m_wei$scale, distribution = "weibull"
                          )
plot(km, xlim = c(0, 2000), xlab = "Dias", ylab = "S(t)")
lines(tempos, S_wei, col = "red", lwd = 2)
```

A representação gráfica de Kaplan–Meier costuma terminar no maior tempo observado; matematicamente, a estimativa permanece constante depois do último evento, mas os dados não identificam sua evolução futura. A curva paramétrica prossegue porque a família escolhida impõe essa evolução. A extrapolação é útil e perigosa na mesma medida: fora do seguimento, ela é ditada pela família e não por observações diretas.

Laboratório em R : Truncamento à esquerda: o conjunto de risco corrigido

Simulamos uma coorte com entrada tardia e medimos o viés de ignorá-la.

```
set.seed(1)
n <- 500
T_real  <- rweibull(n, shape = 2, scale = 70)       # tempo de evento
    (idade)
entrada <- runif(n, 40, 65)                          # idade de
   recrutamento

# TRUNCAMENTO: so entram na amostra os que sobreviveram ate a
   entrada
obs     <- T_real > entrada
t_obs   <- pmin(T_real, 85)[obs]                     # censura
   administrativa aos 85
evento  <- (T_real <= 85)[obs]
u       <- entrada[obs]

# (a) ERRADO: ignora a entrada tardia
km_errado  <- survfit(Surv(t_obs, evento) ~ 1)

# (b) CORRETO: individuo entra no conjunto de risco em u
km_correto <- survfit(Surv(u, t_obs, evento) ~ 1)

plot(km_errado, conf.int = FALSE, xlab = "Idade", ylab = "S(t)")
lines(km_correto, conf.int = FALSE, col = "red", lwd = 2)
# Alvo CONDICIONAL: sob truncamento, estima-se S(t)/S(40)
tt <- seq(40, 85, by = 0.5)
lines(tt, (1 - pweibull(tt, 2, 70)) / (1 - pweibull(40, 2, 70)),
      col = "blue", lty = 2)
legend("bottomleft", c("ignora truncamento", "corrigido", "verdade S
   (t)/S(40)"),
       col = c("black", "red", "blue"), lty = c(1, 1, 2))
```

A curva preta fica **muito acima** do alvo nas idades iniciais: cada indivíduo recrutado aos 63 anos foi tratado como se estivesse sob observação desde o tempo zero, ganhando 63 anos de sobrevivência que nunca foram observados. Quanto à curva vermelha, atenção ao *estimando*: como ninguém é observado antes da primeira entrada ($t_{\min} \approx 40$), o estimador de Kaplan–Meier corrigido identifica a sobrevivência *condicional* $S(t)/S(t_{\min})$, e não a incondicional $S(t)$, aqui, $S(t)/S(40)$ com $S(40) = \exp(-(40/70)^2) \approx 0{,}72$. É essa curva condicional (azul tracejada) que a vermelha acompanha; comparar com $1 - \texttt{pweibull(t, 2, 70)}$ faria a correção parecer, falsamente, ainda viesada.

O mesmo se aplica ao Cox, e a correção é igualmente barata. Acrescentando à coorte uma covariável com efeito no tempo de evento:

```
x       <- rnorm(n)                                  # covariavel com
   efeito no risco
T_cov   <- rweibull(n, shape = 2, scale = 70 * exp(-0.3 * x))
obs     <- T_cov > entrada
t_obs   <- pmin(T_cov, 85)[obs]
evento  <- (T_cov <= 85)[obs]
u       <- entrada[obs]
x       <- x[obs]

cox_errado  <- coxph(Surv(t_obs, evento) ~ x)
cox_correto <- coxph(Surv(u, t_obs, evento) ~ x)
```

5.11 Exercícios propostos

Ex. 5.1. Demonstre as relações $f(t) = -S'(t)$, $h(t) = -d\log S(t)/dt$ e $S(t) = \exp(-H(t))$ supondo T contínua. Discuta o que muda no caso discreto.

Ex. 5.2. Considere os tempos $\{2, 3, 5, 5^+, 8, 10, 10^+, 12, 15^+\}$. Compute $\hat{S}(t)$ para todos os tempos relevantes. Há ambiguidade sobre se a censura em 5^+ ocorre antes ou depois do evento em 5? Como o algoritmo padrão resolve?

Ex. 5.3. Suponha que, condicionalmente a x_i, o tempo T_i tenha distribuição exponencial com taxa λ_i, em que $\log \lambda_i = x_i^\top \beta$. Derive a log-verossimilhança incorporando censura à direita e verifique que ela é côncava em β.

Ex. 5.4. Em uma amostra com 5 indivíduos com tempos $(2, 4, 4, 7, 9)$, todos com evento, escreva explicitamente $L_{\text{parcial}}(\beta)$ em função das covariáveis $x_1, \dots, x_5$. Discuta como o método de Breslow trata os empates em $t = 4$.

Ex. 5.5. Em um modelo Cox, $\hat{\beta}_{\text{idade}} = 0{,}03$ por ano. Qual a razão de riscos para uma diferença de 10 anos? E para 30 anos? Discuta a hipótese de proporcionalidade nesse contexto.

Ex. 5.6. *Aplicação prática.* No conjunto `colon`, fornecido pelo pacote `survival`, modele o tempo até morte (`etype == 2`) em função do tratamento (`rx`), idade, sexo e extensão local (`extent`). Reporte: (a) curvas de Kaplan–Meier por braço de tratamento; (b) teste *log-rank*; (c) modelo Cox ajustado; (d) verificação de proporcionalidade.

Ex. 5.7. Demonstre a Proposição 5.11 e complete-a: (a) calcule a informação de Fisher observada e mostre que vale d/λ^2, dependendo do número de *eventos* e não do de indivíduos; (b) obtenha um intervalo de confiança assintótico de 95% para λ e outro para a mediana de sobrevivência $\log 2/\lambda$; (c) explique, com base em (a), por que o cálculo de tamanho amostral em estudos de sobrevivência é feito em número de eventos, e o que isso implica para o planejamento de um ensaio com desfecho raro.

Ex. 5.8. Demonstre o Teorema 5.12 na direção construtiva: (a) partindo da representação de tempo de falha acelerado $\log T = x^\top \beta^{\text{tempo}} + \sigma W$, com W de valor extremo padrão, mostre que $T \mid x$ é Weibull e obtenha $S(t \mid x)$ explicitamente; (b) verifique que essa $S(t \mid x)$ satisfaz $h(t \mid x) = h_0(t) e^{x^\top \beta^{\text{riscos}}}$ com $\beta^{\text{riscos}} = -\beta^{\text{tempo}}/\sigma = -\kappa \beta^{\text{tempo}}$; (c) mostre que a log-normal *não* admite representação de riscos proporcionais, exibindo que a razão $h(t \mid x_1)/h(t \mid x_2)$ depende de t.

Ex. 5.9. Deduza (5.4) e verifique que ela contém, como casos particulares, a censura à direita ($r_i = \infty$), a censura à esquerda ($l_i = 0$) e a observação exata (limite $r_i - l_i \to 0$). Em seguida, considere $n = 4$ observações intervalares $(0, 2]$, $(1, 3]$, $(2, \infty)$ e $(1, \infty)$ sob modelo exponencial. Escreva $\ell(\lambda)$ explicitamente e obtenha $\hat{\lambda}$ numericamente (por `optimize` em `R`, ou por bisseção manual). Compare com a estimativa ingênua obtida imputando o ponto médio de cada intervalo.

Ex. 5.10. *O viés do truncamento ignorado.* Reproduza a simulação do laboratório correspondente com T de distribuição Weibull, forma $\kappa = 2$ e escala 70, e entrada U de distribuição uniforme em $(40, 65)$. (a) Explique por que, sem observações antes de 40, a curva corrigida identifica $S(t)/S(40)$; estime essa sobrevivência condicional em 50 e 60 pelos dois procedimentos. (b) Repita $R = 200$ vezes e reporte o viés médio e o erro de Monte Carlo de cada um. (c) Investigue o sinal do viés do estimador ingênuo nas idades iniciais e explique o mecanismo que tende a torná-lo positivo, sem afirmar que toda réplica finita terá o mesmo sinal. (d) Verifique o que acontece ao viés quando

a janela de recrutamento se estreita para uma distribuição uniforme em $(40, 42)$, e interprete o limite em que todos entram no mesmo instante.

Ex. 5.11. *Viés de comprimento.* Sob incidência estacionária, a duração de um episódio captado por amostragem de casos prevalentes tem densidade $f^{\text{obs}}(t) = tf(t)/\mathbb{E}[T]$. (a) Verifique que f^{obs} é de fato uma densidade. (b) Defina $c_T = \sqrt{\text{Var}(T)}/\mathbb{E}[T]$, o coeficiente de variação de T, e mostre que $\mathbb{E}[T^{\text{obs}}] = \mathbb{E}[T^2]/\mathbb{E}[T] = \mathbb{E}[T](1 + c_T^2)$. (c) Para T com distribuição exponencial, mostre que $\mathbb{E}[T^{\text{obs}}] = 2\,\mathbb{E}[T]$: a amostragem de prevalentes *dobra* a duração média aparente. (d) Descreva um exemplo concreto em saúde pública em que esse viés produziria uma conclusão substantivamente errada, e indique a correção.

Notas e leituras complementares

- Kaplan e Meier 1958: artigo seminal do estimador de produto-limite.
- Cox 1972: artigo seminal do modelo de riscos proporcionais.
- Klein e Moeschberger 2003: texto clássico de pós-graduação, com tratamento completo de modelos paramétricos, semiparamétricos e, como anuncia o subtítulo, de dados censurados *e truncados*.
- Lynden-Bell 1971: origem astronômica do estimador não paramétrico sob truncamento à direita.
- Efron e Hastie 2016, §9: discussão da verossimilhança parcial e conexões com outros métodos.

5.12 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Análise de sobrevivência	*survival analysis*	—
Tempo até o evento	*time-to-event*	—
Função de sobrevivência	*survival function*	—
Função de risco	*hazard function*	—
Risco acumulado	*cumulative hazard*	—
Censura à direita	*right censoring*	—
Censura à esquerda	*left censoring*	—
Censura intervalar	*interval censoring*	—
Censura informativa	*informative censoring*	—
Estimador de Kaplan–Meier	*Kaplan–Meier estimator*	KM
Estimador de produto-limite	*product-limit estimator*	—
Fórmula de Greenwood	*Greenwood's formula*	—
Teste log-rank	*log-rank test*	—
Modelo de riscos proporcionais de Cox	*Cox proportional hazards model*	Cox PH
Verossimilhança parcial	*partial likelihood*	—
Conjunto de risco	*risk set*	—
Razão de riscos	*hazard ratio*	HR
Resíduo de Schoenfeld	*Schoenfeld residual*	—
Modelo exponencial de sobrevivência	*exponential survival model*	—
Modelo de Weibull	*Weibull model*	—
Modelo log-normal	*log-normal model*	—
Modelo de tempo de falha acelerado	*accelerated failure time model*	AFT
Taxa de incidência	*incidence rate*	IR
Truncamento à esquerda	*left truncation*	—
Entrada tardia	*delayed entry*	—
Truncamento à direita	*right truncation*	—
Viés de comprimento	*length bias*	—
Coeficiente de variação	*coefficient of variation*	CV
Informação observada	*observed information*	—
Estimador de Turnbull	*Turnbull estimator*	—

Capítulo 6

Algoritmo de esperança e maximização

Objetivos da unidade

- Apresentar o algoritmo de esperança e maximização como ferramenta geral para maximizar verossimilhanças na presença de variáveis latentes ou dados faltantes.
- Derivar a identidade fundamental que liga a log-verossimilhança observada à *Q-função*.
- Demonstrar a propriedade de monotonicidade e distinguir essa propriedade da convergência dos parâmetros para um máximo.
- Aplicar o algoritmo a dois exemplos canônicos: misturas gaussianas e dados parcialmente observados.

Leitura primária: Efron e Hastie 2016, capítulo 9 (parte 2).
Leitura complementar: Dempster, Laird e Rubin 1977; G. James et al. 2021, capítulo 12.

6.1 Motivação

Sejam $Y_1, \ldots, Y_n$ variáveis aleatórias condicionalmente independentes, com densidade ou função de probabilidade $f(\,\cdot\,;\theta)$, em que θ é o parâmetro desconhecido, e sejam $y_1, \ldots, y_n$ os valores observados. A função de verossimilhança é $L(\theta; y) = \prod_i f(y_i; \theta)$. Sua maximização é simples quando f é tratável e não há observações ausentes. Em muitos problemas reais, contudo, a verossimilhança *observada* é uma marginalização complicada de uma verossimilhança *completa* mais simples. Três cenários típicos:

- **Mistura de distribuições.** Considere $K \geq 2$ componentes. Para a componente k, $f_k(\,\cdot\,;\theta_k)$ é uma densidade com parâmetro θ_k, e $\pi_k \geq 0$ é seu peso, com $\sum_{k=1}^{K} \pi_k = 1$. A densidade de Y_i é $\sum_{k=1}^{K} \pi_k f_k(\cdot;\theta_k)$. O rótulo $Z_i \in \{1, \ldots, K\}$ que indica a componente de origem de Y_i não é observado e, por isso, é *latente*. Maximizar L diretamente envolve um produto de somas, dificultando a otimização.
- **Dados censurados ou truncados.** Para algumas observações, conhecemos apenas que $Y_i > c$ ou $Y_i \in [a, b]$. A verossimilhança completa (se Y_i fosse observado) seria mais simples.
- **Dados faltantes.** Algumas componentes de cada vetor $Y_i \in \mathbb{R}^d$, em que d é o número de variáveis registradas por indivíduo, não foram observadas. Maximizar a verossimilhança da parte observada é difícil; conhecer a parte faltante simplificaria.

O **algoritmo de esperança e maximização**, formalizado em sua generalidade por Dempster, Laird e Rubin 1977, transforma um problema difícil em uma sequência de problemas mais simples. Ele alterna entre calcular esperanças condicionais relativas aos dados latentes, no **passo de esperança**, e maximizar a log-verossimilhança completa esperada, no **passo de maximização**. O cálculo de uma esperança não deve ser confundido com substituir cada valor ausente por uma única imputação.

6.2 Formulação geral

Sejam Y os **dados observados** e Z os **dados latentes** (ou faltantes), com densidade conjunta $f(y, z; \theta)$ parametrizada por $\theta \in \Theta \subseteq \mathbb{R}^d$. A verossimilhança *observada* (incompleta) é

$$L(\theta; y) = \int f(y, z; \theta)\, dz, \qquad \ell(\theta; y) = \log L(\theta; y).$$

A verossimilhança *completa* (se Z fosse conhecido) é

$$L_c(\theta; y, z) = f(y, z; \theta), \qquad \ell_c(\theta; y, z) = \log f(y, z; \theta).$$

Definição 6.1 (Iteração de esperança e maximização)**.** Dada a iteração corrente $\theta^{(t)}$:

- **Passo de esperança**: definir

$$Q(\theta \mid \theta^{(t)}) := \mathbb{E}_{Z \mid y, \theta^{(t)}}\big[\log f(y, Z; \theta)\big].$$

- **Passo de maximização**: definir

$$\theta^{(t+1)} := \arg\max_{\theta \in \Theta} Q(\theta \mid \theta^{(t)}).$$

Observação (Algoritmo generalizado)*.* Em problemas nos quais o passo de maximização não tem solução fechada, basta encontrar $\theta^{(t+1)}$ que *aumente* Q, isto é,

$$Q(\theta^{(t+1)} \mid \theta^{(t)}) \geq Q(\theta^{(t)} \mid \theta^{(t)}).$$

Essa variante é chamada de **algoritmo generalizado de esperança e maximização** e preserva a monotonicidade demonstrada adiante.

6.3 A identidade fundamental e monotonicidade

6.3.1 Decomposição da log-verossimilhança

Considere a distribuição a posteriori do latente, $p(z \mid y; \theta) = f(y, z; \theta)/L(\theta; y)$. Tomando logaritmo,

$$\log f(y, z; \theta) = \log L(\theta; y) + \log p(z \mid y; \theta).$$

Tomando esperança em Z sob a distribuição $p(z \mid y; \theta')$ (com θ' qualquer),

$$\boxed{\ell(\theta; y) = Q(\theta \mid \theta') - H(\theta \mid \theta')} \tag{6.1}$$

onde

$$Q(\theta \mid \theta') = \mathbb{E}_{Z \mid y, \theta'}[\log f(y, Z; \theta)], \qquad H(\theta \mid \theta') = \mathbb{E}_{Z \mid y, \theta'}[\log p(Z \mid y; \theta)].$$

A identidade (6.1) é exata e vale para todo θ, θ'.

6.3.2 Lema de Gibbs

Lema 6.2 (Desigualdade de informação)**.** *Para densidades p, q no mesmo espaço,*

$$\int p(z)\log p(z)\,dz \;\geq\; \int p(z)\log q(z)\,dz,$$

com igualdade se e somente se $p = q$ quase em toda parte.

Demonstração. Equivale a $\int p\log(p/q) \geq 0$ (divergência de Kullback–Leibler). Por concavidade de log e Jensen, $\int p\log(q/p) \leq \log\int q = 0$. □

Em particular, fixando θ', $H(\theta \mid \theta') \leq H(\theta' \mid \theta')$ para todo θ. Há igualdade se e somente se as densidades condicionais $p(z \mid y;\theta)$ e $p(z \mid y;\theta')$ forem iguais quase em toda parte. Isso pode ocorrer mesmo com $\theta \neq \theta'$ quando o modelo não é identificável, isto é, quando parâmetros distintos determinam a mesma distribuição observável.

6.3.3 Monotonicidade

Teorema 6.3 (Monotonicidade do algoritmo)**.** *A sequência $\{\theta^{(t)}\}_{t\geq 0}$ produzida pela Definição 6.1 satisfaz*

$$\ell(\theta^{(t+1)};y) \;\geq\; \ell(\theta^{(t)};y), \qquad t = 0,1,2,\ldots$$

Demonstração. Aplique a identidade (6.1) com $\theta' = \theta^{(t)}$, em $\theta = \theta^{(t+1)}$ e $\theta = \theta^{(t)}$, e subtraia:

$$\ell(\theta^{(t+1)};y) - \ell(\theta^{(t)};y) = \underbrace{\big[Q(\theta^{(t+1)} \mid \theta^{(t)}) - Q(\theta^{(t)} \mid \theta^{(t)})\big]}_{\geq 0 \text{ (passo M)}} - \underbrace{\big[H(\theta^{(t+1)} \mid \theta^{(t)}) - H(\theta^{(t)} \mid \theta^{(t)})\big]}_{\leq 0 \text{ (Gibbs)}}.$$

A primeira diferença é ≥ 0 porque $\theta^{(t+1)}$ *maximiza* $Q(\cdot \mid \theta^{(t)})$. A segunda é ≤ 0 pelo Lema 6.2. Logo a soma é ≥ 0. □

Observação (O que a monotonicidade não garante). A desigualdade $\ell(\theta^{(t+1)};y) \geq \ell(\theta^{(t)};y)$, sozinha, não garante que a sequência de parâmetros convirja. Sob condições adicionais, como continuidade do mapa iterativo, permanência das iterações em um conjunto compacto e regularidade da log-verossimilhança, todo ponto de acumulação é estacionário. Mesmo nessas condições, o limite pode ser um máximo local ou um ponto de sela, e não o máximo global. Se ℓ tem múltiplos máximos locais, como frequentemente ocorre em misturas, diferentes inicializações podem levar a soluções diferentes.

6.4 Mistura de gaussianas

6.4.1 Modelo

Sejam $Y_1,\ldots,Y_n$ independentes e com a mesma distribuição, dada pela mistura

$$Y_i \sim \sum_{k=1}^{K} \pi_k\, N(\mu_k,\sigma_k^2),$$

na qual K é o número de componentes, $\pi_k > 0$ é o peso da componente k, $\sum_{k=1}^{K}\pi_k = 1$, e $N(\mu_k,\sigma_k^2)$ denota a distribuição normal de média μ_k e variância $\sigma_k^2 > 0$. Escreva

$$\phi(y;\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\!\left\{-\frac{(y-\mu)^2}{2\sigma^2}\right\}$$

para a densidade dessa distribuição. Introduza a variável latente $Z_i \in \{1,\ldots,K\}$, chamada de **rótulo da componente**, cuja distribuição é categórica:

$$\mathbb{P}(Z_i = k) = \pi_k, \qquad k = 1,\ldots,K.$$

Condicionalmente a $Z_i = k$, suponha $Y_i \sim N(\mu_k, \sigma_k^2)$.

A verossimilhança completa é

$$L_c(\theta; y, z) = \prod_{i=1}^{n} \prod_{k=1}^{K} \left[\pi_k \, \phi(y_i; \mu_k, \sigma_k^2)\right]^{\mathbb{1}\{z_i = k\}}.$$

Tomando o logaritmo dessa expressão,

$$\log L_c = \sum_i \sum_k \mathbb{1}\{z_i = k\} \left[\log \pi_k + \log \phi(y_i; \mu_k, \sigma_k^2)\right].$$

6.4.2 Passos de esperança e de maximização

Proposição 6.4 (Iteração para uma mistura gaussiana)**.** ***Passo de esperança.*** *As* ***responsabilidades****, isto é, as probabilidades condicionais de cada rótulo dados os valores observados e os parâmetros correntes, são*

$$\gamma_{ik}^{(t)} = \mathbb{P}(Z_i = k \mid y_i, \theta^{(t)}) = \frac{\pi_k^{(t)} \, \phi(y_i; \mu_k^{(t)}, (\sigma_k^{(t)})^2)}{\sum_{l=1}^{K} \pi_l^{(t)} \, \phi(y_i; \mu_l^{(t)}, (\sigma_l^{(t)})^2)}. \tag{6.2}$$

Passo de maximização. *As atualizações em forma fechada são*

$$\begin{aligned}
\pi_k^{(t+1)} &= \frac{1}{n} \sum_{i=1}^{n} \gamma_{ik}^{(t)}, \\
\mu_k^{(t+1)} &= \frac{\sum_i \gamma_{ik}^{(t)} \, y_i}{\sum_i \gamma_{ik}^{(t)}}, \\
(\sigma_k^{(t+1)})^2 &= \frac{\sum_i \gamma_{ik}^{(t)} \, (y_i - \mu_k^{(t+1)})^2}{\sum_i \gamma_{ik}^{(t)}}.
\end{aligned}$$

Demonstração. Substituindo $\mathbb{E}[\mathbb{1}\{Z_i = k\} \mid y_i, \theta^{(t)}] = \gamma_{ik}^{(t)}$ na log-verossimilhança completa,

$$Q(\theta \mid \theta^{(t)}) = \sum_i \sum_k \gamma_{ik}^{(t)} \left[\log \pi_k + \log \phi(y_i; \mu_k, \sigma_k^2)\right].$$

A maximização em π_k sob a restrição $\sum_k \pi_k = 1$ produz, via multiplicador de Lagrange, $\pi_k^{(t+1)} = \frac{1}{n} \sum_i \gamma_{ik}^{(t)}$. A maximização em (μ_k, σ_k^2) corresponde à média ponderada e variância ponderada usuais, com pesos $\gamma_{ik}^{(t)}$. □

Observação (Patologias). A verossimilhança em misturas gaussianas é *não limitada*: posicionando μ_k exatamente em uma observação e fazendo $\sigma_k^2 \to 0$, a verossimilhança diverge. Na prática, restringe-se $\sigma_k^2 \geq \sigma_{\min}^2 > 0$ ou usa-se penalização ou uma formulação bayesiana. Múltiplas inicializações são importantes para investigar máximos locais distintos.

6.5 Dados normais com observações faltantes

Como segundo exemplo arquetípico, considere variáveis Y_i independentes, todas com distribuição $N(\mu, \sigma^2)$, em que m observações foram *censuradas à direita* no valor c: para essas, sabemos apenas que $Y_i \geq c$. Denote por ϕ a densidade da normal padrão e por

$$\Phi(a) = \int_{-\infty}^{a} \phi(u) \, du$$

sua função de distribuição acumulada.

Sejam $y_1, \ldots, y_{n-m}$ os $n - m$ valores observados e $Y_{n-m+1}, \ldots, Y_n$ os censurados. Tratando os censurados como latentes, a iteração de esperança e maximização é:

Proposição 6.5 (Algoritmo para normal com censura à direita)**.** ***Passo de esperança.*** *Para cada i censurado em c,*

$$\mathbb{E}[Y_i \mid Y_i > c, \mu^{(t)}, \sigma^{(t)}] = \mu^{(t)} + \sigma^{(t)}\,\frac{\phi(\xi^{(t)})}{1-\Phi(\xi^{(t)})}, \qquad \xi^{(t)} = \frac{c-\mu^{(t)}}{\sigma^{(t)}},$$

e analogamente para $\mathbb{E}[Y_i^2 \mid \cdot]$.

Passo de maximização. *As atualizações usam as* estatísticas suficientes esperadas*. Com*

$$\mathbb{E}[Y_i^2 \mid Y_i > c, \mu^{(t)}, \sigma^{(t)}] = (\mu^{(t)})^2 + (\sigma^{(t)})^2 + \sigma^{(t)}\,(c+\mu^{(t)})\,\frac{\phi(\xi^{(t)})}{1-\Phi(\xi^{(t)})},$$

tem-se

$$\mu^{(t+1)} = \frac{1}{n}\Big[\sum_{i=1}^{n-m} y_i + m\,\mathbb{E}[Y_i \mid Y_i > c, \cdot]\Big], \qquad (\sigma^{(t+1)})^2 = \frac{1}{n}\Big[\sum_{i=1}^{n-m} y_i^2 + m\,\mathbb{E}[Y_i^2 \mid Y_i > c, \cdot]\Big] - \big(\mu^{(t+1)}\big)^2.$$

Note que não *se trata dos estimadores usuais aplicados aos valores imputados: em σ^2, entra o segundo momento condicional completo, e não o quadrado de $\mathbb{E}[Y_i \mid \cdot]$. A diferença entre os dois é a variância condicional da parte censurada, que a imputação pontual descartaria, subestimando σ^2.*

O cálculo acima *não é uma imputação determinística.* O passo de esperança integra a incerteza sobre cada valor censurado por meio do primeiro e do segundo momentos condicionais. Se o objetivo fosse produzir vários bancos de dados completos para propagar a incerteza da falta, seria necessário sortear repetidamente valores da distribuição preditiva condicional; esse procedimento é chamado de **imputação múltipla**. O algoritmo deste capítulo, por sua vez, tem como objetivo maximizar a verossimilhança observada.

6.5.1 Mecanismos de dados faltantes

Para usar a verossimilhança da parte observada sem modelar o processo que gera a falta, é preciso justificar que esse processo pode ser ignorado. A classificação de Rubin 1976 torna a questão precisa.

Escreva $Y = (Y_{\text{obs}}, Y_{\text{aus}})$, em que Y_{obs} reúne os valores observados e Y_{aus} os valores ausentes. Seja R a matriz de indicadores de observação: $R_{ij} = 1$ quando a entrada (i,j) foi observada e $R_{ij} = 0$ quando está ausente. O **mecanismo de falta** é a distribuição

$$p(r \mid y_{\text{obs}}, y_{\text{aus}}; \psi),$$

na qual ψ é o vetor de parâmetros que governa a probabilidade de observação.

Definição 6.6 (Mecanismos de falta)**.**

- A falta é **completamente aleatória** quando $p(r \mid y_{\text{obs}}, y_{\text{aus}}; \psi) = p(r; \psi)$; nesse caso, a probabilidade de observação não depende de nenhum valor dos dados.
- A falta é **aleatória dado o observado** quando $p(r \mid y_{\text{obs}}, y_{\text{aus}}; \psi) = p(r \mid y_{\text{obs}}; \psi)$; a probabilidade de observação pode depender do que foi observado, mas não depende adicionalmente do valor ausente depois de condicionarmos no observado.
- A falta é **não aleatória dado o observado** quando a probabilidade de observação ainda depende do próprio valor ausente, mesmo depois de condicionarmos em y_{obs}.

Teorema 6.7 (Ignorabilidade para inferência por verossimilhança)**.** *Suponha que a falta seja aleatória dado o observado e que os parâmetros θ do modelo dos dados e ψ do mecanismo de falta sejam* distintos*, no sentido de que o espaço paramétrico conjunto é o produto dos espaços individuais. Então*

$$p(y_{\text{obs}}, r; \theta, \psi) = p(r \mid y_{\text{obs}}; \psi) \cdot \int p(y_{\text{obs}}, y_{\text{aus}}; \theta)\, dy_{\text{aus}},$$

e maximizar em θ apenas a verossimilhança

$$L(\theta; y_{\text{obs}}) = \int p(y_{\text{obs}}, y_{\text{aus}}; \theta)\, dy_{\text{aus}}$$

produz o mesmo estimador de máxima verossimilhança que a maximização conjunta em (θ, ψ). Para inferência bayesiana, exige-se adicionalmente uma fatoração apropriada da distribuição a priori dos dois blocos de parâmetros.

Esboço. Pela hipótese de falta aleatória dado o observado, $p(r \mid y_{\text{obs}}, y_{\text{aus}}; \psi)$ não depende de y_{aus} e sai da integral. A verossimilhança conjunta fatora-se em um termo que envolve apenas ψ e outro que envolve apenas θ; sob distinção dos parâmetros, o primeiro é constante em θ e não afeta o maximizador $\hat{\theta}$. □

Observação (O papel do teorema)*.* O algoritmo da Definição 6.1 maximiza $L(\theta; y_{\text{obs}})$, e apenas isso. O Teorema 6.7 estabelece quando o fator relativo ao mecanismo pode ser omitido na inferência por verossimilhança. Se a falta for não aleatória dado o observado, a verossimilhança conjunta contém um fator que liga θ e ψ; ignorá-lo pode produzir inferência enviesada, ainda que as iterações sejam monotônicas para a função escolhida.

Exemplo 6.8 (Os três regimes)**.** Em uma pesquisa domiciliar de renda:

- **Falta completamente aleatória**: questionários são extraviados por um erro de arquivo independente das respostas. Sob amostragem aleatória, analisar apenas os casos completos preserva a distribuição, embora desperdice informação.
- **Falta aleatória dado o observado**: a taxa de não resposta é maior entre pessoas jovens, e a idade foi registrada para todas. Condicionando em idade, respondentes e não respondentes têm a mesma distribuição de renda. Uma análise que descarte a idade e use apenas casos completos pode enviesar a média marginal; um modelo corretamente especificado que inclua idade pode corrigir a seleção.
- **Falta não aleatória dado o observado**: pessoas com renda alta recusam-se a informá-la, e nenhuma covariável observada captura essa dependência. Sem hipóteses adicionais sobre o mecanismo, a distribuição das rendas ausentes não é identificada pelos dados observados.

Nota (O mecanismo não é identificado sem hipóteses adicionais)*.* Em geral, a distribuição observada de (Y_{obs}, R) não basta para decidir se a falta é aleatória ou não aleatória dado o observado: diferentes modelos para os valores ausentes e para o mecanismo podem induzir a mesma distribuição observável. Portanto, não existe um teste universal que resolva a questão apenas com esses dados. A hipótese precisa ser defendida pelo conhecimento do processo de coleta. Quando for duvidosa, deve-se fazer uma **análise de sensibilidade**: repetir a análise sob modelos plausíveis de falta não aleatória e verificar se a conclusão se mantém.

O exemplo de censura à direita desta seção é mais sutil: a observação deixa de ser exata quando $Y_i > c$, portanto o padrão depende do próprio valor. O dado, porém, não está simplesmente ausente; ele foi **grosseado** por um mecanismo conhecido, a censura em limiar fixo. Sabemos que $Y_i > c$, e essa informação entra na verossimilhança observada pelo fator de sobrevivência $S(c) = 1 - \Phi((c - \mu)/\sigma)$. O análogo problemático em análise de sobrevivência é a *censura informativa* do Capítulo 5, na qual o mecanismo de censura depende do tempo de evento por vias não modeladas.

6.6 Convergência e limitações

O Teorema 6.3 garante que a log-verossimilhança não diminui. Não diz *quão rápido* as iterações se aproximam de um ponto fixo, nem *para qual* ponto irão, nem fornece erros-padrão. Esta seção examina essas limitações.

6.6.1 Taxa de convergência

Escreva a iteração como um mapa $\theta^{(t+1)} = M(\theta^{(t)})$, cujo ponto fixo θ^* é o ponto crítico para o qual o algoritmo converge. Expandindo em série de Taylor em torno de θ^*,

$$\theta^{(t+1)} - \theta^* \approx J(\theta^*)\,(\theta^{(t)} - \theta^*), \qquad J(\theta) = \frac{\partial M(\theta)}{\partial \theta^\top}.$$

Quando o resto da expansão é desprezível e o raio espectral de $J(\theta^*)$ é menor do que um, a convergência é **linear**: assintoticamente, o erro é transformado pela mesma matriz a cada iteração. O **raio espectral** é o maior módulo entre os autovalores de uma matriz.

Teorema 6.9 (Princípio da informação faltante)**.** *Sejam I_{com}, I_{obs} e I_{aus} as matrizes locais de informação dos dados completos, observados e ausentes, avaliadas no ponto fixo θ^*. Suponha que I_{com} seja definida positiva e que as condições de diferenciação do mapa iterativo sejam satisfeitas. Então*

$$I_{\text{obs}} = I_{\text{com}} - I_{\text{aus}}, \qquad e \qquad J(\theta^*) = I_{\text{com}}^{-1} I_{\text{aus}}. \tag{6.3}$$

Demonstração da ordem matricial. Escreva $\partial_1 Q$ para a derivada de $Q(\theta \mid \theta')$ em relação ao primeiro argumento. Como $M(\theta')$ maximiza esse argumento,

$$\partial_1 Q\{M(\theta') \mid \theta'\} = 0.$$

Diferenciando essa identidade em relação a θ' e avaliando em $\theta' = \theta^* = M(\theta^*)$, obtemos

$$-I_{\text{com}} J(\theta^*) + I_{\text{aus}} = 0.$$

A primeira parcela vem da curvatura da log-verossimilhança completa esperada; a segunda mede a alteração da distribuição condicional dos latentes quando o parâmetro corrente é perturbado. Multiplicar à esquerda por I_{com}^{-1} dá

$$J(\theta^*) = I_{\text{com}}^{-1} I_{\text{aus}}.$$

Por outro lado, a identidade de Louis, demonstrada na Equação (6.4), decompõe a curvatura observada como $I_{\text{obs}} = I_{\text{com}} - I_{\text{aus}}$. A ordem dos fatores não pode ser trocada sem uma hipótese de comutatividade. □

A leitura escalar é direta: a taxa local de convergência é a fração de informação ausente. Para um parâmetro vetorial, não há uma única fração antes de escolher uma direção. A matriz J tem os mesmos autovalores que a matriz simétrica

$$I_{\text{com}}^{-1/2} I_{\text{aus}} I_{\text{com}}^{-1/2},$$

e cada autovalor mede a fração de informação ausente na direção correspondente. A taxa local mais lenta é o maior desses autovalores. Assim, uma fração próxima de um significa que o erro quase não se reduz nessa direção.

Observação (Consequências práticas). • O algoritmo tende a ser rápido quando há pouca informação ausente.

- Em misturas com componentes muito sobrepostas, as responsabilidades γ_{ik} ficam todas próximas de $1/K$: a informação sobre a origem de cada ponto é quase nula, J se aproxima da identidade e a convergência é lentíssima. É o caso difícil por excelência.
- Acelerações usuais incluem extrapolação de Aitken sobre a sequência $\{\theta^{(t)}\}$, métodos quase-Newton aplicados ao mapa M e variantes que decompõem o passo de maximização em maximizações condicionais.

Nota (Critério de parada). Uma armadilha decorre diretamente da convergência linear: **não pare com base apenas em** $\left|\ell^{(t+1)} - \ell^{(t)}\right| < \varepsilon$. Perto de um platô, a log-verossimilhança pode mudar pouco enquanto θ ainda se move de modo relevante. Monitore também a variação relativa $\left\|\theta^{(t+1)} - \theta^{(t)}\right\| / (\left\|\theta^{(t)}\right\| + \varepsilon_0)$, na qual $\varepsilon_0 > 0$ evita divisão por zero, e verifique as equações de escore na solução.

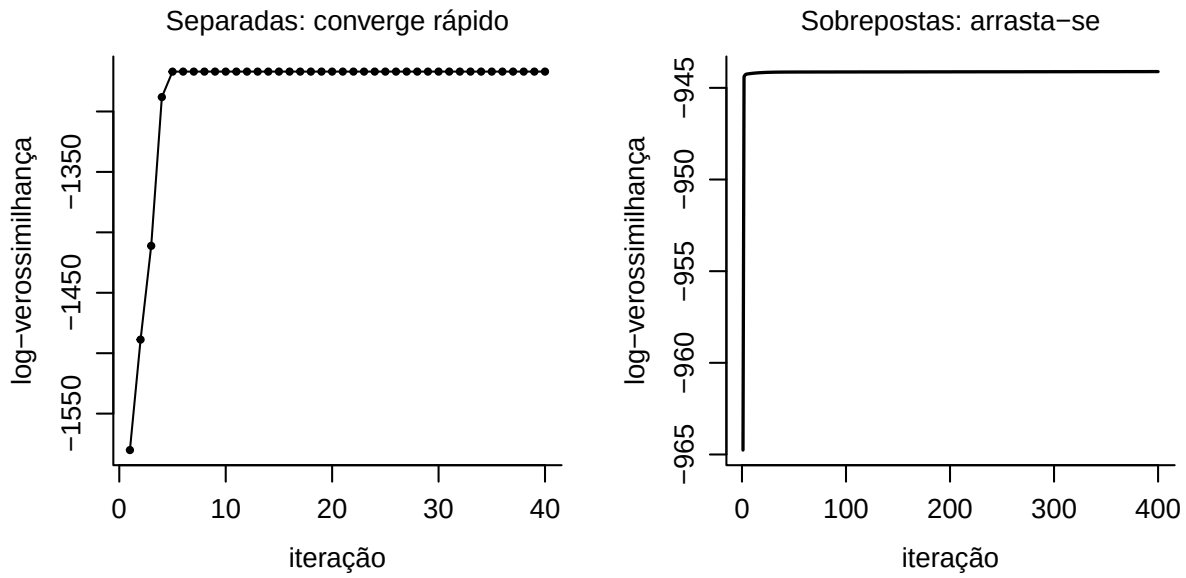


Figura 6.1: Log-verossimilhança ao longo das iterações para uma mistura de duas normais com $n = 600$. À esquerda, componentes bem separadas ($\Delta\mu = 6$); à direita, componentes sobrepostas ($\Delta\mu = 1$). Em ambos os casos a sequência é não decrescente, mas a monotonicidade nada diz sobre a velocidade. A razão entre erros sucessivos da log-verossimilhança é um diagnóstico empírico de lentidão, e não uma estimativa direta da matriz J. A sobreposição torna os rótulos difíceis de inferir e aumenta a informação ausente.

6.6.2 Erros-padrão

O algoritmo de esperança e maximização não produz I_{obs} como subproduto, pois não calcula diretamente a matriz Hessiana de $\ell(\theta; y)$. A **matriz Hessiana** reúne as segundas derivadas de uma função em relação aos parâmetros. Há três maneiras usuais de obter erros-padrão.

Fórmula de Louis. Louis 1982 mostrou que

$$I_{\text{obs}}(\theta) = \underbrace{\mathbb{E}\big[-\nabla^2 \ell_c(\theta; y, Z) \mid y, \theta\big]}_{I_{\text{com}}} - \underbrace{\operatorname{Var}\big(\nabla \ell_c(\theta; y, Z) \mid y, \theta\big)}_{I_{\text{aus}}}, \tag{6.4}$$

isto é, a informação observada é a informação completa esperada menos a *variância condicional do escore completo*. Ambos os termos são esperanças sob a mesma distribuição $Z \mid y, \theta$ que o passo E já calcula, de modo que o custo adicional é modesto. É a solução exata, ao preço de derivar duas quantidades a mais.

Método suplementado. Meng e Rubin 1991 propuseram obter J *numericamente*, perturbando cada coordenada de θ^* e observando o efeito de uma iteração do algoritmo. Denote por I a matriz identidade da mesma dimensão que J. De (6.3),

$$I_{\text{obs}} = I_{\text{com}}(I - J),$$

e, portanto,

$$\operatorname{Var}(\hat{\theta}) \approx I_{\text{obs}}^{-1} = (I - J)^{-1} I_{\text{com}}^{-1}.$$

Esse método exige apenas o código iterativo já escrito e I_{com}, tipicamente disponível em forma fechada. Mais uma vez, inverter a ordem dos fatores alteraria o resultado em geral.

Reamostragem *bootstrap*. Reamostre os dados e execute o algoritmo inteiro em cada reamostra, tomando o desvio padrão das estimativas (Capítulo 8). O procedimento evita derivar a informação em forma fechada, ao custo de B ajustes, em que B é o número de reamostras. Ele não elimina problemas de não regularidade: misturas com componentes quase coincidentes, variâncias na fronteira ou troca de rótulos exigem cuidado e podem invalidar a aproximação usual.

6.6.3 Limitações

Reunindo o que já apareceu ao longo do capítulo:

Limitação	**Mitigação**
Pode convergir a um ponto estacionário que não é o máximo global	Múltiplas inicializações; inicialização por k-médias ou agrupamento hierárquico em misturas
Verossimilhança não limitada em misturas	Restringir $\sigma_k^2 \geq \sigma_{\min}^2$; penalização; formulação bayesiana
Convergência local apenas linear, lenta com muita informação ausente	Extrapolação de Aitken, método quase-Newton ou maximizações condicionais
Não fornece erros-padrão diretamente	Fórmula de Louis, método suplementado ou reamostragem *bootstrap*
Critério de parada em ℓ é enganoso	Monitorar a variação relativa de θ
Troca de rótulos (*label switching*) em misturas	Fixar uma ordenação canônica das componentes na saída
Omitir o mecanismo é inválido quando a falta não é aleatória dado o observado	Análise de sensibilidade; modelar o mecanismo explicitamente

Observação (Quando preferir a maximização direta). Se a log-verossimilhança observada for fácil de derivar e a dimensão for pequena, os métodos de Newton–Raphson ou quase-Newton, como o implementado pela função literal `optim` da linguagem `R`, podem ser mais rápidos e produzir uma aproximação da Hessiana. O algoritmo de esperança e maximização é atraente quando cada passo preserva naturalmente as restrições e tem forma fechada. A monotonicidade, porém, não impede convergência para uma solução degenerada nem garante estabilidade numérica; essas propriedades devem ser verificadas no problema concreto.

6.7 Exemplos resolvidos

Exercício resolvido 6.1 : Mistura de duas normais: iteração numérica

Enunciado. Considere $n = 6$ observações: $\{-1{,}2,\ -0{,}5,\ 0{,}3,\ 3{,}8,\ 4{,}2,\ 5{,}1\}$. Modele-as como mistura de duas normais com $\sigma_1 = \sigma_2 = 1$ conhecidas e estime $\pi = (\pi_1, \pi_2)$ e $\mu = (\mu_1, \mu_2)$ pelo algoritmo de esperança e maximização. Inicialize $\pi^{(0)} = (0{,}5, 0{,}5)$, $\mu^{(0)} = (0, 4)$. Execute uma iteração.

Solução. Passo de esperança. Para cada y_i, calcule $\gamma_{i1}^{(0)} = \pi_1^{(0)}\phi(y_i; 0, 1)/[\pi_1^{(0)}\phi(y_i; 0, 1) + \pi_2^{(0)}\phi(y_i; 4, 1)]$. Aproximadamente:

y_i	$\phi(y_i;0,1)$	$\phi(y_i;4,1)$	γ_{i1}	γ_{i2}
-1,2	0,194	$5{,}4\times10^{-7}$	1,000	0,000
-0,5	0,352	$1{,}6\times10^{-5}$	1,000	0,000
0,3	0,381	$4{,}2\times10^{-4}$	0,999	0,001
3,8	$2{,}9\times10^{-4}$	0,391	0,001	0,999
4,2	$5{,}9\times10^{-5}$	0,391	0,000	1,000
5,1	$9{,}0\times10^{-7}$	0,218	0,000	1,000

Passo de maximização. Com os pesos γ_{ik} da tabela,

$$\pi_1^{(1)} = \tfrac{1}{6}\sum_i \gamma_{i1} \approx 0{,}500, \quad \mu_1^{(1)} = \frac{\sum_i \gamma_{i1}\, y_i}{\sum_i \gamma_{i1}} \approx -0{,}466, \quad \mu_2^{(1)} = \frac{\sum_i \gamma_{i2}\, y_i}{\sum_i \gamma_{i2}} \approx 4{,}365,$$

valores quase idênticos aos das médias simples dos dois blocos, $(-1{,}2-0{,}5+0{,}3)/3 \approx -0{,}467$ e $(3{,}8+4{,}2+5{,}1)/3 = 4{,}367$, pois as responsabilidades estão muito próximas de 0 ou 1. A primeira iteração já separa quase perfeitamente as componentes. Iterações subsequentes refinam minimamente os parâmetros.

Exercício resolvido 6.2 : Coeficiente da mistura como classificador

Enunciado. A partir das responsabilidades γ_{ik} ao final do algoritmo, descreva como classificar uma nova observação y_* na componente mais provável.
Solução. Aplica-se a regra de Bayes com os parâmetros estimados $\hat\theta$:

$$\hat{\mathbb{P}}(Z_* = k \mid y_*) = \frac{\hat\pi_k\, \phi(y_*;\hat\mu_k,\hat\sigma_k^2)}{\sum_l \hat\pi_l\, \phi(y_*;\hat\mu_l,\hat\sigma_l^2)}, \qquad \hat z_* = \arg\max_k \hat{\mathbb{P}}(Z_* = k \mid y_*).$$

Esse procedimento é a base da **análise discriminante quadrática** supervisionada e do agrupamento não supervisionado baseado em modelos probabilísticos.

Exercício resolvido 6.3 : Censura à direita: uma iteração

Enunciado. Sejam Y_i independentes, todos com distribuição $N(\mu,1)$. Observamos $\{-0{,}3,\ 0{,}1,\ 0{,}9,\ 1{,}5\}$ sem censura e dois valores censurados em $c=2$. Inicialize $\mu^{(0)}=0{,}5$ e execute uma iteração.
Solução. Passo de esperança. $\xi^{(0)} = (2-0{,}5)/1 = 1{,}5$; $\phi(1{,}5)/(1-\Phi(1{,}5)) \approx 0{,}129/0{,}067 \approx 1{,}93$. Logo $\mathbb{E}[Y_i \mid Y_i>2, \mu^{(0)}] \approx 0{,}5+1{,}93 = 2{,}43$ para cada censurado.
Passo de maximização. $\mu^{(1)} = (-0{,}3+0{,}1+0{,}9+1{,}5+2{,}43+2{,}43)/6 \approx 1{,}18$.
Compare com a substituição ingênua de cada valor censurado por $c=2$, que produz $\mu^{\text{ing}} \approx 1{,}03$. Como $\mathbb{E}(Y_i \mid Y_i>2) > 2$, essa substituição descarta a cauda além do limiar e tende a puxar a estimativa para baixo. Iterações sucessivas levam ao estimador de máxima verossimilhança sob o modelo normal censurado; uma única iteração ainda não é a solução final.

6.8 Laboratório computacional em R

Laboratório em R : Algoritmo manual para mistura gaussiana

Implementação do zero, em poucas linhas:

```
em_mistura <- function(y, K, max_iter = 100, tol = 1e-6) {
  n   <- length(y)
  pi  <- rep(1/K, K)
  mu  <- quantile(y, probs = (seq_len(K) - 0.5) / K)
  sd  <- rep(sd(y), K)
  for (it in seq_len(max_iter)) {
    parametros_antes <- c(pi, mu, sd)
    # Passo de esperanca, calculado em escala logaritmica
    log_dens <- sapply(seq_len(K), function(k)
      log(pi[k]) + dnorm(y, mu[k], sd[k], log = TRUE))
    maior     <- apply(log_dens, 1, max)
    log_total <- maior + log(rowSums(exp(log_dens - maior)))
    gamma     <- exp(log_dens - log_total)
    # Passo de maximizacao
    nk      <- colSums(gamma)
    pi      <- nk / n
    mu      <- as.numeric(crossprod(gamma, y) / nk)
    sd      <- sqrt(colSums(gamma * sweep(matrix(y, n, K), 2, mu)^2)
       / nk)
    sd      <- pmax(sd, sqrt(.Machine$double.eps))
    parametros_depois <- c(pi, mu, sd)
    erro_relativo <- sqrt(sum((parametros_depois - parametros_antes)
       ^2)) /
      (sqrt(sum(parametros_antes^2)) + sqrt(.Machine$double.eps))
    if (erro_relativo < tol) break
  }
  log_dens <- sapply(seq_len(K), function(k)
    log(pi[k]) + dnorm(y, mu[k], sd[k], log = TRUE))
  maior     <- apply(log_dens, 1, max)
  log_total <- maior + log(rowSums(exp(log_dens - maior)))
  gamma     <- exp(log_dens - log_total)
  list(pi = pi, mu = mu, sd = sd, gamma = gamma,
       log_verossimilhanca = sum(log_total), iteracoes = it,
       erro_relativo = erro_relativo)
}

set.seed(2026)
y <- c(rnorm(150, 0, 1), rnorm(100, 4, 1.5))
ajuste <- em_mistura(y, K = 2)
ajuste$pi; ajuste$mu; ajuste$sd
```

O cálculo das responsabilidades é feito na escala logarítmica. Em cada linha, subtrai-se o maior logaritmo antes de exponenciar; a subtração cancela no quociente e evita que densidades muito pequenas sejam arredondadas numericamente para zero. A parada usa a variação relativa do vetor completo de parâmetros.

Laboratório em R : Pacote mclust

O pacote `mclust` oferece uma implementação consolidada e compara diferentes números K de componentes pelo critério de Schwarz:

```
library(mclust)
```

```
set.seed(2026)
y <- c(rnorm(150, 0, 1), rnorm(100, 4, 1.5))
ajuste <- Mclust(y)
summary(ajuste, parameters = TRUE)
plot(ajuste, what = "density")
plot(ajuste, what = "BIC")
```

A forma usual do critério de Schwarz é

$$\text{Schwarz} = -2\hat{\ell} + d \log n,$$

em que $\hat{\ell}$ é a log-verossimilhança maximizada e d é o número de parâmetros livres; nessa convenção, escolhe-se o menor valor. A saída literal `BIC` do pacote usa o sinal oposto, $2\hat{\ell} - d \log n$, e por isso escolhe o *maior* valor. O critério auxilia a comparação, mas não torna automática a decisão científica sobre o número de componentes.

Laboratório em R : Visualização da convergência

Para apreciar a monotonicidade da log-verossimilhança:

```
em_mistura_log <- function(y, K, maxit = 500, tol = 1e-8, mu_ini =
   NULL) {
  # Retorna a sequencia de log-verossimilhancas e usa como
  # parada a variacao relativa do vetor de parametros
  n  <- length(y)
  pi <- rep(1/K, K)
  mu <- if (is.null(mu_ini)) quantile(y, (seq_len(K) - 0.5) / K)
     else mu_ini
  sd <- rep(sd(y), K)
  ll_seq <- numeric(0)
  for (it in seq_len(maxit)) {
    parametros_antes <- c(pi, mu, sd)
    log_dens <- sapply(seq_len(K), function(k)
      log(pi[k]) + dnorm(y, mu[k], sd[k], log = TRUE))
    maior     <- apply(log_dens, 1, max)
    log_total <- maior + log(rowSums(exp(log_dens - maior)))
    gamma     <- exp(log_dens - log_total)
    nk    <- colSums(gamma)
    pi    <- nk / n
    mu    <- as.numeric(crossprod(gamma, y) / nk)
    sd    <- sqrt(colSums(gamma * sweep(matrix(y, n, K), 2, mu)^2) /
        nk)
    sd    <- pmax(sd, sqrt(.Machine$double.eps))
    log_dens <- sapply(seq_len(K), function(k)
      log(pi[k]) + dnorm(y, mu[k], sd[k], log = TRUE))
    maior     <- apply(log_dens, 1, max)
    ll        <- sum(maior + log(rowSums(exp(log_dens - maior))))
    ll_seq <- c(ll_seq, ll)
    parametros_depois <- c(pi, mu, sd)
    erro_relativo <- sqrt(sum((parametros_depois - parametros_antes)
       ^2)) /
      (sqrt(sum(parametros_antes^2)) + sqrt(.Machine$double.eps))
    if (erro_relativo < tol) break
  }
  list(log_verossimilhanca = ll_seq, parametros = parametros_depois,
       erro_relativo = erro_relativo)
```

```
}

set.seed(1)
y  <- c(rnorm(100, -2, 1), rnorm(100, 2, 1))
ll <- em_mistura_log(y, K = 2)$log_verossimilhanca
plot(ll, type = "o", pch = 19, xlab = "iteracao",
     ylab = "log-verossimilhanca",
     main = "Monotonicidade da log-verossimilhanca")
```

A curva é estritamente não decrescente, ilustrando o Teorema 6.3.

Laboratório em R : Diagnóstico empírico da taxa de convergência

Variamos a separação entre as componentes e medimos a razão entre erros sucessivos da log-verossimilhança. Essa razão evidencia a lentidão, embora não seja uma estimativa direta dos autovalores de J, que descrevem o erro nos parâmetros.

```
set.seed(1)

# Mesma mistura, tres graus de sobreposicao
for (delta in c(6, 3, 1)) {          # separacao entre as medias
  y  <- c(rnorm(300, -delta/2, 1), rnorm(300, delta/2, 1))
  ll <- em_mistura_log(y, K = 2, maxit = 500)$log_verossimilhanca

  # Razao entre lacunas sucessivas da log-verossimilhanca
  lstar <- tail(ll, 1)
  erro  <- abs(head(ll, -1) - lstar)
  taxa  <- erro[-1] / head(erro, -1)
  cat("separacao =", delta,
      " iteracoes =", length(ll),
      " taxa ~", round(median(tail(taxa, 20)), 3), "\n")
}
```

A saída mostra a razão aproximando-se de um e o número de iterações crescendo à medida que as componentes se sobrepõem. Com $\delta = 1$, os rótulos são muito mais incertos e o algoritmo se move lentamente. Para verificar quantitativamente o Teorema 6.9, seria necessário aproximar numericamente o jacobiano J perturbando cada coordenada do ponto fixo.

Compare com o comportamento sob máximo local:

```
# Inicializacoes distintas podem levar a pontos criticos distintos
set.seed(7)
y <- c(rnorm(200, -2, 1), rnorm(200, 2, 1), rnorm(100, 6, 0.5))
ajustes <- replicate(20, {
  ini <- sample(y, 3)
  tail(em_mistura_log(y, K = 3, mu_ini = ini)$log_verossimilhanca,
       1)
})
round(sort(unique(round(ajustes, 2))), 2)    # varios maximos locais
```

Podem aparecer valores distintos de log-verossimilhança final. Por isso, rode múltiplas inicializações, descarte soluções degeneradas e, entre os ajustes admissíveis, retenha aquele de maior log-verossimilhança. A monotonicidade vale dentro de cada trajetória e não compara trajetórias diferentes.

Laboratório em R : Erros-padrão por *bootstrap*

O ajuste iterativo não devolve medidas de incerteza. Uma rota simples é reamostrar.

```
set.seed(1)
y <- c(rnorm(150, -2, 1), rnorm(150, 2, 1))

# Funcao que devolve o vetor de parametros estimados
estimar <- function(dados) {
  aj <- em_mistura(dados, K = 2)      # versao que devolve os
     parametros
  c(pi1 = aj$pi[1], mu1 = aj$mu[1], mu2 = aj$mu[2],
    s1 = aj$sd[1], s2 = aj$sd[2])
}

B <- 300
reps <- replicate(B, estimar(sample(y, replace = TRUE)))

round(rbind(estimativa = estimar(y),
            ep_boot    = apply(reps, 1, sd)), 3)
```

Atenção à troca de rótulos: em cada reamostra, a componente "1" pode sair como a de média maior ou menor, e a média das réplicas fica sem sentido. Imponha uma ordenação canônica antes de agregar:

```
estimar <- function(dados) {
  aj <- em_mistura(dados, K = 2)
  ord <- order(aj$mu)                    # ordena componentes por media
  c(pi1 = aj$pi[ord][1], mu = aj$mu[ord], sigma = aj$sd[ord])
}
```

Sem essa linha, os erros-padrão saem inflados por um artefato puramente rotulacional, um dos enganos mais comuns em aplicações de mistura.

6.9 Exercícios propostos

Ex. 6.1. Mostre que, em uma mistura gaussiana com (μ_k, σ_k^2) conhecidos e π desconhecido, o passo M reduz-se a $\hat{\pi}_k = \frac{1}{n}\sum_i \gamma_{ik}$. Justifique o uso do multiplicador de Lagrange.

Ex. 6.2. No problema de censura à direita normal (Proposição 6.5), derive a expressão explícita para $\mathbb{E}[Y \mid Y > c, \mu, \sigma^2]$ usando que $Y \mid Y > c$ é uma normal truncada.

Ex. 6.3. Demonstre o Teorema 6.3 *sem* usar a identidade (6.1), usando diretamente a desigualdade de Jensen aplicada a $\log L(\theta; y) = \log \int p(z \mid y; \theta') \cdot \frac{f(y,z;\theta)}{p(z \mid y;\theta')}\, dz$.

Ex. 6.4. *Mistura de duas exponenciais.* Sejam $Y_i \sim \pi \mathrm{Exp}(\lambda_1) + (1-\pi)\mathrm{Exp}(\lambda_2)$. Derive os passos E e M.

Ex. 6.5. Considere vetores $Y_i = (Y_{i1}, Y_{i2})$ independentes e com a mesma distribuição normal bivariada $N_2(\mu, \Sigma)$, com $\mu \in \mathbb{R}^2$ e Σ desconhecidos. Suponha que algumas componentes sejam ausentes. Esboce o algoritmo de esperança e maximização, identificando como a covariância aparece nos passos de esperança e de maximização.

Ex. 6.6. *Aplicação prática.* No conjunto `faithful` do pacote literal `datasets`, modele a coluna `eruptions`, que contém durações em minutos, como mistura de duas normais. Reporte $\hat{\pi}$, $\hat{\mu}$, $\hat{\sigma}$ e represente a densidade ajustada sobre o histograma.

Ex. 6.7. *Os três mecanismos.* Simule $n = 1000$ pares (X_i, Y_i) normais bivariados com média $(0, 0)$, variâncias 1 e correlação 0,7, mantendo X sempre observado. Gere valores ausentes em Y segundo: (a) falta completamente aleatória, com probabilidade 0,3; (b) falta aleatória dado X, com $\mathbb{P}(\text{faltar}) = \text{logistica}^{-1}(X)$; (c) falta não aleatória dado o observado, com $\mathbb{P}(\text{faltar}) = \text{logistica}^{-1}(Y)$. Em cada caso, estime $\mathbb{E}[Y]$ por casos completos e por um modelo normal bivariado ajustado pelo algoritmo deste capítulo. Reporte os vieses em 200 réplicas e explique os resultados à luz do Teorema 6.7.

Ex. 6.8. *Fração de informação ausente.* Considere variáveis Y_i independentes e com a mesma distribuição $N(\mu, 1)$, $i = 1, \dots, n$, das quais as m últimas estão ausentes por um mecanismo completamente aleatório. (a) Escreva o mapa iterativo $M(\mu)$ e mostre que $M(\mu) = \frac{n-m}{n}\bar{y}_{\text{obs}} + \frac{m}{n}\mu$. (b) Conclua que $J = m/n$ e verifique diretamente que essa é a fração de informação ausente, calculando $I_{\text{com}} = n$ e $I_{\text{obs}} = n - m$. (c) Determine quantas iterações são necessárias para reduzir o erro por um fator 10^{-6} quando m/n vale 0,1, 0,5 e 0,95. (d) Comente por que esse exemplo, apesar de trivial, pois o estimador de máxima verossimilhança é $\bar{y}_{\text{obs}}$, descreve a lentidão do algoritmo em problemas maiores.

Ex. 6.9. Deduza a fórmula de Louis (6.4) a partir da identidade fundamental $\ell(\theta; y) = Q(\theta \mid \theta') - H(\theta \mid \theta')$, diferenciando duas vezes em θ e avaliando em $\theta = \theta'$. *Sugestão*: mostre primeiro que $-\nabla^2 H(\theta \mid \theta)\big|_{\theta=\theta'} = -\text{Var}(\nabla \ell_c \mid y, \theta')$, usando que H é a esperança condicional do log da densidade condicional de Z. Em seguida, aplique (6.4) ao modelo do exercício anterior e verifique que devolve $I_{\text{obs}} = n - m$.

Ex. 6.10. *O critério de parada enganoso.* No modelo de mistura de duas normais com $\sigma_1 = \sigma_2 = 1$ conhecidas e componentes muito sobrepostas ($\mu_1 = -0{,}5$, $\mu_2 = 0{,}5$, $n = 500$), execute o algoritmo registrando a cada iteração tanto $\ell^{(t)}$ quanto $\left\|\theta^{(t)} - \theta^{(t-1)}\right\|$. Compare os dois critérios com tolerância 10^{-6}, quantifique quanto $\hat{\mu}$ ainda se move após a parada baseada em ℓ e proponha um critério híbrido.

Ex. 6.11. *Troca de rótulos.* Estime por *bootstrap* os erros-padrão dos parâmetros de uma mistura de duas normais ajustada a `faithful$eruptions`, com $B = 300$. (a) Faça-o *sem* impor ordenação das componentes e reporte os erros-padrão. (b) Refaça impondo $\hat{\mu}_1 < \hat{\mu}_2$ em cada reamostra. (c) Explique a diferença e mostre, com um histograma das réplicas de $\hat{\mu}_1$, exatamente o que a ausência de ordenação produz. (d) Esse problema afeta também a estimativa pontual, ou apenas a medida de incerteza? Justifique.

Notas e leituras complementares

- Dempster, Laird e Rubin 1977: artigo seminal, com a primeira formalização geral e já com o princípio da informação faltante.
- McLachlan & Krishnan (2008): tratamento abrangente do algoritmo de esperança e maximização e de suas extensões.
- Rubin 1976: origem da classificação dos mecanismos de falta e do conceito de ignorabilidade; Little e Rubin 2019 apresenta um tratamento amplo da área.
- Louis 1982 e Meng e Rubin 1991: duas rotas clássicas para obter erros-padrão a partir do algoritmo iterativo.
- Efron e Hastie 2016, §9.5: conexão com o caso paramétrico de Bayes empírico do Capítulo 1.

6.10 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Algoritmo de esperança e maximização	*expectation–maximization algorithm*	EM
Passo de esperança	*expectation step*	E-step
Passo de maximização	*maximization step*	M-step
Algoritmo generalizado de esperança e maximização	*generalized expectation–maximization algorithm*	GEM
Dados observados	*observed data*	—
Dados completos	*complete data*	—
Dados faltantes	*missing data*	—
Variável latente	*latent variable*	—
Log-verossimilhança observada	*observed-data log-likelihood*	—
Log-verossimilhança de dados completos	*complete-data log-likelihood*	—
Lema de Gibbs	*Gibbs' inequality*	—
Monotonicidade	*monotonicity*	—
Mistura gaussiana	*Gaussian mixture model*	GMM
Responsabilidade	*responsibility*	—
Troca de rótulos	*label switching*	—
Falta completamente aleatória	*missing completely at random*	MCAR
Falta aleatória dado o observado	*missing at random*	MAR
Falta não aleatória dado o observado	*missing not at random*	MNAR
Ignorabilidade	*ignorability*	—
Imputação múltipla	*multiple imputation*	MI
Análise de sensibilidade	*sensitivity analysis*	—
Informação observada	*observed information*	—
Informação completa	*complete information*	—
Informação faltante	*missing information*	—
Razão de Mills	*Mills ratio*	—
Matriz Hessiana	*Hessian matrix*	—

Capítulo 7

Jackknife

Objetivos da unidade

- Apresentar o *jackknife* como técnica geral de estimação não paramétrica de viés e variância.
- Definir as amostras com uma observação removida, os pseudo-valores de Tukey e os estimadores de viés e variância.
- Demonstrar a conexão com funções de influência por meio de uma expansão funcional de Taylor.
- Reconhecer as limitações do método para estatísticas insuficientemente suaves e introduzir a remoção de d observações.

Leitura primária: Efron e Hastie 2016, capítulo 10 (parte 1).
Leitura complementar: Quenouille 1956; Tukey 1958; Efron e R. J. Tibshirani 1993, capítulos 10–11.

7.1 Motivação

Suponha que $\hat{\theta} = T(X_1, \ldots, X_n)$ seja um estimador de um parâmetro populacional θ. Seu **viés** é $\mathbb{E}(\hat{\theta}) - \theta$ e sua **variância** é $\mathrm{Var}(\hat{\theta})$. Para a média amostral, essas quantidades têm forma fechada simples. Para estimadores mais complexos, como razões, correlações e coeficientes de regressões não lineares, os cálculos podem ser difíceis ou depender fortemente de hipóteses distribucionais.

O *jackknife*, desenvolvido por Quenouille 1956 e Tukey 1958, fornece estimativas *não paramétricas* de viés e variância que dependem apenas do *algoritmo* usado para calcular $\hat{\theta}$. A ideia central: avaliar como $\hat{\theta}$ muda quando uma observação é removida.

Nota (Etimologia). O nome *jackknife* (canivete) refere-se à versatilidade do método: como um canivete, é uma ferramenta de uso geral, aplicável a uma vasta classe de estimadores sem modificações específicas. A metáfora foi introduzida por Tukey.

7.2 Definição

Definição 7.1 (Pseudo-amostras e estimadores *jackknife*)**.** Seja $\hat{\theta} = T(X_1, \ldots, X_n)$. Para cada $i = 1, \ldots, n$, a *amostra reduzida* i é o conjunto de dados obtido removendo a observação i, e a *réplica com a observação* i *removida* é o estimador avaliado nessa amostra:

$$\hat{\theta}_{(-i)} = T(X_1, \ldots, X_{i-1}, X_{i+1}, \ldots, X_n).$$

Defina a média das réplicas

$$\hat{\theta}_{(\cdot)} = \frac{1}{n} \sum_{i=1}^{n} \hat{\theta}_{(-i)}.$$

Os estimadores *jackknife* de viés e variância são

$$\widehat{\mathrm{vies}}_{\mathrm{jack}} = (n-1)(\hat{\theta}_{(\cdot)} - \hat{\theta}), \tag{7.1}$$

$$\widehat{\mathrm{Var}}_{\mathrm{jack}} = \frac{n-1}{n}\sum_{i=1}^{n}(\hat{\theta}_{(-i)} - \hat{\theta}_{(\cdot)})^2. \tag{7.2}$$

Definição 7.2 (Estimador *jackknife* corrigido por viés)**.**

$$\hat{\theta}_{\mathrm{jack}} = \hat{\theta} - \widehat{\mathrm{vies}}_{\mathrm{jack}} = n\,\hat{\theta} - (n-1)\,\hat{\theta}_{(\cdot)}.$$

Observação (Notação assintótica)*.* Para sequências determinísticas positivas b_n, escrever $a_n = O(b_n)$ significa que $|a_n|/b_n$ permanece limitado quando n cresce. Para variáveis aleatórias R_n, escrever $R_n = o_p(b_n)$ significa que R_n/b_n converge em probabilidade para zero; escrever $R_n = O_p(b_n)$ significa que R_n/b_n permanece limitado em probabilidade. Os símbolos $\xrightarrow{p}$ e $\xrightarrow{d}$ denotam, respectivamente, convergência em probabilidade e convergência em distribuição.

7.2.1 Justificativa intuitiva

Para fixar a intuição, considere um estimador cujo viés admita expansão $\mathbb{E}[\hat{\theta}] = \theta + a_1/n + a_2/n^2 + O(n^{-3})$. Como $\hat{\theta}_{(-i)}$ é calculado em uma amostra de tamanho $n-1$,

$$\mathbb{E}[\hat{\theta}_{(-i)}] = \theta + \frac{a_1}{n-1} + \frac{a_2}{(n-1)^2} + O(n^{-3}),$$

e portanto $\mathbb{E}[\hat{\theta}_{(\cdot)}] = \theta + a_1/(n-1) + a_2/(n-1)^2 + O(n^{-3})$. Daí

$$\mathbb{E}[(n-1)(\hat{\theta}_{(\cdot)} - \hat{\theta})] = a_1\left(\frac{n-1}{n-1} - \frac{n-1}{n}\right) + a_2\left(\frac{n-1}{(n-1)^2} - \frac{n-1}{n^2}\right) + O(n^{-2}) = \frac{a_1}{n} + O(n^{-2}).$$

Ou seja, $\widehat{\mathrm{vies}}_{\mathrm{jack}}$ estima o viés de primeira ordem a_1/n com erro $O(n^{-2})$. Subtraindo-o de $\hat{\theta}$, obtemos um estimador com viés $O(n^{-2})$ em vez de $O(n^{-1})$: a redução de viés é exatamente o objetivo original de Quenouille.

7.3 Pseudo-valores

Definição 7.3 (Pseudo-valor de Tukey)**.**

$$\hat{\theta}_i^{*} = n\,\hat{\theta} - (n-1)\,\hat{\theta}_{(-i)}, \qquad i = 1, \ldots, n.$$

Nota (Colisão notacional)*.* O asterisco em $\hat{\theta}_i^{*}$ é tradicional, mas colide com a notação $\hat{\theta}^{*}$ das réplicas *bootstrap* do Capítulo 8. Os pseudo-valores *não* são réplicas *bootstrap*: o contexto deixará claro qual objeto está em jogo.

Os pseudo-valores podem ser interpretados como "contribuições individuais" de cada observação ao estimador. Note que sua média coincide com o estimador corrigido:

$$\bar{\hat{\theta}}^{*} = \frac{1}{n}\sum_{i=1}^{n}\hat{\theta}_i^{*} = n\,\hat{\theta} - (n-1)\,\hat{\theta}_{(\cdot)} = \hat{\theta}_{\mathrm{jack}}.$$

Proposição 7.4 (Reescrita da variância *jackknife*)**.**

$$\widehat{\mathrm{Var}}_{jack} = \frac{1}{n(n-1)}\sum_{i=1}^{n}(\hat{\theta}_i^{*} - \bar{\hat{\theta}}^{*})^2.$$

Demonstração. $\hat{\theta}_i^{*} - \bar{\hat{\theta}}^{*} = -(n-1)(\hat{\theta}_{(-i)} - \hat{\theta}_{(\cdot)})$. Substituindo na soma e multiplicando pelo fator $1/(n(n-1))$, obtém-se exatamente a fórmula (7.2). □

A Proposição 7.4 remonta a Tukey e usa os pseudo-valores por analogia com uma amostra de contribuições individuais. Eles não são, em geral, observações independentes. O fator $1/(n(n-1))$ reflete que estamos estimando a variância *do estimador* $\hat{\theta}$, não a variância das observações individuais.

7.4 Conexão com funções de influência

A intuição mais profunda do *jackknife* vem da teoria estatística clássica de *funções de influência*.

Definição 7.5 (Função de influência)**.** Seja $T(F)$ um funcional estatístico avaliado na distribuição F. Para um ponto x, denote por δ_x a distribuição que concentra toda a probabilidade em x. A *função de influência* de T em F é

$$\mathrm{Infl}(x; T, F) = \lim_{\varepsilon \downarrow 0} \frac{T\{(1-\varepsilon)F + \varepsilon\delta_x\} - T(F)}{\varepsilon},$$

quando o limite existe.

A função de influência mede o efeito infinitesimal de adicionar uma observação no ponto x à distribuição F.

Defina a **distribuição empírica** por

$$\hat{F}_n = \frac{1}{n}\sum_{i=1}^{n} \delta_{X_i};$$

ela atribui massa $1/n$ a cada observação.

Teorema 7.6 (Variância assintótica pela função de influência)**.** *Suponha que $X_1, \ldots, X_n$ sejam independentes e tenham a mesma distribuição F, que $\mathbb{E}_F\{\mathrm{Infl}(X; T, F)^2\} < \infty$ e que o funcional admita a expansão assintoticamente linear*

$$T(\hat{F}_n) - T(F) = \int \mathrm{Infl}(x; T, F)\, d(\hat{F}_n - F)(x) + o_p(n^{-1/2}).$$

Então

$$\sqrt{n}\{T(\hat{F}_n) - T(F)\} \xrightarrow{d} N\Big(0, \mathbb{E}_F\{\mathrm{Infl}(X; T, F)^2\}\Big).$$

Demonstração. A derivada de um funcional ao longo de distribuições tem média zero sob F, isto é, $\int \mathrm{Infl}(x; T, F)\, dF(x) = 0$. Substituindo a definição de $\hat{F}_n$ na expansão,

$$\sqrt{n}\{T(\hat{F}_n) - T(F)\} = \frac{1}{\sqrt{n}}\sum_{i=1}^{n} \mathrm{Infl}(X_i; T, F) + o_p(1).$$

As parcelas da soma são independentes, têm média zero e variância finita. O teorema central do limite implica a convergência para uma distribuição normal com a variância declarada, e o termo $o_p(1)$ desaparece em probabilidade. A demonstração também explicita a suavidade necessária: não basta que a derivada pontual exista; o resto da expansão precisa ser pequeno na sequência empírica. □

Proposição 7.7 (Aproximação amostral da função de influência)**.** *Quando T admite uma expansão funcional uniforme nas amostras reduzidas,*

$$n\,(\hat{\theta}_{(-i)} - \hat{\theta}_{(\cdot)}) = -\,\mathrm{Infl}(X_i; T, F) + o_p(1),$$

uniformemente nos índices relevantes, e

$$n\,\widehat{\mathrm{Var}}_{jack} \xrightarrow{p} \mathbb{E}_F\{\mathrm{Infl}(X; T, F)^2\}.$$

Justificativa. A distribuição da amostra sem X_i é

$$\hat{F}_{(-i)} = \frac{n\hat{F}_n - \delta_{X_i}}{n-1} = \hat{F}_n + \frac{\hat{F}_n - \delta_{X_i}}{n-1}.$$

Uma expansão funcional em torno de $\hat{F}_n$ fornece

$$T(\hat{F}_{(-i)}) - T(\hat{F}_n) = -\frac{1}{n-1}\,\mathrm{Infl}(X_i; T, \hat{F}_n) + r_{ni},$$

porque a média empírica das funções de influência é zero. Centrar as réplicas em $\hat{\theta}_{(\cdot)}$ remove termos comuns. Se $\max_i |r_{ni}| = o_p(n^{-1})$ e a função de influência empírica converge para a populacional, multiplicar por n produz a primeira aproximação. Substituí-la em (7.2) e aplicar a lei dos grandes números produz a segunda conclusão. □

7.5 Limitações

7.5.1 Estatísticas insuficientemente suaves

A Proposição 7.7 exige mais do que a existência de uma derivada funcional: requer que o resto da expansão seja uniformemente pequeno para as perturbações discretas produzidas pela remoção de observações. O funcional mediana, por exemplo, é diferenciável em um sentido adequado quando a densidade é positiva na mediana, o que explica a validade de sua aproximação normal e da reamostragem *bootstrap*. Ainda assim, a remoção de apenas uma observação não produz uma aproximação de variância consistente, como mostra o exemplo seguinte.

Exemplo 7.8 (Falha do *jackknife* para a mediana)**.** Seja $\hat{\theta}_n$ a mediana amostral. Pode-se mostrar que $n\,\widehat{\mathrm{Var}}_{\mathrm{jack}}$ não converge em probabilidade para a variância assintótica de $\sqrt{n}\hat{\theta}_n$; seu limite é aleatório. Sua esperança assintótica também excede o alvo. Veja o Exercício 7.3.

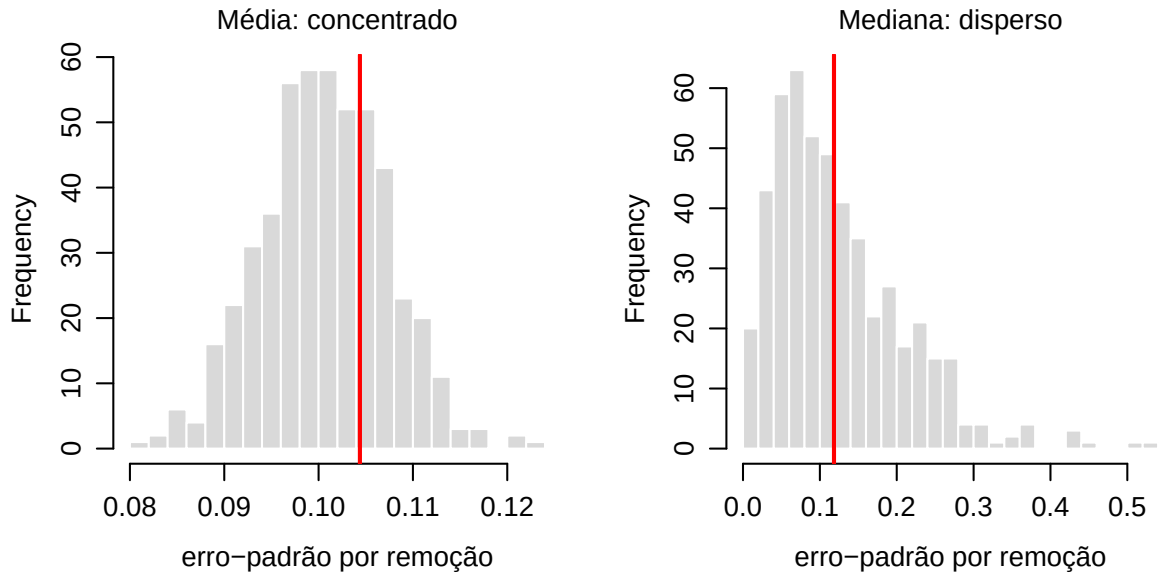


Figura 7.1: Distribuição do erro-padrão estimado pelo *jackknife* em 500 amostras de tamanho $n = 99$ da $N(0,1)$; a linha vermelha marca o valor verdadeiro. Para a **média** (esquerda) as estimativas concentram-se em torno do alvo. Para a **mediana** (direita) a dispersão é enorme e, este é o ponto, *não diminui com* n: o coeficiente de variação permanece em torno de 0,7 de $n = 49$ a $n = 399$. Na escala da variância, $\mathbb{E}[\widehat{\mathrm{Var}}_{\mathrm{jack}}]/\mathrm{Var}$ vale 1,29 em $n = 25$ e sobe para 1,53 em $n = 399$, confirmando que a razão não tende a 1. A distribuição é assimétrica à direita, de modo que a amostra *típica* subestima enquanto a *média* superestima.

7.5.2 Remoção de d observações

A solução proposta para estatísticas não suaves é remover *blocos* de $d > 1$ observações em vez de uma única.

Definição 7.9 (Método com remoção de d observações)**.** Para $d \in \{1, 2, \ldots, n-1\}$, considere os

$$N_d = \binom{n}{d}$$

subconjuntos $S \subset \{1, \ldots, n\}$ com $|S| = d$. Seja $\hat{\theta}_{(-S)} = T(\{X_i : i \notin S\})$ e defina

$$\hat{\theta}_{(\cdot,d)} = \frac{1}{N_d} \sum_{|S|=d} \hat{\theta}_{(-S)}.$$

As estimativas de viés e variância e o estimador corrigido são, respectivamente,

$$\widehat{\text{vies}}_d = \frac{n-d}{d}\{\hat{\theta}_{(\cdot,d)} - \hat{\theta}\},$$
$$\widehat{\text{Var}}_d = \frac{n-d}{dN_d} \sum_{|S|=d} \{\hat{\theta}_{(-S)} - \hat{\theta}_{(\cdot,d)}\}^2,$$
$$\hat{\theta}_{d,\text{corr}} = \hat{\theta} - \widehat{\text{vies}}_d = \frac{n}{d}\hat{\theta} - \frac{n-d}{d}\hat{\theta}_{(\cdot,d)}.$$

Quando $d = 1$, essas expressões se reduzem às fórmulas (7.1) e (7.2).

Para a mediana, uma escolha assintótica usual requer simultaneamente $d \to \infty$, $d/n \to 0$ e $\sqrt{n}/d \to 0$. Por exemplo, $d = \lfloor n^{2/3} \rfloor$ satisfaz as três condições. A escolha $d = \lfloor \sqrt{n} \rfloor$ *não* satisfaz a terceira, pois $\sqrt{n}/d$ tende a um. Como N_d pode ser enorme, aplicações grandes aproximam a soma por um conjunto planejado ou aleatório de subconjuntos; a variabilidade adicional dessa aproximação deve ser considerada. Detalhes em Efron e R. J. Tibshirani 1993, Cap. 11.

7.6 Exemplos resolvidos

Exercício resolvido 7.1 : *Jackknife* para a média

Enunciado. Seja $\hat{\theta} = \bar{X} = (1/n)\sum_i X_i$. Mostre que $\widehat{\text{vies}}_{\text{jack}} = 0$ e $\widehat{\text{Var}}_{\text{jack}} = s^2/n$, onde $s^2 = (1/(n-1))\sum_i (X_i - \bar{X})^2$.
Solução. Para a média, $\hat{\theta}_{(-i)} = (n\bar{X} - X_i)/(n-1)$. Daí

$$\hat{\theta}_{(\cdot)} = \frac{1}{n}\sum_{i=1}^{n} \frac{n\bar{X} - X_i}{n-1} = \frac{n^2\bar{X} - n\bar{X}}{n(n-1)} = \bar{X}.$$

Logo $\widehat{\text{vies}}_{\text{jack}} = (n-1)(\bar{X} - \bar{X}) = 0$, como esperado (o estimador da média já é não viesado). Para a variância,

$$\hat{\theta}_{(-i)} - \hat{\theta}_{(\cdot)} = \frac{n\bar{X} - X_i}{n-1} - \bar{X} = \frac{\bar{X} - X_i}{n-1}.$$

Substituindo em (7.2),

$$\widehat{\text{Var}}_{\text{jack}} = \frac{n-1}{n}\sum_i \frac{(\bar{X} - X_i)^2}{(n-1)^2} = \frac{1}{n(n-1)}\sum_i (X_i - \bar{X})^2 = \frac{s^2}{n},$$

que é exatamente o estimador clássico de $\text{Var}(\bar{X})$.

Exercício resolvido 7.2 : *Jackknife* para a variância amostral

Enunciado. Considere $\hat{\theta} = (1/n)\sum_i (X_i - \bar{X})^2$ (variância amostral com denominador n). É bem sabido que $\mathbb{E}[\hat{\theta}] = (n-1)/n \cdot \sigma^2$, viés $-\sigma^2/n$. Mostre que $\widehat{\text{vies}}_{\text{jack}}$ recupera essa correção.

Solução. Após cálculos algébricos (Exercício 7.2),

$$\hat{\theta}_{(\cdot)} = \frac{n(n-2)}{(n-1)^2}\,\hat{\theta},$$

donde $\widehat{\text{vies}}_{\text{jack}} = (n-1)(\hat{\theta}_{(\cdot)} - \hat{\theta}) = -\hat{\theta}/(n-1)$. O resultado é *exato*, não apenas aproximado: como $\mathbb{E}[\hat{\theta}] = (n-1)\sigma^2/n$, segue $\mathbb{E}[\widehat{\text{vies}}_{\text{jack}}] = -\sigma^2/n$, exatamente o viés verdadeiro. O estimador corrigido $\hat{\theta}_{\text{jack}} = n\hat{\theta} - (n-1)\hat{\theta}_{(\cdot)}$ resulta em $(n/(n-1))\hat{\theta} = (1/(n-1))\sum (X_i - \bar{X})^2$, exatamente o estimador clássico não viesado.

Exercício resolvido 7.3 : *Jackknife* para o coeficiente de correlação

Enunciado. Considere $n = 5$ pares (X_i, Y_i) com correlação amostral $\hat{\rho} = 0{,}80$. Suponha que, ao remover cada par individualmente, as cinco correlações sejam $\{0{,}75, 0{,}82, 0{,}79, 0{,}65, 0{,}88\}$. Calcule a estimativa do viés e o erro-padrão estimado de $\hat{\rho}$.

Solução. $\hat{\rho}_{(\cdot)} = (0{,}75 + 0{,}82 + 0{,}79 + 0{,}65 + 0{,}88)/5 = 0{,}778$. Assim, $\widehat{\text{vies}}_{\text{jack}} = 4(0{,}778 - 0{,}80) = -0{,}088$. Além disso,

$$\sum_i (\hat{\rho}_{(-i)} - 0{,}778)^2 = 0{,}02948,$$

de modo que $\widehat{\text{Var}}_{\text{jack}} = (4/5)0{,}02948 = 0{,}023584$ e o erro-padrão estimado é $\sqrt{0{,}023584} \approx 0{,}154$. A transformação

$$z = \operatorname{arctanh}(\hat{\rho}) = \frac{1}{2}\log\!\left(\frac{1+\hat{\rho}}{1-\hat{\rho}}\right)$$

é usada para estabilizar a variância e melhorar a aproximação normal sob normalidade bivariada; ela não garante, por si só, menor viés em toda amostra.

7.7 Laboratório computacional em R

Laboratório em R : *Jackknife* manual

```
jackknife <- function(x, estatistica) {
  n       <- length(x)
  theta   <- estatistica(x)
  thetas <- sapply(seq_len(n), function(i) estatistica(x[-i]))
  theta_pt <- mean(thetas)
  vies      <- (n - 1) * (theta_pt - theta)
  var_jack <- (n - 1) / n * sum((thetas - theta_pt)^2)
  list(theta = theta, vies = vies, ep = sqrt(var_jack),
       theta_corr = theta - vies)
}

set.seed(1)
y <- rgamma(40, shape = 2, rate = 1)
jackknife(y, sd)
```

A saída traz $\hat{\sigma}$, viés estimado, erro padrão e estimador corrigido.

Laboratório em R : Falha do *jackknife* para a mediana

```
set.seed(2026)

# Simulacao: comparar jackknife com a variancia exata
R <- 500
n <- 99

variancia_exata <- 1 / (4 * n * dnorm(0)^2)    # Med ~ N(0, 1/(4n f(M
    )^2))

ep_jack <- numeric(R)
for (r in seq_len(R)) {
  x           <- rnorm(n)
  ep_jack[r] <- jackknife(x, median)$ep
}

c(media_ep_jack = mean(ep_jack), ep_assintotico = sqrt(
    variancia_exata))
```

Na escala do erro-padrão, as médias enganam: `media_ep_jack` = 0,1238 fica até ligeiramente *abaixo* de `ep_assintotico` = 0,1260. A falha aparece na escala da *variância*, pois mean(`ep_jack`^{2}) excede a variância exata por um fator de aproximadamente 1,4. Ela aparece, sobretudo, na dispersão enorme das estimativas: o coeficiente de variação é $\approx 0{,}7$ e a mediana de `ep_jack` (0,104) fica bem abaixo da média, refletindo a forte assimetria à direita da Figura 7.1. É essa distribuição que não se concentra, ilustrando a inconsistência do *jackknife* para a mediana.

Laboratório em R : Comparação entre *jackknife* e *bootstrap*

```
library(boot)

set.seed(1)
y <- rgamma(50, 2, 1)

# Jackknife (manual)
jack <- jackknife(y, function(z) sd(z))

# Bootstrap (B = 2000)
boot_obj <- boot(y, function(d, idx) sd(d[idx]), R = 2000)

cat("ep jackknife:", round(jack$ep, 4), "\n",
    "ep bootstrap:", round(sd(boot_obj$t), 4), "\n")
```

Para o desvio-padrão amostral (estatística suave), os dois métodos produzem valores próximos. Repita com `median` e veja a divergência sistemática.

7.8 Exercícios propostos

Ex. 7.1. Verifique pelas fórmulas explícitas (sem recorrer ao Exemplo 7.1) que $\widehat{\mathrm{vies}}_{\mathrm{jack}}(\bar{X}) = 0$ e $\widehat{\mathrm{Var}}_{\mathrm{jack}}(\bar{X}) = s^2/n$.

Ex. 7.2. Para $\hat{\theta} = (1/n)\sum_i (X_i - \bar{X})^2$, mostre que

$$\hat{\theta}_{(-i)} = \frac{n}{n-1}\,\hat{\theta} - \frac{n}{(n-1)^2}(X_i - \bar{X})^2.$$

Conclua que $\hat{\theta}_{(\cdot)} = \dfrac{n(n-2)}{(n-1)^2}\,\hat{\theta}$ e, portanto, que $\widehat{\mathrm{vies}}_{\mathrm{jack}}(\hat{\theta}) = -\hat{\theta}/(n-1)$, cuja esperança é *exatamente* $-\sigma^2/n$.

Ex. 7.3. Considere $X_1, \ldots, X_n$ independentes e com a mesma distribuição contínua F, cuja densidade f é positiva na mediana populacional M. Tome $n = 2m$ par, de modo que $\hat{\theta}_n = (X_{(m)} + X_{(m+1)})/2$. Mostre que

$$\hat{\theta}_{(-i)} = \begin{cases} X_{(m)} & \text{se } X_i \geq X_{(m+1)}, \\ X_{(m+1)} & \text{se } X_i \leq X_{(m)}, \end{cases}$$

ou seja, as réplicas com uma observação removida assumem apenas *dois* valores. Conclua que

$$\widehat{\mathrm{Var}}_{\mathrm{jack}} = \frac{n-1}{4}\,\big(X_{(m+1)} - X_{(m)}\big)^2.$$

Como o espaçamento central satisfaz $X_{(m+1)} - X_{(m)} = O_p(1/n)$, a estimativa tem ordem $O_p(1/n)$, que é a *mesma* ordem da variância verdadeira da mediana. A falha real é de *inconsistência*: usando que $n\,(X_{(m+1)} - X_{(m)})$ converge em distribuição para uma exponencial de média $1/f(M)$, mostre que

$$n\,\widehat{\mathrm{Var}}_{\mathrm{jack}} \xrightarrow{d} \left(\frac{\chi^2_2}{2}\right)^2 \frac{1}{4f(M)^2},$$

um limite *aleatório*, em vez de convergir em probabilidade para a variância assintótica $1/(4f(M)^2)$. Como $\mathbb{E}[(\chi^2_2/2)^2] = 2$, a estimativa superestima em média (por um fator próximo de 2 no limite) e seu coeficiente de variação não decai com n, em concordância com a Figura 7.1.

Ex. 7.4. Mostre que, para $\hat{\theta} = \bar{X}$, os pseudo-valores são exatamente $\hat{\theta}^*_i = X_i$. Interprete.

Ex. 7.5. Sob uma população normal bivariada, use o método delta para mostrar que a transformação $z = \frac{1}{2}\log\{(1+\hat{\rho})/(1-\hat{\rho})\}$ tem variância assintótica que não depende de ρ. A aproximação de pequena amostra usual substitui essa variância por $1/(n-3)$. Explique por que a estabilização da variância pode melhorar uma aproximação normal e discuta por que ela não garante que a estimativa de viés por remoção de observações seja sempre menor.

Ex. 7.6. *Aplicação prática.* No conjunto `Boston` (`ISLR2`), modele `medv` contra `rm` e `lstat` via regressão linear. Use *jackknife* para estimar o erro padrão de $\hat{\beta}_{\mathrm{rm}}$ e compare com o erro padrão clássico do `summary()`.

Notas e leituras complementares

- Quenouille 1956: artigo seminal sobre redução de viés.
- Tukey 1958: introdução dos pseudo-valores e da estimativa de variância.
- Efron e R. J. Tibshirani 1993, Cap. 10–11: tratamento abrangente, com aplicações e variantes (delete-d, *infinitesimal jackknife*).
- Efron e Hastie 2016, Cap. 10: discussão da relação *jackknife–bootstrap* e função de influência.

7.9 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Método jackknife	*jackknife*	—
Pseudo-amostra com uma observação removida	*leave-one-out sample*	LOO sample
Réplica jackknife	*jackknife replicate*	—
Estimativa jackknife de viés	*jackknife estimate of bias*	—
Estimativa jackknife de erro padrão	*jackknife estimate of standard error*	SE
Estimador corrigido por viés	*bias-corrected estimator*	—
Pseudo-valor de Tukey	*Tukey pseudovalue*	—
Distribuição empírica	*empirical distribution*	—
Funcional estatístico	*statistical functional*	—
Função de influência	*influence function*	IF
Valor de influência empírico	*empirical influence value*	EIV
Jackknife infinitesimal	*infinitesimal jackknife*	IJ
Estatística suave	*smooth statistic*	—
Estatística não suave	*nonsmooth statistic*	—
Remoção de d observações	*delete-d jackknife*	—
Método delta	*delta method*	—
Transformação de Fisher	*Fisher transformation*	—
Transformação estabilizadora da variância	*variance-stabilizing transformation*	VST

Capítulo 8

Bootstrap

Objetivos da unidade

- Definir o princípio *bootstrap* (*plug-in*) e a distribuição empírica como estimador não paramétrico da distribuição populacional.
- Distinguir *bootstrap* não paramétrico, paramétrico e suavizado.
- Construir intervalos de confiança pela aproximação normal, por percentis, por correção de viés, por correção de viés e aceleração e por estudentização.
- Aplicar o método em regressão, distinguindo a reamostragem de pares da reamostragem de resíduos.

Leitura primária: Efron e Hastie 2016, capítulos 10–11.
Leitura complementar: Efron 1979; Efron e R. J. Tibshirani 1993.

8.1 Motivação e princípio do *plug-in*

Sejam $X_1, \ldots, X_n$ observações independentes com distribuição populacional F, e seja $\hat{\theta} = T(X_1, \ldots, X_n)$ uma estatística, isto é, uma função calculada a partir da amostra. A **distribuição amostral** G_n é a distribuição que $\hat{\theta}$ teria sob repetidas amostras independentes de tamanho n de F. Conhecer G_n permite construir intervalos de confiança, testar hipóteses e estimar erros-padrão. Em situações canônicas, como a média de uma população normal, G_n é tratável; em geral, não.

O **bootstrap**, introduzido por Efron 1979, é uma resposta sistemática a esse problema. A ideia central é substituir F pela sua *estimativa empírica*.

Definição 8.1 (Distribuição empírica)**.** Para uma afirmação A, denote por $\mathbb{1}\{A\}$ o indicador, igual a um quando A é verdadeira e a zero caso contrário. A distribuição empírica de $X_1, \ldots, X_n$ é

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}\{X_i \leq x\}.$$

Equivalentemente, $\hat{F}_n$ atribui massa $1/n$ a cada X_i.

Teorema 8.2 (Glivenko–Cantelli)**.** *Se $X_1, X_2, \ldots$ forem independentes e tiverem a mesma distribuição F, então*

$$\sup_x |\hat{F}_n(x) - F(x)| \xrightarrow{\text{quase certamente}} 0.$$

Demonstração. A desigualdade de Dvoretzky, Kiefer e Wolfowitz afirma que, para todo $\varepsilon > 0$,

$$\mathbb{P}\Big\{\sup_x |\hat{F}_n(x) - F(x)| > \varepsilon\Big\} \le 2e^{-2n\varepsilon^2}.$$

A soma do lado direito em n é finita. Pelo primeiro lema de Borel–Cantelli, o evento entre chaves ocorre apenas um número finito de vezes, com probabilidade um. Aplique esse argumento sucessivamente a $\varepsilon = 1, 1/2, 1/3, \ldots$ e tome a interseção, ainda de probabilidade um, dos eventos resultantes. Nessa interseção, para todo m existe n_m tal que o supremo é menor do que $1/m$ sempre que $n \ge n_m$; logo o supremo converge para zero. □

O teorema garante que $\hat{F}_n$ estima F uniformemente. Se um funcional T for contínuo na topologia relevante, então $T(\hat{F}_n)$ converge para $T(F)$. Essa é a essência do **princípio da substituição**: substitui-se a distribuição desconhecida F por $\hat{F}_n$ e calcula-se, sob $\hat{F}_n$, a distribuição análoga à distribuição amostral de interesse. A continuidade de T e a consistência dessa aproximação precisam ser verificadas; o Teorema 8.2, sozinho, não torna válida toda reamostragem.

8.2 Bootstrap não paramétrico

8.2.1 Algoritmo

Definição 8.3 (Amostra *bootstrap*)**.** Uma *amostra bootstrap* $\mathbf{X}^* = (X_1^*, \ldots, X_n^*)$ é obtida amostrando n vezes *com reposição* de $\{X_1, \ldots, X_n\}$. Equivalentemente, condicionalmente aos dados, $X_1^*, \ldots, X_n^*$ são independentes e têm a mesma distribuição $\hat{F}_n$.

A *réplica bootstrap* de $\hat{\theta}$ é $\hat{\theta}^* = T(\mathbf{X}^*)$. Geram-se B amostras bootstrap independentes, produzindo $\hat{\theta}^{*(1)}, \ldots, \hat{\theta}^{*(B)}$, que aproximam a distribuição G_n^* de $\hat{\theta}^*$ sob $\hat{F}_n$. Os estimadores são:

$$\begin{aligned}
\widehat{\mathbb{E}}[\hat{\theta}^*] &\approx \bar{\hat{\theta}}^* = \frac{1}{B}\sum_{b=1}^{B} \hat{\theta}^{*(b)}, \\
\widehat{\mathrm{Var}}_{\mathrm{boot}}(\hat{\theta}) &\approx \frac{1}{B-1}\sum_{b=1}^{B} (\hat{\theta}^{*(b)} - \bar{\hat{\theta}}^*)^2, \\
\widehat{\mathrm{vies}}_{\mathrm{boot}}(\hat{\theta}) &\approx \bar{\hat{\theta}}^* - \hat{\theta}.
\end{aligned}$$

8.2.2 Como escolher B

O número B controla apenas o erro da simulação condicional aos dados; aumentá-lo não corrige uma aproximação de reamostragem inadequada. Se $\hat{p}_B = B^{-1}\sum_{b=1}^{B} \mathbb{1}\{A_b\}$ estima por simulação uma probabilidade p, então

$$\text{desvio-padrão da simulação}(\hat{p}_B) = \sqrt{\frac{p(1-p)}{B}}.$$

Por exemplo, para $p = 0{,}025$ e $B = 2\,000$, esse erro-padrão é aproximadamente $0{,}0035$. A incerteza de um quantil na escala de θ também depende da densidade da distribuição de réplicas perto do quantil: caudas esparsas exigem mais simulações. Uma prática verificável é executar um valor inicial de B, repetir a análise com outra semente e aumentar B até que os algarismos reportados e as conclusões se estabilizem.

8.3 Bootstrap paramétrico

Quando há justificativa para um modelo paramétrico $F = F_\theta$ com θ desconhecido, pode-se reamostrar do modelo *ajustado*. O ganho potencial vem acompanhado da sensibilidade à especificação desse modelo.

Definição 8.4 (*Bootstrap* paramétrico)**.** Estime $\hat{\theta}$ pelos dados, por exemplo por máxima verossimilhança. Condicionalmente aos dados, gere $X_1^*, \ldots, X_n^*$ de maneira independente da distribuição $F_{\hat{\theta}}$. Calcule $\hat{\theta}^* = T(\mathbf{X}^*)$ e repita o processo B vezes.

Observação (Escolha entre as duas versões).
- A versão *não paramétrica* usa apenas $\hat{F}_n$ e evita impor uma família paramétrica, mas pode representar mal caudas ou eventos raros em amostras pequenas.
- A versão *paramétrica* pode ser mais precisa quando o modelo é uma boa aproximação, mas reproduz também seus erros de especificação.

Em situações intermediárias, há variantes semiparamétricas, como a reamostragem de resíduos em regressão.

8.4 Intervalos de confiança *bootstrap*

Para um nível de confiança $1-\alpha$, denote por

$$\Phi(u) = \mathbb{P}(Z \leq u), \qquad Z \sim N(0,1),$$

a função de distribuição acumulada da normal padrão e por $z_q = \Phi^{-1}(q)$ seu quantil de ordem q.

8.4.1 Intervalo pela aproximação normal

Use diretamente $\widehat{\mathrm{Var}}_{\mathrm{boot}}$ para estimar o erro-padrão e construa o intervalo simétrico

$$\mathcal{I}_{\mathrm{normal}} = \left[\hat{\theta} - z_{1-\alpha/2}\sqrt{\widehat{\mathrm{Var}}_{\mathrm{boot}}}, \hat{\theta} + z_{1-\alpha/2}\sqrt{\widehat{\mathrm{Var}}_{\mathrm{boot}}}\right].$$

Essa construção depende de uma aproximação normal adequada e pode ser ruim quando G_n é assimétrica.

8.4.2 Percentil

Definição 8.5 (Intervalo de percentis)**.** Seja q_α^* o quantil α da distribuição empírica de $\{\hat{\theta}^{*(b)}\}$. Então

$$\mathcal{I}_{\mathrm{perc}} = [q_{\alpha/2}^*, q_{1-\alpha/2}^*].$$

O intervalo não impõe simetria, mas requer que a distribuição condicional das réplicas aproxime corretamente a distribuição amostral e que o funcional seja regular o suficiente. Ele respeita uma restrição natural, como $\theta \geq 0$, somente quando todas as réplicas também a respeitam. Viés e transformação não linear podem prejudicar sua cobertura.

8.4.3 Intervalo básico

A distribuição das réplicas também pode ser usada para aproximar diretamente o erro de estimação. Se a distribuição condicional de $\hat{\theta}^* - \hat{\theta}$ aproxima a distribuição de $\hat{\theta} - \theta$, então

$$\mathbb{P}\Big(q_{\alpha/2}^* - \hat{\theta} \leq \hat{\theta} - \theta \leq q_{1-\alpha/2}^* - \hat{\theta}\Big) \approx 1-\alpha.$$

Isolar θ produz o **intervalo básico**

$$\mathcal{I}_{\mathrm{basico}} = \left[2\hat{\theta} - q_{1-\alpha/2}^*, 2\hat{\theta} - q_{\alpha/2}^*\right].$$

Ele é a reflexão do intervalo de percentis em torno de $\hat{\theta}$. Essa reflexão corrige o deslocamento no sentido indicado pela distribuição das réplicas, mas pode gerar limites incompatíveis com o espaço paramétrico, como um limite negativo para uma variância. O intervalo de percentis, em contraste, preserva restrições respeitadas por todas as réplicas.

8.4.4 Intervalo com correção de viés

Seja $r = \sum_{b=1}^{B} \mathbb{1}\{\hat{\theta}^{*(b)} < \hat{\theta}\}$. Para evitar um quantil normal infinito quando r for zero ou B, use a pequena correção de continuidade

$$\hat{z}_0 = \Phi^{-1}\left(\frac{r + 1/2}{B + 1}\right).$$

O valor $\hat{z}_0$ mede a posição de $\hat{\theta}$ dentro da distribuição de réplicas. Defina

$$\alpha_1^{\text{corr}} = \Phi(2\hat{z}_0 + z_{\alpha/2}), \qquad \alpha_2^{\text{corr}} = \Phi(2\hat{z}_0 + z_{1-\alpha/2}),$$

e construa

$$\mathcal{I}_{\text{corr}} = [q^*_{\alpha_1^{\text{corr}}}, q^*_{\alpha_2^{\text{corr}}}].$$

Se metade das réplicas estiver abaixo de $\hat{\theta}$, então $\hat{z}_0$ estará próximo de zero e a correção será pequena.

8.4.5 Intervalo com correção de viés e aceleração

A **constante de aceleração** $\hat{a}$ corrige a variação do erro-padrão quando o parâmetro muda. Para calculá-la, remova cada observação por vez, obtenha as réplicas $\hat{\theta}_{(-i)}$ e sua média $\hat{\theta}_{(\cdot)} = n^{-1}\sum_i \hat{\theta}_{(-i)}$. Então

$$\hat{a} = \frac{\sum_i (\hat{\theta}_{(\cdot)} - \hat{\theta}_{(-i)})^3}{6\left\{\sum_i (\hat{\theta}_{(\cdot)} - \hat{\theta}_{(-i)})^2\right\}^{3/2}}.$$

Os níveis ajustados são

$$\alpha_j^{\text{acel}} = \Phi\left[\hat{z}_0 + \frac{\hat{z}_0 + z_{q_j}}{1 - \hat{a}(\hat{z}_0 + z_{q_j})}\right], \qquad (q_1, q_2) = (\alpha/2, 1 - \alpha/2),$$

e o intervalo é

$$\mathcal{I}_{\text{acel}} = [q^*_{\alpha_1^{\text{acel}}}, q^*_{\alpha_2^{\text{acel}}}].$$

Em problemas regulares com estatísticas suficientemente suaves, esse intervalo pode ter erro de cobertura de ordem n^{-1}, propriedade chamada de **precisão de segunda ordem**. A afirmação não se estende automaticamente a parâmetros na fronteira, seleção de modelos, distribuições discretas ou estatísticas não regulares.

8.4.6 Intervalo estudentizado

Seja $\hat{s}$ um estimador do erro-padrão de $\hat{\theta}$. A **estatística estudentizada** é

$$U = \frac{\hat{\theta} - \theta}{\hat{s}}.$$

Em cada reamostra, calcule tanto $\hat{\theta}^{*(b)}$ quanto seu erro-padrão estimado $\hat{s}^{*(b)}$ e forme

$$U^{*(b)} = \frac{\hat{\theta}^{*(b)} - \hat{\theta}}{\hat{s}^{*(b)}}.$$

Se $q_r^{U^*}$ denota o quantil de ordem r dessas réplicas, o intervalo é

$$\mathcal{I}_{\text{estud}} = \left[\hat{\theta} - q^{U^*}_{1-\alpha/2}\hat{s}, \hat{\theta} - q^{U^*}_{\alpha/2}\hat{s}\right].$$

O método exige um erro-padrão para cada réplica e, por isso, pode requerer uma reamostragem interna. Em problemas regulares, também pode alcançar precisão de segunda ordem; sem regularidade, essa garantia não vale.

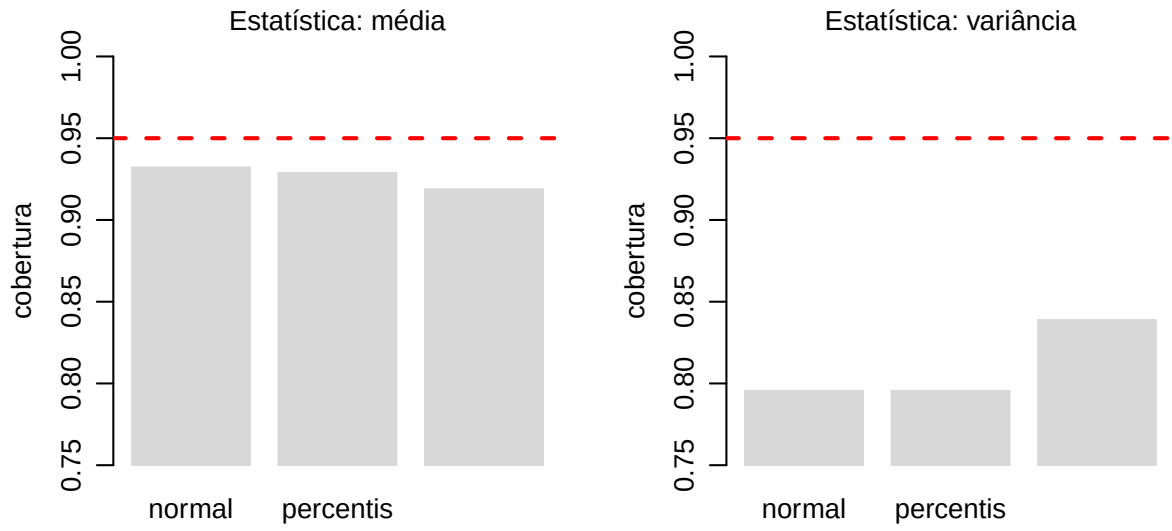


Figura 8.1: Cobertura empírica de intervalos nominais de 95% em 300 amostras de tamanho $n = 30$ de uma distribuição gama de forma 2 e taxa 1; cada intervalo usa 800 reamostras. Para a média, as coberturas foram 0,933, 0,930 e 0,920 para a aproximação normal, os percentis e a correção de viés e aceleração. Para a variância, foram 0,797, 0,797 e 0,840. A correção melhora a variância neste experimento, mas não a média. Com apenas 300 repetições externas, diferenças de alguns pontos percentuais ainda têm erro de Monte Carlo apreciável; a figura ilustra um caso, não uma ordenação universal.

Nota (Resumo prático).

- Use a aproximação normal somente quando a distribuição das réplicas for aproximadamente simétrica e uma transformação não for necessária.
- Considere correção de viés e aceleração ou estudentização quando as condições de regularidade forem plausíveis e a precisão de cobertura for importante.
- Para reportar apenas um erro-padrão, o desvio-padrão das réplicas costuma ser o resumo mais direto.
- Em todos os casos, examine falhas de ajuste, valores na fronteira e sensibilidade ao número de réplicas.

8.5 Bootstrap em regressão

Em regressão $y_i = x_i^\top \beta + \varepsilon_i$, há duas formas naturais de reamostrar.

8.5.1 Bootstrap de pares

Amostre, com reposição, n pares (y_i^*, x_i^*) do conjunto $\{(y_1, x_1), \ldots, (y_n, x_n)\}$. Reajuste o modelo. Esta versão preserva a distribuição conjunta (y, x) e é apropriada quando x é *aleatório*.

8.5.2 Bootstrap de resíduos

(i) Ajuste o modelo e obtenha resíduos $\hat{\varepsilon}_i = y_i - x_i^\top \hat{\beta}$. (ii) Centralize-os, definindo $\tilde{\varepsilon}_i = \hat{\varepsilon}_i - \bar{\hat{\varepsilon}}$. (iii) Amostre ε_i^* com reposição de $\{\tilde{\varepsilon}_1, \ldots, \tilde{\varepsilon}_n\}$. (iv) Construa $y_i^* = x_i^\top \hat{\beta} + \varepsilon_i^*$ e reajuste o modelo. Essa versão preserva a matriz de preditores X e requer que a forma da média esteja correta e que os erros sejam identicamente distribuídos; em particular, a versão simples supõe variância constante.

Observação. Sob variância não constante, a **reamostragem selvagem**, proposta por Wu 1986, usa $\varepsilon_i^* = \tilde{\varepsilon}_i V_i$, em que os multiplicadores V_i são independentes, têm média zero e variância

um. Como a escala de $\tilde{\varepsilon}_i$ permanece ligada à observação i, o procedimento pode reproduzir a heterogeneidade. Correções de alavancagem dos resíduos são recomendáveis quando alguns valores de x_i são extremos.

8.6 Exemplos resolvidos

Exercício resolvido 8.1 : *Bootstrap* para a média

Enunciado. Para variáveis $X_1, \dots, X_n$ independentes e com a mesma distribuição F, de média μ e variância finita σ^2, mostre que (a) $\widehat{\mathrm{Var}}_{\mathrm{boot}}(\bar{X}) \approx s^2/n$; (b) o intervalo de percentis de 95% é assintoticamente equivalente ao intervalo clássico $\bar{X} \pm 1{,}96 s/\sqrt{n}$.
Solução. (a) Para a média, $\bar{X}^* = n^{-1}\sum_i X_i^*$, e as variáveis X_i^* são condicionalmente independentes com distribuição $\hat{F}_n$. Sob $\hat{F}_n$, $\mathbb{E}(X_i^*) = \bar{X}$ e $\mathrm{Var}(X_i^*) = n^{-1}\sum_i (X_i - \bar{X})^2 = \tilde{s}^2$. Logo $\mathrm{Var}_{\hat{F}_n}(\bar{X}^*) = \tilde{s}^2/n$. Como $s^2 = n\tilde{s}^2/(n-1)$, a diferença entre $\tilde{s}^2/n$ e s^2/n é de ordem menor, e ambas convergem para a variância assintótica correta sob a lei dos grandes números. (b) Pelo teorema central do limite aplicado condicionalmente aos dados, $\bar{X}^*$ é assintoticamente normal de média $\bar{X}$ e variância $\tilde{s}^2/n$. Portanto, $q^*_{0{,}025} \approx \bar{X} - 1{,}96 s/\sqrt{n}$ e $q^*_{0{,}975} \approx \bar{X} + 1{,}96 s/\sqrt{n}$. Os dois intervalos são assintoticamente equivalentes.

Exercício resolvido 8.2 : *Bootstrap* para o coeficiente de correlação

Enunciado. Sejam (X_i, Y_i), $i = 1, \dots, n = 20$, observações com correlação amostral $\hat{\rho} = 0{,}65$. Suponha que $B = 1\,000$ réplicas bootstrap forneçam:

$$\bar{\hat{\rho}}^* = 0{,}637, \qquad \hat{s}_{\mathrm{boot}}(\hat{\rho}) = 0{,}095, \qquad q^*_{0{,}025} = 0{,}45, \quad q^*_{0{,}975} = 0{,}81,$$

Reporte: (a) a estimativa de viés; (b) o intervalo normal de 95%; (c) o intervalo de percentis de 95%.
Solução. (a) $\widehat{\mathrm{vies}}_{\mathrm{boot}} = 0{,}637 - 0{,}65 = -0{,}013$. (b) $\mathcal{I}_{\mathrm{normal}} = 0{,}65 \pm 1{,}96(0{,}095) = [0{,}464, 0{,}836]$. (c) $\mathcal{I}_{\mathrm{perc}} = [0{,}45, 0{,}81]$. O intervalo de percentis é mais curto e assimétrico neste conjunto de réplicas. Isso descreve a simulação, mas não prova que sua cobertura seja melhor; os métodos devem ser comparados por suas propriedades de cobertura, não apenas pela largura.

Exercício resolvido 8.3 : *Bootstrap* de resíduos em regressão simples

Enunciado. Seja $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, $i = 1, \dots, n$, com $\hat{\beta}_1 = 2{,}3$ e $\hat{\sigma} = 0{,}5$. Esboce o algoritmo de reamostragem de resíduos para estimar o erro-padrão de $\hat{\beta}_1$.
Solução. Pseudo-código:

1. Ajustar $y \sim x$ por mínimos quadrados e obter $\hat{\beta}_0$, $\hat{\beta}_1$ e $\hat{\varepsilon}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$. Centralizar os resíduos: $\tilde{\varepsilon}_i = \hat{\varepsilon}_i - \bar{\hat{\varepsilon}}$.
2. Para $b = 1, \dots, B$:
   - Amostrar ε_i^* com reposição de $\{\tilde{\varepsilon}_1, \dots, \tilde{\varepsilon}_n\}$.
   - Construir $y_i^* = \hat{\beta}_0 + \hat{\beta}_1 x_i + \varepsilon_i^*$.
   - Ajustar $y^* \sim x$ e armazenar $\hat{\beta}_1^{*(b)}$.
3. Estimar o erro-padrão de $\hat{\beta}_1$ pelo desvio-padrão amostral de $\{\hat{\beta}_1^{*(b)}\}_{b=1}^{B}$.

Compare com o erro-padrão clássico $\hat{\sigma}/\sqrt{\sum_i (x_i - \bar{x})^2}$. Sob as hipóteses do modelo, ambos são consistentes. A reamostragem de resíduos pode aproximar melhor uma distribuição não normal em alguns problemas, mas não é automaticamente robusta a variância não

constante, forma incorreta da média ou observações influentes.

8.7 Laboratório computacional em R

Laboratório em R : *Bootstrap* manual

```
boot_manual <- function(x, estatistica, B = 2000) {
  n         <- length(x)
  thetas_b <- replicate(B, estatistica(sample(x, n, replace = TRUE))
     )
  list(theta = estatistica(x),
       vies = mean(thetas_b) - estatistica(x),
       ep    = sd(thetas_b),
       ic_perc = quantile(thetas_b, c(0.025, 0.975)),
       replicas = thetas_b)
}

set.seed(2026)
y <- rgamma(50, shape = 2, rate = 1)
boot_manual(y, mean)
```

Laboratório em R : Pacote `boot`

A interface padrão de `boot` requer uma função `statistic(data, indices)`:

```
library(boot)
library(ISLR2)

# Variancia minima de uma carteira de dois ativos
estat_alpha <- function(d, idx) {
  d <- d[idx, ]
  with(d, (var(Y) - cov(X, Y)) / (var(X) + var(Y) - 2 * cov(X, Y)))
}

set.seed(1)
res <- boot(Portfolio, estat_alpha, R = 1000)
res

# Intervalos de confianca
boot.ci(res, type = c("norm", "perc", "bca"))
```

Com a semente acima, $\hat{\alpha} = 0{,}576$, com viés estimado $-0{,}0016$ e erro-padrão $0{,}094$. A saída da função literal `boot.ci` traz, lado a lado, os intervalos de 95% normal $(0{,}394; 0{,}761)$, de percentis $(0{,}392; 0{,}754)$ e com correção de viés e aceleração $(0{,}404; 0{,}772)$.

Laboratório em R : *Bootstrap* de resíduos em regressão

```
library(ISLR2)

# Regressao Boston
ajuste <- lm(medv ~ rm + lstat, data = Boston)
```

```
res    <- residuals(ajuste)
res    <- res - mean(res)
yhat   <- fitted(ajuste)
beta   <- coef(ajuste)

set.seed(2026)
B <- 2000
betas <- replicate(B, {
  res_b <- sample(res, length(res), replace = TRUE)
  y_b   <- yhat + res_b
  coef(lm(y_b ~ Boston$rm + Boston$lstat))
})

# Erros padrao bootstrap
apply(betas, 1, sd)
# Comparar com summary(ajuste)
summary(ajuste)$coefficients[, "Std. Error"]
```

Laboratório em R : Comparação de cobertura por simulação

```
set.seed(2026)
R <- 500
n <- 30

cobertura <- function(metodo) {
  acertos <- replicate(R, {
    x   <- rgamma(n, 2, 1)
    res <- boot(x, function(d, idx) mean(d[idx]), R = 1000)
    ic  <- boot.ci(res, type = metodo)
    if (metodo == "norm")
      ci <- ic$normal[2:3]
    else if (metodo == "perc")
      ci <- ic$percent[4:5]
    else # bca
      ci <- ic$bca[4:5]
    ci[1] <= 2 && 2 <= ci[2]
  })
  mean(acertos)
}

c(normal = cobertura("norm"),
  percentil = cobertura("perc"),
  vies_e_aceleracao = cobertura("bca"))
```

Com a semente indicada, as coberturas são aproximadamente 0,906, 0,908 e 0,936, na ordem mostrada. O erro-padrão de Monte Carlo dessas proporções está entre 1,1 e 1,3 ponto percentual. Em outra distribuição ou para outra estatística, a ordenação pode mudar; a simulação avalia este cenário específico.

8.8 Exercícios propostos

Ex. 8.1. Para variáveis $X_1, \ldots, X_n$ independentes e com a mesma distribuição F, de mediana populacional M, sejam $\hat{M}$ a mediana amostral e $\hat{M}^*$ a mediana de uma reamostra. Mostre, por

simulação ou argumento assintótico sob densidade positiva em M, que o intervalo de percentis tem cobertura assintoticamente correta, ao passo que a remoção de uma observação falha para estimar sua variância; compare com o Capítulo 7.

Ex. 8.2. Mostre que $\widehat{\text{vies}}_{\text{boot}}$ é uma estimativa do viés *do estimador* $\hat\theta = T(\hat F_n)$ relativamente a $T(F)$. Compare com a estimativa *jackknife* de viés.

Ex. 8.3. Considere $\hat\theta = \hat q_{0{,}75} - \hat q_{0{,}25}$, a diferença entre os quantis amostrais de ordens 0,75 e 0,25, com $n = 100$ observações de $N(0,1)$. Construa intervalos de 95% por percentis, por correção de viés e por correção de viés e aceleração, e reporte a cobertura empírica em 1.000 repetições externas.

Ex. 8.4. Para 20 pares (X_i, Y_i) independentes com distribuição normal bivariada de correlação $\rho = 0{,}5$, simule 500 amostras e compare intervalos de 95% baseados na transformação de Fisher, em percentis e na correção de viés e aceleração. Reporte cobertura e largura média.

Ex. 8.5. Em uma simulação de regressão linear cuja variância $\sigma^2(x)$ cresce com x, compare a reamostragem de pares e a reamostragem simples de resíduos para estimar o erro-padrão de $\hat\beta_1$. Qual delas fica mais próxima do desvio-padrão empírico de $\hat\beta_1$ em muitas amostras simuladas? Inclua também a reamostragem selvagem.

Ex. 8.6. *Aplicação prática.* Use o conjunto literal `lung` do pacote `survival`. Ajuste um modelo de Cox para sobrevida em função de `age` e `sex`. Use as funções literais `boot` ou `rsample::bootstraps` para estimar um intervalo de 95% para a razão de riscos associada a `sex` e compare-o com o intervalo clássico baseado na verossimilhança parcial.

Notas e leituras complementares

- Efron 1979: artigo seminal.
- Efron e R. J. Tibshirani 1993: introdução abrangente ao tema.
- Hall, P. (1992): tratamento teórico por expansões assintóticas, incluindo as condições para precisão de segunda ordem dos intervalos com correção de viés e aceleração e dos intervalos estudentizados.
- Efron e Hastie 2016, Cap. 10–11: discussão moderna, conexões com inferência em grande escala.

8.9 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Método bootstrap	*bootstrap*	—
Princípio da substituição	*plug-in principle*	—
Função de distribuição empírica	*empirical distribution function*	EDF
Teorema de Glivenko–Cantelli	*Glivenko–Cantelli theorem*	—
Bootstrap não paramétrico	*nonparametric bootstrap*	—
Bootstrap paramétrico	*parametric bootstrap*	—
Amostra bootstrap	*bootstrap sample*	—
Réplica bootstrap	*bootstrap replicate*	—
Distribuição bootstrap	*bootstrap distribution*	—
Erro de Monte Carlo	*Monte Carlo error*	MC error
Erro padrão bootstrap	*bootstrap standard error*	SE
Estimativa bootstrap de viés	*bootstrap estimate of bias*	—
Intervalo pela aproximação normal	*normal-approximation interval*	—
Intervalo de percentis	*percentile interval*	—
Intervalo básico	*basic bootstrap interval*	—
Intervalo com correção de viés	*bias-corrected interval*	BC
Intervalo com correção de viés e aceleração	*bias-corrected and accelerated interval*	BCa
Constante de aceleração	*acceleration constant*	—
Intervalo estudentizado	*studentized bootstrap interval*	bootstrap-t
Precisão de segunda ordem	*second-order accuracy*	—
Bootstrap de pares	*pairs bootstrap*	—
Bootstrap de resíduos	*residual bootstrap*	—
Bootstrap selvagem	*wild bootstrap*	—

Capítulo 9

Validação cruzada

Objetivos da unidade

- Distinguir entre erro de treinamento, erro de teste condicional e erro esperado de predição.
- Definir validação cruzada em k blocos e seu caso limite, no qual uma observação é removida por vez.
- Discutir o dilema entre viés e variância na escolha de k e a heurística de um erro-padrão.
- Empregar validação cruzada para selecionar hiperparâmetros, como λ na regressão regularizada e a complexidade de uma árvore.

Leitura primária: Efron e Hastie 2016, §12.1–12.2.
Leitura complementar: Stone 1974; G. James et al. 2013, capítulo 5.

9.1 Motivação

Considere um procedimento estatístico que produz um preditor $\hat{f}$ a partir dos dados $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}$. Para avaliar a qualidade preditiva de $\hat{f}$, é tentador usar o *erro de treinamento*

$$\overline{\text{err}} = \frac{1}{n} \sum_{i=1}^{n} L(y_i, \hat{f}(x_i)),$$

onde $L(y, a)$ quantifica o custo de predizer a quando a resposta é y. Como os mesmos dados foram usados para construir e avaliar $\hat{f}$, o erro de treinamento tende a ser otimista para o erro em dados novos. Se os valores x_i forem distintos, um polinômio não regularizado de grau no máximo $n - 1$ pode interpolar os n pares e produzir erro quadrático de treinamento igual a zero; esse fato, sozinho, nada garante sobre sua predição fora da amostra.

A **validação cruzada**, formalizada por Stone 1974, separa repetidamente os papéis de ajuste e avaliação. Sob observações representativas da população futura e uma partição compatível com a dependência dos dados, ela estima o desempenho do procedimento de modelagem. O método não exige uma família paramétrica, mas exige que o esquema de validação reproduza a forma como novas observações surgirão.

9.2 Erro de predição

Seja (X, Y) um par futuro com a mesma distribuição F dos dados, independente de $\mathcal{D}$. Definem-se duas quantidades análogas mas distintas.

Definição 9.1 (Erros de predição)**.** • **Erro de teste condicional** (em $\mathcal{D}$):

$$\mathrm{Err}_{\mathcal{D}} = \mathbb{E}\big[L(Y, \hat{f}(X)) \mid \mathcal{D}\big].$$

• **Erro esperado de predição**:

$$\mathrm{Err} = \mathbb{E}_{\mathcal{D}}[\mathrm{Err}_{\mathcal{D}}] = \mathbb{E}\big[L(Y, \hat{f}(X))\big].$$

Frequentemente gostaríamos de estimar $\mathrm{Err}_{\mathcal{D}}$, o erro específico do ajuste corrente. A validação cruzada, contudo, aproxima mais diretamente o desempenho médio de ajustes feitos em amostras um pouco menores, e sua relação com $\mathrm{Err}_{\mathcal{D}}$ depende da estabilidade do algoritmo. A distinção afeta tanto a interpretação quanto a quantificação da incerteza e não deve ser descartada automaticamente.

Nota (Decomposição viés-variância)*.* Para perda quadrática e modelo $Y = f(X) + \varepsilon$, suponha que $\mathbb{E}(\varepsilon \mid X) = 0$, $\mathrm{Var}(\varepsilon \mid X = x_0) = \sigma^2$ e que a nova resposta seja independente dos dados de treinamento. Então

$$\mathbb{E}_{\mathcal{D},Y}\Big[\{Y - \hat{f}_{\mathcal{D}}(x_0)\}^2 \mid X = x_0\Big] = \sigma^2 + \Big[\mathbb{E}_{\mathcal{D}}\{\hat{f}_{\mathcal{D}}(x_0)\} - f(x_0)\Big]^2 + \mathrm{Var}_{\mathcal{D}}\{\hat{f}_{\mathcal{D}}(x_0)\}.$$

Os três termos são, respectivamente, o ruído irredutível, o quadrado do viés e a variância causada pela amostra de treinamento.

9.3 Validação *holdout* simples

A versão mais simples particiona os índices em um conjunto de treinamento $\mathcal{A}$ e um conjunto de avaliação $\mathcal{T}$, sem interseção. Ajusta-se o modelo somente em $\mathcal{A}$ e avalia-se em $\mathcal{T}$:

$$\widehat{\mathrm{Erro}}_{\text{partição}} = \frac{1}{|\mathcal{T}|} \sum_{i \in \mathcal{T}} L\{y_i, \hat{f}^{(\mathcal{A})}(x_i)\}.$$

A vantagem é a simplicidade computacional. A estimativa, porém, avalia um algoritmo treinado em apenas $|\mathcal{A}|$ observações e pode variar muito com uma única partição.

9.4 Validação cruzada em k blocos

Definição 9.2 (Validação cruzada em k blocos)**.** Escolha k com $2 \le k \le n$ e particione $\{1, \dots, n\}$ em blocos aproximadamente iguais $B_1, \dots, B_k$. Isso significa que os blocos são disjuntos dois a dois, sua união é o conjunto de todos os índices e $|B_j| \approx n/k$. Para observações independentes, a partição pode ser aleatória; dados agrupados ou dependentes exigem os esquemas discutidos na Seção 9.10. Para cada j:
1. Ajuste o modelo em $\mathcal{D} \setminus B_j$, obtendo $\hat{f}^{(-B_j)}$.
2. Calcule a perda nos elementos de B_j.
A estimativa de validação cruzada é

$$\widehat{\mathrm{Val}}_k = \frac{1}{n} \sum_{j=1}^{k} \sum_{i \in B_j} L(y_i, \hat{f}^{(-B_j)}(x_i)). \tag{9.1}$$

Observação (Casos especiais)*.* • Quando $k = 2$, cada ajuste usa aproximadamente metade das observações.
• Quando $k = n$, cada bloco contém uma observação; essa é a **validação com uma observação removida por vez**.
• Os valores $k = 5$ e $k = 10$ são escolhas usuais, mas não universais.

9.4.1 Estratificação

Em problemas de classificação com classes desbalanceadas, pode-se estratificar a partição para que cada bloco preserve aproximadamente a proporção das classes em $\mathcal{D}$. Isso evita blocos sem observações de uma classe e pode reduzir a variabilidade, desde que a amostragem futura tenha a mesma estrutura de prevalência.

9.5 Remoção de uma observação por vez: caso $k = n$

Nesse caso,

$$\widehat{\mathrm{Val}}_n = \frac{1}{n}\sum_{i=1}^{n} L\{y_i, \hat{f}^{(-i)}(x_i)\},$$

e a definição direta requer n ajustes. Em alguns modelos há atalhos algébricos.

Teorema 9.3 (Remoção individual em regressão linear)**.** *Considere a regressão linear por mínimos quadrados, com matriz de desenho X de posto completo, matriz de projeção $H = X(X^\top X)^{-1}X^\top$ e valores ajustados $\hat{y} = Hy$. Denote por h_{ii} a entrada diagonal i de H, chamada de* ***alavancagem****, e suponha $h_{ii} < 1$ para todo i. Sob perda quadrática,*

$$\widehat{\mathrm{Val}}_n = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{y_i - \hat{y}_i}{1 - h_{ii}}\right)^2.$$

Demonstração. Seja $\hat{\beta}$ o ajuste por mínimos quadrados sobre todos os dados e $\hat{\beta}_{(-i)}$ o ajuste sem a observação i. Pela fórmula de Sherman–Morrison,

$$\hat{\beta}_{(-i)} = \hat{\beta} - \frac{(X^\top X)^{-1}x_i(y_i - \hat{y}_i)}{1 - h_{ii}}.$$

Avaliando o preditor no ponto x_i,

$$\hat{y}_i^{(-i)} = x_i^\top \hat{\beta}_{(-i)} = \hat{y}_i - \frac{h_{ii}(y_i - \hat{y}_i)}{1 - h_{ii}} = \frac{\hat{y}_i - h_{ii}y_i}{1 - h_{ii}}.$$

Daí $y_i - \hat{y}_i^{(-i)} = (y_i - \hat{y}_i)/(1 - h_{ii})$, e elevando ao quadrado e somando obtém-se a fórmula. □

Observação. A fórmula do Teorema 9.3 permite computar a validação com remoção individual após um único ajuste. Uma identidade análoga vale para suavizadores lineares, como a regressão regularizada e certas funções de suavização. Para modelos lineares generalizados, expressões baseadas em alavancagens e na iteração de mínimos quadrados reponderados são aproximações de primeira ordem, e não a mesma identidade exata.

9.5.1 Validação cruzada generalizada

Um **suavizador linear** é um procedimento cujos valores ajustados podem ser escritos como $\hat{y} = Sy$, em que a matriz de suavização S pode depender dos preditores e de um hiperparâmetro, mas não da resposta y. Para muitos desses procedimentos, a fórmula de remoção individual envolve os elementos diagonais s_{ii} de S. A validação cruzada generalizada substitui cada s_{ii} por sua média $\mathrm{tr}(S)/n$. Definindo $Q = \sum_i (y_i - \hat{y}_i)^2$ como a soma de quadrados dos resíduos, obtém-se

$$\widehat{\mathrm{Val}}_{\mathrm{geral}} = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{y_i - \hat{y}_i}{1 - \mathrm{tr}(S)/n}\right)^2 = \frac{Q/n}{\{1 - \mathrm{gl}\,/n\}^2},$$

em que $\mathrm{gl} = \mathrm{tr}(S)$ é o número efetivo de graus de liberdade. A expressão é uma aproximação à remoção individual, proposta por Craven e Wahba 1979 e Golub, Heath e Wahba 1979; ela é mais fiel quando os s_{ii} não são muito heterogêneos.

Na regressão linear por mínimos quadrados, $S = H$ e $\mathrm{gl} = p$ quando a matriz de planejamento tem p colunas linearmente independentes. Na regressão quadrática regularizada com hiperparâmetro λ, denote por I_p a identidade de ordem p e use

$$S_\lambda = X(X^\top X + \lambda I_p)^{-1} X^\top.$$

Se d_j são os valores singulares positivos de X, então $\mathrm{gl}(\lambda) = \mathrm{tr}(S_\lambda) = \sum_j d_j^2/(d_j^2 + \lambda)$. Portanto, tanto os resíduos quanto a complexidade efetiva variam com λ na curva de validação generalizada.

9.6 Viés e variância da estimativa de validação

9.6.1 Viés

Cada modelo é ajustado em aproximadamente $n - n/k$ observações e, portanto, avalia o procedimento em uma amostra menor. Se o risco esperado do algoritmo diminuir com o tamanho da amostra, essa diferença produz viés positivo em relação ao risco do algoritmo treinado nas n observações. A monotonicidade do risco não é uma lei: algoritmos instáveis, regularização dependente de n e mudanças de procedimento podem contrariá-la.

- $k = 2$: cada modelo usa só $n/2$ observações; viés substancial.
- $k = 10$: cada modelo usa $9n/10$; viés pequeno.
- $k = n$: cada modelo usa $n - 1$ observações; a diferença de tamanho é mínima.

9.6.2 Variância

A variância de $\widehat{\mathrm{Val}}_k$ é mais sutil. As perdas de validação são dependentes porque os conjuntos de treinamento se sobrepõem.

- Com $k = n$, os modelos diferem por apenas uma observação e as perdas podem ser fortemente correlacionadas. Dependendo da estabilidade do algoritmo, a variância pode ser maior ou menor do que a obtida com poucos blocos.
- Com $k = 5$ ou 10, há menos ajustes e uma diferença maior entre o tamanho de treinamento e n.

9.6.3 Recomendação prática

Os valores $k = 5$ e $k = 10$ são pontos de partida usuais, não ótimos universais. A escolha deve considerar custo computacional, tamanho de cada classe ou grupo, dependência e estabilidade do algoritmo. Repetir a partição algumas vezes permite medir a sensibilidade à divisão; essas repetições não tornam independentes as perdas produzidas pelos mesmos dados. O caso $k = n$ é atraente quando há a fórmula fechada do Teorema 9.3 ou quando cada observação é valiosa e o custo é aceitável.

9.7 Seleção de hiperparâmetros por validação cruzada

Um **hiperparâmetro** é uma configuração do procedimento de ajuste que não é estimada no ajuste interno, como a intensidade de regularização, a complexidade de uma árvore ou o número de vizinhos. Para valores candidatos de λ, define-se a curva

$$\lambda \longmapsto \widehat{\mathrm{Val}}_k(\lambda),$$

e escolhe-se $\hat{\lambda}_{\min} = \arg\min_\lambda \widehat{\mathrm{Val}}_k(\lambda)$.

9.7.1 Heurística de um erro-padrão

A curva $\widehat{\mathrm{Val}}_k(\lambda)$ varia com os dados e com a partição. Se $\bar{L}_j(\lambda)$ é a perda média no bloco j, muitos programas calculam

$$\widehat{s}_{\mathrm{blocos}}(\lambda) = \sqrt{\frac{1}{k(k-1)} \sum_{j=1}^{k} \{\bar{L}_j(\lambda) - \bar{L}_\cdot(\lambda)\}^2},$$

e escolhem o maior λ, se valores maiores significarem modelos mais simples, que satisfaça

$$\widehat{\mathrm{Val}}_k(\lambda) \le \widehat{\mathrm{Val}}_k(\hat{\lambda}_{\min}) + \widehat{s}_{\mathrm{blocos}}(\hat{\lambda}_{\min}).$$

A motivação é escolher um modelo mais simples quando a curva é plana perto do mínimo. Como os modelos de treinamento se sobrepõem, as perdas dos blocos não são independentes; assim, $\widehat{s}_{\mathrm{blocos}}$ não é, em geral, um erro-padrão inferencial válido, e a regra não é um teste de equivalência. Trata-se de uma heurística de parcimônia.

9.8 Funções de perda e métricas de erro

Toda a teoria até aqui foi escrita em termos de uma perda genérica $L(y, \hat{y})$, e os exemplos usaram a perda quadrática por conveniência. Chegou o momento de levar a escolha de L a sério, porque ela não é um detalhe de relatório: **trocar a função de perda muda o que está sendo estimado**, e não apenas como o resultado é pontuado.

9.8.1 Regressão: perdas quadrática e absoluta

Definição 9.4 (Métricas de regressão)**.** Sobre um conjunto de avaliação de tamanho m:

$$Q_m = \frac{1}{m} \sum_{i=1}^{m} (y_i - \hat{y}_i)^2, \qquad R_m = \sqrt{Q_m}, \qquad A_m = \frac{1}{m} \sum_{i=1}^{m} |y_i - \hat{y}_i|.$$

Q_m é o **erro quadrático médio**, R_m é sua raiz e A_m é o **erro absoluto médio**.

R_m e A_m têm a mesma unidade de y, enquanto Q_m tem unidade ao quadrado. Pela desigualdade entre a média quadrática e a média aritmética aplicada aos erros absolutos, $R_m \ge A_m$, com igualdade se e somente se todos os erros absolutos forem iguais. A razão R_m/A_m descreve a heterogeneidade dos erros, embora não identifique sua causa.

O ponto essencial, porém, é outro.

Proposição 9.5 (O alvo de cada perda)**.** *Seja Y com distribuição condicional a $X = x$. Então*

$$\arg\min_c \ \mathbb{E}\big[(Y-c)^2 \mid X = x\big] = \mathbb{E}[Y \mid X = x],$$
$$\arg\min_c \ \mathbb{E}\big[|Y-c| \mid X = x\big] = \mathrm{mediana}(Y \mid X = x).$$

Demonstração. Para a perda quadrática,

$$\mathbb{E}\{(Y-c)^2 \mid x\} = \mathrm{Var}(Y \mid x) + \{\mathbb{E}(Y \mid x) - c\}^2,$$

e o segundo termo é minimizado em $c = \mathbb{E}(Y \mid x)$. Para a perda absoluta, escreva $g(c) = \mathbb{E}(|Y-c| \mid x)$ e denote por F_x a função de distribuição condicional. A função g é convexa e suas derivadas laterais são

$$g'_-(c) = 2F_x(c^-) - 1, \qquad g'_+(c) = 2F_x(c) - 1.$$

Um ponto minimiza uma função convexa se sua derivada à esquerda é não positiva e sua derivada à direita é não negativa. Logo os minimizadores satisfazem $F_x(c^-) \le 1/2 \le F_x(c)$, que é exatamente a definição de mediana condicional. A demonstração inclui distribuições com átomos e permite múltiplas medianas. □

Observação (A consequência que costuma passar despercebida). Minimizar a perda quadrática estima a **média** condicional; minimizar a perda absoluta estima uma **mediana** condicional. Em distribuições assimétricas, essas quantidades podem diferir substancialmente. É legítimo ajustar por uma perda e relatar várias métricas descritivas, mas a seleção do modelo deve ser alinhada à perda que representa a decisão de interesse.

Quanto à robustez, a perda quadrática dá peso cem vezes maior a um erro dez vezes maior, enquanto a perda absoluta aumenta linearmente. A perda absoluta é menos sensível a observações extremas, mas só é a escolha decisória correta quando o custo cresce aproximadamente de forma linear com o erro; se erros grandes forem especialmente custosos, a perda quadrática ou outra função de custo pode ser mais apropriada.

Nota (Outras perdas de regressão).
- **Erro percentual absoluto médio**, $m^{-1}\sum_i |(y_i - \hat{y}_i)/y_i|$: é adimensional, mas fica indefinido em $y_i = 0$ e dá peso muito grande a valores observados próximos de zero. Para respostas positivas, seu alvo populacional é uma mediana ponderada por $1/Y$, o que pode favorecer previsões baixas. Use-o somente quando essa ponderação fizer sentido.
- **Perda de Huber**: é quadrática para erros pequenos e linear para erros grandes, com um parâmetro que define a transição. Ela combina sensibilidade local quadrática e crescimento linear nas caudas.
- **Perda *pinball*** $L_\tau(y, \hat{y}) = (y - \hat{y})(\tau - \mathbb{1}\{y < \hat{y}\})$: minimizada pelo quantil τ condicional, base da regressão quantílica. A perda absoluta é, a menos de um fator $\frac{1}{2}$, o caso $\tau = 1/2$, coerentemente com a Proposição 9.5 e o Exercício 9.7.

9.8.2 Classificação: além da acurácia

Com resposta binária, a perda 0–1 conduz à **acurácia**, a proporção de acertos. É a métrica mais reportada e, com frequência, a menos informativa.

Exemplo 9.6 (A armadilha das classes desbalanceadas)**.** No conjunto `Default`, cerca de 3% dos clientes são inadimplentes. O classificador que prevê "ninguém dá calote", independentemente das covariáveis, tem acurácia de 97%, e é inteiramente inútil. Qualquer modelo que se orgulhe de 97% de acurácia nesse problema está, na verdade, empatando com a constante.

Seja $y_i \in \{0, 1\}$ a classe verdadeira e $\tilde{y}_i \in \{0, 1\}$ a classe predita. Defina

$$n_{ab} = \sum_{i=1}^{m} \mathbb{1}\{y_i = a, \tilde{y}_i = b\}, \qquad a, b \in \{0, 1\}.$$

Assim, por exemplo, n_{10} conta positivos reais classificados como negativos e n_{01} conta negativos reais classificados como positivos. As medidas principais são:

Medida	Fórmula	Pergunta que responde
Sensibilidade	$n_{11}/(n_{10} + n_{11})$	Dos positivos reais, quantos foram encontrados?
Especificidade	$n_{00}/(n_{00} + n_{01})$	Dos negativos reais, quantos foram preservados?
Precisão	$n_{11}/(n_{01} + n_{11})$	Dos casos sinalizados, quantos eram positivos?
Média harmônica	$2\,\frac{\text{precisão}\times\text{sensibilidade}}{\text{precisão}+\text{sensibilidade}}$	Resume precisão e sensibilidade

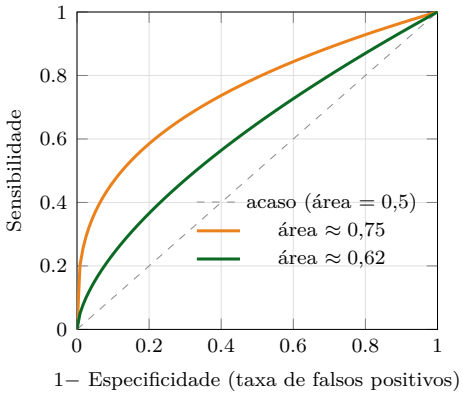
Todas elas, contudo, compartilham uma limitação estrutural: dependem de um **limiar** c arbitrário aplicado a $\hat{p}(x)$, tipicamente 0,5 por inércia. Como o limiar ótimo depende dos custos relativos de errar em cada direção, que variam com a aplicação e raramente são 1:1, avaliar um modelo em um único limiar mistura duas coisas distintas: a qualidade do modelo e a adequação do limiar.

9.8.3 Curva de sensibilidade e área de ordenação

Definição 9.7 (Curva de sensibilidade contra falsos positivos)**.** Para cada limiar c, classifique como positivo um caso cujo escore S seja maior do que c. A curva de sensibilidade contra taxa de falsos positivos é o conjunto

$$\mathcal{C} = \{(1 - \text{Especificidade}(c), \text{Sensibilidade}(c)) : c \in \mathbb{R}\}.$$

Quando os escores são probabilidades, basta variar c entre zero e um. Denote por $\mathcal{A}$ a área sob essa curva, calculada com metade do crédito para empates.



A área resume a ordenação dos escores ao longo de todos os limiares. Sua interpretação é mais concreta do que a construção geométrica sugere.

Teorema 9.8 (Área como probabilidade de concordância)**.** *Sejam S^+ o escore atribuído pelo modelo a uma observação positiva sorteada ao acaso e S^- o escore de uma negativa, independentes. Então*

$$\mathcal{A} = \mathbb{P}(S^+ > S^-) + \tfrac{1}{2}\mathbb{P}(S^+ = S^-).$$

Esboço. No caso contínuo, integrar a sensibilidade enquanto o limiar atravessa a distribuição dos escores negativos dá

$$\mathcal{A} = \int \mathbb{P}(S^+ > s)\, dF_-(s) = \mathbb{E}\{\mathbb{P}(S^+ > S^- \mid S^-)\} = \mathbb{P}(S^+ > S^-),$$

em que F_- é a função de distribuição de S^-. Para distribuições discretas, a interpolação linear dos degraus da curva atribui metade do peso aos pares empatados, produzindo o termo adicional. □

Observação (O que a área mede e o que não mede)*.* A caracterização acima dá à área uma leitura imediata: ela é a probabilidade de o modelo ordenar corretamente um par positivo–negativo tomado ao acaso. Daí seguem suas propriedades e seus limites:

- **Depende apenas da ordenação.** Qualquer transformação estritamente crescente dos escores preserva $\mathcal{A}$. Portanto, a área não mede calibração: alterar todas as probabilidades sem mudar sua ordem preserva a área.
- **É invariante à prevalência se as distribuições condicionais dos escores forem fixas.** Essa propriedade não é um viés matemático, mas pode ocultar a consequência operacional de uma classe rara: mesmo com boa ordenação, a precisão pode ser baixa porque há muitos negativos disponíveis para gerar alarmes falsos. A curva de precisão contra sensibilidade torna explícita a prevalência.
- **Pondera todos os limiares igualmente**, inclusive regiões da curva que jamais seriam usadas na prática. Se o custo de falso positivo e de falso negativo é conhecido, avaliar diretamente a perda esperada com esses custos é preferível.

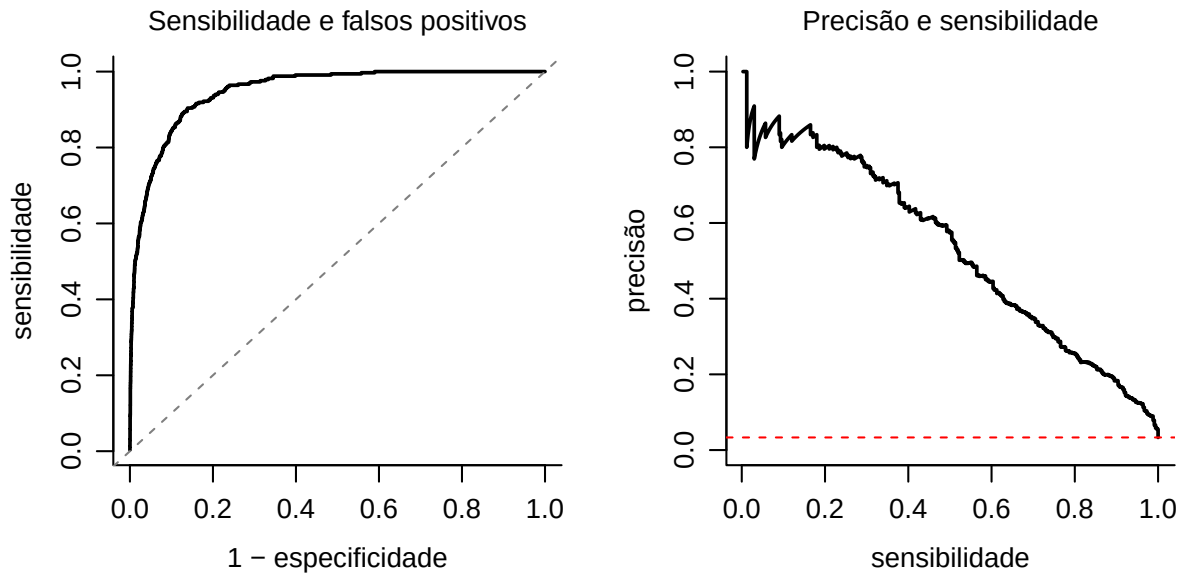


Figura 9.1: Duas leituras do mesmo modelo logístico ajustado ao conjunto `Default`, no qual aproximadamente 3% dos clientes são inadimplentes. A curva de sensibilidade contra taxa de falsos positivos, à esquerda, tem área 0,950, indicando boa ordenação entre pares das duas classes. À direita, no ponto com sensibilidade 0,8, a precisão é apenas 0,26: há quase três alarmes falsos para cada acerto. A linha tracejada marca a prevalência, que é a precisão de referência de um classificador aleatório. A área não está matematicamente enviesada pela prevalência; ela simplesmente responde a uma pergunta que não incorpora o número relativo de negativos.

9.8.4 Avaliar probabilidades: regras de pontuação próprias

Quando a saída do modelo é uma probabilidade destinada a decisão, e não apenas a ordenação, a métrica precisa premiar honestidade.

Definição 9.9 (Pontuações quadrática e logarítmica)**.** Para respostas $y_i \in \{0,1\}$ e probabilidades preditas $0 < \hat{p}_i < 1$, a pontuação quadrática de Brier e a perda logarítmica médias são

$$\text{Brier} = \frac{1}{m}\sum_{i=1}^{m}(\hat{p}_i - y_i)^2, \qquad \text{Logaritmica} = -\frac{1}{m}\sum_{i=1}^{m}\{y_i \log \hat{p}_i + (1-y_i)\log(1-\hat{p}_i)\}.$$

Uma perda probabilística é **própria** quando sua esperança, sob a probabilidade verdadeira $p = \mathbb{P}(Y=1 \mid X=x)$, é minimizada ao anunciar $q = p$. Para a perda quadrática,

$$\mathbb{E}\{(q-Y)^2 \mid x\} = p(1-p) + (q-p)^2,$$

cujo mínimo único é $q = p$. Para a perda logarítmica, a derivada da esperança em relação a q é

$$-\frac{p}{q} + \frac{1-p}{1-q} = \frac{q-p}{q(1-q)},$$

que muda de negativa para positiva em $q = p$. Assim, ambas são estritamente próprias. A acurácia e a área $\mathcal{A}$ não têm essa propriedade: a primeira depende de um limiar e a segunda apenas da ordenação.

Nota (Qual métrica usar).

Pergunta	Métrica	Cuidado
Erro típico na escala de y	Raiz do erro quadrático ou erro absoluto	Alvos diferentes: média e mediana
O modelo ordena bem?	Área $\mathcal{A}$	Não mede calibração
As probabilidades são calibradas?	Brier, perda logarítmica e curva de calibração	Uma pontuação agrega calibração e resolução
Decisão com custos conhecidos	Perda esperada com esses custos	Exige explicitar os custos
Classes muito raras	Precisão contra sensibilidade	Depende da prevalência

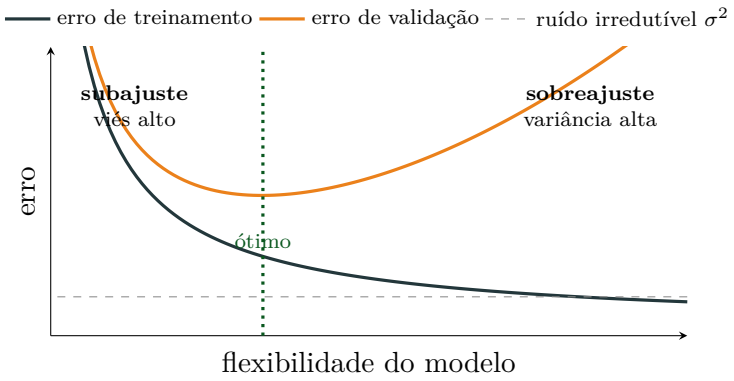
Cada uma dessas quantidades deve ser calculada **fora da amostra de ajuste**, por validação cruzada ou em um conjunto de teste. A área de treinamento é otimista pelas mesmas razões que o erro de treinamento.

9.9 Sobreajuste e subajuste na prática

Os termos são usados o tempo todo e definidos raramente. Convém fixá-los com precisão e, sobretudo, produzir um procedimento que diga *qual dos dois* está ocorrendo, porque os remédios são opostos, e aplicar o errado piora o modelo.

9.9.1 As duas curvas

Fixe uma família de modelos indexada por uma medida de flexibilidade (grau do polinômio, número de folhas, $1/\lambda$). Duas curvas se comportam de maneiras muito diferentes:



Para classes de modelos encaixadas e minimização exata da mesma perda empírica, o erro de treinamento não pode aumentar com a flexibilidade. Ele só chega a zero se a classe conseguir interpolar os dados. O erro de validação pode apresentar uma forma de U pelo compromisso entre viés e variância, mas ruído da partição, regularização implícita e regimes superparametrizados podem produzir outras formas. A distância vertical entre as curvas é uma estimativa da lacuna de generalização.

Definição 9.10 (Subajuste e sobreajuste)**.** Diz-se que um modelo **subajusta** quando sua classe ou seu ajuste é incapaz de capturar estrutura preditiva relevante, de modo que aumentar justificadamente a flexibilidade reduz o erro de validação. Diz-se que **sobreajusta** quando adapta peculiaridades da amostra de treinamento que não se repetem em dados novos, produzindo uma lacuna grande e desempenho de validação pior do que alternativas mais regularizadas. Esses diagnósticos são relativos à distribuição futura e às alternativas comparadas, não apenas à altura absoluta das curvas.

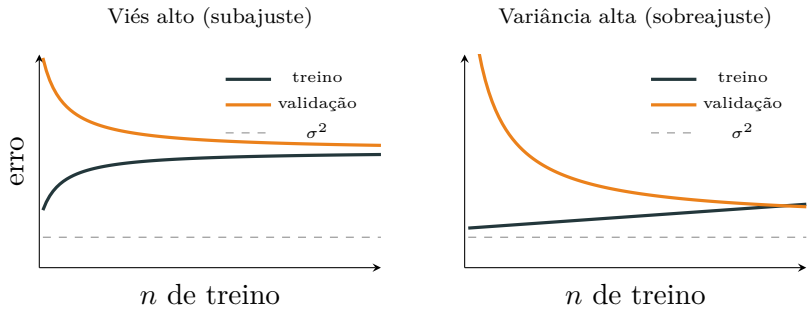
9.9.2 Diagnóstico e remédios

Situação	Erro treino	Lacuna	O que fazer
Subajuste	Alto	Pequena	Aumentar flexibilidade; acrescentar covariáveis, interações, termos não lineares; reduzir a regularização; trocar por família mais rica
Sobreajuste	Baixo	Grande	Regularizar mais ($\lambda \uparrow$); podar; reduzir B no *boosting*; selecionar variáveis; *obter mais dados*
Bom ajuste	Baixo	Pequena	Confirmar o protocolo e avaliar em dados externos
Suspeito	Muito baixo	Nenhuma	Procurar vazamento de dados (Seção 9.10)

A última linha merece uma verificação. Erros de validação e treinamento genuinamente baixos podem ocorrer quando o sinal é forte, mas também podem revelar vazamento do alvo, duplicatas entre partições ou uma divisão feita no nível errado, como separar entre blocos consultas do mesmo paciente. O resultado deve ser confrontado com uma linha de base, conhecimento do domínio e um teste externo.

9.9.3 Curvas de aprendizado

A curva de complexidade acima não responde à pergunta prática mais frequente, *vale a pena coletar mais dados?*, porque mantém n fixo. Para respondê-la, traçam-se os erros em função do **tamanho da amostra de treino**, com a flexibilidade fixa.



A leitura é direta e decide a próxima ação:

- Se as duas curvas se aproximam de um patamar alto dentro da faixa estudada, há evidência de limitação por viés. Coletar mais dados do mesmo tipo pode trazer pouco ganho; melhores covariáveis ou uma família mais rica devem ser investigadas.
- Se persiste uma lacuna e a curva de validação ainda cai com n, há evidência de limitação por variância. Mais dados podem ajudar; extrapolar a inclinação para tamanhos muito além dos observados, porém, é incerto.

Essa distinção é, na prática cotidiana, mais valiosa que a curva de complexidade, porque separa um problema que se resolve com orçamento de coleta de outro que se resolve com trabalho de modelagem.

Nota (Um cuidado contemporâneo). Em alguns modelos superparametrizados observa-se a **dupla descida**: o erro de teste cresce perto do limiar de interpolação e volta a cair quando a parametrização aumenta ainda mais. Portanto, a forma de U é uma heurística, não uma lei. A validação cruzada não precisa impor uma forma à curva, mas sua aplicação nesses regimes ainda exige partição correta e controle do custo de selecionar entre muitas configurações.

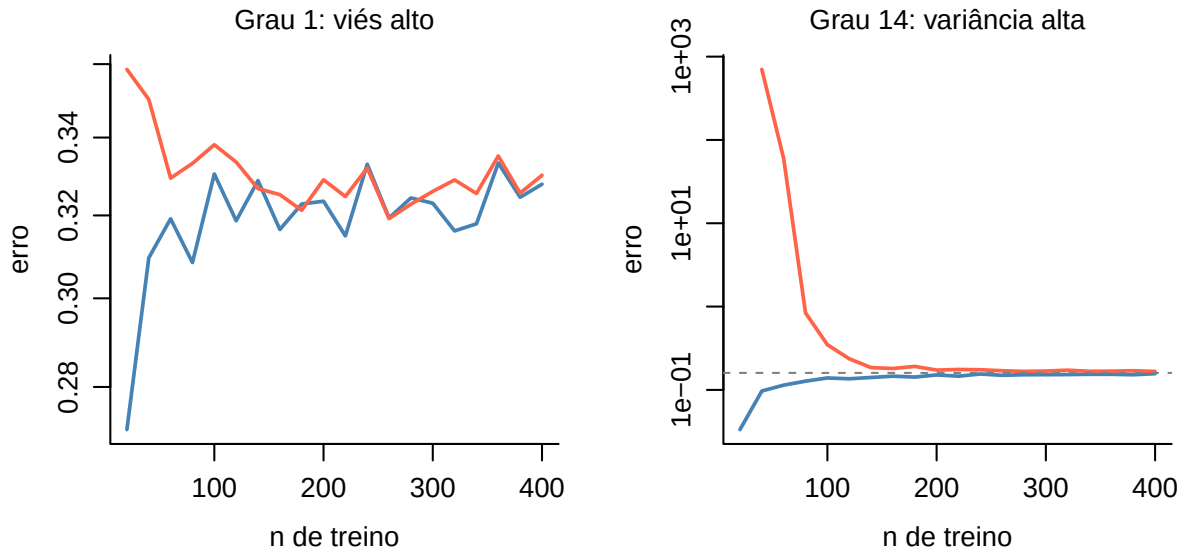


Figura 9.2: Simulação para $y = \sin(x) + \varepsilon$, com $\varepsilon \sim N(0, 0{,}4^2)$; a linha tracejada marca a variância irredutível 0,16 e a escala vertical é logarítmica. Com polinômio de grau 1, à esquerda, dobrar n de 100 para 200 reduziu o erro de teste simulado em apenas 2,7%. Com grau 14, à direita, a redução foi 58%. Os números dependem da semente e do desenho; o padrão sugere investigar maior flexibilidade no primeiro caso e mais dados ou regularização no segundo.

9.9.4 Protocolo

1. Separe um conjunto de teste externo *antes* de olhar os dados, e não o toque de novo.
2. Escolha a métrica em função da pergunta (Seção 9.8) antes de comparar configurações. Quando o algoritmo otimizar uma perda substituta, justifique sua relação com a métrica; use a métrica escolhida para selecionar e reportar.
3. Trace as duas curvas: erro de treinamento e de validação contra flexibilidade.
4. Diagnostique pela tabela acima; se houver dúvida entre coletar dados e melhorar o modelo, trace a curva de aprendizado.
5. Selecione o hiperparâmetro pelo mínimo da validação, ou pela heurística de um erro-padrão da Seção 9.7 se a parcimônia importar.
6. Reporte o desempenho final no conjunto de teste externo, nunca o mínimo da curva usada para selecionar.

9.10 Ressalvas e armadilhas

Vazamento de dados (*data leakage*). Se uma transformação aprendida nos dados, como imputação, padronização, seleção de variáveis, redução de dimensão ou construção supervisionada de atributos, usar toda a amostra, a validação será otimista. Todo passo que estima qualquer quantidade a partir de x ou de y deve ser ajustado somente no conjunto de treinamento de cada bloco e depois aplicado, sem reaprendizado, ao bloco de avaliação.

Séries temporais. Em dados temporais com dependência, uma partição aleatória pode treinar no futuro e avaliar no passado. Use uma validação por origem móvel, na qual cada ajuste usa apenas tempos anteriores à janela de avaliação.

Observações agrupadas. Quando várias linhas pertencem à mesma entidade, como consultas do mesmo paciente, imagens da mesma pessoa ou medições da mesma escola, a entidade é a

unidade de partição. Todas as suas linhas devem permanecer no mesmo bloco. Dividir linhas individualmente permite que informações quase duplicadas da mesma entidade apareçam no treinamento e na avaliação, produzindo uma estimativa excessivamente otimista para a predição em entidades novas. Se o alvo futuro forem novas medições de entidades já conhecidas, o esquema deve reproduzir explicitamente esse objetivo diferente.

Reuso para teste duplo. Selecionar $\hat{\lambda}$ pela mesma curva cujo mínimo será reportado tende a produzir otimismo, pois também se selecionou uma flutuação favorável. Reserve um conjunto de teste externo ou use validação cruzada aninhada, com um laço interno para seleção e um laço externo para avaliação.

9.11 Exemplos resolvidos

Exercício resolvido 9.1 : Remoção individual em pequena amostra

Enunciado. Considere as quatro observações $(x_i, y_i) = (0,1), (1,3), (2,4), (3,6)$. Ajuste uma regressão linear simples e calcule $\widehat{\mathrm{Val}}_4$ tanto pela definição, refazendo quatro ajustes, quanto pela fórmula do Teorema 9.3.
Solução. O ajuste por mínimos quadrados sobre todos os dados dá $\hat{\beta}_0 = 1{,}1$, $\hat{\beta}_1 = 1{,}6$, $\hat{y} = (1{,}1, 2{,}7, 4{,}3, 5{,}9)$ e resíduos $(-0{,}1, 0{,}3, -0{,}3, 0{,}1)$. Na regressão simples com intercepto, $h_{ii} = 1/n + (x_i - \bar{x})^2 / \sum_j (x_j - \bar{x})^2$. Como $\bar{x} = 1{,}5$ e a soma do denominador é 5, obtemos $h = (0{,}70, 0{,}30, 0{,}30, 0{,}70)$. Pelo Teorema 9.3,

$$\widehat{\mathrm{Val}}_4 = \tfrac{1}{4}\left[(\tfrac{-0{,}1}{0{,}30})^2 + (\tfrac{0{,}3}{0{,}70})^2 + (\tfrac{-0{,}3}{0{,}70})^2 + (\tfrac{0{,}1}{0{,}30})^2\right] \approx 0{,}147.$$

Refazer manualmente os quatro ajustes com uma observação removida produz a mesma estimativa.

Exercício resolvido 9.2 : Curva de validação para regressão polinomial

Enunciado. Sejam $n = 50$ pontos com $y_i = \sin(\pi x_i) + \varepsilon_i$, $x_i \sim U(0,2)$ e $\varepsilon_i \sim N(0, 0{,}3^2)$. Para graus polinomiais $d = 1, \ldots, 10$, esboce o que se espera da curva $\widehat{\mathrm{Val}}_{10}(d)$ e do erro de treinamento.
Solução. Como as classes polinomiais são encaixadas, o mínimo da perda quadrática de treinamento não aumenta com d. Se os x_i forem distintos e o ajuste não for regularizado, o grau $n-1$ pode interpolar os dados. A curva de validação pode inicialmente cair ao capturar a estrutura suave e depois subir com a instabilidade dos graus altos, mas a localização do mínimo é aleatória e não se deduz antecipadamente como grau 3 ou 4. O grau deve ser escolhido pela curva calculada, e seu desempenho final deve ser avaliado fora do processo de escolha.

Exercício resolvido 9.3 : Vazamento via padronização

Enunciado. Em uma análise, uma pessoa padroniza todas as covariáveis usando $\bar{x}$ e s_x calculados na amostra completa e depois aplica validação cruzada. Outra estima esses valores apenas no bloco de treinamento. Compare os dois procedimentos.
Solução. A primeira abordagem permite que a distribuição do bloco de avaliação influencie a transformação aplicada ao treinamento. A direção e o tamanho do viés dependem do algoritmo e não precisam ser desprezíveis. A segunda reproduz corretamente o que seria possível diante de dados novos. Em `R`, os pacotes literais `recipes` e `tidymodels` permitem

encapsular os passos aprendidos nos dados.

9.12 Laboratório computacional em R

Laboratório em R : Validação manual em k blocos

```
cv_kfold <- function(X, y, k = 10, ajustar) {
  n      <- length(y)
  folds  <- sample(rep(seq_len(k), length.out = n))
  erro   <- numeric(k)
  for (j in seq_len(k)) {
    idx_test <- which(folds == j)
    f_hat    <- ajustar(X[-idx_test, , drop = FALSE], y[-idx_test])
    pred     <- f_hat(X[idx_test, , drop = FALSE])
    erro[j]  <- mean((y[idx_test] - pred)^2)
  }
  list(erro_medio = mean(erro),
       dispersao_blocos = sd(erro))
}

# Uso: regressao polinomial em senoidal
set.seed(2026)
x <- runif(50, 0, 2)
y <- sin(pi * x) + rnorm(50, sd = 0.3)
graus <- 1:10
res <- sapply(graus, function(d) {
  cv_kfold(matrix(x), y, k = 10,
           ajustar = function(X_treino, y_treino) {
             dados <- data.frame(y = y_treino,
                                 x = as.numeric(X_treino))
             m <- lm(y ~ poly(x, d, raw = TRUE), data = dados)
             function(X_novo)
               predict(m, newdata = data.frame(x = as.numeric(X_novo
                  )))
           })$erro_medio
})
plot(graus, res, type = "o", pch = 19,
     xlab = "grau polinomial", ylab = "erro de validacao")
```

O desvio-padrão entre blocos descreve a heterogeneidade das perdas nesta partição; devido à sobreposição dos conjuntos de treinamento, não deve ser interpretado automaticamente como um erro-padrão baseado em observações independentes.

Laboratório em R : Função `cv.glmnet` e heurística de um erro-padrão

```
library(ISLR2)
library(glmnet)

dados <- na.omit(Hitters)
X <- model.matrix(Salary ~ ., dados)[, -1]
y <- dados$Salary

set.seed(1)
```

```r
cv_lasso <- cv.glmnet(X, y, alpha = 1, nfolds = 10)
plot(cv_lasso)

# Lambdas selecionados
c(min   = cv_lasso$lambda.min,
  oneSE = cv_lasso$lambda.1se)

# Coeficientes nos dois lambdas
coef(cv_lasso, s = "lambda.min")
coef(cv_lasso, s = "lambda.1se")
```

Laboratório em R : Remoção individual por alavancagens

Verificação numérica do Teorema 9.3:

```r
set.seed(2026)
n <- 30
x <- rnorm(n)
y <- 2 + 3 * x + rnorm(n)

ajuste <- lm(y ~ x)
h      <- hatvalues(ajuste)
res    <- residuals(ajuste)

cv_formula <- mean((res / (1 - h))^2)

cv_manual <- mean(sapply(seq_len(n), function(i) {
  ajuste_i <- lm(y[-i] ~ x[-i])
  pred_i   <- coef(ajuste_i)[1] + coef(ajuste_i)[2] * x[i]
  (y[i] - pred_i)^2
}))

c(formula = cv_formula, manual = cv_manual)
```

Os dois valores devem coincidir até a precisão numérica.

Laboratório em R : Perdas quadrática e absoluta têm alvos diferentes

A Proposição 9.5 pode ser verificada sem introduzir erro de especificação do modelo. Fixe $x_0 = 0{,}5$ e simule diretamente a distribuição condicional nesse ponto.

```r
set.seed(1)
x0 <- 0.5
n  <- 2000
y  <- rlnorm(n, meanlog = 1 + 2 * x0, sdlog = 1)

# Alvos teoricos e estimativas naturais
alvos <- c(media_teorica    = exp(1 + 2*x0 + 1/2),
           mediana_teorica  = exp(1 + 2*x0),
           media_amostral   = mean(y),
           mediana_amostral = median(y))
alvos

# Avaliacao em uma amostra nova e grande no mesmo x0
y_novo <- rlnorm(100000, meanlog = 1 + 2*x0, sdlog = 1)
```

```
avaliar <- function(predicao) {
  c(raiz_quadratica = sqrt(mean((y_novo - predicao)^2)),
    erro_absoluto   = mean(abs(y_novo - predicao)))
}
rbind(predizer_media   = avaliar(mean(y)),
      predizer_mediana = avaliar(median(y)))
```

A média e a mediana diferem pelo fator $e^{1/2} \approx 1{,}65$. Na grande amostra de avaliação, predizer a média minimiza a perda quadrática, enquanto predizer a mediana minimiza a perda absoluta, salvo pequena variação de simulação. O exemplo isola a escolha do alvo sem ajustar retas a funções condicionais exponenciais.

Laboratório em R : Curva de sensibilidade e a armadilha da acurácia

```
library(ISLR2)
y <- as.numeric(Default$default == "Yes")
mean(y)                                  # ~3% de eventos

m <- glm(default ~ balance + student + income,
         data = Default, family = binomial)
p_hat <- fitted(m)

# O classificador CONSTANTE ja acerta 97%
c(constante = mean(y == 0),
  modelo    = mean((p_hat > 0.5) == y))
```

A diferença entre os dois números é pequena; a acurácia nesse limiar esconde a capacidade de ordenação. Construímos a curva do zero:

```
roc_manual <- function(p, y) {
  cortes <- c(Inf, sort(unique(p), decreasing = TRUE), -Inf)
  sens <- sapply(cortes, function(c) sum(p >= c & y == 1) / sum(y ==
      1))
  fpr  <- sapply(cortes, function(c) sum(p >= c & y == 0) / sum(y ==
      0))
  data.frame(fpr, sens)
}
r <- roc_manual(p_hat, y)
plot(r$fpr, r$sens, type = "l", lwd = 2,
     xlab = "1 - especificidade", ylab = "sensibilidade")
abline(0, 1, lty = 2)

# Area por integracao trapezoidal
area_trap <- sum(diff(r$fpr) *
                 (head(r$sens, -1) + tail(r$sens, -1)) / 2)

# Area pela probabilidade de concordancia, incluindo empates
area_pares <- mean(outer(p_hat[y == 1], p_hat[y == 0], ">")) +
              0.5 * mean(outer(p_hat[y == 1], p_hat[y == 0], "=="))
c(trapezio = area_trap, pares = area_pares)
```

Os dois valores coincidem: é o Teorema 9.8. Confirme a invariância a transformações monótonas e o contraste com as regras próprias:

```
p_desc <- p_hat / 3                      # descalibra, preserva a
    ordem
area <- function(p)
```

```
  mean(outer(p[y == 1], p[y == 0], ">")) +
  0.5 * mean(outer(p[y == 1], p[y == 0], "=="))
c(original = area(p_hat), descalibrado = area(p_desc))    # IDENTICOS

brier <- function(p) mean((p - y)^2)
c(original = brier(p_hat), descalibrado = brier(p_desc)) #
   DIFERENTES
```

A área não distingue os dois modelos; a pontuação de Brier, sim. Essa é a diferença entre ordenar casos e quantificar probabilidades.

Laboratório em R : Curvas de complexidade e de aprendizado

Primeiro a curva de complexidade, que localiza o ótimo:

```
set.seed(1)
n <- 120
x <- runif(n, -3, 3);  y <- sin(x) + rnorm(n, sd = 0.4)
graus <- 1:15

erro <- t(sapply(graus, function(g) {
  m       <- lm(y ~ poly(x, g))
  treino  <- mean(residuals(m)^2)
  # Validacao em 10 blocos
  blocos  <- sample(rep(1:10, length.out = n))
  vc <- mean(sapply(1:10, function(b) {
    mb    <- lm(y ~ poly(x, g), subset = blocos != b)
    novos <- data.frame(x = x[blocos == b])
    pred  <- predict(mb, newdata = novos)
    mean((y[blocos == b] - pred)^2)
  }))
  c(treino = treino, validacao = vc)
}))

matplot(graus, erro, type = "l", lwd = 2, lty = 1, log = "y",
        xlab = "grau do polinomio", ylab = "erro")
legend("topleft", c("treino", "validacao"), col = 1:2, lty = 1, lwd
   = 2)
abline(v = which.min(erro[, "validacao"]), lty = 3)
```

Nesta simulação e com classes polinomiais encaixadas, o erro de treinamento cai e o erro de validação apresenta aproximadamente uma forma de U. A diferença observada entre as curvas estima a lacuna de generalização, mas ambas têm variabilidade de simulação. Agora a curva de aprendizado, que responde a “vale a pena coletar mais dados?”:

```
curva_aprendizado <- function(grau, tamanhos = seq(20, 400, by = 20)
   ) {
  t(sapply(tamanhos, function(m) {
    r <- replicate(30, {
      xi <- runif(m, -3, 3); yi <- sin(xi) + rnorm(m, sd = 0.4)
      xt <- runif(500, -3, 3); yt <- sin(xt) + rnorm(500, sd = 0.4)
      aj <- lm(yi ~ poly(xi, grau))
      c(mean(residuals(aj)^2),
        mean((yt - predict(aj, data.frame(xi = xt)))^2))
    })
    rowMeans(r)
  }))
```

```
}

par(mfrow = c(1, 2))
matplot(seq(20, 400, 20), curva_aprendizado(1),  type = "l", lty =
   1, lwd = 2,
        main = "Grau 1: vies alto",     xlab = "n", ylab = "erro")
matplot(seq(20, 400, 20), curva_aprendizado(14), type = "l", lty =
   1, lwd = 2,
        main = "Grau 14: variancia alta", xlab = "n", ylab = "erro")
```

No painel esquerdo, o padrão dentro da faixa simulada sugere limitação pela forma do modelo. No painel direito, a queda do erro de teste sugere que mais dados podem ajudar. Essas curvas informam a decisão, mas extrapolações além dos tamanhos estudados devem ser tratadas como hipóteses.

9.13 Exercícios propostos

Ex. 9.1. Demonstre o Teorema 9.3 a partir da fórmula de Sherman–Morrison–Woodbury, detalhando o passo da expressão $\hat{\beta}_{(-i)} = \hat{\beta} - (X^\top X)^{-1} x_i (y_i - \hat{y}_i)/(1 - h_{ii})$.

Ex. 9.2. Para regressão linear de posto completo com $p < n$, defina $Q = \sum_i (y_i - \hat{y}_i)^2$. Mostre que a validação generalizada pode ser escrita como $(Q/n)/(1 - p/n)^2$. Compare-a com a estimativa de risco de Mallows e com o critério de Akaike do Capítulo 10.

Ex. 9.3. Considere validação em dois blocos aplicada à predição pela média amostral, sob perda quadrática, com $X_1, \ldots, X_n$ independentes, de mesma distribuição e variância finita. Calcule a esperança da estimativa de validação e mostre seu viés positivo em relação ao erro de predição da média calculada com as n observações.

Ex. 9.4. Na regressão regularizada, escreva a decomposição compacta em valores singulares como $X = UDV^\top$, em que $r = \operatorname{posto}(X)$ e $D = \operatorname{diag}(d_1, \ldots, d_r)$ contém os valores singulares positivos. Mostre que

$$\widehat{\mathrm{Val}}_{\mathrm{geral}}(\lambda) = \frac{1}{n}\left[\sum_{j=1}^{r}\left(\frac{\lambda}{d_j^2 + \lambda}\right)^2 (u_j^\top y)^2 + \|(I - UU^\top)y\|^2\right]\left(1 - \frac{\sum_{j=1}^{r} d_j^2/(d_j^2 + \lambda)}{n}\right)^{-2},$$

em que I é a matriz identidade de ordem n e o termo $\|(I - UU^\top)y\|^2$ é a norma ao quadrado da componente de y ortogonal ao espaço-coluna de X.

Ex. 9.5. Em classificação binária com $\hat{f}(x) = \mathbb{1}\{\hat{p}(x) > 0{,}5\}$ e perda zero–um, descreva a validação estratificada em k blocos e justifique quando a estratificação reproduz o processo de amostragem futuro.

Ex. 9.6. *Aplicação prática.* No conjunto literal `Hitters` do pacote `ISLR2`, compare por validação em dez blocos: mínimos quadrados, regressão quadrática regularizada, regressão com penalidade absoluta e regressão polinomial em `CHits`. Selecione cada hiperparâmetro somente dentro do protocolo de validação e reporte o erro quadrático médio e o número efetivo de parâmetros.

Ex. 9.7. Demonstre a Proposição 9.5 nas duas partes. Em seguida: (a) mostre que a perda quantílica $L_\tau(y, a) = (y - a)\{\tau - \mathbb{1}(y < a)\}$ é minimizada por um quantil condicional de ordem τ; (b) para $Y \mid x$ lognormal com parâmetros $\mu(x)$ e σ^2, calcule a média e a mediana condicionais

e mostre que sua razão é $e^{\sigma^2/2}$; (c) explique por que um relatório de valor médio esperado de sinistro deve visar a média e o que mudaria ao minimizar erro absoluto.

Ex. 9.8. Demonstre o Teorema 9.8 para escores contínuos. Mostre que a área $\mathcal{A}$ é invariante sob transformações estritamente crescentes e que trocar S por $-S$ produz área $1-\mathcal{A}$ com a convenção de meio crédito para empates. Explique por que uma área amostral menor do que 0,5 pode resultar de codificação invertida, de um sinal genuinamente inverso ou de variação amostral, e não é sempre um erro. Construa ainda um exemplo com três casos de cada classe e verifique a igualdade entre integração trapezoidal e contagem de pares.

Ex. 9.9. *Regras de pontuação próprias.* Seja Y de Bernoulli com probabilidade p e considere anunciar $q \in [0,1]$. Mostre que as esperanças das perdas quadrática e logarítmica são minimizadas em $q = p$. Mostre também que a acurácia após limiarização não é própria: para $p = 0{,}6$, qualquer $q > 0{,}5$ produz a mesma decisão. Discuta por que otimizar apenas acurácia não identifica probabilidades calibradas.

Ex. 9.10. *Ordenação e precisão sob desbalanceamento.* Simule um problema binário com $n = 10\,000$ e prevalência de 1%, ajustando um modelo logístico de poder discriminativo moderado. Trace a curva de sensibilidade contra taxa de falsos positivos e a curva de precisão contra sensibilidade; calcule suas áreas. Escolha um limiar com sensibilidade 0,8 e reporte a precisão. Repita com prevalência de 30%, mantendo fixas as distribuições dos escores dentro de cada classe, e explique por que a primeira área permanece aproximadamente constante enquanto a precisão muda.

Ex. 9.11. *Curvas de aprendizado como instrumento de decisão.* Para $y = \sin(x) + \varepsilon$, com $\varepsilon \sim N(0, 0{,}4^2)$ e x uniforme em $[-3, 3]$, trace erros de treinamento e teste contra n para polinômios de graus 1, 4 e 14. Classifique os padrões observados, estime por interpolação o ganho de dobrar n e compare esse ganho com uma semana de trabalho de modelagem. Por fim, decomponha o patamar de teste em variância irredutível 0,16 e erro de aproximação da classe polinomial; explique por que o excesso pode ser quase nulo para um grau alto sem ser exatamente determinado pela figura.

Notas e leituras complementares

- Stone 1974: artigo fundador, com a primeira derivação rigorosa.
- Hastie, R. Tibshirani e J. Friedman 2009, Cap. 7: tratamento detalhado da decomposição viés-variância e das diferenças entre $\mathrm{Err}_{\mathcal{D}}$ e Err.
- G. James et al. 2013, Cap. 5: introdução acessível com aplicações em `R`.
- Hanley e McNeil 1982: exposição clássica da curva de sensibilidade contra falsos positivos e da interpretação de sua área como probabilidade de concordância.
- Brier 1950: origem do escore que leva seu nome, proposto para avaliar previsões meteorológicas probabilísticas.

9.14 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Validação cruzada	*cross-validation*	CV
Erro de predição	*prediction error*	—
Erro de treinamento	*training error*	—
Erro de teste	*test error*	—
Conjunto de treinamento	*training set*	—
Conjunto de validação	*validation set*	—
Conjunto de teste	*test set*	—
Validação por retenção simples	*holdout validation*	—
Validação cruzada em k blocos	*k-fold cross-validation*	k-fold CV
Validação cruzada estratificada	*stratified cross-validation*	—
Validação cruzada com uma observação removida	*leave-one-out cross-validation*	LOOCV
Validação cruzada generalizada	*generalized cross-validation*	GCV
Suavizador linear	*linear smoother*	—
Matriz de suavização	*smoother matrix*	—
Validação cruzada aninhada	*nested cross-validation*	nested CV
Hiperparâmetro	*hyperparameter*	—
Curva de validação	*validation curve*	—
Regra de um erro padrão	*one-standard-error rule*	1-SE rule
Função de perda	*loss function*	—
Erro quadrático médio	*mean squared error*	MSE
Raiz do erro quadrático médio	*root mean squared error*	RMSE
Erro absoluto médio	*mean absolute error*	MAE
Erro percentual absoluto médio	*mean absolute percentage error*	MAPE
Perda de Huber	*Huber loss*	—
Perda quantílica	*pinball loss*	—
Acurácia	*accuracy*	—
Sensibilidade	*sensitivity; true positive rate*	TPR
Especificidade	*specificity; true negative rate*	TNR
Precisão	*precision; positive predictive value*	PPV
Média harmônica de precisão e sensibilidade	*F_1 score*	F_1
Curva de sensibilidade contra falsos positivos	*receiver operating characteristic curve*	ROC curve
Área sob a curva de sensibilidade contra falsos positivos	*area under the receiver operating characteristic curve*	ROC AUC
Curva de precisão contra sensibilidade	*precision–recall curve*	PR curve
Pontuação de Brier	*Brier score*	—
Perda logarítmica	*log loss*	—
Regra de pontuação própria	*proper scoring rule*	—
Calibração	*calibration*	—
Subajuste	*underfitting*	—
Sobreajuste	*overfitting*	—
Lacuna de generalização	*generalization gap*	—
Curva de aprendizado	*learning curve*	—

Continua na página seguinte.

Terminologia no manual (português do Brasil)	Termo no livro-texto (inglês)	Sigla
Vazamento de informação	*data leakage*	—
Unidade de partição	*splitting unit*	—

Capítulo 10

Erro de predição e seleção de modelos

Objetivos da unidade

- Distinguir o erro em novos valores de resposta nos pontos de treinamento do erro em novos pares de preditores e respostas, e formalizar o conceito de otimismo.
- Apresentar o C_p de Mallows e justificá-lo via covariância.
- Derivar os critérios de Akaike e de Schwarz e discutir suas motivações por divergência de Kullback–Leibler e evidência bayesiana.
- Comparar os critérios em termos de eficiência preditiva e consistência de seleção.
- Aplicar a seleção de modelos em regressão linear e em modelos lineares generalizados.

Leitura primária: Efron e Hastie 2016, §12.3–12.4 e §13.3.
Leitura complementar: Mallows 1973; Akaike 1974; Schwarz 1978; G. James et al. 2013, capítulo 6.

10.1 Otimismo do erro de treinamento

Considere dados $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^n$, em que x_i é o vetor de preditores e y_i a resposta da observação i, e um procedimento de modelagem que produz o preditor $\hat{f}$ a partir de $\mathcal{D}$. Já vimos no Capítulo 9 que o *erro de treinamento* com perda quadrática,

$$\overline{\text{err}} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{f}(x_i))^2$$

tende a subestimar o erro de predição em dados novos. A diferença esperada é o *otimismo*.

Definição 10.1 (Erro nos pontos observados e otimismo)**.** O **erro em novas respostas nos pontos observados** avalia o preditor nos mesmos x_i, mas com novas respostas independentes Y_i^{novo} geradas da distribuição condicional em x_i:

$$\text{Err}_{\text{pontos}} = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}\Big[\{Y_i^{\text{novo}} - \hat{f}(x_i)\}^2 \mid x_i, \mathcal{D}\Big]\,.$$

O *otimismo* é

$$\text{Otimismo} = \mathbb{E}(\text{Err}_{\text{pontos}} - \overline{\text{err}})\,.$$

Teorema 10.2 (Identidade do otimismo, de Efron)**.** *Sob perda quadrática,*

$$\text{Otimismo} = \frac{2}{n}\sum_{i=1}^{n} \operatorname{Cov}(\hat{y}_i, y_i),$$

onde $\hat{y}_i = \hat{f}(x_i)$ e a covariância é tomada sob a distribuição amostral de $(y_i, \hat{y}_i)$ com x_i fixo.

Demonstração. Fixe i e defina $\mu_i = \mathbb{E}(y_i \mid x_i)$. A nova resposta Y_i^{novo} tem, condicionalmente a x_i, a mesma média e o mesmo segundo momento que y_i, mas é independente dos dados usados para obter $\hat{y}_i$. Ao expandir os dois quadrados e tomar esperança também sobre os dados de treinamento,

$$\begin{aligned}&\mathbb{E}\{(Y_i^{\text{novo}} - \hat{y}_i)^2\} - \mathbb{E}\{(y_i - \hat{y}_i)^2\} \\ &\quad = \mathbb{E}\{(Y_i^{\text{novo}})^2\} - \mathbb{E}(y_i^2) - 2\mathbb{E}(Y_i^{\text{novo}}\hat{y}_i) + 2\mathbb{E}(y_i\hat{y}_i).\end{aligned}$$

O primeiro par de termos se cancela porque as duas respostas têm a mesma distribuição marginal. Pela independência da nova resposta,

$$\mathbb{E}(Y_i^{\text{novo}}\hat{y}_i) = \mu_i \mathbb{E}(\hat{y}_i).$$

Pela definição de covariância,

$$\mathbb{E}(y_i\hat{y}_i) = \mu_i\mathbb{E}(\hat{y}_i) + \operatorname{Cov}(y_i, \hat{y}_i).$$

Portanto, a diferença para o ponto i é $2\operatorname{Cov}(y_i, \hat{y}_i)$. Somar sobre $i = 1, \ldots, n$ e dividir por n fornece a identidade. □

Observação (Caso linear)*.* Para regressão linear, seja X a matriz de planejamento e seja $H = X(X^\top X)^{-1}X^\top$ a matriz de projeção, de modo que $\hat{y} = Hy$. Denote por I_n a matriz identidade de ordem n e por $\operatorname{tr}(H)$ o traço, isto é, a soma dos elementos diagonais de H. Com erros independentes de variância comum σ^2, temos $\operatorname{Var}(y) = \sigma^2 I_n$ e

$$\sum_i \operatorname{Cov}(\hat{y}_i, y_i) = \operatorname{tr}(H\sigma^2 I_n) = \sigma^2 \operatorname{tr}(H).$$

Se X tem posto completo e d coeficientes, incluindo o intercepto quando presente, então $\operatorname{tr}(H) = d$ e o otimismo é $2d\sigma^2/n$.

A identidade do Teorema 10.2 é central: **quanto mais o ajuste $\hat{y}_i$ "segue" o ruído de y_i, maior o otimismo**. É a expressão quantitativa da intuição de *sobreajuste*.

10.2 C_p de Mallows

Definição 10.3 (Estimativa de risco de Mallows e C_p)**.** Considere um modelo linear com d coeficientes livres. Denote por Q a soma de quadrados dos resíduos, isto é,

$$Q = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2.$$

Se σ^2 for conhecida, a estimativa de risco corrigida pelo otimismo é

$$\widehat{R}_{\text{Mallows}} = \frac{Q}{n} + \frac{2d\sigma^2}{n}.$$

Na prática, Mallows propôs estimar σ^2 por $\hat{\sigma}^2$ obtida de um modelo de referência suficientemente amplo e definiu

$$C_p = \frac{Q}{\hat{\sigma}^2} - n + 2d.$$

Quando a mesma $\hat{\sigma}^2$ é usada para todos os candidatos,

$$\widehat{R}_{\text{Mallows}} = \frac{\hat{\sigma}^2}{n}(C_p + n),$$

de modo que as duas formas produzem o mesmo ranqueamento, embora não sejam a mesma quantidade.

Proposição 10.4 (Correção não viesada do risco)**.** *Sob o modelo linear de posto completo, com erros independentes de média zero e variância conhecida σ^2,*

$$\mathbb{E}(\widehat{R}_{\text{Mallows}}) = \mathbb{E}(\text{Err}_{\text{pontos}}).$$

Demonstração. Pela identidade de Efron,

$$\mathbb{E}(\text{Err}_{\text{pontos}}) = \mathbb{E}(\overline{\text{err}}) + \frac{2d\sigma^2}{n}.$$

Como $\overline{\text{err}} = Q/n$, o lado direito é $\mathbb{E}(\widehat{R}_{\text{Mallows}})$. Se σ^2 for substituída por uma estimativa, a igualdade exata exige condições adicionais sobre essa estimativa. □

Entre candidatos avaliados com a mesma estimativa de variância, minimizar C_p equivale a minimizar $\widehat{R}_{\text{Mallows}}$.

10.3 Critério de Akaike

Definição 10.5 (Critério de Akaike)**.** Seja $\hat{\ell}$ a log-verossimilhança maximizada e seja d o número total de parâmetros livres estimados. O critério de Akaike é

$$\text{Akaike} = -2\hat{\ell} + 2d.$$

Entre modelos ajustados à mesma resposta e com log-verossimilhanças comparáveis, prefere-se o menor valor.

10.3.1 Motivação via divergência de Kullback–Leibler

Seja $g(y)$ a densidade verdadeira e $f_\theta(y)$ uma família paramétrica candidata. A **divergência de Kullback–Leibler** é

$$\mathcal{K}(g, f_\theta) = \int g(y) \log \frac{g(y)}{f_\theta(y)}\, dy.$$

Ela é não negativa e vale zero apenas quando as densidades são iguais quase em toda parte. Como $\int g \log g$ não depende de θ, minimizar $\mathcal{K}$ equivale a maximizar $\mathbb{E}_g\{\log f_\theta(Y)\}$.

A não negatividade segue da desigualdade de Jensen. Com Y distribuído segundo g e supondo que f_θ não atribua massa fora do suporte relevante,

$$-\mathcal{K}(g, f_\theta) = \mathbb{E}_g\left[\log \frac{f_\theta(Y)}{g(Y)}\right] \le \log \mathbb{E}_g\left[\frac{f_\theta(Y)}{g(Y)}\right] = \log \int f_\theta(y)\, dy = 0.$$

Seja $\mathcal{D}^0$ uma nova amostra independente, também de tamanho n, e denote por $\ell^0(\hat{\theta})$ sua log-verossimilhança avaliada no estimador obtido de $\mathcal{D}$. Sob regularidade, dimensão fixa e igualdade entre as matrizes de informação e de variabilidade do escore, Akaike mostrou que

$$\mathbb{E}\{-2\ell^0(\hat{\theta})\} = \mathbb{E}\{-2\hat{\ell} + 2d\} + o(1).$$

Assim, $-2\hat{\ell}$ é otimista para a desviância em dados novos e $2d$ é sua correção de primeira ordem. Se a família estiver mal especificada, a penalidade geral envolve um traço de matrizes de informação e não precisa ser $2d$; essa extensão é o critério de Takeuchi.

10.3.2 Caso gaussiano

Para regressão linear gaussiana com σ^2 estimada por máxima verossimilhança, descartando constantes comuns,

$$\text{Akaike} = n \log(Q/n) + 2d,$$

em que d inclui todos os coeficientes da média e o parâmetro σ^2. Quando σ^2 é conhecida e comum aos modelos, d inclui apenas os coeficientes e

$$\text{Akaike}_{\sigma^2 \text{ conhecida}} = Q/\sigma^2 + 2d + \text{constante} = C_p + n + \text{constante}.$$

Nessa situação específica, os critérios ranqueiam os candidatos da mesma maneira.

10.4 Critério de Schwarz

Definição 10.6 (Critério de Schwarz)**.**

$$\text{Schwarz} = -2\hat{\ell} + d \log n,$$

em que d é o número total de parâmetros livres.

10.4.1 Motivação via probabilidade posterior

Seja $\mathbb{P}(M_j)$ a probabilidade a priori do modelo M_j e seja $\pi(\theta_j \mid M_j)$ a densidade a priori de seus parâmetros. Pelo teorema de Bayes,

$$\mathbb{P}(M_j \mid \mathcal{D}) \propto p(\mathcal{D} \mid M_j)\mathbb{P}(M_j),$$

em que a **evidência** do modelo é

$$p(\mathcal{D} \mid M_j) = \int f(\mathcal{D} \mid \theta_j, M_j)\pi(\theta_j \mid M_j)\, d\theta_j.$$

Se a dimensão d_j for fixa, o máximo for interior e identificável, a curvatura for não singular e a densidade a priori for positiva e contínua perto do máximo, a aproximação de Laplace produz

$$\log p(\mathcal{D} \mid M_j) = \hat{\ell}_j - \frac{d_j}{2} \log n + O(1).$$

O símbolo $O(1)$ representa um termo que permanece limitado quando n cresce. Esse termo pode depender do modelo, da curvatura e da distribuição a priori, mas é assintoticamente menor do que o termo em $\log n$. Se as probabilidades a priori dos modelos não introduzirem termos de ordem $\log n$, minimizar Schwarz aproxima, em primeira ordem, maximizar a probabilidade posterior do modelo. Essa equivalência não é exata em amostras finitas nem vale automaticamente para misturas, fronteiras ou dimensões que crescem rapidamente.

10.5 Comparação dos critérios

Nota (Resumo das penalidades)*.*

Critério	Penalidade por parâmetro	Comportamento
$\widehat{R}_{\text{Mallows}}$	$2\sigma^2/n$	corrige otimismo quadrático
Akaike	2	visa perda logarítmica preditiva
Schwarz	$\log n$	aproxima evidência bayesiana

As penalidades da última coluna multiplicam o número de parâmetros; as escalas das três linhas são diferentes e não devem ser comparadas numericamente sem transformação.

10.5.1 Eficiência preditiva do critério de Akaike

Resultados de Shibata 1981 mostram eficiência preditiva do critério de Akaike em regimes específicos, como sequências de modelos lineares encaixados cuja dimensão candidata pode crescer e nas quais o alvo não tem representação finita exata. Isso significa que, sob essas condições, o risco do modelo selecionado se aproxima do menor risco disponível. Não é um teorema universal para toda coleção mal especificada ou todo algoritmo de seleção.

10.5.2 Consistência de seleção do critério de Schwarz

Para uma coleção finita de modelos regulares e identificáveis que contém um único modelo verdadeiro de menor dimensão, o critério de Schwarz é consistente: a probabilidade de selecionar esse modelo tende a um. Sob condições análogas, a penalidade constante do critério de Akaike pode deixar probabilidade positiva de selecionar um supermodelo. Se nenhum candidato for verdadeiro, ou se houver não identificabilidade e fronteiras, a interpretação de "modelo correto" deixa de sustentar o resultado.

10.5.3 Recomendação prática

- Para **predição**, compare o critério de Akaike, a estimativa de Mallows e validação cruzada, verificando se suas hipóteses e perdas correspondem ao objetivo.
- Para comparar modelos bayesianos regulares por evidência, o critério de Schwarz é uma aproximação de primeira ordem; interpretação substantiva não é, sozinha, uma justificativa para sua penalidade.
- Uma correção de pequena amostra frequentemente usada é

$$\text{Akaike}_{\text{corr}} = \text{Akaike} + \frac{2d(d+1)}{n-d-1},$$

definida somente quando $n > d+1$. Ela é exata em alguns modelos gaussianos e aproximada em outros. A regra informal baseada em uma razão fixa entre n e d não é universal.

10.6 Seleção de subconjuntos

Em regressão com p preditores candidatos, há 2^p subconjuntos. A enumeração exata torna-se rapidamente cara; algoritmos de ramificação e poda podem evitar examinar explicitamente todos eles, mas seu custo depende do desenho. Para coleções maiores, usam-se aproximações ou penalizações.

Seleção progressiva. Comece com o modelo nulo. A cada passo, adicione o preditor que mais reduz o critério escolhido. Pare quando nenhuma adição o melhorar.

Eliminação regressiva. Comece com modelo completo. A cada passo, remova o preditor cuja remoção menos prejudica o critério.

Busca bidirecional. Permita adicionar e remover preditores em cada iteração.

Esses procedimentos são gulosos e podem produzir subótimos (não encontram o melhor entre todos os 2^p), mas são computacionalmente acessíveis.

Nota (Crítica moderna). A busca sequencial pode produzir estimativas instáveis e, quando a seleção é ignorada, valores de p e intervalos excessivamente otimistas. A regressão com penalidade absoluta e a validação em dados separados melhoram certos aspectos preditivos, mas também não tornam automaticamente válida a inferência sobre coeficientes selecionados. Inferência pós-seleção exige métodos específicos ou uma amostra de confirmação verdadeiramente independente.

10.7 Exemplos resolvidos

Exercício resolvido 10.1 : C_p e Akaike sob normalidade

Enunciado. Mostre que, em regressão linear gaussiana com uma variância σ^2 conhecida e comum aos candidatos, C_p e o critério de Akaike produzem o mesmo ranqueamento.
Solução. Com σ^2 conhecida, $\hat{\ell} = -\frac{n}{2}\log(2\pi\sigma^2) - Q/(2\sigma^2)$. Para um modelo com d coeficientes,

$$\text{Akaike} = n\log(2\pi\sigma^2) + Q/\sigma^2 + 2d.$$

Como $C_p = Q/\sigma^2 - n + 2d$, temos $\text{Akaike} = C_p + n + n\log(2\pi\sigma^2)$. Os termos adicionais são comuns aos modelos, logo o ranqueamento coincide. Se cada candidato usar uma estimativa diferente de σ^2, a transformação deixa de ser comum e a equivalência pode falhar.

Exercício resolvido 10.2 : Comparação entre Akaike e Schwarz

Enunciado. Em uma regressão polinomial em $x \in [0,1]$ com $n = 100$, os graus $g = 1, \dots, 8$ produzem somas de quadrados dos resíduos $(40, 25, 20, 18, 17{,}5, 17{,}2, 17{,}1, 17{,}0)$. Selecione o grau pelos critérios de Akaike e de Schwarz, contando também a variância estimada como parâmetro.
Solução. Denote por Q_g a soma de quadrados dos resíduos para o grau g. A log-verossimilhança maximizada é $\hat{\ell}_g = -\frac{n}{2}[\log(2\pi Q_g/n) + 1]$. Há $g+1$ coeficientes da média e um parâmetro de variância, portanto $d_g = g + 2$. Calculando $-2\hat{\ell}_g + 2d_g$ e $-2\hat{\ell}_g + d_g \log n$:

g	Q_g	d_g	$\hat{\ell}_g$	Akaike	Schwarz
1	40	3	−96,079	198,159	205,974
2	25	4	−72,579	153,158	163,579
3	20	5	−61,422	132,844	145,870
4	18	6	−56,154	124,308	**139,939**
5	17,5	7	−54,745	**123,491**	141,727
6	17,2	8	−53,881	123,762	144,603
7	17,1	9	−53,589	125,179	148,625
8	17,0	10	−53,296	126,592	152,644

O critério de Akaike seleciona grau 5 e o de Schwarz seleciona grau 4. Neste exemplo, $\log(100) \approx 4{,}605 > 2$, de modo que Schwarz cobra mais por parâmetro adicional. Isso não implica que ele sempre escolha um modelo estritamente menor quando as verossimilhanças ou conjuntos candidatos diferem.

Exercício resolvido 10.3 : Risco quadrático nos pontos observados

Enunciado. No modelo linear $y_i = x_i^\top \beta + \varepsilon_i$, suponha erros independentes com média zero e variância σ^2. Decomponha diretamente $\text{Err}_{\text{pontos}}$ em ruído, viés e variância.
Solução. Para cada i fixo,

$$\mathbb{E}[(y_i^{\text{novo}} - \hat{y}_i)^2] = \mathbb{E}[(y_i^{\text{novo}} - x_i^\top\beta)^2] + \mathbb{E}[(x_i^\top\beta - \hat{y}_i)^2] = \sigma^2 + \text{vies}_i^2 + \text{Var}(\hat{y}_i),$$

em que $\text{vies}_i = \mathbb{E}(\hat{y}_i) - x_i^\top\beta$, e usamos a independência entre y_i^{novo} e $\hat{y}_i$. Somando sobre i e dividindo por n:

$$\mathbb{E}(\text{Err}_{\text{pontos}}) = \sigma^2 + \frac{1}{n}\sum_i \text{vies}_i^2 + \frac{1}{n}\,\text{tr}\{\text{Var}(\hat{y})\}.$$

No modelo correto sem viés e com matriz de desenho de posto d, $\mathrm{Var}(\hat{y}) = \sigma^2 H$ e o risco é $\sigma^2 + d\sigma^2/n$. A estimativa de Mallows $Q/n + 2d\sigma^2/n$ é não viesada para esse risco porque a soma de quadrados dos resíduos tem esperança $(n-d)\sigma^2$.

10.8 Laboratório computacional em R

Laboratório em R : Seleção em leaps

O pacote `leaps` implementa seleção de subconjuntos e buscas progressiva e regressiva. Os nomes curtos da saída abaixo são identificadores literais do programa.

```
library(ISLR2)
library(leaps)

dados <- na.omit(Hitters)
ajuste <- regsubsets(Salary ~ ., data = dados, nvmax = 19)
resumo <- summary(ajuste)

# Comparar criterios
data.frame(
  p    = seq_along(resumo$cp),
  Mallows  = resumo$cp,
  Schwarz = resumo$bic,
  R2_ajustado = resumo$adjr2
)

which.min(resumo$cp)      # menor criterio de Mallows
which.min(resumo$bic)     # menor criterio de Schwarz
which.max(resumo$adjr2)   # maior coeficiente de determinacao
    ajustado

# Modelo selecionado pelo criterio de Schwarz
coef(ajuste, which.min(resumo$bic))
```

Compare os subconjuntos, não apenas seu tamanho. O critério de Schwarz frequentemente seleciona menos preditores nesta aplicação, mas isso é um resultado dos dados, não uma ordenação garantida entre critérios.

Laboratório em R : Critérios em modelos lineares generalizados

```
library(ISLR2)

# Comparar modelos de Poisson com diferentes preditores
m1 <- glm(bikers ~ temp,
          data = Bikeshare, family = poisson)
m2 <- glm(bikers ~ temp + hr,
          data = Bikeshare, family = poisson)
m3 <- glm(bikers ~ temp + hr + workingday,
          data = Bikeshare, family = poisson)

c(Akaike_m1 = AIC(m1), Akaike_m2 = AIC(m2), Akaike_m3 = AIC(m3))
c(Schwarz_m1 = BIC(m1), Schwarz_m2 = BIC(m2), Schwarz_m3 = BIC(m3))
```

```
# Selecao stepwise
m_step <- step(m3, direction = "backward")
```

As funções literais `AIC` e `BIC` da linguagem `R` calculam, respectivamente, os critérios de Akaike e de Schwarz. A função `step` faz uma busca sequencial e não examina necessariamente todos os subconjuntos.

Laboratório em R : Mallows e validação em simulação

```
set.seed(2026)
n <- 100; p_max <- 15
x <- matrix(rnorm(n * p_max), n, p_max)
beta <- c(rep(1, 5), rep(0, p_max - 5))
y <- x %*% beta + rnorm(n)

# Subconjuntos nos dados completos: apenas para Mallows e Schwarz
ajuste <- regsubsets(x, y, nvmax = p_max, method = "exhaustive")
resumo <- summary(ajuste)

# Validacao em dez blocos. A selecao do subconjunto e refeita
# DENTRO de cada conjunto de treinamento para evitar vazamento.
blocos <- sample(rep(1:10, length.out = n))
erro_validacao <- numeric(p_max)
for (tamanho in seq_len(p_max)) {
  perdas <- numeric(n)
  for (b in 1:10) {
    treino <- blocos != b
    ajuste_b <- regsubsets(x[treino, , drop = FALSE], y[treino],
                           nvmax = p_max, method = "exhaustive")
    vars_b <- which(summary(ajuste_b)$which[tamanho, -1])
    desenho_treino <- cbind(1, x[treino, vars_b, drop = FALSE])
    beta_b <- lm.fit(desenho_treino, y[treino])$coefficients
    desenho_teste <- cbind(1, x[!treino, vars_b, drop = FALSE])
    pred_b <- as.vector(desenho_teste %*% beta_b)
    perdas[!treino] <- (y[!treino] - pred_b)^2
  }
  erro_validacao[tamanho] <- mean(perdas)
}

data.frame(p = seq_len(p_max),
           Mallows = resumo$cp,
           Schwarz = resumo$bic,
           Validacao = erro_validacao)
```

É essencial refazer a escolha das variáveis dentro de cada conjunto de treinamento. Escolhê-las uma vez nos dados completos antes da validação revelaria ao procedimento as respostas dos blocos de avaliação e produziria otimismo. Os critérios podem selecionar tamanhos diferentes em uma réplica; isso deve ser interpretado como variação do procedimento, e não como uma ordenação necessária.

10.9 Exercícios propostos

Ex. 10.1. Mostre que, sob normalidade e uma variância σ^2 conhecida e comum, C_p e o critério de Akaike produzem o mesmo ranqueamento. Explique por que usar uma estimativa de variância diferente em cada candidato rompe a transformação afim comum.

Ex. 10.2. Resolva $\log n > 2$ e interprete quando a penalidade por parâmetro do critério de Schwarz excede a do critério de Akaike. Explique por que uma penalidade maior não garante, para toda coleção, um modelo selecionado estritamente menor.

Ex. 10.3. Demonstre o Teorema 10.2: Otimismo $= (2/n)\sum_i \operatorname{Cov}(\hat{y}_i, y_i)$. Explicite onde se usam a igualdade das distribuições marginais de y_i e Y_i^{novo} e a independência da nova resposta.

Ex. 10.4. A definição original de C_p usa perda quadrática e variância comum. Para um modelo de Poisson, explique por que a soma de quadrados deixa de ser a perda natural e derive o análogo de Akaike, dado pela desviância mais duas vezes o número de parâmetros, a menos de constantes comuns.

Ex. 10.5. Para $n = 30$, calcule a correção $2d(d+1)/(n-d-1)$ para $d = 5, 10, 20$ e some-a a um mesmo valor hipotético do critério de Akaike. Verifique a condição $n > d+1$ e discuta por que a correção cresce rapidamente quando a dimensão se aproxima do tamanho amostral.

Ex. 10.6. *Aplicação prática.* No conjunto literal `Hitters`, use a função `regsubsets` para comparar subconjuntos pelo C_p, pelo critério de Schwarz, pelo coeficiente de determinação ajustado e por validação em dez blocos. Refaça a seleção dentro de cada bloco de treinamento e compare variáveis, tamanho e erro externo.

Notas e leituras complementares

- Mallows 1973: artigo seminal do C_p.
- Akaike 1974: artigo seminal do critério de Akaike.
- Schwarz 1978: artigo seminal do critério de Schwarz.
- Hastie, R. Tibshirani e J. Friedman 2009, Cap. 7: tratamento detalhado dos critérios e suas inter-relações.
- G. James et al. 2013, Cap. 6: aplicações práticas em `R`.

10.10 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Erro de predição	*prediction error*	—
Erro de treinamento	*training error*	—
Otimismo	*optimism*	—
Penalidade de covariância	*covariance penalty*	—
Graus de liberdade	*degrees of freedom*	df
Soma de quadrados residual	*residual sum of squares*	RSS
Critério de Mallows	*Mallows' C_p*	C_p
Critério de informação de Akaike	*Akaike information criterion*	AIC
Critério de informação de Akaike corrigido	*corrected Akaike information criterion*	AICc
Divergência de Kullback–Leibler	*Kullback–Leibler divergence*	KL
Critério de Schwarz	*Bayesian information criterion*	BIC
Verossimilhança marginal	*marginal likelihood*	—
Fator de Bayes	*Bayes factor*	BF
Eficiência preditiva	*predictive efficiency*	—
Consistência de seleção	*selection consistency*	—
Seleção do melhor subconjunto	*best subset selection*	BSS
Seleção progressiva	*forward stepwise selection*	—
Seleção regressiva	*backward stepwise selection*	—
Coeficiente de determinação ajustado	*adjusted coefficient of determination*	adjusted R^2

Capítulo 11

Inferência bayesiana objetiva

Objetivos da unidade

- Apresentar a motivação para *prioris* não informativas em situações de pouca informação *a priori*.
- Construir a *priori* de Jeffreys e demonstrar sua propriedade de invariância sob reparametrização.
- Introduzir métodos de Monte Carlo via cadeias de Markov: os algoritmos de Metropolis–Hastings e de Gibbs.
- Discutir diagnósticos de cadeias, como o fator de redução de escala e o tamanho efetivo de amostra, e implementar exemplos em `R`.

Leitura primária: Efron e Hastie 2016, capítulo 13.
Leitura complementar: Jeffreys 1946.

11.1 Bayes objetivo: motivação

A inferência bayesiana parte do teorema de Bayes. Seja θ o parâmetro, ou o vetor de parâmetros, de interesse; seja y o conjunto de dados observado; seja $f(y \mid \theta)$ a densidade ou função de probabilidade dos dados quando θ é fixado; e seja $\pi(\theta)$ a densidade a priori, que representa a informação adotada antes de observar y. A densidade a posteriori é

$$\pi(\theta \mid y) = \frac{f(y \mid \theta)\,\pi(\theta)}{\int f(y \mid \theta)\,\pi(\theta)\,d\theta}.$$

A integral no denominador é a densidade marginal dos dados e normaliza o numerador para que a posterior integre a um. A escolha da *priori* $\pi(\theta)$ tem sido tradicionalmente alvo de duas escolas:

- **Bayes subjetivo**: π representa crenças *a priori* do pesquisador sobre θ. A inferência é honestamente subjetiva.
- **Bayes objetivo**: π é escolhida por um critério formal e publicamente verificável, como invariância, informação esperada ou concordância de cobertura.

A escola objetiva oferece escolhas de referência quando a informação substantiva é limitada ou quando se deseja separar uma análise de referência de análises de sensibilidade. Nenhuma *priori* é literalmente "sem informação": invariância em uma parametrização, boa cobertura e baixa influência podem favorecer distribuições diferentes. Em modelos regulares, algumas escolhas produzem intervalos numericamente próximos dos frequentistas, mas a coincidência depende das condições estudadas adiante.

11.2 Princípios da inferência bayesiana

Antes de discutir qual *priori* escolher, convém fixar os objetos e as decisões que serão usados no restante do capítulo.

11.2.1 Os três ingredientes e a posterior

A inferência bayesiana combina a verossimilhança $f(y \mid \theta)$ com a *priori* $\pi(\theta)$ para produzir a **posterior**

$$\pi(\theta \mid y) = \frac{f(y \mid \theta)\pi(\theta)}{m(y)}, \qquad m(y) = \int f(y \mid \theta)\pi(\theta)\, d\theta,$$

onde $m(y)$ é a **marginal** (ou *evidência*). A posterior é o objeto completo da inferência: tudo o que se relata (estimativas, intervalos, testes, predições) é um funcional dela.

Observação (Atualização sequencial). Se os dados chegam em dois lotes, $y = (y_1, y_2)$ condicionalmente independentes dado θ, então

$$\pi(\theta \mid y_1, y_2) \propto f(y_2 \mid \theta)\, \pi(\theta \mid y_1),$$

isto é, a posterior do primeiro lote funciona como *priori* para o segundo, e a ordem de processamento é irrelevante. Se os lotes não forem condicionalmente independentes, o fator correto é $f(y_2 \mid y_1, \theta)$, e não $f(y_2 \mid \theta)$. Essa coerência permite acumular evidência ao longo do tempo; procedimentos frequentistas podem admitir atualizações sequenciais, mas isso depende da construção específica.

Nota (O princípio da verossimilhança). Como $\pi(\theta \mid y)$ depende dos dados apenas através de $f(y \mid \theta)$ vista como função de θ, duas experiências que produzam verossimilhanças proporcionais levam a *idênticas* conclusões bayesianas quando se usa a mesma *priori*. A atualização bayesiana obedece ao **princípio da verossimilhança**. Procedimentos frequentistas cuja calibração usa todo o espaço amostral podem não obedecer a esse princípio, pois consideram também o que *poderia* ter sido observado; métodos frequentistas construídos apenas com a verossimilhança podem obedecê-lo. A divergência é entre critérios de inferência, não uma propriedade uniforme de todo procedimento frequentista.

11.2.2 Estimação pontual como decisão

A escolha de um resumo pontual da posterior não é arbitrária: decorre de uma função de perda, exatamente como na Seção 9.8.

Proposição 11.1 (Estimadores de Bayes)**.** *Sob perda quadrática, a ação que minimiza o risco a posteriori é a* ***média*** *da posterior; sob perda absoluta, qualquer* ***mediana*** *posterior. Se a perda for zero dentro de uma vizinhança de raio ε da ação e um fora dela, o limite dos minimizadores quando $\varepsilon \downarrow 0$, sob regularidade e uma moda única, é a* ***moda posterior****.*

Demonstração. Se $m = \mathbb{E}(\theta \mid y)$, então

$$\mathbb{E}\{(\theta - a)^2 \mid y\} = \mathrm{Var}(\theta \mid y) + (m - a)^2,$$

cujo mínimo é $a = m$. Para a perda absoluta, as derivadas laterais do risco são $2F(a^- \mid y) - 1$ e $2F(a \mid y) - 1$; o mínimo satisfaz $F(a^- \mid y) \le 1/2 \le F(a \mid y)$, definição de mediana. Na terceira perda, minimizar o risco equivale a maximizar $\mathbb{P}(|\theta - a| \le \varepsilon \mid y)$. Para densidade contínua,

$$\mathbb{P}(|\theta - a| \le \varepsilon \mid y) = 2\varepsilon\pi(a \mid y) + o(\varepsilon),$$

uniformemente perto de uma moda regular; logo o maximizador tende à moda única. □

O paralelo com a Proposição 9.5 é exato: são as mesmas contas aplicadas à posterior. A regressão quadrática regularizada do Capítulo 2 coincide com uma moda posterior sob *priori* gaussiana, enquanto o Bayes empírico do Capítulo 1 usa a média posterior. Para uma distribuição contínua, a perda zero–um literal dá risco um para toda ação; a construção por vizinhanças é indispensável para justificar a moda.

11.2.3 Intervalos de credibilidade

Definição 11.2 (Conjunto de credibilidade e maior densidade)**.** Um conjunto C tem **credibilidade** $1-\alpha$ se $\mathbb{P}(\theta \in C \mid y) = 1-\alpha$. Quando a posterior tem densidade em relação a uma medida de referência, um **conjunto de maior densidade posterior** tem a forma

$$C_{\text{dens}} = \{\theta : \pi(\theta \mid y) \geq k_\alpha\},$$

com k_α escolhido para produzir probabilidade $1-\alpha$. Sob condições que excluem patamares de densidade, ele minimiza o volume medido nessa parametrização entre conjuntos com a mesma credibilidade; pode ser desconexo quando a posterior é multimodal.

O intervalo de *caudas iguais*, $[q_{\alpha/2}, q_{1-\alpha/2}]$, é simples de obter de uma amostra da posterior e é equivariante sob transformações monótonas. O conjunto de maior densidade não tem essa propriedade, pois densidades e volumes mudam com a parametrização. Sob uma posterior simétrica e unimodal, os dois coincidem; sob assimetria ou multimodalidade, respondem a critérios diferentes, e nenhum é universalmente "mais honesto".

11.2.4 Predição

Duas distribuições preditivas merecem nome:

$$\underbrace{m(y) = \int f(y \mid \theta)\pi(\theta)\, d\theta}_{\text{preditiva } a \textit{ priori}}, \qquad \underbrace{p(\tilde{y} \mid y) = \int f(\tilde{y} \mid \theta)\, \pi(\theta \mid y)\, d\theta}_{\text{preditiva } a \textit{ posteriori}}.$$

A segunda é o que se usa para prever uma observação futura $\tilde{y}$, e sua virtude é integrar as duas fontes de incerteza, a do parâmetro e a amostral, em vez de fixar θ em uma estimativa pontual. Ela é também a base da *verificação preditiva a posteriori*: simular réplicas de conjuntos de dados a partir dela e comparar com o observado é o diagnóstico de ajuste mais natural em análise bayesiana.

11.2.5 Conjugação

Quando a *priori* pertence a uma família fechada sob multiplicação pela verossimilhança, a posterior tem forma fechada.

Nesta tabela, Gama(α, β) usa forma α e taxa β, e a gama inversa sobre $v > 0$ tem densidade proporcional a $v^{-(\alpha+1)}e^{-\beta/v}$. Para a linha normal de média desconhecida, defina

$$\tau_n^2 = (\tau^{-2} + n\sigma^{-2})^{-1}, \qquad \mu_n = \tau_n^2(\mu_0\tau^{-2} + n\bar{y}\sigma^{-2}).$$

Verossimilhança	*Priori* conjugada	Posterior
Bin(n, θ)	Beta(α, β)	Beta$(\alpha + y,\ \beta + n - y)$
$Y_i \sim$ Poisson(θ)	Gama(α, β)	Gama$(\alpha + \sum_i y_i, \beta + n)$
$Y_i \sim N(\theta, \sigma^2)$, σ^2 conhecida	$N(\mu_0, \tau^2)$	$N(\mu_n, \tau_n^2)$
$Y_i \sim N(\mu, v)$, μ conhecida	Gama inversa(α, β)	Gama inversa$(\alpha + n/2, \beta + \frac{1}{2}\sum_i (y_i - \mu)^2)$

O leitor reconhecerá as duas primeiras linhas do Capítulo 1. A álgebra é a mesma; o que muda é a justificativa dos hiperparâmetros, lá estimados dos dados e aqui escolhidos por um critério formal. A conjugação é conveniência computacional, não princípio; métodos de Monte Carlo via cadeias de Markov permitem trabalhar com posteriores sem forma fechada.

11.3 Prioris não informativas

11.3.1 Prior uniforme e suas patologias

A escolha mais ingênua é tomar $\pi(\theta) \propto 1$ (constante) sobre o espaço Θ. Quando Θ é não limitado, esta é uma *priori imprópria* (não integra a 1). Isto é admissível desde que a *posterior* seja própria, mas a uniformidade traz uma falha conceitual mais séria:

Exemplo 11.3 (Não invariância da prior uniforme)**.** Seja $\theta \in (0,1)$ e $\eta = \log(\theta/(1-\theta))$ (*logito*). Se $\pi(\theta) = 1$ é uniforme, então

$$\pi(\eta) = \pi(\theta(\eta)) \cdot |d\theta/d\eta| = \frac{e^{\eta}}{(1+e^{\eta})^2},$$

que *não* é uniforme em η. Portanto a uniformidade depende da parametrização, e duas pessoas que tomem "priors uniformes" em parametrizações diferentes obterão *posteriores diferentes* sobre o mesmo objeto físico.

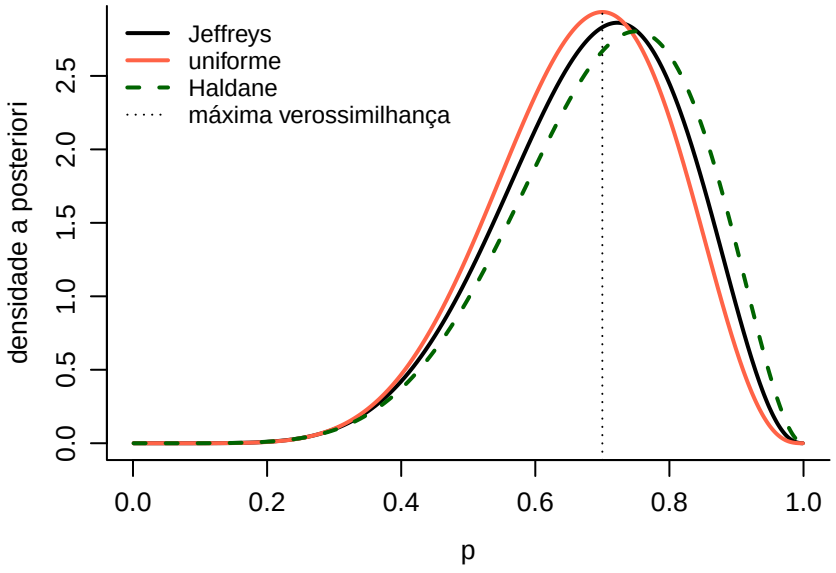


Figura 11.1: Posteriores de p após 7 sucessos em 10 ensaios de Bernoulli, sob as *prioris* de Jeffreys, uniforme e de Haldane; a linha pontilhada marca o estimador de máxima verossimilhança 0,7. Neste exemplo, as três posteriores são próximas, mas não idênticas. Na fronteira, como em zero sucessos, as diferenças são mais visíveis e o intervalo normal de Wald pode degenerar. Isso ilustra a necessidade de análise de sensibilidade; não implica que toda *priori* se torne irrelevante com dez observações.

11.4 A priori de Jeffreys

Jeffreys 1946 propôs uma classe de *prioris* construídas a partir da informação de Fisher, que tem a propriedade de ser *invariante* sob reparametrização. Defina o vetor escore por $s_\theta(y) = \partial \log f(y \mid \theta)/\partial\theta$. A matriz de informação de Fisher é

$$I(\theta) = \mathbb{E}_\theta\{ s_\theta(Y) s_\theta(Y)^\top \};$$

sob condições regulares, ela também é a esperança da negativa da matriz de segundas derivadas de $\log f(Y \mid \theta)$. Em uma dimensão, $I(\theta)$ é um número não negativo.

Definição 11.4 (*Priori* de Jeffreys)**.** Seja $I(\theta)$ a informação de Fisher do modelo $f(y \mid \theta)$. A *priori de Jeffreys* é

$$\pi_J(\theta) \propto \sqrt{\det I(\theta)}.$$

11.4.1 Invariância sob reparametrização

Teorema 11.5 (Invariância de Jeffreys)**.** *Para uma reparametrização diferenciável e bijetora $\eta = g(\theta)$, seja $J(\eta) = \partial\theta/\partial\eta^\top$ a matriz jacobiana da transformação inversa. A* priori *de Jeffreys calculada em η satisfaz*

$$\pi_J(\eta) = \pi_J\{\theta(\eta)\}\,|\det J(\eta)|,$$

que é exatamente a regra de mudança de variáveis para densidades.

Demonstração. Pela regra da cadeia, o vetor escore na nova parametrização é $s_\eta = J^\top s_\theta$. Portanto,

$$I_\eta(\eta) = \mathbb{E}(s_\eta s_\eta^\top) = J^\top I_\theta\{\theta(\eta)\} J.$$

Tomando determinantes,

$$\det I_\eta = (\det J)^2 \det I_\theta.$$

Extrair a raiz quadrada dá $\sqrt{\det I_\eta} = |\det J| \sqrt{\det I_\theta}$, o resultado desejado. Em uma dimensão, $J = d\theta/d\eta$ e a mesma conta reduz-se à regra escalar. □

11.4.2 Casos clássicos

Exemplo 11.6 (Bernoulli)**.** Para $Y \sim \text{Bernoulli}(p)$, $\log f(y;p) = y\log p + (1-y)\log(1-p)$. A informação de Fisher é

$$I(p) = -\mathbb{E}[\partial^2 \log f / \partial p^2] = \frac{1}{p(1-p)}.$$

Logo

$$\pi_J(p) \propto \frac{1}{\sqrt{p(1-p)}} = p^{-1/2}(1-p)^{-1/2},$$

que é a densidade $\text{Beta}(1/2, 1/2)$ (sem o termo de normalização). A posterior, após observar y sucessos em n tentativas, é $\text{Beta}(y + 1/2, n - y + 1/2)$.

Exemplo 11.7 (Poisson)**.** Para $Y \sim \text{Poisson}(\lambda)$, $I(\lambda) = 1/\lambda$, donde

$$\pi_J(\lambda) \propto \lambda^{-1/2}.$$

Esta *priori* é imprópria, mas a posterior $\pi(\lambda \mid y)$ proporcional a $\lambda^{y-1/2}e^{-\lambda}$ é uma $\text{Gama}(y+1/2, 1)$ e portanto própria desde que $y > -1/2$, ou seja, para qualquer observação válida.

Exemplo 11.8 (Normal com μ desconhecido e σ^2 conhecido)**.** $I(\mu) = 1/\sigma^2$, constante em μ. Logo $\pi_J(\mu) \propto 1$, a *priori uniforme imprópria* sobre $\mathbb{R}$. A posterior é a normal usual com média $\bar{y}$ e variância σ^2/n.

Exemplo 11.9 (Normal com $\sigma > 0$ desconhecido e μ conhecido)**.** $I(\sigma) = 2/\sigma^2$, donde $\pi_J(\sigma) \propto 1/\sigma$ (imprópria). Equivalentemente, $\pi_J(\sigma^2) \propto 1/\sigma^2$. Esta *priori* é a regra clássica para parâmetros de escala.

Nota (Caso multivariado: regra de Jeffreys e *prioris* independentes). Para $\theta = (\mu, \sigma)$ na normal, a aplicação direta da Definição 11.4 produz $\pi_J(\mu, \sigma) \propto 1/\sigma^2$. Mas é prática comum tratar μ e σ separadamente, multiplicando $\pi_J(\mu) \cdot \pi_J(\sigma) \propto 1/\sigma$. As duas escolhas levam a posteriores marginais ligeiramente diferentes; Jeffreys 1946 recomendou a versão fatorada para parâmetros de natureza distinta (locação e escala). Em problemas com vários parâmetros, a *reference prior* de Bernardo é hoje preferida.

11.5 Prioris de referência

A *priori* de Jeffreys resolve o problema da invariância e tem propriedades atraentes em muitos modelos unidimensionais. Com vários parâmetros, a regra conjunta pode não produzir a concordância desejada para o parâmetro de interesse, limitação reconhecida pelo próprio Jeffreys.

Exemplo 11.10 (A falha da regra de Jeffreys no modelo normal)**.** Para observações independentes $Y_i \sim N(\mu, \sigma^2)$, com ambos os parâmetros desconhecidos, a regra conjunta produz $\pi_J(\mu, \sigma) \propto 1/\sigma^2$. Para μ, a posterior padronizada resultante tem distribuição t de Student com n graus de liberdade, enquanto a escolha $\pi(\mu, \sigma) \propto 1/\sigma$ produz t com $n-1$ graus de liberdade e coincide com o intervalo frequentista clássico. Jeffreys recomendou a versão fatorada para parâmetros de locação e escala. O exemplo mostra que invariância conjunta e concordância marginal são critérios distintos.

O que falta é um critério explícito para escolher uma distribuição de referência quando há vários parâmetros e um deles é o alvo principal. Bernardo 1979 propôs uma construção baseada na informação esperada. Ela resolve vários conflitos da regra conjunta de Jeffreys, mas não elimina a necessidade de declarar o parâmetro de interesse, verificar que a posterior é própria e estudar a sensibilidade.

11.5.1 A ideia: maximizar o que os dados têm a dizer

Uma *priori* não informativa deveria ser aquela que *menos* interfere, ou, equivalentemente, aquela que permite aos dados provocarem a maior mudança de opinião possível. Formalize-se "mudança de opinião" pela divergência de Kullback–Leibler entre posterior e *priori*, e "a maior possível" por uma maximização.

Definição 11.11 (*Priori* de referência, versão heurística)**.** A *priori* de referência é aquela que maximiza a informação esperada que os dados trazem sobre θ,

$$\pi_R = \arg\max_{\pi} \lim_{n\to\infty} \mathbb{E}_{y^{(n)}}\Big[\mathcal{K}\big(\pi(\theta \mid y^{(n)}), \pi(\theta)\big)\Big],$$

o limite sendo tomado sobre réplicas hipotéticas de n observações.

A definição rigorosa exige cuidado (o limite em geral não existe sem uma sequência de compactos, e a formulação definitiva é a de Berger, Bernardo e Sun 2009), mas a intuição é exatamente essa: *a priori de referência é a que deixa os dados falarem mais alto.*

Teorema 11.12 (Coincidência em uma dimensão)**.** *Para um modelo regular com um único parâmetro, a* priori *de referência coincide com a de Jeffreys,* $\pi_R(\theta) \propto \sqrt{I(\theta)}$.

Isso é tranquilizador: a construção de Bernardo não descarta Jeffreys, ela o *explica*, e o estende corretamente ao caso multiparamétrico, onde a regra original falhava.

11.5.2 Vários parâmetros: a ordenação importa

A diferença essencial aparece com parâmetros de perturbação. Seja $\theta = (\theta_1, \theta_2)$, com θ_1 o **parâmetro de interesse** e θ_2 o **parâmetro de perturbação**. A construção de referência procede por condicionamento sucessivo:

1. Obtenha a *priori* de referência condicional $\pi(\theta_2 \mid \theta_1)$, tratando θ_1 como fixo, problema de um parâmetro, resolvido pelo Teorema 11.12.
2. Integre θ_2 para obter a verossimilhança marginal de θ_1.
3. Obtenha a *priori* marginal de referência $\pi(\theta_1)$ desse problema reduzido.
4. Combine: $\pi_R(\theta_1, \theta_2) = \pi(\theta_2 \mid \theta_1)\,\pi(\theta_1)$.

Observação (A *priori* depende do que se quer estimar). Segue-se que **a priori de referência não é única**: ela depende de qual parâmetro foi declarado de interesse. Isso costuma soar como defeito e é, na verdade, o ponto central da construção. "Não informativo" não é uma propriedade absoluta de uma distribuição sobre Θ: é uma propriedade *relativa à quantidade que se deseja estimar*. Uma *priori* que é neutra quanto a μ pode ser fortemente informativa quanto a σ, ou quanto a μ/σ. Exigir neutralidade simultânea para todos os funcionais possíveis é exigir demais, e é exatamente essa exigência impossível que fazia a regra de Jeffreys tropeçar.

Exemplo 11.13 (Normal com média e variância desconhecidas)**.** Aplicando o algoritmo a observações independentes $Y_i \sim N(\mu, \sigma^2)$, com μ de interesse e σ de perturbação:

- Passo 1: com μ fixo, $I(\sigma) \propto 1/\sigma^2$, logo $\pi(\sigma \mid \mu) \propto 1/\sigma$.
- Passo 3: a verossimilhança marginal de μ é de locação, e a *priori* de referência de um parâmetro de locação é $\pi(\mu) \propto 1$.
- Passo 4: $\pi_R(\mu, \sigma) \propto 1/\sigma$.

Obtém-se, por um princípio geral, exatamente a *priori* que Jeffreys havia recomendado como exceção. Por simetria do argumento, a ordenação inversa (com σ de interesse) produz a mesma resposta neste caso particular, o que não ocorre em geral.

A recompensa é concreta: sob $\pi_R \propto 1/\sigma$, a posterior marginal de μ é

$$\frac{\mu - \bar{y}}{s/\sqrt{n}} \;\Big|\; y \;\sim\; t_{n-1},$$

de modo que o intervalo de credibilidade de 95% para μ é *numericamente idêntico* ao intervalo t clássico. Não aproximadamente: exatamente.

Nota (Onde a diferença é dramática: Neyman–Scott). Considere $Y_{ij} \sim N(\mu_i, \sigma^2)$, com $j = 1, 2$ e $i = 1, \ldots, n$: surge um novo parâmetro de perturbação μ_i para cada par. Neyman e Scott 1948 mostraram que o estimador de máxima verossimilhança de σ^2 converge para $\sigma^2/2$ e, portanto, é inconsistente. A regularidade usual falha porque o número de parâmetros cresce com a amostra.

Uma construção de referência apropriada integra os μ_i antes de resumir σ^2 e pode produzir estimadores consistentes nesse problema. O exemplo mostra que "objetivo" não significa "idêntico à máxima verossimilhança"; a conclusão depende da construção e da quantidade de interesse.

Observação (Cuidados com *prioris* impróprias). Prioris de referência são frequentemente impróprias. Duas consequências exigem atenção: (i) é obrigatório **verificar que a posterior é própria**, o que não é automático e falha em modelos hierárquicos comuns, uma *priori* $\propto 1/\tau$ para o desvio-padrão de efeitos aleatórios produz posterior imprópria; (ii) a marginal $m(y)$ é indefinida a menos de constante multiplicativa arbitrária, de modo que **fatores de Bayes calculados com *prioris* impróprias não têm sentido**. Para comparação de modelos, use *prioris* próprias, ou variantes como o fator de Bayes intrínseco.

11.6 Métodos de Monte Carlo via cadeias de Markov

Em geral, a constante que normaliza $f(y \mid \theta)\pi(\theta)$ é intratável. Uma **cadeia de Markov** é uma sequência aleatória na qual a distribuição do próximo estado, dado todo o passado, depende apenas do estado corrente. Os métodos desta seção constroem uma cadeia cuja distribuição estacionária é a posterior: se um estado tiver essa distribuição, o estado seguinte também terá. Para que as distribuições das iterações efetivamente se aproximem da posterior a partir de estados iniciais arbitrários, são necessárias condições adicionais. Em termos informais, **irredutibilidade** significa que a cadeia pode alcançar toda região com probabilidade posterior positiva; **aperiodicidade** significa que ela não fica presa a um ciclo determinístico; e **recorrência positiva** significa que o tempo médio de retorno a regiões relevantes é finito.

11.6.1 Algoritmo Metropolis–Hastings

Defina a posterior não normalizada por $\tilde{\pi}(\theta \mid y) = f(y \mid \theta)\pi(\theta)$. Ela difere da posterior apenas pela constante marginal $m(y)$, que não depende de θ.

Definição 11.14 (Metropolis–Hastings)**.** Dado o estado corrente $\theta^{(t)}$:
1. Proponha θ^* a partir de uma *distribuição de proposta* $q(\theta^* \mid \theta^{(t)})$.
2. Calcule a razão de aceitação

$$\alpha(\theta^*, \theta^{(t)}) = \min\left\{1,\ \frac{\tilde{\pi}(\theta^* \mid y)\, q(\theta^{(t)} \mid \theta^*)}{\tilde{\pi}(\theta^{(t)} \mid y)\, q(\theta^* \mid \theta^{(t)})}\right\},$$

3. Com probabilidade α, defina $\theta^{(t+1)} = \theta^*$; senão, $\theta^{(t+1)} = \theta^{(t)}$.

A constante de normalização de $\tilde{\pi}$ cancela no quociente. Quando a proposta é simétrica, $q(a \mid b) = q(b \mid a)$, a razão de propostas também cancela, dando o algoritmo de Metropolis original.

Teorema 11.15 (Estacionariedade do algoritmo de Metropolis–Hastings)**.** *Suponha que a posterior seja própria e que a razão da Definição 11.14 esteja bem definida em seu suporte. O núcleo de transição satisfaz o balanço detalhado em relação a $\pi(\cdot \mid y)$ e, portanto, essa posterior é estacionária.*

Demonstração. Para $\theta' \neq \theta$, a densidade de transição é $k(\theta, \theta') = q(\theta' \mid \theta)\alpha(\theta', \theta)$. Multiplicando pela densidade posterior normalizada,

$$\begin{aligned}\pi(\theta \mid y)k(\theta, \theta') &= \min\{\pi(\theta \mid y)q(\theta' \mid \theta), \pi(\theta' \mid y)q(\theta \mid \theta')\} \\ &= \pi(\theta' \mid y)k(\theta', \theta).\end{aligned}$$

A expressão é simétrica em θ e θ'. A probabilidade restante mantém a cadeia em θ e satisfaz trivialmente a mesma identidade na diagonal. Integrar o balanço detalhado em θ mostra que aplicar o núcleo a π devolve π; logo ela é estacionária. □

Observação (Estacionariedade não implica convergência)*.* Uma cadeia pode ter a posterior como distribuição estacionária e ainda ser redutível, periódica ou incapaz de atravessar modos separados. Para uma cadeia irredutível, aperiódica e recorrente positiva, médias ergódicas convergem para esperanças posteriores sob condições de integrabilidade. Essas condições fazem parte da validade do método, não são garantidas apenas pela fórmula de aceitação.

11.6.2 Algoritmo Gibbs

Para $\theta = (\theta_1, \ldots, \theta_d)$, denote por θ_{-j} o vetor de todas as coordenadas exceto a j-ésima. Quando é possível sortear de cada posterior condicional $\pi(\theta_j \mid \theta_{-j}, y)$, o **amostrador de Gibbs** atualiza uma coordenada por vez. Ele pode ser visto como um passo de Metropolis–Hastings cuja proposta condicional é sempre aceita.

Definição 11.16 (Iteração de Gibbs)**.** Dado $\theta^{(t)} = (\theta_1^{(t)}, \ldots, \theta_d^{(t)})$:

$$\begin{aligned}\theta_1^{(t+1)} &\sim \pi(\theta_1 \mid \theta_2^{(t)}, \ldots, \theta_d^{(t)}, y), \\ \theta_2^{(t+1)} &\sim \pi(\theta_2 \mid \theta_1^{(t+1)}, \theta_3^{(t)}, \ldots, \theta_d^{(t)}, y), \\ &\vdots \\ \theta_d^{(t+1)} &\sim \pi(\theta_d \mid \theta_1^{(t+1)}, \ldots, \theta_{d-1}^{(t+1)}, y).\end{aligned}$$

11.7 Diagnósticos de convergência

Aproximações por cadeias são válidas somente quando o núcleo é ergódico e a execução explora adequadamente a distribuição de interesse. Em uma execução finita, dois efeitos são centrais:

- **Inicialização e adaptação**: as primeiras iterações podem refletir o estado inicial ou a adaptação do algoritmo. Uma fase de aquecimento costuma ser descartada, mas nenhum descarte de comprimento fixo garante estacionariedade.
- **Autocorrelação**: estados consecutivos são dependentes, de modo que o número de iterações excede, em geral, a quantidade equivalente de informação independente.

11.7.1 Fator de redução de escala

Rode, de preferência, pelo menos quatro cadeias de comprimento T com inicializações dispersas. Denote o número de cadeias por M, seja W a média das variâncias dentro das cadeias e defina a variabilidade entre suas médias por

$$B = \frac{T}{M-1} \sum_{m=1}^{M} \left(\bar{\theta}_m - \bar{\theta}\right)^2,$$

onde $\bar{\theta}_m$ é a média da cadeia m e $\bar{\theta}$ a média global. Então

$$\hat{R} = \sqrt{\frac{(T-1)/T \cdot W + B/T}{W}}.$$

O valor $\hat{R}$ compara a variabilidade entre cadeias com a variabilidade dentro delas. Valores bem acima de um revelam que as cadeias ainda diferem. Implementações modernas dividem cada cadeia, normalizam os postos e também examinam as caudas; essa versão é preferível à fórmula clássica acima. Um valor menor do que 1,01 é um critério de alerta comum, não uma prova de convergência: cadeias podem permanecer juntas no mesmo modo e nunca visitar outro.

11.7.2 Tamanho efetivo de amostra

Para uma cadeia estacionária de comprimento T, defina $\rho_k = \operatorname{Corr}(\theta^{(t)}, \theta^{(t+k)})$, a autocorrelação na defasagem k. Quando a soma converge, o tamanho efetivo para estimar a média é aproximado por

$$T_{\text{efetivo}} = \frac{T}{1 + 2\sum_{k=1}^{\infty} \rho_k}.$$

O denominador é o tempo integrado de autocorrelação. Na prática, a soma infinita é truncada por um estimador estável e combina-se a informação de cadeias independentes. Para a média de uma quantidade $h(\theta)$, o erro-padrão de Monte Carlo é aproximadamente

$$\sqrt{\operatorname{Var}_{\pi}\{h(\theta)\}/T_{\text{efetivo}}}.$$

Portanto, o tamanho necessário depende da precisão desejada e da quantidade resumida; não há um limiar universal por parâmetro. Quantis de cauda podem exigir muito mais informação do que médias centrais.

11.7.3 Gráficos de trajetória

Represente $\theta^{(t)}$ contra t para todas as cadeias. Tendências, mudanças de escala, longos períodos imóveis e separação entre cadeias revelam problemas. Um aspecto visualmente estacionário é apenas evidência parcial: não detecta um modo que nenhuma cadeia alcançou nem torna própria uma posterior imprópria.

11.8 Bayes objetivo e inferência frequentista

A motivação da Seção 11.1 anunciou que as técnicas objetivas "convergem, em muitos casos, para procedimentos frequentistas". É hora de tornar isso preciso, e de delimitar os casos em que não convergem.

11.8.1 A diferença de interpretação

Um intervalo de credibilidade de 95% e um intervalo de confiança de 95% podem ser numericamente idênticos e ainda assim afirmar coisas distintas:

- **Credibilidade**: dado *estes* dados, $\mathbb{P}(\theta \in C \mid y) = 0{,}95$. A afirmação probabilística é sobre θ.
- **Confiança**: sobre repetições hipotéticas do experimento, 95% dos intervalos construídos por este procedimento conterão o θ verdadeiro. A afirmação probabilística é sobre o *procedimento*; para o intervalo já calculado, θ está dentro ou não está.

A interpretação bayesiana é a que muitos usuários *atribuem* aos intervalos de confiança, interpretação incorreta no arcabouço frequentista e correta para um intervalo de credibilidade calculado sob o modelo bayesiano. Parte da atratividade prática do Bayes objetivo está em fornecer uma justificativa coerente para essa leitura, desde que o modelo e a distribuição a priori também sejam considerados na interpretação.

11.8.2 Concordância assintótica

Teorema 11.17 (Bernstein–von Mises, versão informal)**.** *Em um modelo identificável de dimensão fixa, com parâmetro verdadeiro interior θ_0, informação não singular, comportamento local assintoticamente normal da verossimilhança e uma* priori *própria, positiva e contínua perto de θ_0, seja $\hat{\theta}_n$ o estimador de máxima verossimilhança e seja $I_n(\hat{\theta}_n)$ a informação de Fisher total das n observações, avaliada nesse estimador. Então a posterior é aproximada localmente por*

$$\pi(\theta \mid y^{(n)}) \approx N\Big(\hat{\theta}_n, I_n(\hat{\theta}_n)^{-1}\Big)\,,$$

em uma métrica probabilística apropriada, com erro que tende a zero em probabilidade quando $n \to \infty$.

Dentro dessas condições, o efeito local de duas *prioris* fixas e positivas é de ordem menor na aproximação de primeira ordem, e conjuntos de credibilidade regulares podem ter cobertura frequentista assintótica. Isso não significa que a *priori* seja globalmente irrelevante, que funcionais de cauda concordem rapidamente ou que o resultado sobreviva a dimensão crescente, fronteiras, misturas e não identificação. Quando o teorema falha, uma análise bayesiana ainda pode ser útil, mas sua validade não decorre deste resultado e sua sensibilidade à *priori* deve ser examinada.

11.8.3 *Prioris* de casamento de probabilidade

Pode-se ir além do assintótico de primeira ordem e *exigir* concordância como critério de escolha da *priori*.

Definição 11.18 (*Priori* de casamento de probabilidade)**.** π é de casamento de probabilidade se o intervalo de credibilidade unilateral de nível $1-\alpha$ tiver cobertura frequentista $1-\alpha+O(n^{-1})$, e não apenas $1-\alpha+O(n^{-1/2})$.

Aqui $O(n^{-1})$ denota um erro cujo valor absoluto é limitado por uma constante vezes n^{-1} para n suficientemente grande; a notação $O(n^{-1/2})$ tem interpretação análoga.

Welch e Peers 1963 mostraram que, em modelos regulares de *um* parâmetro, a *priori* de Jeffreys é de casamento de primeira ordem. Em vários parâmetros, a *priori* de referência para o parâmetro de interesse costuma sê-lo, ao passo que a regra de Jeffreys multivariada em geral não é, mais uma manifestação da falha documentada no Exemplo 11.10. E há casos de concordância *exata*, não apenas assintótica: o Exemplo 11.13 exibe um deles.

11.8.4 Onde os dois paradigmas divergem

Regras de parada. Observam-se nove sucessos em doze ensaios de Bernoulli e testa-se a hipótese nula $p = 1/2$.

- Se o desenho era "12 ensaios fixos", o valor-p é $\mathbb{P}(X \geq 9 \mid n = 12, p = \frac{1}{2}) = 299/4096 = 0{,}073$.
- Se o desenho era "ensaiar até obter 3 fracassos", o mesmo resultado dá $\mathbb{P}(X \geq 9) = 67/2048 = 0{,}033$.

Os resultados observados geram verossimilhanças proporcionais, mas os valores-p unilaterais diferem porque cada plano amostral define repetições hipotéticas distintas. O plano não é mero estado mental: deve fazer parte do protocolo documentado. Sob uma regra de parada não informativa e a mesma *priori*, a posterior é idêntica nos dois casos pelo princípio da verossimilhança. A análise frequentista usa o plano para controlar taxas de erro de longo prazo; a bayesiana condiciona no resultado observado. Elas respondem a critérios de desempenho diferentes.

Parâmetros de perturbação em número crescente. No problema de Neyman–Scott da Seção 11.5, a máxima verossimilhança usual é inconsistente, enquanto a construção de referência descrita naquela seção evita essa inconsistência específica.

Paradoxos de marginalização. Com *prioris* impróprias, é possível construir exemplos (Dawid, Stone e Zidek) em que a posterior marginal obtida por dois caminhos legítimos difere. É o preço de trabalhar fora do arcabouço probabilístico próprio, e mais uma razão para verificar sempre que a posterior é própria.

Amostras pequenas e fronteiras. Quando uma estimativa cai na fronteira, aproximações normais de Wald podem colapsar ou sair do espaço paramétrico. Uma posterior baseada em *priori* própria pode respeitar o espaço e fornecer um resumo útil, mas não está automaticamente bem definida nem livre de sensibilidade: massa na fronteira, não identificação e escolhas de *priori* exigem tratamento explícito.

11.8.5 Síntese

	Frequentista	**Bayes objetivo**
Objeto aleatório	O procedimento	O parâmetro
Depende do espaço amostral	Sim	Não
Regra de parada afeta?	Sim	Não, sob parada não informativa
Requer *priori*	Não	Sim (formal)
Grandes amostras regulares	Aproximações podem coincidir em primeira ordem	
Fronteira do espaço	Normalidade de Wald pode falhar	Resultado depende do modelo e da *priori*
Perturbação em alta dimensão	Métodos usuais podem falhar	A posterior também requer regularização e verificação
Custo computacional	Depende do procedimento	Integração ou simulação pode ser necessária

Observação (Uma posição prática). Em modelos regulares, as duas abordagens frequentemente fornecem aproximações numéricas próximas, embora suas interpretações permaneçam distintas. Em amostras pequenas, fronteiras e modelos hierárquicos, tanto a construção frequentista quanto a escolha da *priori* ficam mais delicadas. Uma prática defensável explicita o alvo, verifica as condições do método, faz análise de sensibilidade e compara procedimentos quando suas conclusões diferem.

11.9 Exemplos resolvidos

Exercício resolvido 11.1 : Jeffreys para Bernoulli e posterior Beta

Enunciado. Em dez tentativas observam-se sete sucessos. Calcule a posterior de p sob a *priori* de Jeffreys e um intervalo de credibilidade de 95%.
Solução. Pelo Exemplo 11.6, $\pi_J(p) \propto p^{-1/2}(1-p)^{-1/2}$ (Beta$(1/2, 1/2)$). A posterior é

$$\pi(p \mid y) \propto p^{7-1/2}(1-p)^{3-1/2} = p^{6{,}5}(1-p)^{2{,}5},$$

ou seja, Beta$(7{,}5, 3{,}5)$. Em `R`, `qbeta(c(0.025, 0.975), 7.5, 3.5)` dá aproximadamente $(0{,}394, 0{,}907)$. O intervalo normal de Wald é aproximadamente $(0{,}416, 0{,}984)$. Os intervalos têm interpretações diferentes; a comparação numérica mostra a assimetria e o efeito da *priori*, não uma dominância universal de um procedimento.

Exercício resolvido 11.2 : Posterior Poisson sob Jeffreys

Enunciado. Observam-se cinco contagens $\{2, 3, 1, 4, 2\}$, de soma $T = 12$. Calcule a posterior de λ sob $\pi_J(\lambda) \propto \lambda^{-1/2}$ e um intervalo de credibilidade de 95%.
Solução. A verossimilhança é $\prod_i e^{-\lambda}\lambda^{y_i}/y_i! \propto e^{-n\lambda}\lambda^{T}$. A posterior é

$$\pi(\lambda \mid y) \propto \lambda^{T-1/2}\, e^{-n\lambda} = \lambda^{11{,}5}\, e^{-5\lambda},$$

ou seja, gama de forma 12,5 e taxa 5. Sua média é $12{,}5/5 = 2{,}5$, próxima da média amostral 2,4, e os quantis de ordens 0,025 e 0,975 são aproximadamente $(1{,}312, 4{,}065)$.

Exercício resolvido 11.3 : Metropolis para média de mistura

Enunciado. Considere $\pi(\theta \mid y) \propto \exp(-(\theta-1)^2/2) + \exp(-(\theta+2)^2/2)$ (mistura de duas normais, não normalizada). Esboce o algoritmo Metropolis com proposta $q(\theta^* \mid \theta) = N(\theta, 1^2)$ e discuta a importância da escala da proposta.
Solução. A proposta é simétrica, e a razão de aceitação é simplesmente $\pi(\theta^*)/\pi(\theta^{(t)})$. Pseudo-código:

1. Inicialize $\theta^{(0)}$ (digamos, 0).
2. Para $t = 0, 1, \ldots$:
   - Proponha $\theta^* \sim N(\theta^{(t)}, 1)$.
   - Compute $\alpha = \min(1, \pi(\theta^*)/\pi(\theta^{(t)}))$.
   - Aceite com probabilidade α.

Escala da proposta: valores muito pequenos produzem alta aceitação e passos curtos; valores muito grandes produzem muitas rejeições. Os valores de 44% em uma dimensão e 23,4% em dimensão alta derivam de limites assintóticos específicos para passeios aleatórios e alvos regulares. São referências de ajuste, não taxas ótimas universais nem diagnósticos de correção.

11.10 Laboratório computacional em `R`

Laboratório em R : Posterior Beta–Bernoulli

```
# Posterior de p sob Jeffreys, n=10, y=7
n <- 10; y <- 7
alpha <- y + 1/2
beta_p <- n - y + 1/2

# Densidade posterior
curve(dbeta(x, alpha, beta_p), 0, 1, lwd = 2,
      xlab = "p", ylab = "pi(p | y)")

# Intervalo de 95 por cento e media posterior
qbeta(c(0.025, 0.975), alpha, beta_p)
alpha / (alpha + beta_p)
```

Laboratório em R : Metropolis manual

```
# Posterior alvo (mistura, nao normalizada)
log_alvo <- function(theta) {
  a <- -(theta - 1)^2 / 2
  b <- -(theta + 2)^2 / 2
  maior <- max(a, b)
  maior + log(exp(a - maior) + exp(b - maior))
}

metropolis <- function(T = 5000, sigma_prop = 1) {
  theta <- numeric(T)
  theta[1] <- 0
  aceitos <- 0
  for (t in 2:T) {
    prop  <- theta[t-1] + rnorm(1, 0, sigma_prop)
    log_a <- log_alvo(prop) - log_alvo(theta[t-1])
    if (log(runif(1)) < log_a) {
      theta[t] <- prop
      aceitos <- aceitos + 1
    } else {
      theta[t] <- theta[t-1]
    }
  }
  list(theta = theta, taxa = aceitos / (T - 1))
}

set.seed(2026)
res <- metropolis()
res$taxa
hist(res$theta, breaks = 50, freq = FALSE,
     main = "Posterior Metropolis", xlab = expression(theta))
plot(res$theta[1:1000], type = "l", xlab = "iteracao",
     ylab = expression(theta), main = "Trajetoria da cadeia")
```

Laboratório em R : rstanarm em regressão

```
library(rstanarm)
library(ISLR2)

# Regressao bayesiana de medv em rm e lstat
ajuste <- stan_glm(medv ~ rm + lstat, data = Boston,
                   family = gaussian(),
                   prior = normal(0, 10),
                   prior_intercept = normal(0, 10),
                   prior_aux = exponential(1),
                   chains = 4, iter = 2000, seed = 2026)
print(ajuste, digits = 3)

# Intervalos de credibilidade de 95 por cento
posterior_interval(ajuste, prob = 0.95)

# Diagnosticos numericos das cadeias
summary(ajuste)[, c("Rhat", "n_eff")]
```

Os identificadores literais `Rhat` e `n_eff` representam o fator de redução de escala e o tamanho efetivo. Valores adequados são evidências necessárias, mas não suficientes; examine também divergências do integrador, trajetórias, caudas e sensibilidade a inicializações.

Laboratório em R : Concordância exata: referência e intervalo t

O Exemplo 11.13 afirma coincidência *numérica*, não aproximada. Verificamos.

```
set.seed(1)
n <- 12
y <- rnorm(n, mean = 5, sd = 2)

# (a) Classico: intervalo t
ic_t <- t.test(y)$conf.int

# (b) Bayesiano com priori de referencia pi(mu, sigma) ~ 1/sigma
# Posterior marginal: (mu - ybar)/(s/sqrt(n)) | y ~ t_{n-1}
ybar <- mean(y); s <- sd(y)
ic_cred <- ybar + qt(c(0.025, 0.975), df = n - 1) * s / sqrt(n)

rbind(confianca = ic_t, credibilidade = ic_cred)      # IDENTICOS
```

Confirme por simulação direta da posterior, sem usar a forma fechada:

```
B     <- 50000
sig2  <- (n - 1) * s^2 / rchisq(B, df = n - 1)        # sigma^2 | y
mu    <- rnorm(B, ybar, sqrt(sig2 / n))               # mu | sigma^2,
    y
quantile(mu, c(0.025, 0.975))
```

E contraste com a regra de Jeffreys multivariada $\pi \propto 1/\sigma^2$, que *não* concorda:

```
sig2_J <- (n - 1) * s^2 / rchisq(B, df = n)           # um grau a
   mais
c(referencia = mean(sig2), jeffreys_regra = mean(sig2_J),
  verdadeiro = 4)
```

A regra de Jeffreys multivariada concentra a posterior de σ^2 em valores menores que a de referência, comportando-se como se houvesse uma observação a mais ($\mathbb{E}[\sigma^2 \mid y] =$

$(n-1)s^2/(n-2)$ sob $1/\sigma^2$, contra $(n-1)s^2/(n-3)$ sob $1/\sigma$). Esse comportamento é a falha documentada no Exemplo 11.10.

Laboratório em R : A regra de parada e o princípio da verossimilhança

Reproduzimos o exemplo da Seção 11.8: nove sucessos em doze ensaios, sob a hipótese nula $p = 1/2$.

```
# (a) Desenho binomial: n = 12 fixo
p_binom <- sum(dbinom(9:12, size = 12, prob = 0.5))

# (b) Desenho binomial negativo: ensaiar ate obter 3 fracassos
# P(X >= 9 sucessos) = P(no maximo 2 fracassos nos 11 primeiros
    ensaios)
p_nbinom <- sum(dbinom(0:2, size = 11, prob = 0.5))

c(binomial = p_binom, binomial_negativa = p_nbinom)
# 0.0730  e  0.0327  -- lados opostos de 0.05!
```

Os resultados observados geram verossimilhanças proporcionais, mas os planos amostrais documentados definem espaços de repetição distintos. Agora considere a análise bayesiana sob a mesma *priori*:

```
# Posterior sob priori de Jeffreys Beta(1/2, 1/2) -- identica nos
    DOIS desenhos
a <- 0.5 + 9; b <- 0.5 + 3
c(prob_posterior_p_maior_meio = pbeta(0.5, a, b, lower.tail = FALSE)
    ,
  ic95 = qbeta(c(0.025, 0.975), a, b))

curve(dbeta(x, a, b), 0, 1, lwd = 2, ylab = "densidade a posteriori"
    )
abline(v = 0.5, lty = 2)
```

Sob esses dois desenhos, a regra de parada é não informativa e as verossimilhanças são proporcionais; por isso a posterior é a mesma. É o princípio da verossimilhança em funcionamento.

11.11 Exercícios propostos

Ex. 11.1. Verifique que $\pi_J(\lambda) \propto \lambda^{-1/2}$ para $Y \sim \text{Poisson}(\lambda)$. Mostre, em seguida, que sob a reparametrização $\eta = \log \lambda$ a Jeffreys é $\pi_J(\eta) \propto e^{\eta/2}$ e verifique a invariância.

Ex. 11.2. Demonstre o Teorema 11.5 no caso multidimensional: para $\eta = g(\theta)$ com matriz Jacobiana $J = \partial\theta/\partial\eta$, vale $\det I(\eta) = (\det J)^2 \det I(\theta)$.

Ex. 11.3. Para Y de distribuição exponencial com taxa λ e média $1/\lambda$, mostre que $\pi_J(\lambda) \propto 1/\lambda$ e que sob a reparametrização $\theta = 1/\lambda$ (média), $\pi_J(\theta) \propto 1/\theta$.

Ex. 11.4. Implemente o algoritmo Metropolis para $\pi(\theta) \propto e^{-\theta^2/2}\,(1+\theta^2)$ (alvo bimodal não normalizado). Compare a distribuição empírica das amostras com a verdadeira para diferentes escalas de proposta (0,1, 1, 10).

Ex. 11.5. Considere observações condicionalmente normais de média μ e variância σ^2, com priori normal de média zero e variância 100 para μ e priori gama inversa de forma 2 e escala 2 para σ^2. Derive as posteriores condicionais $\pi(\mu \mid \sigma^2, y)$ e $\pi(\sigma^2 \mid \mu, y)$ e descreva o amostrador de Gibbs.

Ex. 11.6. *Aplicação prática.* Use `rstanarm::stan_glm()` no conjunto literal `Default` do pacote `ISLR2`. Ajuste o modelo `default ~ balance + income + student` com *prioris* fracamente informativas. Reporte: (a) intervalos de credibilidade de 95% para os coeficientes; (b) o diagnóstico de redução potencial de escala $\hat{R}$ e o tamanho efetivo da amostra; (c) compare com a saída clássica de `glm()`.

Ex. 11.7. Demonstre a Proposição 11.1 para perdas quadrática e absoluta. Para uma posterior gama de forma 3 e taxa 1, calcule média, mediana e moda; construa o intervalo de caudas iguais e o conjunto de maior densidade posterior com credibilidade de 95%. Verifique o comprimento na parametrização original e mostre que apenas o intervalo de caudas iguais é equivariante sob toda transformação monótona. Explique por que comparar volumes depende da parametrização.

Ex. 11.8. *Prioris de referência.* Aplique o condicionamento sucessivo a observações normais independentes com média e variância desconhecidas, tomando primeiro σ e depois μ como parâmetro de interesse. Faça o mesmo para observações exponenciais independentes. Para uma variável binomial, obtenha a *priori* beta de referência e compare-a com a uniforme quando há zero sucessos em vinte tentativas; compare cobertura, comprimento e interpretação, em vez de declarar um intervalo simplesmente "mais razoável".

Ex. 11.9. *Regra de parada.* Reproduza o exemplo dos 9 sucessos em 12 ensaios. (a) Verifique os dois valores-p analiticamente. (b) Mostre que as duas verossimilhanças, como funções de p, são proporcionais, exiba a constante de proporcionalidade. (c) Calcule a posterior sob *priori* de Jeffreys nos dois desenhos e confirme que são idênticas. (d) Discuta, em um parágrafo, se a dependência da conclusão frequentista quanto ao desenho é um defeito ou uma característica desejável, apresentando o melhor argumento de cada lado.

Ex. 11.10. *Bernstein–von Mises na prática.* Para observações de Bernoulli independentes com $p_0 = 0{,}3$, simule tamanhos $n \in \{5, 20, 100, 1000\}$ e compare as *prioris* $\mathrm{Beta}(1,1)$, $\mathrm{Beta}(1/2, 1/2)$ e $\mathrm{Beta}(20, 2)$. Sobreponha posteriores, compare intervalos de credibilidade com intervalos de Wilson e defina uma decisão concreta antes de julgar quando as diferenças se tornam irrelevantes. Relacione o resultado às condições do Teorema 11.17.

Ex. 11.11. *Posterior imprópria.* Considere o modelo hierárquico $y_i \mid \theta_i$ normal de média θ_i e variância 1, e $\theta_i \mid \tau$ normal de média zero e variância τ^2, com $i = 1, \dots, N$ e $\pi(\tau) \propto 1/\tau$. Mostre a divergência da posterior marginal perto de $\tau = 0$. Explique por que condicionais completas próprias, o diagnóstico de redução potencial de escala $\hat{R}$ e o tamanho efetivo não detectam necessariamente a patologia. Proponha duas *prioris* próprias para τ e justifique a propriedade da posterior.

Notas e leituras complementares

- Jeffreys 1946: artigo seminal sobre a *priori* invariante.
- Bernardo 1979: introdução das *prioris* de referência; Berger, Bernardo e Sun 2009 para a definição formal definitiva.
- Welch e Peers 1963: origem das *prioris* de casamento de probabilidade.
- Neyman e Scott 1948: o problema de parâmetros incidentais que expõe a falha da máxima verossimilhança.

- Vaart 1998, Cap. 10: enunciado e demonstração rigorosos do teorema de Bernstein–von Mises.
- Berger, J. O. (2006), *The Case for Objective Bayesian Analysis*: tratamento moderno e abrangente.
- Robert, C. P. & Casella, G. (2004): tratamento detalhado de Monte Carlo via cadeias de Markov, com fundamentos teóricos.
- Efron e Hastie 2016, Cap. 13: discussão da relação Bayes objetivo $\leftrightarrow$ frequentismo.

11.12 Glossário bilíngue e de siglas

Os equivalentes em inglês seguem a terminologia do livro-texto de Efron e Hastie (2016). A última coluna registra a sigla usada no livro ou consagrada na literatura em inglês. Um travessão indica que não há uma sigla corrente para o conceito.

Terminologia no manual (português do Brasil)	**Termo no livro-texto (inglês)**	**Sigla**
Inferência bayesiana objetiva	*objective Bayes inference*	—
Distribuição a priori	*prior distribution*	—
Função de verossimilhança	*likelihood function*	—
Distribuição posterior	*posterior distribution*	—
Distribuição preditiva posterior	*posterior predictive distribution*	—
Estimador de Bayes	*Bayes estimator*	—
Média posterior	*posterior mean*	—
Mediana posterior	*posterior median*	—
Moda posterior	*posterior mode; maximum a posteriori estimate*	MAP
Intervalo de credibilidade	*credible interval*	CrI
Intervalo de caudas iguais	*equal-tailed interval*	ETI
Conjunto de maior densidade posterior	*highest posterior density set*	HPD
Distribuição a priori conjugada	*conjugate prior distribution*	—
Distribuição a priori não informativa	*noninformative prior distribution*	—
Distribuição a priori imprópria	*improper prior distribution*	—
Posterior própria	*proper posterior distribution*	—
Distribuição a priori de Jeffreys	*Jeffreys prior*	—
Informação de Fisher	*Fisher information*	—
Invariância por reparametrização	*reparameterization invariance*	—
Distribuição a priori de referência	*reference prior*	—
Parâmetro de interesse	*parameter of interest*	—
Parâmetro de perturbação	*nuisance parameter*	—
Monte Carlo via cadeias de Markov	*Markov chain Monte Carlo*	MCMC
Distribuição estacionária	*stationary distribution*	—
Algoritmo de Metropolis–Hastings	*Metropolis–Hastings algorithm*	MH
Razão de aceitação	*acceptance ratio*	—
Amostrador de Gibbs	*Gibbs sampler*	—
Período de aquecimento	*burn-in; warm-up*	—
Fator de redução potencial de escala	*potential scale reduction factor*	$\widehat{R}$
Tamanho efetivo da amostra	*effective sample size*	ESS
Erro padrão de Monte Carlo	*Monte Carlo standard error*	MCSE
Gráfico de trajetória	*trace plot*	—
Verificação preditiva posterior	*posterior predictive check*	PPC
Teorema de Bernstein–von Mises	*Bernstein–von Mises theorem*	BvM
Distribuição a priori de casamento de probabilidade	*probability-matching prior*	—
Princípio da verossimilhança	*likelihood principle*	LP
Regra de parada	*stopping rule*	—

Apêndice A

Resumo de `R` para a disciplina

Este apêndice reúne os pacotes, as funções e os comandos essenciais da linguagem `R` usados ao longo do livro. Os nomes em tipo monoespaçado são identificadores literais de programas e, por isso, conservam a grafia adotada pelos respectivos autores. O apêndice não é uma introdução à linguagem: pressupõe familiaridade básica.

A.1 Pacotes utilizados

Pacote	Capítulo	Função principal
`ISLR2`	Todos	Conjuntos de dados
`lme4`	1	`lmer` (efeitos aleatórios)
`glmnet`	2, 9	Regressão em crista, *lasso* e validação cruzada
`MASS`	3	`glm.nb` (binomial negativa)
`rpart`, `rpart.plot`	4	Árvores
`randomForest`, `gbm`	4	Florestas aleatórias e *boosting*
`survival`	5	Kaplan–Meier, Cox
`mclust`	6	Mistura de gaussianas
`boot`	7, 8, 10	*Jackknife*, *bootstrap* e `cv.glm`
`leaps`	10	Seleção de subconjuntos
`rstanarm`, `coda`	11	Amostragem por cadeias de Markov e diagnóstico

A.2 Instalação rápida

```
pacotes <- c("ISLR2", "lme4", "glmnet", "MASS", "rpart", "rpart.plot",
             "randomForest", "gbm", "survival", "mclust", "boot",
             "leaps", "rstanarm", "coda")
install.packages(setdiff(pacotes, rownames(installed.packages())))
```

A.3 Convenções de código

- Sempre fixar a semente: `set.seed(1)`.
- Comentários em português.
- Indentação de 2 espaços.
- Variáveis em `snake_case`.

A.4 Reproduzindo gráficos do livro

As 11 figuras do livro são geradas pelo script `livro/figuras/R/gerar-figuras.R`, que grava os arquivos gráficos em `livro/figuras/` referenciados pelos capítulos por meio de `\includegraphics`. Execute-o a partir da raiz do projeto:

```
Rscript livro/figuras/R/gerar-figuras.R
```

Todas as sementes aleatórias são fixadas dentro do próprio script, de modo que os arquivos gerados são idênticos a cada execução. Já os *scripts* de laboratório reproduzidos nos capítulos desenham no dispositivo gráfico ativo da sessão e não gravam arquivos.

Apêndice B

Gabarito dos exercícios propostos

Este apêndice apresenta as respostas e indicações de solução para os exercícios propostos ao final de cada capítulo. Para os exercícios computacionais, fornece-se o resultado numérico esperado e o trecho de `R` correspondente.

Capítulo 1: Bayes Empírico

Ex. 1.1. Pela definição da marginal,

$$f_G(x+1) = \int_0^1 \theta(1-\theta)^{x+1}\, dG(\theta) = \int_0^1 \theta(1-\theta)\,(1-\theta)^x\, dG(\theta).$$

Logo $f_G(x) - f_G(x+1) = \int_0^1 \theta(1-\theta)^x\big[1-(1-\theta)\big]\, dG(\theta) = \int_0^1 \theta^2(1-\theta)^x\, dG(\theta)$, e dividindo por $f_G(x)$ obtém-se a identidade desejada.

Ex. 1.2. A partir de $\hat\mu_i^{\text{Bayes}} = (1-B)X_i + BM$ e $1-B = A/(A+\sigma^2)$, segue que $\hat\mu_i^{\text{Bayes}} = M + (1-B)(X_i - M) = M + \frac{A}{A+\sigma^2}(X_i - M)$. O fator $A/(A+\sigma^2)$ é a razão entre a variância do sinal (A) e a variância total ($A+\sigma^2$); aproxima-se de 1 quando o sinal é forte e de 0 quando o ruído domina.

Ex. 1.3. Seja $Y = \|X\|^2/\tau^2 \sim \chi^2_k$. Então $\mathbb{E}[1/Y] = 1/(k-2)$ para $k \geq 3$. Logo

$$\mathbb{E}\left[\frac{k-2}{\|X\|^2}\right] = \frac{k-2}{\tau^2}\,\mathbb{E}\left[\frac{1}{Y}\right] = \frac{k-2}{\tau^2}\cdot\frac{1}{k-2} = \frac{1}{\tau^2}.$$

Ex. 1.4. Sob (1.7), $\hat\mu_i^{\text{Bayes}} - \mu_i = (1-B)(X_i-\mu_i) - B(\mu_i - M)$. Como $X_i-\mu_i$ e $\mu_i - M$ são independentes, com variâncias σ^2 e A,

$$\mathbb{E}[(\hat\mu_i^{\text{Bayes}} - \mu_i)^2] = (1-B)^2\sigma^2 + B^2 A.$$

Substituindo $B = \sigma^2/(\sigma^2+A)$ e $1-B = A/(\sigma^2+A)$, simplifica-se para $\sigma^2 A/(\sigma^2+A) = (1-B)\sigma^2$. Para $\sigma^2 = 1$: erro por componente $A/(A+1)$, e total $N\cdot A/(A+1)$, estritamente menor que N para $A < \infty$.

Ex. 1.5. *Resposta indicativa.* Com $E_i = \texttt{populacao}_i/1000$ e taxa bruta $x_i = X_i/E_i$: (a) a marginal Poisson–Gama tem $\mathbb{E}[x_i] = \hat a/\hat b$ e $\mathrm{Var}(x_i) = \mathrm{Var}(\theta_i) + \mathbb{E}[\theta_i]/E_i$; igualando média e variância amostrais das taxas brutas (descontada a parcela de ruído Poisson $\mathbb{E}[\theta]\cdot\overline{1/E_i}$) obtêm-se $\hat a$ e $\hat b$. Em um ano típico do arquivo, a taxa média fica em torno de 8–9 óbitos por mil habitantes. (b) A estimativa de Bayes empírico $\hat\theta_i = (\hat a + X_i)/(\hat b + E_i)$ é média ponderada entre a taxa bruta e $\hat a/\hat b$, com peso $E_i/(\hat b + E_i)$ da taxa bruta crescente na população. (c) O gráfico da taxa bruta contra a população em escala logarítmica exibe o funil clássico: dispersão muito maior nos municípios pequenos, como prevê $\mathrm{Var}(x_i \mid \theta_i) = \theta_i/E_i$. (d) O *ranking* bruto tem os primeiros

lugares dominados por municípios minúsculos (mediana populacional dos vinte primeiros na casa de poucos milhares de habitantes); no *ranking* por Bayes empírico essa mediana sobe para valores várias vezes maiores: o encolhimento retira dos extremos os municípios cuja posição era sustentada apenas por ruído amostral.

Ex. 1.6. A posterior é $\theta_i \mid X_i = x \sim \text{Beta}(\alpha + x, \beta + n_i - x)$, cuja média é $(\alpha + x)/(\alpha + \beta + n_i)$. Para os estimadores de momentos, denote $p_i = X_i/n_i$. A média marginal é $\mathbb{E}[p_i] = \alpha/(\alpha+\beta) =: \mu$ e a variância $\text{Var}(p_i) = \mu(1-\mu)/n_i + \mu(1-\mu)/[(\alpha+\beta)+1] \cdot [1 - 1/n_i]$ (decomposição em variância intra e entre). Igualando médias e variâncias amostrais aos seus valores teóricos, obtêm-se equações para $(\hat\alpha, \hat\beta)$. Para $n_i \equiv n$ constante, resolve-se explicitamente:

$$\hat\alpha + \hat\beta = \frac{\hat\mu(1-\hat\mu) - \hat s^2}{\hat s^2 - \hat\mu(1-\hat\mu)/n},$$

com $\hat s^2$ a variância amostral das proporções (o termo $\hat\mu(1-\hat\mu)/n$ no denominador desconta o ruído binomial); para n grande, essa expressão aproxima-se de $\hat\mu(1-\hat\mu)/\hat s^2 - 1$. Em seguida, $\hat\alpha = \hat\mu(\hat\alpha + \hat\beta)$, $\hat\beta = (1-\hat\mu)(\hat\alpha + \hat\beta)$.

Ex. 1.7. Denote por Q_{dentro} e Q_{entre} os quadrados médios dentro e entre grupos definidos no capítulo. Escreva $\bar Y_{i\cdot} = \mu + a_i + \bar\varepsilon_{i\cdot}$ e $Y_{ij} - \bar Y_{i\cdot} = \varepsilon_{ij} - \bar\varepsilon_{i\cdot}$. A segunda expressão não envolve a_i: dentro de cada grupo, $\sum_j (\varepsilon_{ij} - \bar\varepsilon_{i\cdot})^2/\sigma^2 \sim \chi^2_{n-1}$, de modo que $\mathbb{E}[\sum_j (Y_{ij} - \bar Y_{i\cdot})^2] = (n-1)\sigma^2$; somando sobre os N grupos e dividindo por $N(n-1)$ obtém-se $\mathbb{E}[Q_{\text{dentro}}] = \sigma^2$. Para a soma entre grupos, as médias $\bar Y_{i\cdot}$ são independentes e normais, com média μ e variância $\tau^2 + \sigma^2/n$; logo $\sum_i (\bar Y_{i\cdot} - \bar Y_{\cdot\cdot})^2$ tem esperança $(N-1)(\tau^2 + \sigma^2/n)$ e

$$\mathbb{E}[Q_{\text{entre}}] = \frac{n}{N-1}\,(N-1)\left(\tau^2 + \frac{\sigma^2}{n}\right) = \sigma^2 + n\tau^2.$$

Igualando-os às suas esperanças resulta $\hat\sigma^2 = Q_{\text{dentro}}$ e $\hat\tau^2 = (Q_{\text{entre}} - Q_{\text{dentro}})/n$.

Ex. 1.8. Derivando, $\partial B_i/\partial n_i = -\sigma^2\tau^2/(\sigma^2 + n_i\tau^2)^2 < 0$ e, analogamente, $\partial B_i/\partial \tau^2 < 0$ e $\partial B_i/\partial \sigma^2 = n_i\tau^2/(\sigma^2 + n_i\tau^2)^2 > 0$. Interpretações: mais dados no grupo $\Rightarrow$ a média do grupo é confiável e é preservada; maior heterogeneidade real entre grupos $\Rightarrow$ a média geral informa pouco sobre o grupo e o encolhimento diminui; maior ruído amostral $\Rightarrow$ a média do grupo é pouco confiável e o encolhimento aumenta. Para o erro, use o Exercício 1.4 com σ^2 substituído por σ^2/n_i: o erro do preditor de Bayes é $(1-B_i)\sigma^2/n_i$, contra σ^2/n_i da média bruta. A razão é $1 - B_i$, e como B_i decresce em n_i, a redução relativa B_i é maior justamente nos grupos pequenos.

Ex. 1.9. *Resposta indicativa.* O *script* segue o laboratório da Seção 1.8: simular, ajustar `lmer(y ~ 1 + (1|escola))`, extrair $\hat\tau^2$, $\hat\sigma^2$ e formar $B_i = \hat\sigma^2/(\hat\sigma^2 + n_i\hat\tau^2)$. O resultado esperado é nítido: no *ranking* bruto, as 10 primeiras e as 10 últimas posições são ocupadas quase exclusivamente por escolas pequenas (n_i médio da ordem de algumas dezenas), porque o erro-padrão $80/\sqrt{n_i}$ domina o sinal $\tau = 30$; no *ranking* pelo preditor empírico encolhido, os extremos passam a ser ocupados por escolas de tamanho intermediário ou grande, que são as únicas com evidência suficiente para sustentar uma posição extrema. A moral é que *rankings* por médias brutas medem, em boa parte, tamanho de amostra, e não desempenho, razão pela qual divulgações públicas desse tipo devem sempre reportar intervalos ou usar estimativas encolhidas.

Ex. 1.10. *Resposta indicativa.* (a) Filtrando por `populacao` < 20000 no ano de 2019 restam pouco mais de 400 municípios, com contagens de óbitos concentradas entre 10 e 200. Como as contagens não se repetem muito acima de algumas dezenas, a frequência empírica $\hat f_N(x)$ é aproveitável apenas na faixa baixa. (b) O estimador $\hat\theta^{\text{R}}(x) = (x+1)\hat f_N(x+1)/\hat f_N(x)$ depende de uma razão entre duas frequências; quando ambas são baseadas em um punhado de municípios, a razão oscila violentamente e pode até ser não monótona: há valores de x para os quais $\hat f_N(x+1) = 0$ e a estimativa colapsa. Suavizações usuais: agrupar x em faixas, ajustar uma regressão de Poisson isotônica a $\log \hat f_N$, ou usar o estimador de máxima verossimilhança não paramétrica de G. (c) O

estimador paramétrico Poisson–Gama é muito mais estável, porque toma emprestada informação de toda a amostra através de dois hiperparâmetros; a divergência é maior nas caudas, onde Robbins fica errático e a versão paramétrica simplesmente extrapola a forma Gama. O ponto pedagógico é a troca: Robbins não supõe nada sobre G e paga em variância; a versão paramétrica supõe uma família e paga em possível má especificação. Note ainda que aqui as exposições E_i diferem entre municípios, o que a fórmula de Robbins clássica não acomoda, outra razão para preferir a formulação com *offset*.

Capítulo 2: Regressão em crista

Ex. 2.1. No modelo $y = X\beta + \varepsilon$, com $\operatorname{Var}(\varepsilon) = \sigma^2 I_n$, tem-se $\hat\beta_{\text{direto}} = \beta + X^\top\varepsilon$. Portanto, $\hat\beta_\lambda = (1+\lambda)^{-1}\hat\beta_{\text{direto}}$: todas as componentes são multiplicadas pelo mesmo fator. O viés da componente j é $-\lambda\beta_j/(1+\lambda)$, sua variância é $\sigma^2/(1+\lambda)^2$ e seu risco quadrático é

$$R_j(\lambda) = \frac{\sigma^2}{(1+\lambda)^2} + \frac{\lambda^2\beta_j^2}{(1+\lambda)^2}.$$

Como $R_j(0) = \sigma^2$,

$$R_j(\lambda) - R_j(0) = \frac{\lambda\{\lambda(\beta_j^2 - \sigma^2) - 2\sigma^2\}}{(1+\lambda)^2}.$$

Se $\beta_j^2 \le \sigma^2$, todo $\lambda > 0$ reduz o risco; se $\beta_j^2 > \sigma^2$, a redução ocorre exatamente quando $0 < \lambda < 2\sigma^2/(\beta_j^2 - \sigma^2)$. Além disso,

$$R_j'(\lambda) = \frac{2(\lambda\beta_j^2 - \sigma^2)}{(1+\lambda)^3}.$$

Para $\beta_j \neq 0$, o mínimo é atingido em $\lambda_j^\ast = \sigma^2/\beta_j^2$. Para $\beta_j = 0$, o risco decresce para zero quando $\lambda \to \infty$, sem mínimo em um λ finito.

Ex. 2.2. A posterior é $\pi(\beta \mid y) \propto \exp\{-Q(\beta)/2\}$ com

$$Q(\beta) = \tfrac{1}{\sigma^2}(y - X\beta)^\top(y - X\beta) + \tfrac{1}{\tau^2}\beta^\top\beta.$$

Defina

$$P = \sigma^{-2}X^\top X + \tau^{-2}I_p, \qquad h = \sigma^{-2}X^\top y, \qquad m = P^{-1}h.$$

Expandir e completar o quadrado dá, sem omitir o termo compensador,

$$\begin{aligned} Q(\beta) &= \beta^\top P\beta - 2\beta^\top h + \sigma^{-2}y^\top y \\ &= (\beta - m)^\top P(\beta - m) + \sigma^{-2}y^\top y - m^\top P m. \end{aligned}$$

Logo $\beta \mid y \sim N_p(m, P^{-1})$. Com $\lambda = \sigma^2/\tau^2$,

$$m = (X^\top X + \lambda I_p)^{-1}X^\top y = \hat\beta_\lambda, \qquad P^{-1} = \sigma^2(X^\top X + \lambda I_p)^{-1}.$$

Ex. 2.3. Como os r valores singulares da decomposição compacta são positivos,

$$\mathrm{gl}'(\lambda) = -\sum_{j=1}^{r} \frac{d_j^2}{(d_j^2 + \lambda)^2} < 0$$

para todo $\lambda \ge 0$ quando $r \ge 1$. Para $X^\top X = I_p$, tem-se $r = p$ e $d_j = 1$ para todo j; portanto $\mathrm{gl}(\lambda) = p/(1+\lambda)$, igual a p em $\lambda = 0$ e tendendo a zero quando $\lambda \to \infty$.

Ex. 2.4. Da Proposição 2.7, $\hat{y}_{\text{direto}} = \lim_{\lambda\to 0}\hat{y}_\lambda = \sum_{j:d_j>0} u_j u_j^\top y$ (a projeção ortogonal de y no espaço gerado pelas colunas de X). A regressão em crista substitui o coeficiente 1 na projeção por $d_j^2/(d_j^2+\lambda) < 1$, isto é, encolhe cada componente da projeção em direção a 0. O encolhimento é maior quanto menor for d_j (direção de menor variabilidade).

Ex. 2.5. Para o ajuste direto e uma matriz normal aleatória,

$$\mathbb{E}\left\|\hat{\beta}_{\text{direto}} - \beta\right\|^2 = \sigma^2 \mathbb{E}\,\mathrm{tr}\{(X^\top X)^{-1}\} = \frac{\sigma^2 p}{n-p-1} = \frac{80}{19} \approx 4{,}2105.$$

O código abaixo implementa exatamente o protocolo do enunciado.

```
library(glmnet)

set.seed(2026)
R <- 200
n <- 100
p <- 80
beta <- c(rnorm(10), rep(0, p - 10))

resultado <- matrix(NA_real_, R, 5)
colnames(resultado) <- c(
  "direto", "minimo", "um_ep", "lambda_min", "lambda_um_ep")

for (r in seq_len(R)) {
  X <- matrix(rnorm(n * p), n, p)
  y <- drop(X %*% beta + rnorm(n))
  blocos <- sample(rep(seq_len(10), length.out = n))

  cv <- cv.glmnet(
    X, y, alpha = 0, foldid = blocos,
    intercept = FALSE, standardize = FALSE)
  b_direto <- qr.solve(X, y)
  b_min <- as.matrix(coef(cv, s = "lambda.min"))[-1, 1]
  b_um_ep <- as.matrix(coef(cv, s = "lambda.1se"))[-1, 1]

  resultado[r, ] <- c(
    sum((b_direto - beta)^2),
    sum((b_min - beta)^2),
    sum((b_um_ep - beta)^2),
    cv$lambda.min, cv$lambda.1se)
}

rbind(
  media = colMeans(resultado),
  erro_padrao = apply(resultado, 2, sd) / sqrt(R))
```

Os valores de `lambda` abaixo seguem a parametrização do pacote. Para a função objetivo (2.2), nas opções usadas aqui, a penalidade correspondente é n vezes o valor devolvido por `glmnet`. A execução produz:

Método ou regra	Risco médio	Erro-padrão	λ médio	Erro-padrão
Ajuste direto	4,2950	0,1176	—	—
Mínimo da validação	1,9218	0,0299	0,3320	0,0083
Heurística de um erro-padrão	2,4133	0,0504	0,8901	0,0351

O valor simulado do ajuste direto é compatível com 80/19. Nesta realização, a heurística de um erro-padrão escolhe penalidades maiores e tem risco mais alto que o mínimo da validação. Essa heurística favorece maior regularização; ela não garante que a escolha de λ varie menos entre

amostras. A regressão em crista tampouco seleciona um subconjunto: salvo coincidências de probabilidade zero, os 80 coeficientes permanecem não nulos.

Ex. 2.6. O ajuste reproduzível é:

```
library(ISLR2)
library(glmnet)

dados <- na.omit(Hitters)
X <- model.matrix(Salary ~ ., data = dados)[, -1]
y <- dados$Salary

set.seed(1)
cv_crista <- cv.glmnet(X, y, alpha = 0)
b_crista <- as.matrix(
  coef(cv_crista, s = "lambda.1se"))[, 1]
b_direto <- coef(lm(Salary ~ ., data = dados))
comparacao <- cbind(
  direto = b_direto[names(b_crista)], crista = b_crista)

cv_crista$lambda.1se
round(comparacao, 4)   # tabela completa
round(comparacao[c("Hits", "Runs", "CHits", "CRuns"), ], 4)
```

Com as versões dos pacotes usadas na preparação do livro, `lambda.1se` = 1843,3433. Quatro linhas representativas da tabela completa são:

Preditor	Ajuste direto	Regressão em crista
`Hits`	7,5008	0,4468
`Runs`	−2,3762	0,7029
`CHits`	0,1340	0,0344
`CRuns`	1,4543	0,0689

`Hits` e `Runs` são contagens da temporada; `CHits` e `CRuns`, contagens acumuladas na carreira. Como os preditores são correlacionados, a regressão em crista não multiplica cada coeficiente do ajuste direto por um fator isolado: ela resolve o sistema conjuntamente, e até o sinal de um coeficiente pode mudar. Os valores mostram regularização, não efeitos causais; uma leitura causal exigiria hipóteses adicionais sobre o desenho e sobre variáveis de confusão.

Ex. 2.7. Escreva $z_j = \hat{\beta}_j^{\text{direto}}$. A função objetivo, salvo uma constante, separa-se como

$$\sum_j \{\beta_j^2 - 2 z_j \beta_j + \lambda \mathbb{1}(\beta_j \neq 0)\}.$$

Para a coordenada j, as candidatas são 0, com contribuição zero, e z_j, com contribuição $-z_j^2 + \lambda$. Assim, escolhe-se z_j quando $|z_j| > \sqrt{\lambda}$ e zero quando $|z_j| < \sqrt{\lambda}$. Na igualdade, zero e z_j são ambos minimizadores; a fórmula do enunciado adota zero como convenção.

Com um limiar comum $c > 0$, as três regras a desenhar são

$$H_c(z) = z\mathbb{1}(|z| > c), \qquad S_c(z) = \text{sinal}(z)(|z| - c)_+, \qquad P_\rho(z) = \frac{z}{1+\rho}, \quad \rho > 0.$$

A calibração é $\lambda_{\text{subconjuntos}} = c^2$ e $\lambda_{\text{lasso}} = 2c$, segundo a convenção da função objetivo deste capítulo. O limiar duro é descontínuo em $\pm c$: uma perturbação infinitesimal pode provocar um salto de magnitude próxima a c. O limiar suave é contínuo, mas subtrai c até de sinais grandes. A regra proporcional também é contínua e nunca zera uma coordenada, mas mantém um viés relativo constante. Logo o limiar duro não encolhe sinais que admite, porém paga por isso com maior instabilidade local na fronteira de seleção.

Ex. 2.8. A posterior satisfaz

$$\pi(\beta \mid y) \propto \exp\left\{-\frac{\|y - X\beta\|^2 + \lambda \|\beta\|_1}{2\sigma^2}\right\}.$$

Portanto, maximizar a posterior equivale a minimizar (2.5), e a moda é $\hat{\beta}^{\mathrm{L}}_{\lambda}$.

Para provar corretamente a afirmação sobre a média, tome $p = 1$, $X^\top X = 1$, $\sigma^2 = 1$ e $h = \hat{\beta}^{\,\text{direto}} = X^\top y$. A posterior pode ser escrita como a inclinação exponencial

$$\pi_h(\beta) = \frac{e^{h\beta} q(\beta)}{Z(h)}, \qquad q(\beta) = \exp\{-\beta^2/2 - \lambda|\beta|/2\}, \qquad Z(h) = \int_{\mathbb{R}} e^{h\beta} q(\beta)\, d\beta.$$

A função q é simétrica. Se $m(h) = \mathbb{E}_h(\beta)$, então

$$m(h) = \frac{d}{dh} \log Z(h), \qquad m'(h) = \mathrm{Var}_h(\beta) > 0.$$

Por simetria, $m(0) = 0$; pela monotonicidade estrita, $\mathrm{sinal}\{m(h)\} = \mathrm{sinal}(h)$ e a média só é zero quando $h = 0$. Sob o modelo gaussiano, h tem distribuição contínua, logo $\Pr(h = 0) = 0$. Em contraste, a moda é $\mathrm{sinal}(h)(|h| - \lambda/2)_+$ e vale zero em todo o intervalo $|h| \le \lambda/2$. A posterior é contínua e não põe massa pontual em zero; a esparsidade pertence à moda escolhida como estimador pontual.

Ex. 2.9. (a) Com $x_2 = x_1$, escreva $z = x_1$ e $s = \beta_1 + \beta_2$. O termo de erro é $\|y - sz\|^2$. Pela desigualdade triangular, $|\beta_1| + |\beta_2| \ge |s|$, com igualdade quando os dois coeficientes têm o sinal de s ou um deles é zero. Defina $I_s = [\min(0, s), \max(0, s)]$. Para s fixo, todos e somente os pares $(t, s - t)$ com $t \in I_s$ atingem a penalidade mínima $\lambda|s|$. Logo, se c minimiza o problema escalar $\|y - sz\|^2 + \lambda|s|$, o conjunto de soluções é

$$\{(t, c - t) : t \in I_c\}.$$

Essa expressão cobre tanto $c > 0$ quanto $c < 0$.

(b) Para s fixo, $t^2 + (s - t)^2 = 2(t - s/2)^2 + s^2/2$, cujo único mínimo ocorre em $t = s/2$. A parcela quadrática torna a função objetivo estritamente convexa, de modo que a solução da regressão em crista é única e satisfaz $\hat{\beta}_1 = \hat{\beta}_2$.

(c) Na penalidade combinada, para $t \in I_s$, a parcela de valor absoluto é $\lambda\alpha|s|$, constante em t, enquanto a parcela quadrática é $\lambda(1 - \alpha)\{t^2 + (s - t)^2\}/2$. Se $\alpha < 1$ e $\lambda > 0$, esta última é estritamente convexa e tem único mínimo em $t = s/2$. Portanto, a solução é única e igualitária. A parcela quadrática rompe a indeterminação do lasso e produz o efeito de agrupamento.

Ex. 2.10. O código completo é:

```
library(glmnet)

set.seed(1)
R <- 100
n <- 100
p <- 60
n_teste <- 1000
alfa <- c(crista = 0, combinada = 0.5, absoluta = 1)

simula <- function(cenario) {
  erro <- ativos <- matrix(NA_real_, R, length(alfa))
  colnames(erro) <- colnames(ativos) <- names(alfa)

  for (r in seq_len(R)) {
    beta <- if (cenario == "esparso") {
      c(rep(2, 5), rep(0, p - 5))
```

```
    } else {
      rnorm(p, 0, 0.2)
    }
    X <- matrix(rnorm(n * p), n, p)
    X_teste <- matrix(rnorm(n_teste * p), n_teste, p)
    y <- drop(X %*% beta + rnorm(n))
    y_teste <- drop(X_teste %*% beta + rnorm(n_teste))
    blocos <- sample(rep(seq_len(10), length.out = n))

    for (j in seq_along(alfa)) {
      cv <- cv.glmnet(
        X, y, alpha = alfa[j], foldid = blocos,
        intercept = FALSE, standardize = FALSE)
      b <- as.matrix(coef(cv, s = "lambda.min"))[-1, 1]
      erro[r, j] <- mean((y_teste - drop(X_teste %*% b))^2)
      ativos[r, j] <- sum(b != 0)
    }
  }

  list(
    media = colMeans(erro),
    erro_padrao = apply(erro, 2, sd) / sqrt(R),
    ativos = colMeans(ativos),
    erro_padrao_ativos = apply(ativos, 2, sd) / sqrt(R))
}

esparso <- simula("esparso")
denso <- simula("denso")
rbind(
  esparso_media = esparso$media,
  esparso_erro_padrao = esparso$erro_padrao,
  esparso_ativos = esparso$ativos,
  denso_media = denso$media,
  denso_erro_padrao = denso$erro_padrao,
  denso_ativos = denso$ativos)
```

O erro de teste inclui o ruído irredutível de variância 1. Os resultados são:

Cenário	Quantidade	Crista	Combinada	Valor absoluto
Esparso	Erro médio	2,4874	1,3371	1,2519
	Erro-padrão	0,0425	0,0170	0,0131
	Número de ativos	60,00	23,94	18,32
Denso	Erro médio	1,7793	1,9207	1,9568
	Erro-padrão	0,0191	0,0227	0,0235
	Número de ativos	60,00	44,23	42,66

No cenário esparso, a penalidade de valor absoluto tem o menor erro, seguida pela combinada; no denso, a regressão em crista tem o menor erro. As diferenças são grandes relativamente aos erros-padrão de Monte Carlo. Contudo, melhor predição não implica recuperação exata do suporte: no cenário esparso, o lasso mantém em média 18,32 coeficientes, bem mais que os cinco verdadeiros. Além disso, para uma nova covariável normal padrão, $\mathbb{E}[(x^\top\hat\beta - x^\top\beta)^2 \mid \hat\beta, \beta] = \left\|\hat\beta - \beta\right\|^2$; o erro de resposta apresentado na tabela soma a esse termo a variância 1 do novo ruído.

Capítulo 3: Modelos lineares generalizados

Ex. 3.1. $f(y;p) = \binom{m}{y} p^y (1-p)^{m-y}$. Reescreva como

$$f(y;p) = \exp\Big\{ y \log\tfrac{p}{1-p} + m\log(1-p) + \log\tbinom{m}{y} \Big\}.$$

Logo $\theta = \log[p/(1-p)]$, $b(\theta) = m\log(1+e^\theta)$, $a(\phi) = 1$, $c(y,\phi) = \log\binom{m}{y}$. Tem-se $b'(\theta) = me^\theta/(1+e^\theta) = mp = \mu = \mathbb{E}[Y]$ e $b''(\theta) = me^\theta/(1+e^\theta)^2 = mp(1-p)$, de modo que, na notação do capítulo, $V(\mu) = b''(\theta(\mu)) = mp(1-p) = \mu(1-\mu/m)$ e $\mathrm{Var}(Y) = a(\phi)\,V(\mu) = mp(1-p)$, como esperado.

Ex. 3.2. Para $Y \sim \mathrm{Gama}(\alpha, \alpha/\mu)$ (parametrização média-forma), a densidade é $f(y) = \frac{(\alpha/\mu)^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\alpha y/\mu}$. Reescreva $\log f$ como

$$\log f(y) = -\frac{y/\mu - (-\log\mu)}{1/\alpha} + (\alpha-1)\log y + \alpha\log\alpha - \log\Gamma(\alpha).$$

Identificando $\theta = -1/\mu$, $b(\theta) = -\log(-\theta) = \log\mu$, $\phi = 1/\alpha$, $a(\phi) = \phi$. Verifica-se $b'(\theta) = -1/\theta = \mu$ e $b''(\theta) = 1/\theta^2 = \mu^2$, donde $V(\mu) = \mu^2$.

Ex. 3.3. A equação de escore para Poisson com ligação log é $X^\top(y-\mu) = 0$ (Exemplo 3.3). Supondo que exista um máximo finito, avalie a equação em $\hat\beta$. Se X inclui uma coluna constante, sua primeira componente é $\sum_i (y_i - \hat\mu_i) = 0$, ou seja, $\sum_i y_i = \sum_i \hat\mu_i$. A ligação log é essencial: sob uma ligação não canônica, a equação do intercepto em geral envolve resíduos ponderados e não produz essa igualdade. Em regressão linear, a equação normal $X^\top(y - X\hat\beta) = 0$ implica analogamente $\sum_i y_i = \sum_i \hat y_i$ quando há intercepto.

Ex. 3.4. $e^{\hat\beta_j} = e^{0{,}5} \approx 1{,}649$: mantendo os demais preditores fixos, cada aumento unitário em x_j multiplica as chances em aproximadamente 1,65. Para um aumento de duas unidades, ainda mantendo os demais preditores fixos, a razão é $e^{2\cdot 0{,}5} = e^1 \approx 2{,}718$.

Ex. 3.5. A log-verossimilhança da Bernoulli é $\ell(p;y) = \sum_i [y_i \log p_i + (1-y_i)\log(1-p_i)]$. No modelo saturado, $\hat p_i = y_i$ e $\ell(y;y) = 0$ (com convenção $0\log 0 = 0$). Logo $D(y,\hat p) = 2[\ell(y;y) - \ell(\hat p;y)] = -2\sum_i [y_i \log\hat p_i + (1-y_i)\log(1-\hat p_i)]$. Esta é a expressão usual da *deviance* binomial.

Ex. 3.6. O código abaixo reproduz os ajustes. Como `hr` é um fator, a hora zero é a categoria de referência e o resultado completo contém 23 indicadores de hora além do intercepto, de `temp` e de `workingday`.

```
library(ISLR2)
library(MASS)

m_gauss <- lm(log(bikers + 1) ~ temp + hr + workingday,
              data = Bikeshare)
m_pois  <- glm(bikers ~ temp + hr + workingday,
               data = Bikeshare, family = poisson)
m_bn    <- glm.nb(bikers ~ temp + hr + workingday,
                  data = Bikeshare)

# Todos os coeficientes, inclusive os 23 indicadores de hora
coeficientes <- cbind(
  gaussiano = coef(m_gauss),
  poisson = coef(m_pois),
  binomial_negativa = coef(m_bn))
round(coeficientes, 4)

diagnosticos <- c(
```

```
  variancia_residual_gaussiana = sigma(m_gauss)^2,
  dispersao_pearson_poisson =
    sum(residuals(m_pois, type = "pearson")^2) / df.residual(m_pois),
  razao_deviancia_poisson = deviance(m_pois) / df.residual(m_pois),
  dispersao_pearson_binomial_negativa =
    sum(residuals(m_bn, type = "pearson")^2) / df.residual(m_bn),
  razao_deviancia_binomial_negativa = deviance(m_bn) / df.residual(m_bn),
  theta_binomial_negativa = m_bn$theta)
round(diagnosticos, 4)
```

Os coeficientes comuns mais importantes são:

	Gaussiano	Poisson	Binomial negativa
Intercepto	2,6004	2,9732	2,9129
`temp`	2,0494	1,6473	1,9312
`workingday`	−0,0511	−0,0132	−0,2168

Os demais coeficientes, um para cada hora em relação à hora zero, são exibidos por `coeficientes`. Não se deve interpretar a proximidade numérica entre as três colunas como igualdade de parâmetros: o primeiro modelo descreve a média de $\log(Y+1)$, enquanto os dois últimos descrevem $\log \mathbb{E}[Y \mid x]$.

Os diagnósticos numéricos são

$$\hat{\sigma}^2_{\text{Gauss}} = 0{,}4197, \qquad \frac{Q_{\text{P},\,Pois}}{n-p} = 32{,}5771, \qquad \frac{D_{\text{Pois}}}{n-p} = 33{,}3290,$$

e, para a binomial negativa,

$$\hat{\theta} = 3{,}0829, \qquad \frac{Q_{\text{P},\,BN}}{n-p} = 0{,}9224, \qquad \frac{D_{\text{BN}}}{n-p} = 1{,}0705.$$

A variância residual gaussiana está na escala de $\log(Y+1)$ e não deve ser comparada numericamente com as razões adimensionais dos modelos de contagem. As duas razões próximas de 33 tornam a hipótese de variância Poisson inadequada. Entre as distribuições de contagem ajustadas, a binomial negativa acomoda muito melhor a dispersão. Isso não encerra o diagnóstico: o preditor linear simples omite, por exemplo, mês e condições meteorológicas, e as observações horárias podem apresentar dependência temporal.

Ex. 3.7. (a) Está feito na demonstração da Proposição 3.9: a integral vale $\Gamma(y+\theta)(1+\theta/\mu)^{-(y+\theta)}$ e o resto é reorganização algébrica. (b) Escrevendo $q = \mu/(\theta+\mu)$ e $1-q = \theta/(\theta+\mu)$, a soma é $(1-q)^\theta \sum_{y\geq 0} \binom{y+\theta-1}{y} q^y = (1-q)^\theta (1-q)^{-\theta} = 1$, pela série binomial negativa $\sum_y \binom{y+\theta-1}{y} q^y = (1-q)^{-\theta}$ para $|q|<1$. (c) $\mathbb{E}[Y] = \mathbb{E}[\Lambda] = \mu$ e $\operatorname{Var}(Y) = \mathbb{E}[\Lambda] + \operatorname{Var}(\Lambda) = \mu + \mu^2/\theta$. (d) Pela função geradora, $G_Y(s) = \left[\theta/(\theta+\mu(1-s))\right]^\theta = \left[1+\mu(1-s)/\theta\right]^{-\theta} \to e^{-\mu(1-s)}$ quando $\theta \to \infty$, que é a f.g.p. da Poisson(μ). Equivalentemente, $\operatorname{Var}(\Lambda) = \mu^2/\theta \to 0$, e a mistura degenera no ponto μ.

Ex. 3.8. Tome o logaritmo de (3.7) com θ fixo:

$$\log \mathbb{P}(Y=y) = y \log\frac{\mu}{\mu+\theta} + \theta \log\frac{\theta}{\mu+\theta} + \log\frac{\Gamma(y+\theta)}{\Gamma(\theta)y!}.$$

Com $\vartheta = \log[\mu/(\mu+\theta)] < 0$, inverte-se $\mu = \theta e^\vartheta/(1-e^\vartheta)$ e o segundo termo vale $\theta\log(1-e^\vartheta)$. Logo $b(\vartheta) = -\theta\log(1-e^\vartheta)$, $a(\phi)=1$ e $c(y,\phi) = \log[\Gamma(y+\theta)/(\Gamma(\theta)y!)]$. Derivando, $b'(\vartheta) = \theta e^\vartheta/(1-e^\vartheta) = \mu$ e $b''(\vartheta) = \theta e^\vartheta/(1-e^\vartheta)^2 = \mu(\mu+\theta)/\theta = \mu + \mu^2/\theta$, como pedido.

A ligação canônica depende do parâmetro de dispersão θ e seu preditor linear precisa permanecer no intervalo $(-\infty, 0)$, restrição inconveniente em regressão. Com ligação log, toda média ajustada é positiva e e^{β_j} tem a leitura simples de razão de taxas, exatamente como no modelo Poisson. Ao abandonar a ligação canônica, a equação de escore deixa de ser $X^\top(y-\mu)=0$, mas o algoritmo

de mínimos quadrados iterativamente reponderados continua válido com a função de variância apropriada.

Ex. 3.9. (a) Com ligação log, $\mu = e^{\eta}$ e $d\mu/d\eta = \mu$, logo $w \propto \mu^2/V(\mu)$. Sob quase-Poisson, $V = \phi\mu$ e $w = \mu/\phi$. Sob binomial negativa, $V = \mu + \mu^2/\theta = \mu(\theta+\mu)/\theta$ e $w = \mu\theta/(\theta+\mu)$. (b) O peso quase-Poisson cresce linearmente em μ; a constante $1/\phi$ é comum às observações e não altera a hierarquia relativa dos pesos do Poisson. O peso binomial negativo, ao contrário, satura: $\mu\theta/(\theta+\mu) \to \theta$ quando $\mu \to \infty$. Assim, comparada ao quase-Poisson, a binomial negativa reduz o peso relativo das observações com média muito alta. (c) Considere contagens de internações em municípios cujas médias ajustadas variam por ordens de grandeza. Mantidos comparáveis os padrões de covariáveis e resíduos, as capitais recebem peso relativo muito maior sob quase-Poisson; sob binomial negativa, esse crescimento é limitado. Por isso, diferenças sistemáticas entre capitais e municípios menores podem alterar materialmente os coeficientes e suas conclusões. Os pesos, sozinhos, não determinam a influência de uma observação: resíduos, covariáveis e alavancagem também participam.

Ex. 3.10. (a)–(c) O código para o modelo correto é:

```
res_quant <- function(modelo, y) {
  mu <- fitted(modelo)
  limite_inferior <- ppois(y - 1, lambda = mu)
  limite_superior <- ppois(y, lambda = mu)
  qnorm(runif(length(y), limite_inferior, limite_superior))
}

correlacao_qq <- function(r) {
  cor(sort(r), qnorm(ppoints(length(r))))
}

set.seed(1)
n <- 300
x <- runif(n, -1, 1)
y <- rpois(n, exp(0.5 + 1.2 * x))
m_correto <- glm(y ~ x, family = poisson)

plot(predict(m_correto), residuals(m_correto, type = "deviance"),
     xlab = "preditor linear", ylab = "residuo de deviancia")

set.seed(2026)
rq_correto <- replicate(5, res_quant(m_correto, y))
round(apply(rq_correto, 2, correlacao_qq), 4)

matplot(qnorm(ppoints(n)), apply(rq_correto, 2, sort),
        type = "l", lty = 1,
        xlab = "quantil normal", ylab = "residuo ordenado")
abline(0, 1, lty = 2)
```

O primeiro gráfico contém faixas curvas associadas aos valores inteiros de y, embora o modelo esteja correto. As cinco correlações quantil-quantil são 0,9983, 0,9977, 0,9982, 0,9982 e 0,9974. As posições dos pontos mudam entre aleatorizações, mas a conclusão global permanece estável.

(d) Para o modelo com termo quadrático omitido:

```
set.seed(1)
x_errado <- runif(n, -1, 1)
y_errado <- rpois(n, exp(0.5 + 1.2 * x_errado + 1.5 * x_errado^2))
m_errado <- glm(y_errado ~ x_errado, family = poisson)

set.seed(2026)
rq_errado <- replicate(5, res_quant(m_errado, y_errado))
```

```
round(apply(rq_errado, 2, correlacao_qq), 4)

par(mfrow = c(1, 3))
qqnorm(rq_errado[, 1]); qqline(rq_errado[, 1], col = "red")

plot(x_errado, rq_errado[, 1],
     xlab = "x", ylab = "residuo quantilico")
lines(lowess(x_errado, rq_errado[, 1]), col = "red", lwd = 2)

res_dev <- residuals(m_errado, type = "deviance")
plot(x_errado, res_dev,
     xlab = "x", ylab = "residuo de deviancia")
lines(lowess(x_errado, res_dev), col = "red", lwd = 2)
```

As cinco correlações quantil-quantil são 0,9973, 0,9973, 0,9975, 0,9980 e 0,9973: o gráfico pode continuar muito próximo da reta apesar de a média condicional estar errada. Em contraste, a curva suavizada dos resíduos contra x revela a forma em U. Isso acontece tanto para os resíduos quantílicos quanto para os de deviância, embora as faixas discretas tornem os últimos mais difíceis de ler. O gráfico quantil-quantil avalia sobretudo a distribuição marginal dos resíduos; uma falha condicional deve ser procurada também nos gráficos contra as covariáveis.

Ex. 3.11. (a) Com a grade especificada no enunciado:

```
x <- seq(-1, 1, length.out = 40)
y <- as.integer(x > 0)

m_ml <- glm(y ~ x, family = binomial,
            control = glm.control(maxit = 25, epsilon = 1e-8))
coef(summary(m_ml))
c(convergiu = m_ml$converged,
  iteracoes = m_ml$iter,
  deviancia = deviance(m_ml))
```

O `glm` emite os avisos de que o algoritmo não convergiu e de que há probabilidades ajustadas numericamente iguais a zero ou um. Uma execução produz

	estimativa	erro-padrão	valor-p
intercepto	$2{,}2 \times 10^{-9}$	5 526,6	1,0000
x	738,18	215 523,3	0,9973

após 25 iterações, com deviância residual $2{,}4 \times 10^{-8}$. Esses números não são estimativas válidas e podem mudar com o critério de parada; os avisos, a divergência dos coeficientes e erros-padrão e a deviância quase nula são os resultados relevantes.

(b)–(c) Ao longo de $(\beta_0, \beta_1) = (0, t)$,

$$\ell(0,t) = -\sum_{x_i>0} \log(1+e^{-tx_i}) - \sum_{x_i<0} \log(1+e^{tx_i}).$$

Cada parcela cresce para zero quando $t \to \infty$, mas é estritamente negativa para todo t finito. Logo o supremo da log-verossimilhança é zero e não é atingido: o estimador de máxima verossimilhança finito não existe. Próximo desse limite, a informação observada colapsa, o erro-padrão explode e a estatística de Wald pode tender a zero. Seu valor-p próximo de um não significa ausência de associação; é um sintoma da separação. A deviância tende a zero porque as probabilidades ajustadas tendem aos valores observados zero e um.

(d) A correção de Firth maximiza $L(\beta)|I(\beta)|^{1/2}$, ou, equivalentemente, adiciona $\frac{1}{2}\log|I(\beta)|$ à log-verossimilhança. Por exemplo:

```
m_firth <- logistf::logistf(y ~ x)
coef(m_firth)
confint(m_firth)
```

Para esta grade, os coeficientes ficam aproximadamente em 0 para o intercepto e 16,32 para a inclinação: grandes, mas finitos. Os intervalos devem ser obtidos pelo perfil da verossimilhança penalizada, não pela aproximação de Wald degenerada do ajuste original.

Ex. 3.12. (a) Pela caracterização $\mathcal{A} = \mathbb{P}(\hat{s}_+ > \hat{s}_-)$ da Seção 9.8, a área de ordenação depende apenas da ordem dos escores. Como $\tilde{p} = \hat{p}/3$ é uma transformação estritamente crescente, para qualquer par de observações

$$\hat{p}_i > \hat{p}_j \quad \Longleftrightarrow \quad \tilde{p}_i > \tilde{p}_j,$$

e os empates também são preservados. Portanto, as duas áreas são exatamente iguais.

(b) Como o modelo logístico contém intercepto, sua equação de escore implica

$$\sum_i (y_i - \hat{p}_i) = 0 \quad \Longrightarrow \quad \overline{\hat{p}} = \bar{y}.$$

Trata-se de calibração média na própria amostra de ajuste. Depois da transformação,

$$\overline{\tilde{p}} = \frac{\overline{\hat{p}}}{3} = \frac{\bar{y}}{3} \neq \bar{y}$$

sempre que há algum evento. Assim, $\tilde{p}$ perde até mesmo a calibração média. Esse argumento não pressupõe calibração perfeita ponto a ponto.

(c) Se fizermos a hipótese adicional de que a previsão original é perfeitamente calibrada, isto é, $\mathbb{E}[Y \mid \hat{p} = s] = s$, então, para $0 < t < 1/3$,

$$\mathbb{E}[Y \mid \tilde{p} = t] = \mathbb{E}[Y \mid \hat{p} = 3t] = 3t \neq t.$$

Sem essa hipótese, apenas a primeira igualdade é automática; por isso não se deve usar a última igualdade como demonstração geral.

(d) Uma reprodução numérica é:

```
dados <- ISLR2::Default
m <- glm(default ~ balance + student + income,
         data = dados, family = binomial)
p_hat <- fitted(m)
p_til <- p_hat / 3
y <- as.integer(dados$default == "Yes")

area_ordenacao <- function(escore, y) {
  n1 <- sum(y == 1); n0 <- sum(y == 0)
  postos_positivos <- sum(rank(escore, ties.method = "average")[y == 1])
  (postos_positivos - n1 * (n1 + 1) / 2) / (n1 * n0)
}

c(area_original = area_ordenacao(p_hat, y),
  area_transformada = area_ordenacao(p_til, y),
  frequencia_observada = mean(y),
  media_original = mean(p_hat),
  media_transformada = mean(p_til))

grupo <- cut(p_hat, breaks = quantile(p_hat, 0:10 / 10),
             include.lowest = TRUE)
tabela <- aggregate(cbind(p_hat, p_til, y) ~ grupo, FUN = mean)
tabela

plot(tabela$p_hat, tabela$y, pch = 19,
     xlab = "media predita", ylab = "frequencia observada")
points(tabela$p_til, tabela$y, pch = 17, col = "blue")
abline(0, 1, col = "red")
legend("topleft", c("original", "dividida por tres"),
       pch = c(19, 17), col = c("black", "blue"))
```

As duas áreas valem 0,949558. A frequência observada e a média de $\hat{p}$ valem 0,0333, enquanto a média de $\tilde{p}$ vale 0,0111. Os decis contêm as mesmas observações, porque a transformação preserva a ordem; em cada um, a média predita é dividida por três e a frequência observada permanece igual. Isso não implica que a distância à diagonal aumente em todo decil isoladamente, mas a falha de calibração média é inequívoca. Como a igualdade $\overline{\hat{p}} = \bar{y}$ é garantida mecanicamente na amostra de ajuste, tanto a ordenação quanto a calibração relevante para decisões devem ser avaliadas em dados não usados no ajuste.

Capítulo 4: Árvores

Ex. 4.1. Seja $|R| = n$, $|R_1| = n_1$, $|R_2| = n_2 = n - n_1$, $\bar{y} = n^{-1}\sum_{i\in R} y_i$ e $\bar{y}_k = n_k^{-1}\sum_{i\in R_k} y_i$. Defina $Q(A) = \sum_{i\in A}(y_i - \bar{y}_A)^2$ para qualquer nó A. Então

$$Q(R) = \sum_{i\in R}(y_i - \bar{y})^2 = \sum_{k=1}^{2} Q(R_k) + \sum_{k=1}^{2} n_k(\bar{y}_k - \bar{y})^2.$$

O primeiro termo após a última igualdade é $Q(R_1) + Q(R_2)$. Como $\bar{y} = (n_1\bar{y}_1 + n_2\bar{y}_2)/n$, $\bar{y}_1 - \bar{y} = (n_2/n)(\bar{y}_1 - \bar{y}_2)$ e $\bar{y}_2 - \bar{y} = -(n_1/n)(\bar{y}_1 - \bar{y}_2)$. Logo o segundo termo é $n_1(n_2/n)^2(\bar{y}_1 - \bar{y}_2)^2 + n_2(n_1/n)^2(\bar{y}_1 - \bar{y}_2)^2 = (n_1n_2/n)(\bar{y}_1 - \bar{y}_2)^2$.

Se n e a diferença entre as médias forem mantidos fixos, $n_1n_2 = n_1(n - n_1)$ é máximo em $n_1 = n/2$ (ou nos dois inteiros mais próximos, se n for ímpar). Entre divisões candidatas reais, porém, a diferença $|\bar{y}_1 - \bar{y}_2|$ também muda. Uma divisão desequilibrada pode vencer se separar médias suficientemente distintas: o critério negocia equilíbrio dos tamanhos e separação das médias, e não maximiza cada fator isoladamente.

Ex. 4.2. Considere $n = 4$ pontos (x_1, x_2, y) com uma interação exclusiva: $(0, 0, 0)$, $(1, 0, 0)$, $(0, 1, 1)$, $(1, 1, -1)$. A soma de quadrados residual da raiz é 2. A divisão em x_1 produz filhos $\{0, 1\}$ e $\{0, -1\}$, com soma total $\frac{1}{2} + \frac{1}{2} = 1$; a divisão em x_2 produz $\{0, 0\}$ e $\{1, -1\}$, com soma total $0 + 2 = 2$. O algoritmo guloso escolhe, portanto, x_1, e a melhor árvore com $|T| = 3$ que começa por x_1 termina com soma $\frac{1}{2}$. A árvore globalmente ótima divide primeiro em x_2, com ganho imediato zero, e em seguida divide o filho $\{x_2 = 1\}$ em x_1, atingindo soma zero. O algoritmo guloso falha porque avalia cada divisão isoladamente e não enxerga que x_2 só rende em composição com x_1.

Ex. 4.3. Há $2^{3-1} - 1 = 3$ partições binárias: $\{A\} \mid \{B, C\}$, $\{B\} \mid \{A, C\}$ e $\{C\} \mid \{A, B\}$. Pelo Exercício 4.1, o ganho é proporcional a $(\bar{y}_{R_1} - \bar{y}_{R_2})^2 \cdot |R_1||R_2|/|R|$. Com tamanhos iguais ($n/3$ cada), $|R_1||R_2|/|R| \in \{2n/9, 2n/9, 2n/9\}$ é constante; o ganho depende apenas de $(\bar{y}_{R_1} - \bar{y}_{R_2})^2$:

- $\{A\} \mid \{B, C\}$: $\bar{y}_{R_1} = 1$, $\bar{y}_{R_2} = 4$; diferença ao quadrado $= 9$.
- $\{B\} \mid \{A, C\}$: $\bar{y}_{R_1} = 5$, $\bar{y}_{R_2} = 2$; diferença ao quadrado $= 9$.
- $\{C\} \mid \{A, B\}$: $\bar{y}_{R_1} = 3$, $\bar{y}_{R_2} = 3$; diferença ao quadrado $= 0$.

Empate entre as duas primeiras; ambas reduzem a soma de quadrados residual ao máximo. O algoritmo de árvores de classificação e regressão, ao reordenar pelas médias ($A < C < B$), considera apenas $\{A\} \mid \{B, C\}$ e $\{A, C\} \mid \{B\}$, exatamente as duas ótimas.

Ex. 4.4. Comparando T_0 e T_1: $C_\alpha(T_0) = 14 + 4\alpha$ e $C_\alpha(T_1) = 18 + 3\alpha$. A árvore T_1 é ótima quando $18 + 3\alpha \le 14 + 4\alpha$, isto é, $\alpha \ge 4$. Logo $\alpha_1 = 4$.

Comparando T_1 e T_2: $24 + 2\alpha \le 18 + 3\alpha \Leftrightarrow \alpha \ge 6$. Logo $\alpha_2 = 6$.

Comparando T_2 e a raiz: $34 + \alpha \le 24 + 2\alpha \Leftrightarrow \alpha \ge 10$. Logo $\alpha_3 = 10$.

Intervalos: T_0 para $\alpha \in [0, 4)$, T_1 para $\alpha \in (4, 6)$, T_2 para $\alpha \in (6, 10)$ e a raiz para $\alpha > 10$. Nos pontos de transição há empate: T_0 e T_1 em $\alpha = 4$; T_1 e T_2 em $\alpha = 6$; T_2 e a raiz em $\alpha = 10$.

Ex. 4.5. O código abaixo mantém a resposta na escala original e usa o mesmo conjunto de teste para todos os ajustes.

```
library(ISLR2)
library(rpart)
library(glmnet)

dados <- na.omit(Hitters)
set.seed(1)
id_treino <- sort(sample(seq_len(nrow(dados)),
                         floor(0.7 * nrow(dados))))
id_teste <- setdiff(seq_len(nrow(dados)), id_treino)

set.seed(2)
arvore <- rpart(
  Salary ~ ., data = dados[id_treino, ], method = "anova",
  control = rpart.control(cp = 0.001, minsplit = 5, xval = 10))
tab <- arvore$cptable
i_min <- which.min(tab[, "xerror"])
i_1ep <- min(which(tab[, "xerror"] <=
                   tab[i_min, "xerror"] + tab[i_min, "xstd"]))
cp <- c(minimo = tab[i_min, "CP"], um_ep = tab[i_1ep, "CP"])
a_min <- prune(arvore, cp = cp["minimo"])
a_1ep <- prune(arvore, cp = cp["um_ep"])
alpha <- cp * arvore$frame$dev[1]

X <- model.matrix(Salary ~ ., data = dados)[, -1]
y <- dados$Salary
set.seed(2)
cv_crista <- cv.glmnet(X[id_treino, ], y[id_treino],
                       alpha = 0, nfolds = 10)

ecm <- function(observado, predito)
  mean((observado - drop(predito))^2)
c(
  arvore_min = ecm(y[id_teste], predict(a_min, dados[id_teste, ])),
  arvore_1ep = ecm(y[id_teste], predict(a_1ep, dados[id_teste, ])),
  crista_min = ecm(y[id_teste], predict(
    cv_crista, X[id_teste, ], s = "lambda.min")),
  crista_1ep = ecm(y[id_teste], predict(
    cv_crista, X[id_teste, ], s = "lambda.1se")))
```

Obtêm-se `CP` iguais a 0,06257 e 0,14105 para o mínimo e para um erro-padrão. Como a soma de quadrados residual da raiz é 35 766 710, os parâmetros na escala do texto são, respectivamente, $\alpha = 2\,237\,762$ e $\alpha = 5\,044\,914$. A primeira poda tem três folhas. A regra de um erro-padrão escolhe duas: se `CHits`< 450, prediz 228,3; caso contrário, prediz 766,9. Assim, a interpretação é uma comparação simples entre jogadores com menos ou mais de 450 rebatidas válidas acumuladas na carreira.

Os erros quadráticos médios de teste são 121 294 e 137 377 para as árvores de mínimo e de um erro-padrão, e 136 793 e 136 676 para as duas escolhas da regressão em crista. Nesta partição, portanto, a árvore de três folhas tem o menor erro, enquanto a árvore mais parcimoniosa e a regressão em crista ficam praticamente empatadas. Essa ordem é uma constatação deste teste, não uma dominância geral entre os métodos. Valores na faixa de 0,3–0,4 corresponderiam ao erro na escala de log(`Salary`) e não respondem ao enunciado.

Ex. 4.6. Uma forma de garantir exatamente 10 folhas é localizar na tabela de complexidade a linha com nove divisões:

```
library(rpart)

gera <- function(n) {
```

```
  x <- runif(n)
  data.frame(x = x,
             y = sin(2 * pi * x) + rnorm(n, sd = 0.1))
}

set.seed(2026)
treino <- gera(200)
teste <- gera(1000)

polinomio <- lm(y ~ poly(x, 5, raw = TRUE), data = treino)
grande <- rpart(
  y ~ x, data = treino, method = "anova",
  control = rpart.control(cp = 0, minsplit = 2, minbucket = 1,
                          maxdepth = 30, xval = 0))
linha <- which(grande$cptable[, "nsplit"] == 9)
stopifnot(length(linha) == 1)
arvore_10 <- prune(grande, cp = grande$cptable[linha, "CP"])

ecm <- function(m) mean((teste$y - predict(m, teste))^2)
c(polinomio = ecm(polinomio), arvore = ecm(arvore_10),
  folhas = sum(arvore_10$frame$var == "<leaf>"))
```

O resultado é 0,01018 para o polinômio e 0,02254 para a árvore, que tem 10 folhas. O primeiro valor está próximo da variância irredutível $0{,}1^2 = 0{,}01$; a árvore paga erro adicional por aproximar a senoide suave por uma função em degraus.

Ex. 4.7. Escreva $Z_b = \hat{f}^{*b}(x)$, com $\mathrm{Var}(Z_b) = \sigma^2$ e $\mathrm{Cov}(Z_b, Z_{b'}) = \rho\sigma^2$ para $b \neq b'$. Então

$$\mathrm{Var}\left(\frac{1}{B}\sum_{b=1}^{B} Z_b\right) = \frac{1}{B^2}\left\{B\sigma^2 + B(B-1)\rho\sigma^2\right\} = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

(a) O limite quando $B \to \infty$ é $\rho\sigma^2$: a variância *não* vai a zero, e sim ao piso imposto pela correlação entre as árvores. Só o segundo termo é controlado por B. (b) Com $\sigma^2 = 1$:

$\rho \backslash B$	10	50	100	500	∞
0,0	0,100	0,020	0,010	0,002	0,000
0,2	0,280	0,216	0,208	0,202	0,200
0,5	0,550	0,510	0,505	0,501	0,500
0,8	0,820	0,804	0,802	0,800	0,800

(c) Com $\rho = 0{,}5$, passar de $B = 100$ para $B = 500$ reduz a variância de 0,505 para 0,501, menos de 1%, a custo de cinco vezes mais computação. Já trocar $\rho = 0{,}8$ por $\rho = 0{,}5$, mantendo $B = 100$ e $\sigma^2 = 1$, leva a variância de 0,802 a 0,505: queda de 37%. Dentro desta fórmula, o segundo ganho é muito maior. Em uma floresta real, porém, alterar o número de preditores candidatos também pode mudar σ^2 e o viés de cada árvore; por isso não se pode atribuir toda a margem de melhoria somente a ρ.

Ex. 4.8. (a) Cada um dos n sorteios independentes deixa de escolher a observação i com probabilidade $1 - 1/n$; logo a probabilidade de não ser escolhida em nenhum é $(1-1/n)^n \to e^{-1}$. Numericamente: 0,349 ($n = 10$), 0,364 ($n = 50$), 0,366 ($n = 100$), 0,368 ($n = 1000$); a convergência é rápida e por baixo. (b) Para cada i, seja $\mathcal{B}_i = \{b : i \notin \mathcal{D}^{*b}\}$ o conjunto das árvores que não viram i. Defina

$$\hat{f}^{\text{fora}}(x_i) = |\mathcal{B}_i|^{-1} \sum_{b \in \mathcal{B}_i} \hat{f}^{*b}(x_i), \qquad \widehat{R}_{\text{fora}} = \frac{1}{n}\sum_{i=1}^{n} L\{y_i, \hat{f}^{\text{fora}}(x_i)\}.$$

(c) Os dois procedimentos predizem y_i sem tê-lo usado no ajuste correspondente, mas não são equivalentes. Cada árvore da floresta é construída a partir de n sorteios com reposição, que contêm aproximadamente $0{,}632n$ observações distintas; cada ajuste da validação que retira uma observação usa $n-1$ observações distintas. Além disso, $\hat{f}^{\text{fora}}(x_i)$ agrega cerca de B/e árvores. A diferença no número agregado desaparece quando B cresce, mas a diferença nas amostras de treinamento permanece. Por isso o sentido do viés não é universal: depende do algoritmo, do tamanho das folhas, da força do sinal e dos demais ajustes. (d) A estimativa pode tornar-se otimista se qualquer etapa dependente de y for feita fora da reamostragem, ou se m e outros parâmetros forem escolhidos pelo próprio erro interno e esse mesmo mínimo for reportado como avaliação final. Toda escolha deve ser refeita dentro de uma camada de avaliação independente.

Ex. 4.9. O protocolo reproduzível é:

```
library(ISLR2)
library(randomForest)
library(gbm)

set.seed(1)
treino <- sample(nrow(Boston), nrow(Boston) / 2)
teste <- setdiff(seq_len(nrow(Boston)), treino)
B <- c(10, 25, 50, 100, 250, 500, 1000, 2500, 5000)
p <- ncol(Boston) - 1
ecm <- function(pred) mean((Boston$medv[teste] - pred)^2)

erro_floresta <- sapply(B, function(b) {
  # A mesma semente torna as sequencias de arvores aninhadas.
  set.seed(1)
  ajuste <- randomForest(
    medv ~ ., data = Boston, subset = treino,
    mtry = floor(p / 3), ntree = b)
  ecm(predict(ajuste, Boston[teste, ]))
})

ajusta_sequencial <- function(nu) {
  set.seed(1)
  ajuste <- gbm(
    medv ~ ., data = Boston[treino, ], distribution = "gaussian",
    n.trees = max(B), interaction.depth = 4, shrinkage = nu,
    cv.folds = 5, n.cores = 1, verbose = FALSE)
  list(
    erro = sapply(B, function(b)
      ecm(predict(ajuste, Boston[teste, ], n.trees = b))),
    B_cv = gbm.perf(ajuste, method = "cv", plot.it = FALSE))
}

seq_01 <- ajusta_sequencial(0.1)
seq_001 <- ajusta_sequencial(0.01)
resultado <- data.frame(
  B, floresta = erro_floresta,
  sequencial_01 = seq_01$erro,
  sequencial_001 = seq_001$erro)
round(resultado, 3)
c(B_cv_01 = seq_01$B_cv, B_cv_001 = seq_001$B_cv)

matplot(B, resultado[, -1], type = "l", log = "x",
        xlab = "numero de arvores", ylab = "erro de teste")
legend("topright", names(resultado)[-1], lty = 1:3, col = 1:3)
```

(a) Nesta realização, os mínimos na grade ocorrem em $B = 25$ para a floresta (erro 18,617), em $B = 1\,000$ para $\nu = 0{,}1$ (erro 16,513) e no limite da grade, $B = 5\,000$, para $\nu = 0{,}01$ (erro 17,134). O primeiro resultado não significa que a floresta sobreajustou depois de 25 árvores: por exemplo, seus erros em $B = 500$, 1 000, 2 500 e 5 000 são 18,988, 18,753, 18,817 e 18,753. São oscilações finitas em torno de um patamar, e o mínimo empírico depende da grade e deste conjunto de teste.

(b) Condicionalmente aos dados, a floresta acrescenta árvores geradas em paralelo pela mesma regra aleatória e calcula sua média. Aumentar B reduz o erro de Monte Carlo na aproximação da floresta infinita, sem aumentar sistematicamente a adaptação aos dados. Ainda assim, uma curva de teste realizada não precisa ser monótona. Na combinação sequencial, cada nova árvore depende do ajuste corrente e B controla a flexibilidade do próprio modelo; por isso o método *pode* começar a perseguir ruído e elevar o erro de generalização. Ele não precisa, porém, interpolar nem exibir uma subida visível em toda amostra ou grade.

(c) A validação cruzada escolhe $B_{\text{ótimo}} = 221$ para $\nu = 0{,}1$ e $B_{\text{ótimo}} = 2\,112$ para $\nu = 0{,}01$. A razão $2\,112/221 = 9{,}56$ é próxima da razão inversa das taxas, igual a 10. A grade de teste serve aqui para ilustrar as trajetórias; em uma análise real, não se deve escolher B pelo erro do conjunto reservado para a avaliação final.

Ex. 4.10. O enunciado pode ser reproduzido literalmente com:

```
library(randomForest)

n <- 500
set.seed(1)
x1 <- rnorm(n)
x2 <- sample(c(-1, 1), n, replace = TRUE)
x3 <- rnorm(n)
x4 <- factor(sample(sprintf("L%02d", 1:20), n, replace = TRUE))
y <- x1 + x2 + rnorm(n)
dados4 <- data.frame(y, x1, x2, x3, x4)

set.seed(2)
x5 <- x1 + rnorm(n, sd = 0.1)
dados5 <- cbind(dados4, x5 = x5)

set.seed(3)
floresta4 <- randomForest(
  y ~ ., data = dados4, ntree = 1000, mtry = 2,
  importance = TRUE)
set.seed(3)
floresta5 <- randomForest(
  y ~ ., data = dados5, ntree = 1000, mtry = 2,
  importance = TRUE)

round(importance(floresta4, scale = FALSE), 3)
round(importance(floresta5, scale = FALSE), 3)
```

Antes de acrescentar x_5, o resultado é:

	permutação	impureza
x_1	1,587	615,9
x_2	1,864	519,9
x_3	−0,008	160,8
x_4	0,015	244,5

As escalas das duas colunas são diferentes e não devem ser comparadas entre si; interessam suas ordenações. (a) Embora x_3 e x_4 sejam irrelevantes, a redução de impureza atribui a ambos valores positivos e coloca x_4 acima de x_3. Já seus aumentos no erro por permutação ficam próximos de zero.

Uma variável com 20 níveis admite matematicamente $2^{19}-1$ bipartições. Para soma de quadrados, é possível encontrar a melhor delas ordenando os níveis por média da resposta no nó e examinando apenas 19 cortes; portanto, não é correto afirmar que toda implementação necessariamente avalia as $2^{19}-1$ opções. Mesmo assim, tanto a ordenação quanto o corte são escolhidos com as respostas observadas, e a maior flexibilidade cria viés de seleção por acaso. A redução obtida no treino é acumulada pela importância por impureza; a permutação usa observações fora da reamostra e atenua esse problema.

(b) Depois de acrescentar x_5, obtém-se:

	permutação	impureza
x_1	0,951	379,8
x_2	1,818	493,8
x_3	−0,007	112,5
x_4	0,024	223,6
x_5	0,765	344,5

A importância por permutação antes concentrada em x_1 divide-se entre x_1 e seu substituto x_5: ao permutar um deles, o outro preserva parte da informação. A redução de impureza também se divide. Nenhuma medida responde isoladamente "quanto o sinal de x_1 importa"; a permutação responde quanto se perde ao destruir uma variável mantendo disponíveis as demais.

(c) Para descrever predição, prefira a permutação à impureza, mas não trate nenhuma delas como efeito causal ou teste de hipótese. Sob correlação, examine também permutações de grupos. Se a finalidade for *selecionar* variáveis, refaça toda a seleção dentro de cada amostra de uma validação aninhada e avalie o subconjunto escolhido somente na camada externa.

Ex. 4.11. Com $L=\frac{1}{2}(y-f)^2$, tem-se $\partial L/\partial f=-(y-f)$, logo $-\partial L/\partial f=y-f$: o resíduo corrente é o gradiente negativo. Avaliado no modelo anterior, o alvo é $r_i^{(b)}=y_i-\hat{f}_{b-1}(x_i)$.

(a) Para $L=|y-f|$, o gradiente negativo, quando existe, é $\operatorname{sinal}(y-f)$. Com a convenção pedida no ponto não diferenciável,

$$r_i^{(b)}=\operatorname{sinal}\{y_i-\hat{f}_{b-1}(x_i)\},\qquad \operatorname{sinal}(0)=0.$$

Sua magnitude é limitada por 1: um resíduo vertical enorme não recebe peso maior que outro resíduo não nulo com o mesmo sinal. Isso confere robustez a valores atípicos na *resposta*, mas não elimina automaticamente o efeito de observações de alta alavancagem no espaço dos preditores.

(b) Para $L=\log(1+e^{-yf})$, com $y\in\{-1,+1\}$,

$$r_i^{(b)}=\frac{y_i}{1+\exp\{y_i\hat{f}_{b-1}(x_i)\}}.$$

Seu módulo é grande para observações classificadas com margem errada e pequeno para observações classificadas com grande margem correta.

(c) Para Poisson com $f=\log\mu$, omitindo a constante em y, a perda é $L(y,f)=-yf+e^f$. Portanto,

$$r_i^{(b)}=y_i-\exp\{\hat{f}_{b-1}(x_i)\}=y_i-\hat{\mu}_{b-1}(x_i).$$

Em todos os casos, ajusta-se a nova árvore a esses alvos avaliados no modelo corrente e soma-se ao modelo um múltiplo ν da árvore.

Capítulo 5: Sobrevivência

Ex. 5.1. $f(t)=-S'(t)$ por definição da função de distribuição $F=1-S$. Como $h(t)=f(t)/S(t)=-S'(t)/S(t)=-d\log S(t)/dt$, integrando de 0 a t obtém-se $H(t)=-\log S(t)$, ou

$S(t) = e^{-H(t)}$. No caso discreto (tempos $\tau_1 < \tau_2 < \cdots$ com massa f_j), $h_j = f_j / S(\tau_{j-1})$ e $S(\tau_k) = \prod_{j \le k}(1 - h_j)$, em vez da exponencial integrada, a versão multiplicativa.

Ex. 5.2. Tempos distintos de evento: $2, 3, 5, 8, 10, 12$. Calculando $\hat{S}$:

$t_{(j)}$	n_j	d_j	$1 - d_j/n_j$	$\hat{S}(t_{(j)})$
2	9	1	8/9	0,889
3	8	1	7/8	0,778
5	7	1	6/7	0,667
8	5	1	4/5	0,533
10	4	1	3/4	0,400
12	2	1	1/2	0,200

A convenção padrão é tratar a censura em 5^+ como ocorrendo *depois* do evento em 5, ou seja, no tempo 5, há ainda 7 em risco (não 6). Após o evento, o censurado em 5^+ sai do conjunto em risco.

Ex. 5.3. A log-verossimilhança para T_i exponencial com censura à direita é

$$\ell(\beta) = \sum_i \delta_i \log \lambda_i - \sum_i \lambda_i \tilde{T}_i = \sum_i [\delta_i \, x_i^\top \beta - e^{x_i^\top \beta} \tilde{T}_i].$$

Esta é exatamente a log-verossimilhança de uma regressão de Poisson com offset $\log \tilde{T}_i$ e resposta δ_i, que é côncava em β (Hessiana $-\sum_i e^{x_i^\top \beta} \tilde{T}_i \, x_i x_i^\top$, definida negativa).

Ex. 5.4. Os tempos 4 aparecem em dois indivíduos (digamos $i = 2, 3$). Em cada tempo de evento, multiplicamos pelo respectivo termo:

$$L_{\text{parcial}}(\beta) = \frac{e^{x_1^\top \beta}}{\sum_{j=1}^{5} e^{x_j^\top \beta}} \cdot \frac{e^{x_2^\top \beta} e^{x_3^\top \beta}}{\left(\sum_{j=2}^{5} e^{x_j^\top \beta}\right)^2} \cdot \frac{e^{x_4^\top \beta}}{e^{x_4^\top \beta} + e^{x_5^\top \beta}} \cdot \frac{e^{x_5^\top \beta}}{e^{x_5^\top \beta}}.$$

O método de Breslow trata os empates assumindo que ambos os eventos ocorrem "simultaneamente" contra o mesmo conjunto em risco, a aproximação acima. Outras opções (Efron, exata) são mais precisas mas com custo computacional maior.

Ex. 5.5. A razão de riscos para 10 anos é $e^{0{,}03 \cdot 10} = e^{0{,}3} \approx 1{,}35$, isto é, risco instantâneo 35% maior. Para 30 anos, é $e^{0{,}9} \approx 2{,}46$. A hipótese de proporcionalidade postula que esse efeito é constante no tempo, algo questionável em estudos longos, pois o efeito da idade pode mudar conforme o paciente envelhece. A proporcionalidade pode ser investigada com resíduos de Schoenfeld por meio de `cox.zph`.

Ex. 5.6. *Resposta indicativa.* Em `colon`, cada paciente aparece em duas linhas: o tipo de desfecho é `etype` (1 = recorrência, 2 = morte) e `status` já é o indicador 0/1 do evento. Trabalhe com `d <- subset(colon, etype == 2)`. (a) `survfit(Surv(time, status) ~ rx, data = d)`; (b) `survdiff(...)`; (c) `coxph(Surv(time, status) ~ rx + age + sex + extent, data = d)`; (d) `cox.zph(...)`. Esperam-se razões de riscos menores que 1 para tratamentos ativos, indicando proteção; a extensão do tumor costuma ser um dos preditores mais fortes. Os valores numéricos exatos devem ser obtidos da versão instalada dos dados e acompanhados por intervalos de confiança.

Ex. 5.7. A demonstração está no texto. (a) $\ell(\lambda) = d \log \lambda - \lambda \sum_i t_i$, logo $-\ell''(\lambda) = d/\lambda^2$; avaliada em $\hat{\lambda}$, a informação observada é $d/\hat{\lambda}^2 = (\sum t_i)^2/d$. Note que $\sum_i t_i$ aparece apenas através de $\hat{\lambda}$: a precisão relativa $\mathrm{Var}(\hat{\lambda})/\lambda^2 = 1/d$ depende *exclusivamente* do número de eventos. (b) $\hat{\lambda} \pm 1{,}96 \, \hat{\lambda}/\sqrt{d}$, ou melhor, na escala logarítmica, $\hat{\lambda} \exp(\pm 1{,}96/\sqrt{d})$, que respeita $\lambda > 0$. Para a mediana $m = \log 2/\lambda$, pelo método delta na escala log, $\hat{m} \exp(\pm 1{,}96/\sqrt{d})$. (c) Como o erro-padrão

relativo é $1/\sqrt{d}$, dobrar a precisão exige quadruplicar o número de *eventos*, recrutar mais pacientes só ajuda na medida em que produz eventos. Com desfecho raro, um ensaio pode ter milhares de participantes e ainda assim ser inconclusivo; as alternativas são prolongar o seguimento, enriquecer a amostra com participantes de alto risco, ou adotar desfecho composto. É por isso que protocolos de ensaios de sobrevivência especificam análise "guiada por eventos" (*event-driven*), fixando o número de eventos e deixando a duração do estudo como consequência.

Ex. 5.8. (a) Se W tem distribuição de valor extremo padrão, $\mathbb{P}(W > w) = \exp(-e^{w})$. De $\log T = x^{\top}\beta^{\text{tempo}} + \sigma W$ vem $W = (\log t - x^{\top}\beta^{\text{tempo}})/\sigma$, logo

$$S(t \mid x) = \mathbb{P}(W > \tfrac{\log t - x^{\top}\beta^{\text{tempo}}}{\sigma}) = \exp\Big\{-\exp\Big(\tfrac{\log t - x^{\top}\beta^{\text{tempo}}}{\sigma}\Big)\Big\} = \exp\{-t^{1/\sigma}e^{-x^{\top}\beta^{\text{tempo}}/\sigma}\},$$

que é Weibull com forma $\kappa = 1/\sigma$ e escala $e^{x^{\top}\beta^{\text{tempo}}}$. (b) Daí $H(t \mid x) = t^{\kappa}e^{-\kappa x^{\top}\beta^{\text{tempo}}}$ e $h(t \mid x) = \kappa t^{\kappa-1}e^{-\kappa x^{\top}\beta^{\text{tempo}}}$. Escrevendo $h_0(t) = \kappa t^{\kappa-1}$, resulta $h(t \mid x) = h_0(t)\exp(x^{\top}\beta^{\text{riscos}})$ com $\beta^{\text{riscos}} = -\kappa\beta^{\text{tempo}}$. A razão de riscos é constante em t, como exige a representação de riscos proporcionais. (c) Para a log-normal, $S(t \mid x) = 1 - \Phi((\log t - x^{\top}\beta)/\sigma)$ e $h(t \mid x) = \phi(z)/[\sigma t(1-\Phi(z))]$ com $z = (\log t - x^{\top}\beta)/\sigma$. A razão $h(t \mid x_1)/h(t \mid x_2)$ envolve ϕ e $1-\Phi$ avaliadas em argumentos deslocados, e a razão de Mills não é invariante por translação; logo depende de t. Portanto a log-normal admite a representação de tempo de falha acelerado, mas não a de riscos proporcionais.

Ex. 5.9. A dedução de (5.4) segue de $\mathbb{P}(T \in (l, r]) = S(l) - S(r)$ e da independência entre indivíduos. Casos particulares: com $r_i = \infty$ e $S(\infty) = 0$, a contribuição vira $S(l_i)$, censura à direita; com $l_i = 0$ e $S(0) = 1$, vira $1 - S(r_i) = F(r_i)$, censura à esquerda; e $[S(l) - S(r)]/(r - l) \to f(l)$ quando $r \downarrow l$, recuperando a contribuição exata a menos de constante. Para os dados fornecidos, sob $S(t) = e^{-\lambda t}$:

$$\ell(\lambda) = \log(1 - e^{-2\lambda}) + \log(e^{-\lambda} - e^{-3\lambda}) + (-2\lambda) + (-\lambda).$$

Como $e^{-\lambda} - e^{-3\lambda} = e^{-\lambda}(1 - e^{-2\lambda})$, isso se reduz a $\ell(\lambda) = 2\log(1 - e^{-2\lambda}) - 4\lambda$; escrevendo $u = e^{-2\lambda}$, $\ell'(\lambda) = 4u/(1-u) - 4 = 0 \Leftrightarrow u = \tfrac{1}{2}$, ou seja, forma fechada $\hat{\lambda} = \tfrac{\ln 2}{2} \approx 0{,}347$ (confirme com `optimize(f, c(0.01, 3), maximum = TRUE)`). A imputação pelos pontos médios trataria as observações como exatas em 1, 2 e ignoraria ou truncaria as censuradas, produzindo estimativa sensivelmente diferente e, sobretudo, um erro-padrão *artificialmente pequeno*, pois trata como conhecida uma informação que não se tem. O ponto do exercício é este: imputar o ponto médio não é uma aproximação inocente da verossimilhança intervalar; ela subestima a incerteza por construção.

Ex. 5.10. *Resposta indicativa.* (a) Com $\kappa = 2$ e escala 70, $S(40) = 0{,}721$, $S(50) = 0{,}600$ e $S(60) = 0{,}480$. Como ninguém pode ser observado antes de 40, a curva não paramétrica corrigida identifica $S(t \mid T > 40) = S(t)/S(40)$: os alvos em 50 e 60 são, respectivamente, 0,832 e 0,665. Ela não identifica os valores incondicionais 0,600 e 0,480 sem uma hipótese paramétrica adicional. A curva ingênua trata como sob risco indivíduos que ainda não haviam entrado e, portanto, não tem esse alvo condicional. (b) Em cada réplica, compare os estimadores corrigido e ingênuo com $S(t)/S(40)$ e reporte média, viés e erro de Monte Carlo. O corrigido deve oscilar em torno do alvo; o tamanho e até detalhes do viés ingênuo dependem da amostra e do ponto de avaliação, de modo que não se deve substituir a simulação por números universais. (c) Neste desenho, o mecanismo predominante é viés para cima nas idades iniciais: incluir antes da entrada pessoas que, por seleção, sobreviveram até U_i infla o conjunto de risco e reduz os incrementos estimados de risco. Isso é uma afirmação sobre o comportamento médio no desenho, não uma garantia do sinal em toda réplica finita. (d) Quando a entrada é uniforme em $(40, 42)$, os tempos de entrada ficam quase iguais e a diferença entre os conjuntos de risco diminui. No limite em que todos entram exatamente em 40, os dois estimadores coincidem para $t \geq 40$ e estimam a sobrevivência condicional a $T > 40$. Para uma janela estreita, mas não degenerada, diferenças acumuladas entre 40 e 42 podem persistir depois de 42, embora tendam a ser pequenas.

Ex. 5.11. (a) $\int_0^\infty t f(t)/\mathbb{E}[T]\,dt = \mathbb{E}[T]/\mathbb{E}[T] = 1$, e o integrando é não negativo. (b) $\mathbb{E}[T^{\text{obs}}] = \int t \cdot t f(t)/\mathbb{E}[T]\,dt = \mathbb{E}[T^2]/\mathbb{E}[T]$. Como $\mathbb{E}[T^2] = \mathrm{Var}(T) + \mathbb{E}[T]^2$, segue $\mathbb{E}[T^{\text{obs}}] = \mathbb{E}[T] + \mathrm{Var}(T)/\mathbb{E}[T] = \mathbb{E}[T](1 + c_T^2)$, com $c_T = \sqrt{\mathrm{Var}(T)}/\mathbb{E}[T]$, o coeficiente de variação. (c) Para a exponencial, $c_T = 1$, logo $\mathbb{E}[T^{\text{obs}}] = 2\mathbb{E}[T]$. (d) Exemplo: estimar a duração média de internação entrevistando todos os pacientes internados em um hospital num dia dado. Pacientes de internação longa têm probabilidade proporcionalmente maior de estar presentes na data da amostragem. Correções: amostrar admissões, modelar explicitamente o mecanismo de amostragem ou usar métodos de sobrevivência para truncamento e viés de comprimento. A ponderação simples por $1/t_i$ só é aplicável quando a duração total t_i é de fato observada e requer normalização adequada.

Capítulo 6: Algoritmo de esperança e maximização

Ex. 6.1. A função Q envolvendo apenas π é $\sum_i \sum_k \gamma_{ik} \log \pi_k$. Maximizar com restrição $\sum_k \pi_k = 1$ via Lagrange: $\partial/\partial \pi_k [Q + \lambda(1 - \sum \pi_l)] = 0 \Rightarrow \sum_i \gamma_{ik}/\pi_k = \lambda$, donde $\pi_k = \sum_i \gamma_{ik}/\lambda$. Somando em k: $\sum_k \pi_k = (1/\lambda)\sum_i \sum_k \gamma_{ik} = n/\lambda = 1$, portanto $\lambda = n$ e $\hat\pi_k = (1/n)\sum_i \gamma_{ik}$.

Ex. 6.2. Se $Y \sim N(\mu, \sigma^2)$, então $Y \mid Y > c$ tem densidade $\phi((y-\mu)/\sigma)/[\sigma(1 - \Phi(\xi))]$ para $y > c$, com $\xi = (c - \mu)/\sigma$. Calcule

$$\mathbb{E}[Y \mid Y > c] = \mu + \sigma \cdot \mathbb{E}[Z \mid Z > \xi], \qquad Z \sim N(0,1).$$

Para Z normal padrão, $\mathbb{E}[Z \mid Z > \xi] = \phi(\xi)/(1 - \Phi(\xi))$ (*razão de Mills inversa*). Substituindo, obtém-se a expressão da Proposição 6.5.

Ex. 6.3. Tome $q(z) = p(z \mid y; \theta')$ como densidade auxiliar. Por Jensen,

$$\log L(\theta; y) = \log \int q(z) \frac{f(y, z; \theta)}{q(z)}\, dz \;\geq\; \int q(z) \log \frac{f(y, z; \theta)}{q(z)}\, dz = Q(\theta \mid \theta') + c(\theta'),$$

onde $c(\theta') = -\int q \log q$ não depende de θ. O lado direito é maximizado por $\theta^{(t+1)} = \arg\max_\theta Q$, e como a desigualdade vira igualdade em $\theta = \theta'$, conclui-se que $\ell(\theta^{(t+1)}; y) \geq \ell(\theta^{(t)}; y)$.

Ex. 6.4. Passo de esperança. A responsabilidade, isto é, a probabilidade condicional de que a observação i pertença à primeira componente, é $\gamma_{i1}^{(t)} = \pi^{(t)} \lambda_1^{(t)} e^{-\lambda_1^{(t)} y_i} / [\pi^{(t)} \lambda_1^{(t)} e^{-\lambda_1^{(t)} y_i} + (1 - \pi^{(t)}) \lambda_2^{(t)} e^{-\lambda_2^{(t)} y_i}]$, e $\gamma_{i2} = 1 - \gamma_{i1}$.

Passo de maximização. $\pi^{(t+1)} = \frac{1}{n}\sum_i \gamma_{i1}$, e $\lambda_k^{(t+1)} = \sum_i \gamma_{ik} / \sum_i \gamma_{ik} y_i$. A segunda expressão é o inverso da média ponderada dos tempos, como no estimador de máxima verossimilhança da taxa exponencial.

Ex. 6.5. Para a distribuição normal bivariada de vetor de médias μ e matriz de covariâncias Σ, com observações parcialmente faltantes, o passo de esperança calcula, para cada padrão de falta, a esperança e a covariância *condicionais* de $Y_{\text{faltante}} \mid Y_{\text{observado}}$ usando os parâmetros correntes. Por propriedades da normal multivariada,

$$Y_{\text{f}} \mid Y_{\text{o}} = y_o \sim N(\mu_f + \Sigma_{fo}\Sigma_{oo}^{-1}(y_o - \mu_o),\; \Sigma_{ff} - \Sigma_{fo}\Sigma_{oo}^{-1}\Sigma_{of}).$$

O passo de maximização atualiza $\mu = \frac{1}{n}\sum_i \tilde y_i$ (com $\tilde y_i$ o vetor completado pelas esperanças condicionais) e Σ pela média de $\tilde y_i \tilde y_i^\top$ corrigida pelas covariâncias condicionais. Veja Dempster, Laird e Rubin 1977 para o detalhe.

Ex. 6.6. *Resposta indicativa.* Em `faithful$eruptions`, $K = 2$ produz aproximadamente $\hat\pi \approx (0{,}35,\ 0{,}65)$, $\hat\mu \approx (2{,}02,\ 4{,}27)$, $\hat\sigma \approx (0{,}24,\ 0{,}44)$. As duas componentes correspondem aos dois modos visíveis no histograma. `mclust` reproduz valores próximos e mostra o critério de informação de Schwarz sob o identificador literal `BIC`; nessa saída específica, valores maiores são preferidos, como explicado no capítulo.

Ex. 6.7. *Resposta indicativa.* Resultados esperados nas $R = 200$ réplicas, para $\mathbb{E}[Y] = 0$:

Mecanismo	Casos completos	Esperança e maximização
Falta completamente aleatória	viés ≈ 0	viés ≈ 0 (mais eficiente)
Falta aleatória condicional aos dados observados	viés negativo	viés ≈ 0
Falta não aleatória	viés negativo grande	viés negativo grande

Explicações. Sob falta completamente aleatória, o subconjunto observado é uma amostra aleatória simples do todo, e ambos os métodos são não viesados; o algoritmo ganha eficiência por aproveitar a informação que X carrega sobre Y através da correlação 0,7. Sob falta aleatória condicional aos observados, a falta depende de X, que está sempre observado: os casos completos superrepresentam X pequeno e, pela correlação, Y pequeno, mas o modelo normal bivariado condiciona corretamente em X e recupera $\mathbb{E}[Y]$, sob as demais hipóteses do Teorema 6.7. Sob falta não aleatória, a ausência depende de Y mesmo dado X; o mecanismo ignorável deixa de valer e o algoritmo maximiza uma verossimilhança observada inadequada para o mecanismo real. Em geral, os dados observados sozinhos não identificam essa dependência; por isso são necessárias hipóteses externas e análises de sensibilidade.

Ex. 6.8. (a) No passo de esperança, para as m observações faltantes, $\mathbb{E}[Y_i \mid y_{\text{obs}}, \mu] = \mu$. No passo de maximização, toma-se a média de todos os n valores, observados mais completados por suas esperanças,

$$M(\mu) = \frac{1}{n}\Big[(n-m)\bar{y}_{\text{obs}} + m\mu\Big] = \frac{n-m}{n}\bar{y}_{\text{obs}} + \frac{m}{n}\mu.$$

(b) Logo $J = dM/d\mu = m/n$, com ponto fixo $\mu^* = \bar{y}_{\text{obs}}$ (faça $M(\mu) = \mu$). Diretamente: $I_{\text{com}} = n$ é a informação completa, $I_{\text{obs}} = n - m$ é a informação observada e $I_{\text{aus}} = I_{\text{com}} - I_{\text{obs}} = m$ é a informação ausente; portanto $I_{\text{com}}^{-1} I_{\text{aus}} = m/n = J$, confirmando (6.3). Em dimensão maior, a ordem dos fatores deve ser preservada. (c) O número de iterações para reduzir o erro por um fator ε é $t \approx \log \varepsilon / \log J$. Com $\varepsilon = 10^{-6}$: $J = 0{,}1$ dá $t \approx 6$; $J = 0{,}5$ dá $t \approx 20$; $J = 0{,}95$ dá $t \approx 269$. (d) O exemplo é simples porque o estimador de máxima verossimilhança se escreve em uma linha, e por isso mesmo isola o mecanismo: o algoritmo repondera informação, e a lentidão decorre da proporção de informação ausente. Em modelos reais, J pode ser aproximado empiricamente pela razão entre erros sucessivos perto do ponto fixo.

Ex. 6.9. Parta de $\ell(\theta; y) = Q(\theta \mid \theta') - H(\theta \mid \theta')$ com $H(\theta \mid \theta') = \mathbb{E}[\log p(Z \mid y, \theta) \mid y, \theta']$. Diferenciando duas vezes em θ e avaliando em $\theta = \theta'$:

$$-\nabla^2 \ell(\theta; y) = -\nabla^2 Q(\theta \mid \theta)\big|_{\theta'} + \nabla^2 H(\theta \mid \theta)\big|_{\theta'}.$$

O primeiro termo é $I_{\text{com}} = \mathbb{E}[-\nabla^2 \ell_c \mid y, \theta]$. Para o segundo, use a identidade da informação aplicada à densidade condicional $p(z \mid y, \theta)$: como $\int p(z \mid y, \theta) dz = 1$ para todo θ, vale $\mathbb{E}[\nabla \log p(Z \mid y, \theta) \mid y, \theta] = 0$ e $-\nabla^2 H\big|_{\theta'} = \operatorname{Var}(\nabla \log p(Z \mid y, \theta) \mid y, \theta)$. Como $\log p(z \mid y, \theta) = \ell_c(\theta; y, z) - \ell(\theta; y)$ e o segundo termo não depende de z, os gradientes diferem por uma constante em z, e as variâncias condicionais coincidem: $\operatorname{Var}(\nabla \log p(Z \mid y, \theta) \mid y, \theta) = \operatorname{Var}(\nabla \ell_c \mid y, \theta) = I_{\text{aus}}$. Reunindo, $I_{\text{obs}} = I_{\text{com}} - I_{\text{aus}}$, que é (6.4). Aplicando ao modelo do Exercício 6.8: $\nabla \ell_c = \sum_{i=1}^{n} (Y_i - \mu)$, logo $I_{\text{com}} = n$ e $\operatorname{Var}(\nabla \ell_c \mid y, \mu) = \operatorname{Var}(\sum_{i \text{ faltantes}} Y_i \mid \mu) = m$ (as $n - m$ observadas são constantes na condicional). Portanto $I_{\text{obs}} = n - m$, como esperado.

Ex. 6.10. *Resposta indicativa.* (a) Com componentes separadas por apenas 1 desvio padrão, J fica em torno de 0,9–0,95. O critério em ℓ costuma ser satisfeito muito antes do critério em $\|\Delta\theta\|$; os números exatos dependem da amostra simulada. (b) Entre os dois pontos de parada, $\hat{\mu}$ ainda pode se deslocar o bastante para alterar casas decimais reportadas. A razão é geométrica: perto do máximo, a diferença de log-verossimilhança é de segunda ordem no erro em θ. (c) Um critério híbrido razoável exige simultaneamente $|\Delta\ell| / (|\ell| + \varepsilon_0) < \varepsilon$ e $\|\Delta\theta\| / (\|\theta\| + \varepsilon_0) < \varepsilon$. Se a convergência continuar lenta, pode-se aplicar aceleração de Aitken, maximizar diretamente a verossimilhança observada em alguns blocos ou usar um método quase-Newton. Componentes

muito sobrepostas também podem revelar falta de informação, problema que nenhuma aceleração elimina.

Ex. 6.11. *Resposta indicativa.* (a) Sem ordenação, os erros-padrão de $\hat{\mu}_1$ e $\hat{\mu}_2$ saem enormes, da ordem da própria distância entre as médias. (b) Com ordenação, caem para valores plausíveis, compatíveis com a curvatura da verossimilhança. (c) O histograma das réplicas de $\hat{\mu}_1$ sem ordenação é **bimodal**, com modas próximas às duas médias de `eruptions`: em cada reamostra, qual componente recebe o rótulo "1" depende da inicialização e do acaso. (d) O problema afeta qualquer agregação entre ajustes: reamostragem, validação cruzada, amostragem por cadeias de Markov na versão bayesiana e múltiplas inicializações. Antes de resumir componentes entre ajustes, imponha uma correspondência canônica justificável; quando as componentes se sobrepõem fortemente, a própria interpretação por rótulos pode ser inadequada.

Capítulo 7: Jackknife

Ex. 7.1. Repete o cálculo do Exemplo 7.1: $\hat{\theta}_{(-i)} = (n\bar{X} - X_i)/(n-1)$, $\hat{\theta}_{(\cdot)} = \bar{X}$, $\widehat{\text{vies}}_{\text{jack}} = 0$. Para a variância, $\hat{\theta}_{(-i)} - \hat{\theta}_{(\cdot)} = (\bar{X} - X_i)/(n-1)$, e

$$\widehat{\text{Var}}_{\text{jack}} = \frac{n-1}{n} \sum_i \frac{(X_i - \bar{X})^2}{(n-1)^2} = \frac{1}{n(n-1)} \sum (X_i - \bar{X})^2 = \frac{s^2}{n}.$$

Ex. 7.2. Defina $\bar{X}_{(-i)} = (n\bar{X} - X_i)/(n-1)$, de modo que $\bar{X}_{(-i)} - \bar{X} = (\bar{X} - X_i)/(n-1)$. Então

$$\sum_{j \neq i} (X_j - \bar{X}_{(-i)})^2 = \sum_{j \neq i} (X_j - \bar{X})^2 - (n-1)(\bar{X}_{(-i)} - \bar{X})^2 = n\hat{\theta} - \frac{n}{n-1}(X_i - \bar{X})^2,$$

e, dividindo por $n-1$,

$$\hat{\theta}_{(-i)} = \frac{n}{n-1}\,\hat{\theta} - \frac{n}{(n-1)^2}\,(X_i - \bar{X})^2.$$

Como $\frac{1}{n}\sum_i (X_i - \bar{X})^2 = \hat{\theta}$, a média dos $\hat{\theta}_{(-i)}$ é $\hat{\theta}_{(\cdot)} = \frac{n}{n-1}\hat{\theta} - \frac{n}{(n-1)^2}\hat{\theta} = \frac{n(n-2)}{(n-1)^2}\,\hat{\theta}$. Portanto

$$\widehat{\text{vies}}_{\text{jack}} = (n-1)(\hat{\theta}_{(\cdot)} - \hat{\theta}) = (n-1)\,\hat{\theta}\,\frac{n(n-2) - (n-1)^2}{(n-1)^2} = -\frac{\hat{\theta}}{n-1},$$

exatamente, sem resto. Sua esperança é $-\mathbb{E}[\hat{\theta}]/(n-1) = -\sigma^2/n$: o *jackknife* reproduz exatamente o viés clássico do estimador de variância com denominador n.

Ex. 7.3. Com $n = 2m$, $\hat{\theta}_n = (X_{(m)} + X_{(m+1)})/2$. Ao remover X_i, restam $2m-1$ observações: se $X_i \geq X_{(m+1)}$, a mediana do que resta é $X_{(m)}$; se $X_i \leq X_{(m)}$, é $X_{(m+1)}$. Apenas *dois* valores aparecem em $\{\hat{\theta}_{(-i)}\}$, cada um m vezes, de modo que $\hat{\theta}_{(\cdot)} = \hat{\theta}_n$ e cada desvio vale $\pm D/2$, com $D = X_{(m+1)} - X_{(m)}$ o espaçamento central. Logo $\widehat{\text{Var}}_{\text{jack}} = \frac{n-1}{n} \cdot n\,(D/2)^2 = (n-1)D^2/4$. Como $nf(M)\,D \xrightarrow{d} \text{Exp}(1) = \chi^2_2/2$, essas duas estatísticas de ordem distam $D = O_p(1/n)$, e portanto $\widehat{\text{Var}}_{\text{jack}} = O_p(1/n)$: a *mesma* ordem da variância verdadeira $1/(4nf(M)^2)$. A falha real é de *inconsistência*, não de ordem:

$$n\,\widehat{\text{Var}}_{\text{jack}} \xrightarrow{d} \frac{(\chi^2_2/2)^2}{4f(M)^2},$$

um limite *aleatório*, que não converge à constante $1/(4f(M)^2)$. Como $\mathbb{E}[(\chi^2_2/2)^2] = 2$, o *jackknife* superestima a variância da mediana em média por um fator próximo de 2 (uma simulação com $n = 200$ dá razão $\approx 2{,}0$).

Ex. 7.4. Pela definição do pseudo-valor, $\hat{\theta}_i^* = n\bar{X} - (n-1)\cdot(n\bar{X} - X_i)/(n-1) = n\bar{X} - n\bar{X} + X_i = X_i$. *Interpretação:* para a média, cada pseudo-valor é simplesmente a observação original; a média

dos pseudo-valores reproduz $\bar{X}$, e a fórmula da variância *jackknife* (Proposição 7.4) torna-se $\frac{1}{n(n-1)}\sum(X_i-\bar{X})^2 = s^2/n$, exatamente o erro padrão clássico de $\bar{X}$.

Ex. 7.5. A transformação de Fisher $z = \frac{1}{2}\log((1+\hat{\rho})/(1-\hat{\rho})) = \operatorname{atanh}(\hat{\rho})$ estabiliza assintoticamente a variância da correlação sob normalidade bivariada. Isso pode tornar a aproximação linear mais regular, mas não faz dos pseudo-valores observações independentes ou exatamente normais e não garante menor viés em toda amostra. Depois de estimar $\widehat{\mathrm{Var}}_{\mathrm{jack}}(z)$, pode-se construir o intervalo na escala de z e retransformar seus extremos pela tangente hiperbólica; para aproximar apenas a variância na escala de ρ, usa-se o método delta.

Ex. 7.6. *Resposta indicativa.* O erro-padrão usual de `summary(lm)` usa a hipótese de variância condicional constante; a normalidade é necessária para inferência exata em amostras pequenas, não para toda aproximação assintótica. Sob observações independentes e condições de regularidade, a remoção de uma observação aproxima uma variância do tipo sanduíche e pode acomodar heterocedasticidade, mas não é robusta a qualquer forma de dependência ou má especificação. Em `Boston`, compare os números em vez de presumir qual será maior. O laço manual é `n <- nrow(Boston); th <- sapply(seq_len(n), function(i) coef(lm(medv ~ rm + lstat, data = Boston[-i, ]))["rm"]]); sqrt((n - 1)/n * sum((th - mean(th))^2))`.

Capítulo 8: Bootstrap

Ex. 8.1. *Argumento.* Sob observações independentes de distribuição F, mediana M e densidade contínua positiva em M, $\sqrt{n}(\hat{M}-M)$ converge para uma distribuição normal de variância $1/(4f(M)^2)$. A distribuição empírica reproduz essa lei de primeira ordem, o que dá cobertura assintoticamente correta ao intervalo de percentis sob as condições usuais. A falha da remoção de uma observação não deve ser atribuída a uma descontinuidade simples do funcional mediana: sob densidade positiva, ele admite uma derivada funcional apropriada. O problema é que a expansão necessária não é uniforme nas perturbações discretas de tamanho $1/n$; os espaçamentos centrais sobrevivem no limite da estimativa de variância. A simulação deve confirmar cobertura aproximada do primeiro procedimento e instabilidade do segundo.

Ex. 8.2. $\widehat{\mathrm{vies}}_{\mathrm{boot}} = \mathbb{E}_{\hat{F}_n}[T(\hat{F}_n^*)] - T(\hat{F}_n) \approx \mathbb{E}_F[T(\hat{F}_n)] - T(F)$ por substituição. É portanto uma estimativa do viés. A remoção de uma observação usa a aproximação $(n-1)(\hat{\theta}_{(\cdot)} - \hat{\theta})$, enquanto a reamostragem aproxima diretamente a esperança sob a distribuição empírica por Monte Carlo. Para estatísticas funcionalmente suaves, ambas podem funcionar. Para estatísticas não regulares, nenhuma regra universal diz que a reamostragem comum sempre funciona: máximo amostral, parâmetros na fronteira e alguns estimadores de seleção podem exigir versões modificadas.

Ex. 8.3. *Resposta indicativa.* Sob distribuição normal padrão, a diferença interquartil populacional é $2\Phi^{-1}(0{,}75) \approx 1{,}349$. Em cada repetição externa, gere uma amostra, construa os três intervalos a partir de reamostras e registre se 1,349 está contido. Resultados plausíveis, sujeitos à semente, ao número de reamostras e à convenção de quantis, são:

- cobertura por percentis entre aproximadamente 92% e 95%;
- cobertura com correção de viés em faixa semelhante;
- cobertura com correção de viés e aceleração em geral mais próxima de 95% neste desenho, mas sem dominância garantida em toda semente.

A incerteza de Monte Carlo de uma cobertura próxima de 0,95 em 1.000 repetições é cerca de $\sqrt{0{,}95(0{,}05)/1000} = 0{,}0069$, antes de contar o ruído introduzido pelo número finito de reamostras.

Ex. 8.4. *Resposta indicativa.* Em simulação com $\rho = 0{,}5$ e $n = 20$, calcule para cada intervalo sua cobertura e largura. Valores ilustrativos são:

- transformação de Fisher: cobertura perto de 94% e largura perto de 0,9;
- percentis: cobertura perto de 90% e largura perto de 0,85;
- correção de viés e aceleração: cobertura perto de 94% e largura perto de 0,87.

Com apenas 500 repetições, o erro de Monte Carlo da cobertura é próximo de um ponto percentual. A transformação de Fisher estabiliza a variância sob normalidade; a correção de viés e aceleração tenta ajustar também assimetria e aceleração. A comparação deve ser apresentada como resultado da simulação, não como ordem universal.

Ex. 8.5. *Resposta indicativa.* Sob heterocedasticidade, a reamostragem simples de resíduos redistribui o mesmo conjunto de resíduos entre todos os valores de x e destrói a relação entre sua escala e o preditor; por isso sua estimativa do erro-padrão tende a ser inadequada. A reamostragem de pares preserva a distribuição conjunta de (X, Y) e é apropriada quando o desenho é tratado como aleatório. A reamostragem selvagem mantém os x_i fixos e multiplica resíduos centrados por pesos independentes de média zero e variância um, preservando aproximadamente a heterocedasticidade do desenho fixo. Compare ambas com o desvio-padrão empírico de $\hat\beta_1$ em muitas amostras; pares ou selvagem devem ficar mais próximos que resíduos simples, e a preferência entre as duas depende de o alvo ser de desenho aleatório ou fixo.

Ex. 8.6. *Resposta indicativa.* Reamostre indivíduos, refaça o modelo de Cox em cada amostra e armazene $\exp(\hat\beta^*_{\texttt{sex}})$, a razão de riscos. Compare os quantis empíricos com o intervalo obtido ao exponenciar os extremos de `confint`. Em versões usuais de `lung`, a estimativa fica perto de 0,6 e os dois intervalos são semelhantes, mas os valores exatos dependem do tratamento de faltantes, da versão dos dados e da semente. A reamostragem também permite tratar quantidades derivadas, como uma diferença de probabilidades de sobrevivência em tempo fixado, desde que todo o procedimento seja repetido em cada amostra.

Capítulo 9: Validação Cruzada

Ex. 9.1. A fórmula de Sherman–Morrison para inversa atualizada: $(A - uv^\top)^{-1} = A^{-1} + \frac{A^{-1}uv^\top A^{-1}}{1 - v^\top A^{-1}u}$. Aplicando a $A = X^\top X$, $u = v = x_i$, e usando $h_{ii} = x_i^\top (X^\top X)^{-1} x_i$, obtém-se $((X^\top X) - x_i x_i^\top)^{-1} = (X^\top X)^{-1} + \frac{(X^\top X)^{-1} x_i x_i^\top (X^\top X)^{-1}}{1 - h_{ii}}$. Combinando com $X_{(-i)}^\top y_{(-i)} = X^\top y - x_i y_i$, segue-se $\hat\beta_{(-i)} = \hat\beta - \frac{(X^\top X)^{-1} x_i (y_i - \hat y_i)}{1 - h_{ii}}$. O resto da prova é como no texto.

Ex. 9.2. Para regressão linear de posto completo com p colunas na matriz de planejamento, $\operatorname{tr}(H) = p$. Defina $Q = \sum_i (y_i - \hat y_i)^2$ como a soma de quadrados residual. Portanto,

$$\widehat{\mathrm{Val}}_{\mathrm{geral}} = \frac{Q/n}{(1 - p/n)^2},$$

Quando p/n é pequeno, $(1 - p/n)^{-2} = 1 + 2p/n + O(p^2/n^2)$; substituindo $Q/n \approx \sigma^2$ no termo de correção, obtém-se $Q/n + 2p\sigma^2/n$, a estimativa de risco de Mallows. No modelo gaussiano com variância estimada, o critério de Akaike para comparar os mesmos candidatos é $n \log(Q/n) + 2p$, a menos de termos iguais entre modelos e da contagem comum do parâmetro de variância. Os três corrigem o erro de treinamento por flexibilidade, mas a equivalência é aproximada e depende das hipóteses indicadas.

Ex. 9.3. Na validação em dois blocos, cada média de treinamento usa $n/2$ observações e tem variância $2\sigma^2/n$. Para uma observação independente no bloco de avaliação, a perda quadrática esperada é, portanto, $\sigma^2 + 2\sigma^2/n$. A média ajustada com as n observações teria erro futuro $\sigma^2 + \sigma^2/n$. Logo a estimativa de validação tem viés positivo σ^2/n para o procedimento final; no componente de erro de estimação, usa $2\sigma^2/n$ no lugar de σ^2/n.

Ex. 9.4. Da Proposição 2.7, decomponha $y = UU^\top y + (I - UU^\top)y$. Então

$$y - \hat y_\lambda = \sum_{j=1}^{r} \frac{\lambda}{d_j^2 + \lambda} u_j u_j^\top y + (I - UU^\top)y.$$

As duas parcelas são ortogonais, e os u_j são ortonormais; logo o quadrado da norma é a soma dos termos exibidos no exercício. A flexibilidade efetiva é $g(\lambda) = \sum_{j=1}^{r} d_j^2/(d_j^2 + \lambda)$. Dividir por n e por $\{1 - g(\lambda)/n\}^2$ fornece a expressão pedida.

Ex. 9.5. Algoritmo: (i) dentro de cada classe, distribua aleatoriamente as observações entre k blocos; (ii) para cada bloco j, ajuste o classificador nos outros $k-1$, prediga probabilidades ou rótulos no bloco retido e calcule a perda zero–um; (iii) agregue todas as perdas retidas. A estratificação evita blocos sem casos de uma classe e reduz a variabilidade da partição. Ela reproduz o alvo futuro quando a prevalência é considerada fixa ou quando a amostragem futura preservará essa composição. Se a prevalência de implantação for diferente ou aleatória segundo outro mecanismo, a avaliação deve usar pesos ou uma amostra que represente esse mecanismo; estratificar não corrige uma mudança de população.

Ex. 9.6. *Resposta indicativa.* Remova valores faltantes uma única vez para definir a população analisada e use as mesmas divisões externas para todos os métodos. Dentro de cada conjunto de treinamento externo, escolha novamente a penalização ou o grau; só então avalie no bloco retido. Reporte a média das perdas quadráticas retidas, sua dispersão entre divisões e, para cada método, o número efetivo de parâmetros. A regressão em crista mantém todos os coeficientes, mas com flexibilidade efetiva menor que a contagem bruta; a penalidade absoluta pode zerar alguns; o polinômio univariado ignora outras covariáveis. Não há ranqueamento numérico garantido: ele depende da semente, da escala da resposta e do protocolo, razão pela qual a resposta correta inclui o código e a incerteza da comparação.

Ex. 9.7. As duas demonstrações estão no texto. (a) Para $g(q) = \mathbb{E}[L_\tau(Y, q)]$, as derivadas laterais mostram que q minimiza g se e somente se $F(q-) \le \tau \le F(q)$. Assim, qualquer quantil de ordem τ é solução; sob distribuição contínua e estritamente crescente no ponto, a solução é única. Para $\tau = 1/2$, a perda é metade da perda absoluta, sem alterar o minimizador. (b) Para a log-normal, $\mathbb{E}[Y \mid x] = e^{\mu(x)+\sigma^2/2}$ e mediana$(Y \mid x) = e^{\mu(x)}$; a razão entre média e mediana é $e^{\sigma^2/2}$. Com $\sigma = 1$, a média é 1,65 vez a mediana. (c) O custo total esperado é a soma das médias condicionais, não das medianas. Minimizar perda absoluta estima a mediana e, neste exemplo, produziria uma previsão cerca de 39% abaixo da média. Para visar o custo esperado, use uma perda cujo alvo seja a média, como a quadrática, ou um modelo probabilístico coerente com essa média.

Ex. 9.8. Sejam F_+ e F_- as distribuições contínuas dos escores nos positivos e negativos. A curva de sensibilidade contra a taxa de falsos positivos é $\{(1 - F_-(c),\ 1 - F_+(c)) : c\}$. Com $u = 1 - F_-(c)$, tem-se $du = -f_-(c)dc$ e

$$\mathcal{A} = \int_0^1 \mathrm{Sens}(u)\, du = \int_{-\infty}^{\infty} [1 - F_+(c)]\, f_-(c)\, dc = \mathbb{P}(S^+ > S^-),$$

pela independência entre S^+ e S^-. (a) Uma transformação estritamente crescente preserva todas as comparações entre pares e, portanto, $\mathcal{A}$. Isso explica por que a área não mede calibração. (b) Usar $-S$ troca concordâncias por discordâncias e produz $1 - \mathcal{A}$ no caso contínuo. Com empates, conte meio crédito para cada empate, e a identidade continua válida. Uma área amostral abaixo de 0,5 pode refletir codificação invertida, um sinal genuinamente inverso ou simples variação amostral; não é automaticamente um erro. (c) Com escores $0{,}9; 0{,}7; 0{,}4$ nos positivos e $0{,}6; 0{,}3; 0{,}2$ nos negativos, 8 dos 9 pares são concordantes, logo $\mathcal{A} = 8/9 \approx 0{,}889$. A integração trapezoidal da curva escada fornece o mesmo valor.

Ex. 9.9. (a) $\mathbb{E}[(q - Y)^2] = p - 2qp + q^2$, com mínimo único em $q = p$. (b) A perda logarítmica esperada é $-p \log q - (1-p)\log(1-q)$, também minimizada em $q = p$; nos extremos $p = 0$ ou $p = 1$, o resultado vale por limite. (c) A acurácia após limiar em 0,5 vale p para qualquer $q > 0{,}5$ e $1 - p$ para qualquer $q < 0{,}5$. Para $p = 0{,}6$, todos os anúncios acima do limiar induzem a mesma decisão. (d) A acurácia não necessariamente *empurra* as probabilidades para os extremos; ela é simplesmente indiferente aos valores dentro de cada lado do limiar e, por isso, não identifica calibração. Quando

probabilidades alimentam decisões quantitativas, avalie uma regra de pontuação própria, como a quadrática de Brier ou a perda logarítmica, e examine calibração.

Ex. 9.10. *Resposta indicativa.* Mantidas as distribuições condicionais dos escores dentro das duas classes, a curva de sensibilidade contra taxa de falsos positivos e sua área quase não mudam com a prevalência. A curva de precisão contra sensibilidade muda, pois

$$\text{Precisao} = \frac{\text{Sensibilidade}\ \pi}{\text{Sensibilidade}\ \pi + \text{TaxaFalsa}\,(1-\pi)},$$

em que π é a prevalência. Por exemplo, com sensibilidade 0,8, taxa de falsos positivos 0,25 e prevalência 0,01, a precisão é aproximadamente 0,031; com prevalência 0,30, sobe para 0,578. Os valores 0,8 e 0,25 devem ser substituídos pelos observados na simulação. A primeira área não é "otimista" como propriedade matemática; ela responde à ordenação condicional às classes e pode ser insuficiente para resumir a utilidade operacional quando casos positivos são raros.

Ex. 9.11. *Resposta indicativa.* Repita cada tamanho amostral várias vezes e apresente médias com barras de erro. O grau 1 tende a mostrar pequena lacuna entre treinamento e teste, mas patamar alto, sinal de erro de aproximação. O grau 4 costuma aproximar bem a senoide e apresentar lacuna pequena em tamanhos moderados. O grau 14 pode ter treinamento muito baixo e teste instável para amostras pequenas; a lacuna deve diminuir com n. Para estimar o ganho de dobrar n, interpole a curva calculada e reporte a diferença com sua incerteza, em vez de supor uma porcentagem fixa. A decisão entre coletar dados e reformular o modelo depende também de custos: curva de teste ainda descendente favorece coleta; curvas juntas em patamar alto favorecem nova classe de modelos; curvas juntas perto de 0,16 sugerem pouca margem. O erro de teste populacional de qualquer preditor é $0{,}16 + \mathbb{E}\{\sin(X) - \hat{f}(X)\}^2$; o segundo termo pode ser muito pequeno para grau alto, mas seu valor não é determinado exatamente por uma figura finita.

Capítulo 10: Erro de predição

Ex. 10.1. Sob σ^2 conhecido e comum, escreva d para o número de coeficientes ajustados e defina $Q = \sum_i (y_i - \hat{y}_i)^2$. O critério de Akaike é $Q/\sigma^2 + 2d + \text{constante}$, enquanto $C_p = Q/\sigma^2 - n + 2d$. Diferem por uma constante comum e geram o mesmo ranqueamento. Se cada candidato estima sua própria variância, o primeiro passa a envolver $n\log(Q/n)$, enquanto substituir σ^2 no segundo por uma estimativa diferente em cada modelo deixa de ser uma transformação afim comum; a equivalência se rompe.

Ex. 10.2. $\log n > 2$ se e somente se $n > e^2 \approx 7{,}39$. Portanto, para $n \geq 8$, a penalidade *por parâmetro* do critério de Schwarz excede a do critério de Akaike. Isso não obriga seleções diferentes: se a melhora de ajuste do próximo modelo for insuficiente para ambos, ou grande o bastante para ambos, eles escolhem o mesmo candidato. Para uma coleção fixa avaliada pela mesma log-verossimilhança e com minimização global, aumentar o coeficiente da penalidade não pode aumentar a dimensão selecionada, mas pode deixá-la inalterada.

Ex. 10.3. $\mathrm{op}_i = \mathbb{E}[(Y_i^{\text{novo}} - \hat{y}_i)^2] - \mathbb{E}[(y_i - \hat{y}_i)^2]$. Expandindo,

$$\mathbb{E}[(Y_i^{\text{novo}} - \hat{y}_i)^2] = \mathbb{E}[(Y_i^{\text{novo}})^2] - 2\mathbb{E}[Y_i^{\text{novo}}\hat{y}_i] + \mathbb{E}[\hat{y}_i^2].$$

Como Y_i^{novo} e $\hat{y}_i$ são independentes e $\mathbb{E}[Y_i^{\text{novo}}] = \mathbb{E}[y_i]$, temos $\mathbb{E}[Y_i^{\text{novo}}\hat{y}_i] = \mathbb{E}[Y_i^{\text{novo}}]\mathbb{E}[\hat{y}_i] = \mathbb{E}[y_i]\mathbb{E}[\hat{y}_i]$. Já $\mathbb{E}[(y_i - \hat{y}_i)^2] = \mathbb{E}[y_i^2] - 2\mathbb{E}[y_i\hat{y}_i] + \mathbb{E}[\hat{y}_i^2]$. Subtraindo,

$$\mathrm{op}_i = -2(\mathbb{E}[y_i]\mathbb{E}[\hat{y}_i] - \mathbb{E}[y_i\hat{y}_i]) = 2\mathrm{Cov}(y_i, \hat{y}_i),$$

e somando sobre i e dividindo por n, obtém-se $\mathrm{op} = (2/n)\sum_i \mathrm{Cov}(y_i, \hat{y}_i)$.

Ex. 10.4. Em um modelo de Poisson, a variância muda com a média, de modo que a soma de quadrados sem ponderação não corresponde à log-verossimilhança. Seja $D = 2\{\ell_{\text{saturado}} - \hat{\ell}\}$ a

deviância, em que o modelo saturado ajusta uma média por observação. Como ℓ_{saturado} é comum aos candidatos, $-2\hat{\ell} + 2d$ equivale, para ranqueamento, a $D + 2d$. Esse é o análogo de Akaike. O C_p original continua sendo uma construção específica da regressão gaussiana com perda quadrática e variância comum.

Ex. 10.5. Para $n = 30$:

- $d = 5$: a correção ao critério de Akaike é $2 \cdot 5 \cdot 6/(30 - 5 - 1) = 60/24 = 2{,}5$.
- $d = 10$: a correção é $2 \cdot 10 \cdot 11/(30 - 10 - 1) = 220/19 \approx 11{,}6$.
- $d = 20$: a correção é $2 \cdot 20 \cdot 21/(30 - 20 - 1) = 840/9 \approx 93{,}3$.

A correção é pequena para $d = 5$, mas cresce rapidamente quando d se aproxima de $n - 1$ e deixa de estar definida se $n \leq d + 1$. Sob as condições regulares da derivação, ela corrige parte do otimismo de pequena amostra; não transforma um modelo mal especificado ou não regular em um problema válido.

Ex. 10.6. *Resposta indicativa.* Remova observações incompletas e registre a amostra final. No ajuste completo, `summary(regsubsets(...))` fornece C_p, o critério de Schwarz e o coeficiente de determinação ajustado para cada tamanho. Para a avaliação em dez blocos, dentro de cada conjunto de treinamento: (1) refaça `regsubsets`; (2) escolha o tamanho pelo critério sob comparação; (3) extraia as variáveis daquele tamanho; (4) ajuste os coeficientes apenas no treinamento; (5) prediga o bloco retido. Ao final, reporte tamanho escolhido no ajuste completo, frequência de cada tamanho e variável entre os blocos e erro externo. O critério de Schwarz tende a selecionar modelos menores por usar penalidade $d \log n$, mas os valores exatos e a ordem dos erros não são universais. Selecionar uma única vez na amostra completa antes dos blocos produziria vazamento de informação.

Capítulo 11: Bayes Objetivo

Ex. 11.1. $\log f(y;\lambda) = -\lambda + y\log\lambda - \log y!$, $\partial^2 \log f/\partial\lambda^2 = -y/\lambda^2$, $I(\lambda) = \mathbb{E}[Y/\lambda^2] = 1/\lambda$. Logo $\pi_J(\lambda) \propto \lambda^{-1/2}$. Sob $\eta = \log\lambda$, $\lambda = e^\eta$, $|d\lambda/d\eta| = e^\eta$, e $\pi_J(\eta) = \lambda^{-1/2} \cdot e^\eta = e^{\eta/2}$. Verificação: $I(\eta) = I(\lambda) \cdot (d\lambda/d\eta)^2 = (1/\lambda) \cdot e^{2\eta} = e^\eta$, donde $\pi_J(\eta) = \sqrt{e^\eta} = e^{\eta/2}$. ✓

Ex. 11.2. A informação de Fisher transforma-se como $I(\eta) = J^\top I(\theta) J$, com $J = \partial\theta/\partial\eta$. Assim, $\det I(\eta) = (\det J)^2 \det I(\theta)$, e

$$\pi_J(\eta) = \sqrt{\det I(\eta)} = |\det J| \sqrt{\det I(\theta)} = |\det J|\, \pi_J(\theta(\eta)),$$

exatamente a regra de transformação de densidades multivariadas.

Ex. 11.3. Para Y de distribuição exponencial com taxa λ e densidade $f(y) = \lambda e^{-\lambda y}$, $\log f = \log\lambda - \lambda y$, $\partial^2 \log f/\partial\lambda^2 = -1/\lambda^2$, $I(\lambda) = 1/\lambda^2$, donde $\pi_J(\lambda) \propto 1/\lambda$. Sob $\theta = 1/\lambda$ (média), $\lambda = 1/\theta$, $|d\lambda/d\theta| = 1/\theta^2$. Pela regra de mudança de variáveis: $\pi_J(\theta) = \pi_J(1/\theta) \cdot 1/\theta^2 = \theta \cdot (1/\theta^2) = 1/\theta$. Verificação direta: $I(\theta) = I(\lambda)(d\lambda/d\theta)^2 = (\theta^2)(1/\theta^4) = 1/\theta^2$, $\sqrt{I(\theta)} = 1/\theta$.

Ex. 11.4. *Resposta indicativa.* Normalize a densidade numericamente ou compare o histograma com $c\, e^{-\theta^2/2}(1 + \theta^2)$, em que c faz a integral valer 1. Com proposta de desvio padrão 0,1, quase todos os passos são aceitos, mas são curtos e produzem alta autocorrelação. Com desvio 10, muitos candidatos caem nas caudas e são rejeitados, gerando longas repetições. A escala 1 costuma equilibrar deslocamento e aceitação neste alvo. Reporte taxa de aceitação, tamanho efetivo da amostra, autocorrelação e frequência de travessia entre as duas modas. Faixas de aceitação assintoticamente ótimas são guias para regimes específicos, não critérios universais de convergência.

Ex. 11.5. *Posterior condicional de μ.* Sob μ normal de média zero e variância 100 e, condicionalmente a (μ, σ^2), observações y_i normais independentes de média μ e variância σ^2,

$$\mu \mid \sigma^2, y \sim N\left(\frac{\bar{y}/(\sigma^2/n)}{1/(\sigma^2/n) + 1/100},\ \frac{1}{1/(\sigma^2/n) + 1/100} \right).$$

Posterior condicional de σ^2. Sob priori gama inversa de forma 2 e escala 2,

$$\sigma^2 \mid \mu, y \sim \text{GamaInv}\Big(2 + n/2,\ 2 + \tfrac{1}{2}\sum (y_i - \mu)^2\Big),$$

em que $\text{GamaInv}(a, b)$ denota a distribuição gama inversa de forma a e escala b. No amostrador de Gibbs, inicialize $(\mu^{(0)}, \sigma^{2(0)})$ e, alternadamente, amostre $\mu^{(t+1)}$ condicionado a $\sigma^{2(t)}$ e depois $\sigma^{2(t+1)}$ condicionado a $\mu^{(t+1)}$.

Ex. 11.6. *Resposta indicativa.* Ajuste ao menos quatro cadeias a partir de valores iniciais dispersos. Reporte os quantis posteriores de cada coeficiente, o diagnóstico de redução potencial de escala $\hat{R}$, o tamanho efetivo da amostra e gráficos das cadeias. Valores de $\hat{R}$ próximos de 1 e tamanhos efetivos grandes são verificações necessárias, mas não provam convergência nem propriedade da posterior. Compare os centros e intervalos com `glm`; neste conjunto relativamente grande e com prioris fracamente informativas, eles costumam ser próximos. A proximidade deve ser demonstrada pela saída obtida e não generalizada para separação, parâmetros na fronteira, modelos de alta dimensão ou prioris informativas.

Ex. 11.7. Para a perda quadrática, $\mathbb{E}[(\theta - a)^2 \mid y] = \text{Var}(\theta \mid y) + (\mathbb{E}[\theta \mid y] - a)^2$, minimizado em $a = \mathbb{E}[\theta \mid y]$. Para a perda absoluta, as derivadas laterais mostram que o conjunto de minimizadores é o conjunto de medianas posteriores. (a) Para a gama de forma 3 e taxa 1, a média é 3, a mediana é aproximadamente 2,674 e a moda é 2. (b) O intervalo de caudas iguais é aproximadamente $[0{,}619; 7{,}225]$, de comprimento 6,61. O conjunto de maior densidade posterior é aproximadamente $[0{,}303; 6{,}401]$, de comprimento 6,10 na escala original; para uma densidade unimodal contínua, ele é o intervalo de menor comprimento nessa escala e nesse nível. (c) Quantis são equivariantes sob transformações monótonas, mas níveis de densidade não: a densidade transformada inclui o jacobiano. Portanto, a imagem do conjunto de maior densidade na escala original não precisa ser o conjunto de maior densidade na nova escala, e comparações de comprimento ou volume dependem da parametrização.

Ex. 11.8. (a) Para observações normais, a matriz de informação em (μ, σ) é diagonal, com elementos n/σ^2 e $2n/\sigma^2$. O condicionamento sucessivo produz, tanto quando μ é o interesse e σ é perturbação quanto na ordem inversa, a priori de referência conjunta $\pi(\mu, \sigma) \propto 1/\sigma$. Essa coincidência decorre da estrutura de locação e escala e não vale automaticamente em outros modelos multiparamétricos. (b) Para observações exponenciais de taxa λ, $I(\lambda) = n/\lambda^2$, logo a priori de referência é proporcional a $1/\lambda$, a medida invariante de escala. (c) Para a binomial, $I(p) = n/[p(1-p)]$, e a regra de Jeffreys fornece a priori beta de parâmetros $(1/2, 1/2)$. Com zero sucessos em vinte tentativas, a posterior correspondente é beta de parâmetros $(0{,}5, 20{,}5)$; seu limite superior unilateral de credibilidade 95% é aproximadamente 0,0905 e sua média é 0,0244. A priori uniforme produz posterior beta de parâmetros $(1, 21)$, limite superior aproximadamente 0,133 e média 0,0455. O primeiro intervalo é mais curto, mas isso não basta para declará-lo melhor. Para comparar cobertura frequentista, para cada p calcule exatamente $\sum_{x=0}^{20} \mathbb{1}\{p \le u(x)\}\binom{20}{x} p^x (1-p)^{20-x}$, em que $u(x)$ é o limite superior produzido pelo método. A discretização impede cobertura exatamente constante; a priori de Jeffreys tem propriedade de casamento no interior sob condições regulares, enquanto o comportamento junto à fronteira deve ser examinado separadamente. A escolha deve considerar também a interpretação das duas prioris.

Ex. 11.9. (a) Binomial: $\mathbb{P}(X \ge 9 \mid n = 12,\ p = \frac{1}{2}) = (220{+}66{+}12{+}1)/4096 = 299/4096 = 0{,}0730$. Binomial negativa (parar no 3º fracasso): observar ≥ 9 sucessos equivale a ter no máximo 2 fracassos nos 11 primeiros ensaios, logo $(1 + 11 + 55)/2048 = 67/2048 = 0{,}0327$. (b) As verossimilhanças são $L_1(p) = \binom{12}{9} p^9 (1-p)^3$ e $L_2(p) = \binom{11}{2} p^9 (1-p)^3$; a razão é a constante $\binom{12}{9}/\binom{11}{2} = 220/55 = 4$, independente de p. São proporcionais. (c) A posterior é $\pi(p \mid y) \propto p^9(1-p)^3 \cdot p^{-1/2}(1-p)^{-1/2} = p^{8{,}5}(1-p)^{2{,}5}$, isto é, Beta(9,5; 3,5) nos *dois* desenhos: as constantes binomiais se cancelam na normalização. (d) *A favor de ser defeito*: os dados observados são os mesmos e a evidência que eles carregam sobre p está inteiramente na verossimilhança; fazer a conclusão depender de um plano que nunca se materializou, do que o experimentador *teria feito* sob outros resultados, é permitir

que uma intenção não verificável determine a inferência. *A favor de ser característica*: a garantia frequentista é sobre o comportamento do procedimento em uso repetido, e um procedimento que ignora a regra de parada perde o controle da taxa de erro de tipo I, o problema real e documentado da parada opcional em ensaios clínicos, em que espiar os dados e parar ao atingir significância infla drasticamente os falsos positivos. As duas posições são coerentes porque respondem a perguntas diferentes: "o que estes dados dizem?" contra "com que frequência este procedimento me engana?".

Ex. 11.10. *Resposta indicativa.* Para uma amostra com x sucessos, uma priori beta de parâmetros (a, b) produz posterior beta de parâmetros $(a + x, b + n - x)$; essa fórmula permite sobrepor as três densidades sem amostragem computacional. Em tamanhos pequenos, a priori beta $(20, 2)$ pode deslocar fortemente a posterior para valores altos; sua influência relativa decresce quando n cresce. Não existe um tamanho universal a partir do qual a diferença é irrelevante. Defina antes uma decisão, por exemplo tratar quando $\mathbb{P}(p > 0{,}4 \mid y) > 0{,}9$, e compare a ação induzida pelas três prioris em cada repetição. Compare também cobertura e largura dos intervalos de credibilidade e de Wilson ao longo de muitas amostras. O teorema de Bernstein–von Mises explica a aproximação em modelos regulares, de dimensão fixa, com verdade interior e priori positiva e contínua perto dela; não cobre automaticamente fronteiras, dimensão crescente, não identificação ou uma priori que exclui a verdade.

Ex. 11.11. (a) Integrando os θ_i, as variáveis y_i, condicionalmente a τ, são independentes e normais de média zero e variância $1 + \tau^2$. Logo a posterior marginal é $\pi(\tau \mid y) \propto \tau^{-1}(1 + \tau^2)^{-N/2} \exp\{-\sum y_i^2/[2(1 + \tau^2)]\}$. Perto de zero, o último fator tende a uma constante positiva e o integrando comporta-se como $1/\tau$; a integral diverge. (b) Cada condicional completa pode ser própria, mas isso não torna própria a distribuição conjunta. Um amostrador de Gibbs pode rodar sem erro sem possuir distribuição estacionária normalizável. O diagnóstico de redução potencial de escala e o tamanho efetivo da amostra medem aspectos de concordância e autocorrelação das cadeias produzidas; não testam se a integral da posterior é finita. (c) Duas alternativas são uma priori uniforme própria em $(0, A)$, com A finito escolhido substantivamente, e uma meia-Cauchy própria com escala moderada. Em ambos os casos, a verossimilhança marginal é limitada perto de zero e integrável nas caudas quando multiplicada por essas densidades próprias, de modo que a posterior é própria. (d) Prioris impróprias só são utilizáveis depois de demonstrar a propriedade da posterior; condicionais completas e software executável não substituem essa prova.

Referências

Akaike, Hirotugu (1974). «A New Look at the Statistical Model Identification». Em: *IEEE Transactions on Automatic Control* 19.6, pp. 716–723.

Berger, James O., José M. Bernardo e Dongchu Sun (2009). «The Formal Definition of Reference Priors». Em: *Annals of Statistics* 37.2, pp. 905–938.

Bernardo, José M. (1979). «Reference Posterior Distributions for Bayesian Inference». Em: *Journal of the Royal Statistical Society, Series B* 41.2, pp. 113–147.

Breiman, Leo (1996). «Bagging Predictors». Em: *Machine Learning* 24.2, pp. 123–140.

Breiman, Leo (2001). «Random Forests». Em: *Machine Learning* 45.1, pp. 5–32.

Breiman, Leo et al. (1984). *Classification and Regression Trees*. Belmont, CA: Wadsworth.

Brier, Glenn W. (1950). «Verification of Forecasts Expressed in Terms of Probability». Em: *Monthly Weather Review* 78.1, pp. 1–3.

Cox, David R. (1972). «Regression Models and Life-Tables». Em: *Journal of the Royal Statistical Society: Series B* 34.2, pp. 187–220.

Craven, Peter e Grace Wahba (1979). «Smoothing Noisy Data with Spline Functions: Estimating the Correct Degree of Smoothing by the Method of Generalized Cross-Validation». Em: *Numerische Mathematik* 31.4, pp. 377–403.

Dempster, Arthur P., Nan M. Laird e Donald B. Rubin (1977). «Maximum Likelihood from Incomplete Data via the EM Algorithm». Em: *Journal of the Royal Statistical Society: Series B* 39.1, pp. 1–38.

Dunn, Peter K. e Gordon K. Smyth (1996). «Randomized Quantile Residuals». Em: *Journal of Computational and Graphical Statistics* 5.3, pp. 236–244.

Efron, Bradley (1979). «Bootstrap Methods: Another Look at the Jackknife». Em: *Annals of Statistics* 7.1, pp. 1–26.

Efron, Bradley (2010). *Large-Scale Inference: Empirical Bayes Methods for Estimation, Testing, and Prediction*. Cambridge University Press.

Efron, Bradley e Trevor Hastie (2016). *Computer Age Statistical Inference: Algorithms, Evidence, and Data Science*. Cambridge: Cambridge University Press.

Efron, Bradley e Robert J. Tibshirani (1993). *An Introduction to the Bootstrap*. Chapman & Hall/CRC.

Freund, Yoav e Robert E. Schapire (1997). «A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting». Em: *Journal of Computer and System Sciences* 55.1, pp. 119–139.

Friedman, Jerome H. (2001). «Greedy Function Approximation: A Gradient Boosting Machine». Em: *Annals of Statistics* 29.5, pp. 1189–1232.

Golub, Gene H., Michael Heath e Grace Wahba (1979). «Generalized Cross-Validation as a Method for Choosing a Good Ridge Parameter». Em: *Technometrics* 21.2, pp. 215–223.

Hanley, James A. e Barbara J. McNeil (1982). «The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve». Em: *Radiology* 143.1, pp. 29–36.

Hastie, Trevor, Robert Tibshirani e Jerome Friedman (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2ª ed. Springer.

Hastie, Trevor, Robert Tibshirani e Martin Wainwright (2015). *Statistical Learning with Sparsity: The Lasso and Generalizations*. Chapman & Hall/CRC.

Hoerl, Arthur E. e Robert W. Kennard (1970). «Ridge Regression: Biased Estimation for Nonorthogonal Problems». Em: *Technometrics* 12.1, pp. 55–67.

James, Gareth et al. (2013). *An Introduction to Statistical Learning, with Applications in R*. New York: Springer.

James, Gareth et al. (2021). *An Introduction to Statistical Learning, with Applications in R*. 2ª ed. New York: Springer.

James, William e Charles Stein (1961). «Estimation with Quadratic Loss». Em: *Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability* 1, pp. 361–379.

Jeffreys, Harold (1946). «An Invariant Form for the Prior Probability in Estimation Problems». Em: *Proceedings of the Royal Society A* 186.1007, pp. 453–461.

Kaplan, Edward L. e Paul Meier (1958). «Nonparametric Estimation from Incomplete Observations». Em: *Journal of the American Statistical Association* 53.282, pp. 457–481.

Klein, John P. e Melvin L. Moeschberger (2003). *Survival Analysis: Techniques for Censored and Truncated Data*. 2ª ed. Springer.

Little, Roderick J. A. e Donald B. Rubin (2019). *Statistical Analysis with Missing Data*. 3ª ed. Wiley.

Louis, Thomas A. (1982). «Finding the Observed Information Matrix When Using the EM Algorithm». Em: *Journal of the Royal Statistical Society, Series B* 44.2, pp. 226–233.

Lynden-Bell, Donald (1971). «A Method of Allowing for Known Observational Selection in Small Samples Applied to 3CR Quasars». Em: *Monthly Notices of the Royal Astronomical Society* 155.1, pp. 95–118.

Mallows, Colin L. (1973). «Some Comments on C_p». Em: *Technometrics* 15.4, pp. 661–675.

McCullagh, Peter e John A. Nelder (1989). *Generalized Linear Models*. 2ª ed. Chapman e Hall.

Meng, Xiao-Li e Donald B. Rubin (1991). «Using EM to Obtain Asymptotic Variance-Covariance Matrices: The SEM Algorithm». Em: *Journal of the American Statistical Association* 86.416, pp. 899–909.

Nelder, John A. e Robert W. M. Wedderburn (1972). «Generalized Linear Models». Em: *Journal of the Royal Statistical Society: Series A* 135.3, pp. 370–384.

Neyman, Jerzy e Elizabeth L. Scott (1948). «Consistent Estimates Based on Partially Consistent Observations». Em: *Econometrica* 16.1, pp. 1–32.

Quenouille, Maurice H. (1956). «Notes on Bias in Estimation». Em: *Biometrika* 43.3/4, pp. 353–360.

Robbins, Herbert (1956). «An Empirical Bayes Approach to Statistics». Em: *Proceedings of the Third Berkeley Symposium on Mathematical Statistics and Probability* 1, pp. 157–163.

Rubin, Donald B. (1976). «Inference and Missing Data». Em: *Biometrika* 63.3, pp. 581–592.

Schwarz, Gideon (1978). «Estimating the Dimension of a Model». Em: *Annals of Statistics* 6.2, pp. 461–464.

Shibata, Ritei (1981). «An Optimal Selection of Regression Variables». Em: *Biometrika* 68.1, pp. 45–54.

Stone, Mervyn (1974). «Cross-Validatory Choice and Assessment of Statistical Predictions». Em: *Journal of the Royal Statistical Society: Series B* 36.2, pp. 111–147.

Tibshirani, Robert (1996). «Regression Shrinkage and Selection via the Lasso». Em: *Journal of the Royal Statistical Society, Series B* 58.1, pp. 267–288.

Tukey, John W. (1958). «Bias and Confidence in Not Quite Large Samples (Abstract)». Em: *Annals of Mathematical Statistics* 29, p. 614.

Vaart, Aad W. van der (1998). *Asymptotic Statistics*. Cambridge University Press.

Welch, Bernard L. e H. W. Peers (1963). «On Formulae for Confidence Points Based on Integrals of Weighted Likelihoods». Em: *Journal of the Royal Statistical Society, Series B* 25.2, pp. 318–329.

Wu, C. F. Jeff (1986). «Jackknife, Bootstrap and Other Resampling Methods in Regression Analysis». Em: *Annals of Statistics* 14.4, pp. 1261–1295.

Zou, Hui e Trevor Hastie (2005). «Regularization and Variable Selection via the Elastic Net». Em: *Journal of the Royal Statistical Society, Series B* 67.2, pp. 301–320.

Zou, Hui, Trevor Hastie e Robert Tibshirani (2007). «On the "Degrees of Freedom" of the Lasso». Em: *Annals of Statistics* 35.5, pp. 2173–2192.